Universidad de los Andes

Departamento de Ingeniería Industrial · Modelado de Sistemas bajo Incertidumbre

Modelado de Entradas: Del Dato Observado a la Distribución de Probabilidad

Alejandra Tabares Pozos

Índice

1. Motivación: la distribución importa **3**
1.1. El coeficiente de variación como indicador clave . . . 3

2. Proceso metodológico **4**

3. Recolección y calidad de datos **4**
3.1. Tamaño de muestra . . . 4
3.2. Independencia de las observaciones . . . 5
3.3. Homogeneidad temporal (estacionariedad) . . . 5

4. Tipos de datos en sistemas de colas **6**

5. Exploración gráfica **6**
5.1. Histograma . . . 6
5.2. Función de distribución empírica (ECDF) . . . 6
5.3. Gráfico Q-Q (cuantil–cuantil) . . . 7

6. Familias de distribuciones para sistemas de colas **7**
6.1. Exponencial — base de referencia Markoviana . . . 7
6.2. Erlang-k — servicio en fases regulares . . . 7
6.3. Hiperexponencial-k — mezcla de tipos de servicio . . . 7
6.4. Gamma . . . 8
6.5. Weibull — tasa de falla no constante . . . 8
6.6. Log-normal — fenómenos multiplicativos . . . 8
6.7. Tabla resumen . . . 8

7. Estimación de parámetros **9**
7.1. Máxima verosimilitud (MLE) 9
7.2. Método de momentos (MM) 9

8. Pruebas de bondad de ajuste **10**
8.1. Prueba χ^2 10
8.2. Prueba de Kolmogorov–Smirnov (KS) 10
8.3. Prueba de Anderson–Darling (AD) 10
8.4. Interpretación del p-value 11

9. Criterios de selección de modelos **11**
9.1. Criterio de información de Akaike (AIC) 11
9.2. Criterio de información bayesiano (BIC) 11

10. ¿Qué hacer cuando no hay datos? **12**

11. ¿Qué hacer si ninguna distribución ajusta? **12**

12. Ejemplo básico: tiempos de servicio en ventanilla bancaria **13**

13. Ejemplo intermedio: modelado completo del banco **14**
13.1. Análisis de tiempos entre llegadas 14
13.2. Análisis de tiempos de servicio 14
13.3. Impacto en el modelo de colas 15

14. Ejemplo escalado: taller de reparación de equipos industriales **16**
14.1. Análisis de tiempos entre llegadas 16
14.2. Análisis de tiempos de reparación 16
14.3. Impacto en el modelo de colas 17

1. Motivación: la distribución importa

Todo modelo de simulación de eventos discretos (SED) está alimentado por distribuciones de probabilidad que caracterizan la aleatoriedad del sistema: tiempos entre llegadas, tiempos de servicio, tiempos de falla, demandas. El **modelado de entradas** (*input modeling*) es el proceso de transformar datos empíricos en distribuciones parametrizadas que el simulador pueda muestrear. Una distribución mal elegida se propaga como error sistemático a todas las métricas de salida.

Más aún, la distribución elegida determina qué herramientas analíticas están disponibles:

- Cola $M/M/1$: llegadas Poisson, servicio exponencial $\Rightarrow$ solución cerrada exacta.
- Cola $M/G/1$: llegadas Poisson, servicio general $\Rightarrow$ fórmula de Pollaczek–Khinchine.
- Cola $G/G/1$: ambas distribuciones generales $\Rightarrow$ esencialmente solo simulación.

Identificar correctamente las distribuciones puede habilitar análisis analíticos que eviten la simulación, o revelar que la simulación es necesaria.

Principio GIGO

Garbage In, Garbage Out: un modelo computacionalmente sofisticado ajustado con distribuciones incorrectas producirá conclusiones erróneas con alta precisión *aparente*. Los errores de modelado de entradas no se cancelan; se amplifican.

1.1. El coeficiente de variación como indicador clave

El **coeficiente de variación** $\mathrm{CV} = \sigma/\mu$ resume cuán variable es una distribución relativo a su media. Para una cola $M/G/1$ con tráfico $\rho = \lambda\mathbb{E}[S]$, la fórmula de Pollaczek–Khinchine muestra que:

$$W_q^{M/G/1} = \underbrace{\frac{\rho}{\mu(1-\rho)}}_{W_q^{M/M/1}} \cdot \frac{1+\mathrm{CV}_S^2}{2}$$

Bajo $\rho = 0{,}8$ y $\mathbb{E}[S] = 1$ min (por lo que $W_q^{M/M/1} = 4$ min):

Distribución de servicio	**Notación**	CV_S	W_q (min)
Determinista	D	0	2,0
Erlang-2	E_2	$1/\sqrt{2} \approx 0{,}71$	3,0
Exponencial	M	1	4,0
Weibull ($k = 0{,}8$)	G	$\approx 1{,}3$	5,3
Hiperexponencial (CV=2)	H_2	2	10,0

Ignorar la variabilidad real del servicio puede subestimar o sobreestimar el tiempo en cola por un factor de 2 o más.

2. Proceso metodológico

Metodología de modelado de entradas — 5 pasos

1. **Recolección de datos**: registrar observaciones del sistema real; verificar homogeneidad temporal e independencia entre observaciones.
2. **Exploración gráfica**: histograma, ECDF y gráfico Q-Q; identificar forma, asimetría, colas y posibles valores atípicos.
3. **Identificación de la familia**: usar el CV, el soporte del dato y el conocimiento del proceso físico para seleccionar distribuciones candidatas.
4. **Estimación de parámetros**: máxima verosimilitud (MLE) o método de momentos.
5. **Prueba de bondad de ajuste**: χ^2, Kolmogorov–Smirnov o Anderson–Darling; aceptar o rechazar el candidato con nivel de significancia α.

3. Recolección y calidad de datos

3.1. Tamaño de muestra

El tamaño de muestra n afecta directamente el poder de las pruebas de bondad de ajuste y la precisión de los estimadores. Como guía:

- $n < 20$: insuficiente para distinguir distribuciones con confianza; las pruebas formales tienen muy bajo poder. La exploración gráfica y el juicio experto dominan.
- $20 \leq n < 50$: permite ajuste razonable de distribuciones de 1–2 parámetros. Las pruebas KS son aplicables pero poco potentes.
- $50 \leq n < 200$: rango adecuado para la mayoría de aplicaciones. Las pruebas χ^2 y KS tienen poder moderado.
- $n \geq 200$: excelente para ajuste; sin embargo, con muestras muy grandes las pruebas formales rechazan casi cualquier distribución (detectan desviaciones irrelevantes).

Paradoja de las muestras grandes

Con $n \geq 500$, la prueba χ^2 o KS puede rechazar una distribución que ajusta muy bien en la práctica, porque detecta discrepancias estadísticamente significativas pero prácticamente despreciables. En este caso, la inspección visual (Q-Q plot) y los criterios de información (AIC/BIC) son más informativos que el p-value.

3.2. Independencia de las observaciones

Las fórmulas de MLE y las pruebas de bondad de ajuste asumen que las observaciones $X_1, X_2, \ldots, X_n$ son independientes. Esta hipótesis debe verificarse:

Autocorrelación lag-1. El estimador del coeficiente de autocorrelación de primer orden es:

$$\hat{\rho}_1 = \frac{\sum_{i=1}^{n-1}(X_i - \bar{X})(X_{i+1} - \bar{X})}{\sum_{i=1}^{n}(X_i - \bar{X})^2}$$

Si $|\hat{\rho}_1| > 2/\sqrt{n}$ (intervalo aproximado al 95 % bajo H_0 de independencia), hay evidencia de autocorrelación.

Prueba de rachas (runs test). Se clasifica cada observación como "+" si $X_i > \tilde{X}$ (mediana) y "−" si $X_i < \tilde{X}$. Sea R el número de rachas (secuencias consecutivas del mismo signo). Bajo independencia, R tiene distribución aproximadamente normal con:

$$\mathbb{E}[R] = \frac{2n_+n_-}{n} + 1, \qquad \mathrm{Var}[R] = \frac{2n_+n_-(2n_+n_- - n)}{n^2(n-1)}$$

donde n_+ y n_- son los conteos de observaciones por encima y por debajo de la mediana.

Autocorrelación en datos de servicio

En sistemas reales, los tiempos de servicio consecutivos pueden estar correlacionados si un mismo operador se fatiga, si las tareas son similares por lotes, o si el sistema tiene retroalimentación. Si se detecta autocorrelación, considerar: (a) usar un proceso autoregresivo como entrada, (b) submuestrear (tomar cada k-ésima observación), o (c) modelar la dependencia explícitamente.

3.3. Homogeneidad temporal (estacionariedad)

Los datos deben provenir de un proceso estacionario (sin tendencias ni cambios de régimen). Verificar con:

- **Gráfico de serie de tiempo**: X_i vs. i. Buscar tendencias, cambios de nivel o patrones cíclicos.
- **División en subgrupos**: dividir la muestra en k bloques y comparar las medias de cada bloque. Si difieren significativamente (ANOVA o Kruskal-Wallis), los datos no son homogéneos.
- **Efectos de hora del día**: en sistemas de servicio, la tasa de llegadas suele variar con la hora. Ajustar distribuciones separadas por franja horaria o usar un proceso de Poisson no homogéneo.

4. Tipos de datos en sistemas de colas

- **Tiempos entre llegadas** $A_i = T_i - T_{i-1}$: si son exponenciales, el proceso de llegadas es de Poisson (Markoviano). Verificar si $\mathrm{CV}_A \approx 1$ y si el número de llegadas en intervalos fijos sigue una distribución Poisson.
- **Tiempos de servicio** S_i: determinan si la cola es $M/M/c$, $M/G/c$ o $G/G/c$. El CV es el estadístico más informativo.
- **Tiempos de falla**: en modelos de confiabilidad, la tasa de falla puede ser creciente (desgaste) o decreciente (mortalidad infantil), lo cual descarta la exponencial.
- **Tamaños de lote**: cuando llegan grupos de entidades simultáneamente (buses, pedidos por bulk).

Notación de Kendall

La notación $A/S/c/K$ describe una cola por sus distribuciones de llegada (A) y servicio (S), número de servidores (c) y capacidad máxima (K). Letras estándar: M = exponencial/Poisson, D = determinista, E_k = Erlang-k, H_k = hiperexponencial, G = general. Una cola $M/G/1$ tiene llegadas Poisson y servicio arbitrario.

5. Exploración gráfica

5.1. Histograma

El histograma divide el rango en k intervalos y estima la densidad empírica en cada uno. Reglas prácticas para k:

- Sturges: $k = \lceil 1 + \log_2 n \rceil$.
- Raíz cuadrada: $k \approx \sqrt{n}$.
- Scott: $h = 3{,}49\, s\, n^{-1/3}$ (anchura óptima bajo normalidad).

El histograma revela asimetría, multimodalidad y colas, pero es sensible a la elección de k con muestras pequeñas.

5.2. Función de distribución empírica (ECDF)

La ECDF estima $F(x) = \mathbb{P}(X \leq x)$ sin suponer ninguna forma paramétrica:

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^{n} \mathbf{1}_{[X_i \leq x]}$$

Si los datos se ordenan como $X_{(1)} \leq X_{(2)} \leq \cdots \leq X_{(n)}$, entonces $\hat{F}_n(X_{(i)}) = i/n$. El teorema de Glivenko–Cantelli garantiza $\sup_x |\hat{F}_n(x) - F(x)| \xrightarrow{c.s.} 0$. Superponer la ECDF con la CDF teórica

$F(x;\hat{\theta})$ permite una inspección visual global del ajuste.

5.3. Gráfico Q-Q (cuantil–cuantil)

Compara los cuantiles empíricos con los cuantiles teóricos. Si el ajuste es correcto, los puntos se alinean en la recta $y = x$.

Construcción del gráfico Q-Q

1. Ordenar: $X_{(1)} \leq \cdots \leq X_{(n)}$.
2. Probabilidades de trazado: $p_i = (i - 0{,}5)/n$ (fórmula de Hazen).
3. Cuantiles teóricos: $q_i = F^{-1}(p_i;\hat{\theta})$.
4. Graficar $(q_i,\, X_{(i)})$; observar alineación con la diagonal.

Patrones de desviación:

- Puntos *sobre* la diagonal en la cola derecha: datos con colas más pesadas que el modelo.
- Curvatura en "S": los datos son más simétricos o menos asimétricos que el modelo.
- Pendiente distinta de 1: parámetro de escala mal estimado.

6. Familias de distribuciones para sistemas de colas

6.1. Exponencial — base de referencia Markoviana

$X \sim \mathrm{Exp}(\lambda)$: $f(x) = \lambda e^{-\lambda x}$, $\mathbb{E}[X] = 1/\lambda$, $\mathrm{CV} = 1$.

Propiedad de ausencia de memoria: $\mathbb{P}(X > s + t \mid X > s) = \mathbb{P}(X > t)$. Esta propiedad hace que los sistemas con llegadas y servicios exponenciales sean CMTC, tractables analíticamente. Es el único justificativo para el modelo $M/M/c$.

6.2. Erlang-k — servicio en fases regulares

$X \sim E_k(\mu)$ es la suma de k exponenciales i.i.d. con tasa μ: $X = S_1 + \cdots + S_k$. $\mathbb{E}[X] = k/\mu$, $\mathrm{CV} = 1/\sqrt{k}$.

La Erlang modela servicios con k etapas secuenciales (inspección, diagnóstico, prueba). A mayor k, menor variabilidad y, según la fórmula P-K, menor tiempo de espera.

6.3. Hiperexponencial-k — mezcla de tipos de servicio

Se genera eligiendo exponencial i con probabilidad p_i y muestreando $X \sim \mathrm{Exp}(\lambda_i)$. $\mathrm{CV} > 1$. Adecuada para poblaciones heterogéneas (reparaciones simples vs. complejas). La densidad es:

$$f(x) = \sum_{i=1}^{k} p_i \lambda_i e^{-\lambda_i x}, \qquad \sum_{i=1}^{k} p_i = 1$$

Para $k = 2$ con parámetros $(p_1, \lambda_1, p_2, \lambda_2)$: $\mathbb{E}[X] = p_1/\lambda_1 + p_2/\lambda_2$ y el CV siempre es mayor que 1.

6.4. Gamma

$X \sim \text{Gamma}(\alpha, \beta)$: $\mathbb{E}[X] = \alpha/\beta$, $\text{CV} = 1/\sqrt{\alpha}$. La Erlang-$k$ es un caso especial con $\alpha = k \in \mathbb{N}$. El parámetro α no requiere ser entero, lo que da mayor flexibilidad.

6.5. Weibull — tasa de falla no constante

$X \sim \text{Weibull}(k, \lambda)$: $f(x) = \frac{k}{\lambda}\left(\frac{x}{\lambda}\right)^{k-1} e^{-(x/\lambda)^k}$. La tasa de falla (hazard) es $h(x) = \frac{k}{\lambda}(x/\lambda)^{k-1}$:

- $k < 1$: tasa decreciente (mortalidad infantil — equipos nuevos).
- $k = 1$: tasa constante (exponencial, Markoviano).
- $k > 1$: tasa creciente (desgaste — equipos envejecidos).

La Weibull es la distribución estándar para tiempos de falla en ingeniería de confiabilidad y para tiempos de reparación con alta variabilidad.

6.6. Log-normal — fenómenos multiplicativos

$X \sim \text{LogNormal}(\mu, \sigma^2)$ si $\ln X \sim \mathcal{N}(\mu, \sigma^2)$. $\mathbb{E}[X] = e^{\mu+\sigma^2/2}$, $\text{CV} = \sqrt{e^{\sigma^2} - 1}$. Natural cuando el tiempo de servicio resulta de muchos factores multiplicativos (diagnóstico, negociación, resolución de incidencias).

6.7. Tabla resumen

Distribución	**Soporte**	CV	**Tasa de falla**	**Uso típico**
Determinista (D)	$\{d\}$	0	—	Procesos automatizados
Erlang-k (E_k)	$(0, \infty)$	$1/\sqrt{k}$	Creciente	Servicio en etapas
Exponencial (M)	$(0, \infty)$	1	Constante	Baseline Markoviano
Gamma (α, β)	$(0, \infty)$	$1/\sqrt{\alpha}$	Flexible	Modelado general
Weibull (k, λ)	$(0, \infty)$	Variable	Flexible	Fallas, mantenimiento
Log-normal (μ, σ)	$(0, \infty)$	Variable	Unimodal	Actividades humanas
Hiperexponencial	$(0, \infty)$	> 1	Decreciente	Poblaciones mixtas

Guía rápida de selección por CV

- $\text{CV} = 0$: determinista.
- $0 < \text{CV} < 1$: Erlang-k (con $k \approx 1/\text{CV}^2$) o Gamma.
- $\text{CV} = 1$: exponencial (primera candidata) o Weibull con $k \approx 1$.
- $\text{CV} > 1$: hiperexponencial, Weibull con $k < 1$, o Log-normal.

7. Estimación de parámetros

7.1. Máxima verosimilitud (MLE)

Sea $x_1, \ldots, x_n$ una muestra i.i.d. con densidad $f(x;\theta)$. El estimador MLE es:

$$\hat{\theta} = \arg\max_{\theta} \ell(\theta), \qquad \ell(\theta) = \sum_{i=1}^{n} \ln f(x_i;\theta)$$

Los MLE son asintóticamente eficientes (mínima varianza) y consistentes.

Derivación para la exponencial. Sea $X_i \sim \mathrm{Exp}(\lambda)$:

$$\begin{aligned} \ell(\lambda) &= \sum_{i=1}^{n} \ln(\lambda e^{-\lambda x_i}) = n \ln \lambda - \lambda \sum_{i=1}^{n} x_i \\ \frac{d\ell}{d\lambda} &= \frac{n}{\lambda} - \sum_{i=1}^{n} x_i = 0 \\ \Rightarrow \quad \hat{\lambda} &= \frac{n}{\sum_{i=1}^{n} x_i} = \frac{1}{\bar{x}} \end{aligned}$$

La segunda derivada $d^2\ell/d\lambda^2 = -n/\lambda^2 < 0$ confirma que es un máximo. La varianza asintótica del MLE es $\mathrm{Var}[\hat{\lambda}] \approx \lambda^2/n$, obtenida de la información de Fisher $\mathcal{I}(\lambda) = n/\lambda^2$.

MLE para distribuciones comunes:

Distribución	**MLE**	**Forma cerrada**
Exponencial(λ)	$\hat{\lambda} = 1/\bar{x}$	Sí
Normal(μ, σ^2)	$\hat{\mu} = \bar{x}, \ \hat{\sigma}^2 = S^2$	Sí
Log-normal(μ, σ^2)	$\hat{\mu} = \overline{\ln x}, \ \hat{\sigma}^2 = S^2_{\ln x}$	Sí
Gamma(α, β)	ec. transcendental en $\hat{\alpha}$ (digamma)	No
Weibull(k, λ)	sistema de ecuaciones no lineal	No

7.2. Método de momentos (MM)

Iguala los momentos muestrales $\bar{x}^{(r)} = n^{-1} \sum x_i^r$ con los momentos teóricos $\mathbb{E}[X^r]$. Para la exponencial: $\hat{\lambda} = 1/\bar{x}$ (coincide con MLE, ya que la exponencial tiene un solo parámetro y un solo momento utilizado). Para distribuciones de dos parámetros se igualan media y varianza:

Gamma: $\mathbb{E}[X] = \alpha/\beta$ y $\mathrm{Var}[X] = \alpha/\beta^2$ implican $\hat{\alpha} = \bar{x}^2/s^2$ y $\hat{\beta} = \bar{x}/s^2$.

Weibull: $\hat{k}$ y $\hat{\lambda}$ se obtienen del sistema $\mathbb{E}[X] = \lambda\,\Gamma(1+1/k)$, $\mathrm{Var}[X] = \lambda^2[\Gamma(1+2/k) - \Gamma^2(1+1/k)]$.

Estrategia práctica

Estimar siempre con MLE cuando sea factible; usar momentos como valor inicial de la optimización numérica. Si el soporte de los datos incluye cero o hay una masa puntual, considerar distribuciones mixtas o truncadas.

8. Pruebas de bondad de ajuste

Una vez ajustada la distribución, se verifica si los datos son estadísticamente consistentes con $H_0 : F = F_0(\cdot; \hat{\theta})$.

8.1. Prueba χ^2

Agrupa los datos en k celdas con frecuencias observadas O_j y esperadas $E_j = n[F_0(b_j) - F_0(a_j)]$:

$$\chi^2 = \sum_{j=1}^{k} \frac{(O_j - E_j)^2}{E_j} \xrightarrow{H_0} \chi^2_{k-1-p}$$

donde p es el número de parámetros estimados. Rechazar H_0 si $\chi^2 > \chi^2_{\alpha,\, k-1-p}$.

Requisito: $E_j \geq 5$ en cada celda (fusionar celdas adyacentes si no se cumple).

8.2. Prueba de Kolmogorov–Smirnov (KS)

Compara la ECDF con la CDF teórica:

$$D_n = \sup_x \left| \hat{F}_n(x) - F_0(x; \hat{\theta}) \right| = \max_i \max \left(\frac{i}{n} - F_0(X_{(i)}),\ F_0(X_{(i)}) - \frac{i-1}{n} \right)$$

La prueba KS es más sensible que la χ^2 para distribuciones continuas, pero los valores críticos estándar son anticonservativos cuando $\hat{\theta}$ se estima de los mismos datos. En ese caso, usar tablas de Lilliefors o la prueba de Anderson–Darling.

8.3. Prueba de Anderson–Darling (AD)

La prueba AD pondera las discrepancias en las colas, donde la χ^2 y la KS son menos sensibles:

$$A^2 = -n - \sum_{i=1}^{n} \frac{2i-1}{n} \left[\ln F_0(X_{(i)}) + \ln(1 - F_0(X_{(n+1-i)})) \right]$$

Valores críticos dependen de la distribución específica bajo H_0. La prueba AD es generalmente más potente que la KS, especialmente para detectar desviaciones en las colas.

8.4. Interpretación del p-value

p-value

El p-value es la probabilidad de observar un estadístico de prueba al menos tan extremo como el observado, bajo H_0. **No** es la probabilidad de que H_0 sea verdadera.

- $p > 0{,}10$: no hay evidencia contra H_0; la distribución es consistente con los datos.
- $0{,}05 < p \leq 0{,}10$: evidencia débil contra H_0; verificar con gráficos.
- $p \leq 0{,}05$: rechazar H_0 al nivel 5 %.

¿Cuál prueba elegir?

La χ^2 es versátil (discreta y continua) y robusta con parámetros estimados, pero requiere celdas con $E_j \geq 5$. La KS es más poderosa para distribuciones continuas pero supone parámetros conocidos. La AD es la más potente en las colas. Usar al menos dos como diagnóstico complementario; el gráfico Q-Q siempre como referencia visual.

9. Criterios de selección de modelos

Cuando varias distribuciones pasan las pruebas de bondad de ajuste, se necesitan criterios para elegir la mejor.

9.1. Criterio de información de Akaike (AIC)

$$\mathrm{AIC} = -2\,\ell(\hat{\theta}) + 2p$$

donde $\ell(\hat{\theta})$ es la log-verosimilitud evaluada en el MLE y p es el número de parámetros. El AIC penaliza la complejidad del modelo: entre dos modelos que ajustan igualmente bien, se prefiere el más parsimonioso.

9.2. Criterio de información bayesiano (BIC)

$$\mathrm{BIC} = -2\,\ell(\hat{\theta}) + p \ln n$$

El BIC penaliza más fuertemente la complejidad que el AIC cuando $n > 7$ (ya que $\ln n > 2$). Es más conservador en la selección de modelos.

Uso de AIC/BIC

1. Ajustar todas las distribuciones candidatas con MLE.
2. Calcular AIC (o BIC) para cada una.
3. Seleccionar la distribución con el **menor** AIC (o BIC).
4. Si la diferencia $\Delta\text{AIC} < 2$ entre dos modelos, ambos son estadísticamente indistinguibles; preferir el más simple o el más interpretable físicamente.

10. ¿Qué hacer cuando no hay datos?

En la práctica, frecuentemente no se dispone de datos suficientes. Estrategias alternativas:

- **Elicitación de expertos**: preguntar al operador o gerente por los valores mínimo (a), más probable (m) y máximo (b) del proceso. Usar la distribución triangular $\text{Tri}(a, m, b)$ o la PERT:

$$\mathbb{E}[X] = \frac{a + 4m + b}{6}, \qquad \text{Var}[X] = \frac{(b-a)^2}{36}$$

- **Valores de literatura**: publicaciones y benchmarks industriales proporcionan rangos típicos para tiempos de servicio, tasas de falla, etc.
- **Análisis de sensibilidad**: si la entrada es incierta, simular con varias distribuciones y parámetros plausibles para evaluar cuán sensible es la salida a la elección de entrada.
- **Distribución uniforme**: cuando solo se conocen los límites $[a, b]$, la uniforme es la distribución de máxima entropía y la elección menos sesgada.

La triangular no es un sustituto permanente

La distribución triangular es útil para prototipos rápidos y análisis preliminares, pero no para el modelo final. Sus colas son lineales (no exponenciales), lo que la hace inadecuada para representar tiempos de servicio o falla realistas. Siempre buscar datos reales para el modelo definitivo.

11. ¿Qué hacer si ninguna distribución ajusta?

Si todas las distribuciones candidatas son rechazadas por las pruebas de bondad de ajuste:

1. **Verificar los datos**: ¿hay errores de registro, valores atípicos, o datos de periodos distintos mezclados?
2. **Considerar distribuciones mixtas**: si el histograma es bimodal, una mezcla de dos distribuciones puede ajustar: $f(x) = p\, f_1(x) + (1-p) f_2(x)$.
3. **Distribución empírica**: usar la ECDF directamente como entrada del simulador, muestreando

con interpolación lineal. Esto sacrifica la generalización pero respeta los datos.

4. **Transformaciones**: si $\ln X$ se ajusta a una distribución conocida, usar esa transformación.

12. Ejemplo básico: tiempos de servicio en ventanilla bancaria

Sistema

Un banco registra los tiempos de atención (en minutos) de 15 clientes consecutivos en una ventanilla durante una hora. Se quiere determinar si los tiempos de servicio siguen una distribución exponencial, lo que permitiría modelar la ventanilla como cola $M/M/1$.

Datos observados (15 tiempos de servicio, en minutos, ya ordenados):

0,7 0,8 0,9 1,1 1,2 1,5 1,6 1,8 2,1 2,4 2,8 3,1 3,4 4,2 5,6

Paso 1 — Estadísticos muestrales:

$$n = 15, \quad \bar{x} = \frac{0{,}7 + 0{,}8 + \cdots + 5{,}6}{15} = 2{,}21 \text{ min}, \quad s = 1{,}32 \text{ min}, \quad \text{CV} = \frac{1{,}32}{2{,}21} = 0{,}60$$

Paso 2 — Identificación preliminar: el CV empírico de $0{,}60 < 1$ sugiere que los datos son *más regulares* que la exponencial (CV = 1). La guía de selección por CV sugiere Erlang o Gamma. No obstante, con $n = 15$ la incertidumbre del CV es alta, así que probamos la exponencial como hipótesis nula.

Paso 3 — Estimación MLE — Exponencial: $\hat{\lambda} = 1/\bar{x} = 1/2{,}21 = 0{,}452 \text{ min}^{-1}$.

Paso 4 — Prueba χ^2 con $k = 3$ intervalos de igual probabilidad ($E_j = 5$):

Los puntos de corte se obtienen de $F^{-1}(1/3; \hat{\lambda})$ y $F^{-1}(2/3; \hat{\lambda})$:

$$a_1 = -\frac{\ln(2/3)}{0{,}452} = 0{,}90 \text{ min}, \qquad a_2 = -\frac{\ln(1/3)}{0{,}452} = 2{,}43 \text{ min}$$

Celda	**Intervalo**	O_j	E_j	$(O_j - E_j)^2/E_j$
1	[0; 0,90)	3	5,0	0,80
2	[0,90; 2,43)	7	5,0	0,80
3	[2,43; ∞)	5	5,0	0,00
			χ^2 observado	1,60

Con $\nu = 3 - 1 - 1 = 1$ grado de libertad y $\alpha = 0{,}05$, el valor crítico es $\chi^2_{0{,}05,1} = 3{,}84$. Como $1{,}60 < 3{,}84$, **no se rechaza** la hipótesis exponencial.

Precaución con muestras pequeñas

Con $n = 15$, la prueba χ^2 tiene muy bajo poder estadístico: casi ninguna distribución sería rechazada con solo 3 celdas y 1 grado de libertad. El CV de 0,60 es la señal más informativa. Con más datos, probablemente se rechazaría la exponencial en favor de una Gamma o Erlang. Siempre interpretar la prueba junto con el Q-Q plot.

Resultado del ejemplo básico

La exponencial no se rechaza formalmente, pero el CV de 0,60 sugiere que no es la mejor opción. Con esta muestra pequeña, la prueba χ^2 no tiene poder para discriminar. Procedemos en el ejemplo intermedio a recolectar más datos del mismo banco para resolver esta ambigüedad.

13. Ejemplo intermedio: modelado completo del banco

Sistema

Se amplía el estudio del banco del ejemplo básico. Durante una semana se registran 80 tiempos entre llegadas y 80 tiempos de servicio en la misma ventanilla. El objetivo es determinar las distribuciones de entrada para un modelo de simulación de la cola, identificando si el sistema es $M/M/1$, $M/G/1$ o $G/G/1$.

13.1. Análisis de tiempos entre llegadas

Estadísticos: $n_A = 80$, $\bar{A} = 3{,}2$ min, $s_A = 3{,}1$ min, $\mathrm{CV}_A = 0{,}97$.

El CV cercano a 1 es consistente con la exponencial (proceso de Poisson). La prueba de rachas arroja $R = 39$ rachas con $\mathbb{E}[R] = 41$, $Z = -0{,}4$ ($p = 0{,}69$): no se rechaza independencia. La autocorrelación lag-1 es $\hat{\rho}_1 = 0{,}04$, dentro del intervalo $\pm 2/\sqrt{80} = \pm 0{,}22$.

MLE: $\hat{\lambda} = 1/3{,}2 = 0{,}3125$ clientes/min.

Prueba KS: $D_{80} = 0{,}07$. El valor crítico de Lilliefors al 5 % para $n = 80$ es $D^*_{0{,}05} \approx 0{,}10$. Como $0{,}07 < 0{,}10$, no se rechaza.

Prueba AD: $A^2 = 0{,}41$. El valor crítico para exponencial con parámetro estimado al 5 % es $A^{2*} = 1{,}32$. No se rechaza.

Conclusión de llegadas: $A \sim \mathrm{Exp}(0{,}3125)$, proceso de Poisson con $\lambda = 0{,}3125$ clientes/min ($\approx 18{,}75$ clientes/h). La letra de llegada es M.

13.2. Análisis de tiempos de servicio

Estadísticos: $n_S = 80$, $\bar{S} = 2{,}18$ min, $s_S = 1{,}34$ min, $\mathrm{CV}_S = 0{,}61$.

El CV de 0,61 confirma lo observado en el ejemplo básico: los tiempos son *menos variables* que la exponencial. La guía de selección por CV sugiere $k \approx 1/0{,}61^2 \approx 2{,}7$, es decir, Erlang-3 o Gamma.

Se ajustan tres distribuciones candidatas:

Distribución	**Parámetros MLE**	D_{80} (KS)	A^2 (AD)	$\ell(\hat{\theta})$	**AIC**
Exponencial	$\hat{\lambda} = 0{,}459$	0,14	2,87	−148,3	298,6
Erlang-3	$\hat{\mu}_f = 3/2{,}18 = 1{,}376$	0,06	0,38	−137,1	276,2
Gamma	$\hat{\alpha} = 2{,}65$, $\hat{\beta} = 1{,}22$	0,05	0,31	−136,4	276,8

Interpretación:

- La exponencial es **rechazada** por la prueba AD ($2{,}87 > 1{,}32$) y marginalmente por KS ($0{,}14 > 0{,}10$).
- La Erlang-3 y la Gamma pasan ambas pruebas holgadamente.
- El AIC de la Erlang-3 (276,2) y la Gamma (276,8) son prácticamente iguales ($\Delta\text{AIC} = 0{,}6 < 2$).
- Se elige la **Erlang-3** por parsimonia (1 parámetro vs. 2) y porque tiene interpretación física: el servicio consta de tres etapas (saludo y consulta, transacción, despedida).

13.3. Impacto en el modelo de colas

Con $\lambda = 0{,}3125$ cl/min, $\mathbb{E}[S] = 2{,}18$ min, $\rho = 0{,}3125 \times 2{,}18 = 0{,}68$.

$$\mathbb{E}[S^2] = \text{Var}[S] + (\mathbb{E}[S])^2 = (0{,}61 \times 2{,}18)^2 + 2{,}18^2 = 1{,}77 + 4{,}75 = 6{,}52$$

Modelo	**Fórmula**	W_q (min)
$M/M/1$ (si usáramos exponencial)	$\dfrac{\rho}{\mu(1-\rho)}$	4,63
$M/E_3/1$ (distribución correcta)	$\dfrac{\lambda\mathbb{E}[S^2]}{2(1-\rho)}$	3,18

Resultado del ejemplo intermedio

El sistema es $M/E_3/1$: llegadas Poisson ($\lambda = 0{,}3125$ cl/min) y servicio Erlang-3 ($\mathbb{E}[S] = 2{,}18$ min). Usar incorrectamente $M/M/1$ sobreestimaría el tiempo en cola en un **46 %** (4,63 vs. 3,18 min). Este ejemplo muestra la importancia de no asumir ciegamente la exponencial y de disponer de suficientes datos ($n = 80$ vs. $n = 15$) para discriminar distribuciones.

14. Ejemplo escalado: taller de reparación de equipos industriales

Sistema

Un taller de mantenimiento atiende equipos industriales que llegan de diferentes líneas de producción. El gerente quiere determinar cuántos técnicos necesita. Durante dos semanas se registran:

- 50 tiempos entre llegadas sucesivas de equipos.
- 50 tiempos de reparación observados.

La hipótesis de trabajo es $M/M/1$, pero los datos sugieren algo diferente. A diferencia del banco (servicio en etapas regulares), aquí las reparaciones son heterogéneas: algunas son diagnósticos rápidos y otras son revisiones completas.

14.1. Análisis de tiempos entre llegadas

Estadísticos: $\bar{A} = 4{,}8$ h, $s_A = 4{,}6$ h, $\mathrm{CV}_A = 0{,}96 \approx 1$.

Un CV cercano a 1 es consistente con la exponencial (proceso de Poisson). La autocorrelación lag-1 es $\hat{\rho}_1 = 0{,}02$ (insignificante). La prueba KS con $\hat{\lambda} = 1/4{,}8 = 0{,}208$ h^{-1} arroja $D_{50} = 0{,}08 < D^*_{0{,}05,50} = 0{,}12$. La prueba AD da $A^2 = 0{,}52 < 1{,}32$. No se rechaza Poisson por ninguna prueba.

Conclusión de llegadas: $A \sim \mathrm{Exp}(0{,}208)$, proceso de Poisson con $\lambda = 0{,}208$ equipos/h.

14.2. Análisis de tiempos de reparación

Estadísticos: $\bar{S} = 3{,}6$ h, $s_S = 3{,}1$ h, $\mathrm{CV}_S = 0{,}86$.

El CV de 0,86 está entre la Erlang (< 1) y la exponencial ($= 1$). Sin embargo, el histograma muestra **asimetría pronunciada a la derecha** con una cola pesada: la mayoría de reparaciones toman 1–4 horas, pero hay varias de 8–10 horas. El Q-Q exponencial exhibe puntos *sobre* la diagonal en la cola superior, indicando que la exponencial subestima las colas.

Se prueban cuatro candidatas:

Distribución	**Parámetros MLE**	D_{50}	A^2	$\ell(\hat{\theta})$	**AIC**
Exponencial	$\hat{\lambda} = 0{,}278$ h^{-1}	0,13	1,85	−120,8	243,6
Gamma	$\hat{\alpha} = 1{,}42$, $\hat{\beta} = 0{,}39$	0,09	0,72	−117,1	238,2
Weibull	$\hat{k} = 1{,}28$, $\hat{\lambda}_W = 3{,}97$ h	0,06	0,35	−115,2	234,4
Log-normal	$\hat{\mu} = 1{,}05$, $\hat{\sigma} = 0{,}74$	0,08	0,54	−116,3	236,6

Análisis:

- La exponencial es **rechazada** por AD ($1{,}85 > 1{,}32$) y marginalmente por KS ($0{,}13 > 0{,}12$).
- Gamma, Weibull y Log-normal pasan ambas pruebas.

- La **Weibull tiene el menor AIC** (234,4), seguida por la Log-normal (236,6, $\Delta = 2{,}2$) y la Gamma (238,2, $\Delta = 3{,}8$).
- El parámetro $\hat{k} = 1{,}28 > 1$ indica **tasa de falla creciente**: las reparaciones se vuelven más complicadas a medida que el diagnóstico avanza. Esto es coherente con el proceso físico del taller.

Conclusión de servicio: $S \sim \text{Weibull}(1{,}28;\ 3{,}97)$ h.

14.3. Impacto en el modelo de colas

Con $\lambda = 0{,}208\ \text{h}^{-1}$, $\mathbb{E}[S] = 3{,}6$ h, $\rho = \lambda\mathbb{E}[S] = 0{,}75$:

$$\text{Var}[S] = (\text{CV}_S \cdot \mathbb{E}[S])^2 = (0{,}86 \times 3{,}6)^2 = 9{,}59\ \text{h}^2$$

$$\mathbb{E}[S^2] = \text{Var}[S] + (\mathbb{E}[S])^2 = 9{,}59 + 12{,}96 = 22{,}55\ \text{h}^2$$

Modelo	**Fórmula**	W_q
$M/M/1$ (servicio exponencial)	$\dfrac{\rho}{\mu(1-\rho)}$	10,8 h
$M/G/1$ (servicio Weibull)	$\dfrac{\lambda\mathbb{E}[S^2]}{2(1-\rho)}$	9,4 h

Usar $M/M/1$ sobreestimaría el tiempo en cola en un 15 %. Nótese el contraste con el banco: allí el servicio Erlang *reducía* W_q significativamente ($\text{CV} < 1$), mientras que aquí la Weibull con $\text{CV} = 0{,}86$ produce un efecto menor porque está más cerca de 1.

Conclusión del modelado de entradas

El sistema queda caracterizado como $M/G/1$ con llegadas Poisson ($\lambda = 0{,}208\ \text{h}^{-1}$) y servicio Weibull ($k = 1{,}28$; $\lambda_W = 3{,}97$ h). La elección correcta de distribución reduce el error de predicción del tiempo de espera en $\approx 15\,\%$ respecto al supuesto Markoviano.
Este ejemplo ilustra el proceso completo: (1) verificación de independencia y estacionariedad, (2) exploración gráfica, (3) ajuste de múltiples candidatas con MLE, (4) selección por pruebas de bondad de ajuste y AIC, (5) validación de la coherencia física.
Para métricas que no tienen expresión cerrada en $M/G/1$ (percentiles, distribución completa del tiempo de espera), se requiere simulación (Temas 3.3 y 3.4).

Referencias

[1] Law, A. M. (2015). *Simulation Modeling and Analysis*, 5th ed. McGraw-Hill. Cap. 6.

[2] Banks, J., Carson, J. S., Nelson, B. L. & Nicol, D. M. (2014). *Discrete-Event System Simulation*, 5th ed. Pearson. Cap. 9.

[3] Leemis, L. M. & Park, S. K. (2006). *Discrete-Event Simulation: A First Course*. Pearson. Cap. 6.

[4] D'Agostino, R. B. & Stephens, M. A. (1986). *Goodness-of-Fit Techniques*. Marcel Dekker.

[5] Kelton, W. D., Sadowski, R. P. & Zupick, N. B. (2015). *Simulation with Arena*, 6th ed. McGraw-Hill. Cap. 4.

[6] Ross, S. M. (2014). *Introduction to Probability Models*, 11th ed. Academic Press. Cap. 1–2.