Universidad de los Andes

Departamento de Ingeniería Industrial · Modelado de Sistemas bajo Incertidumbre

Modelado de Entradas: Del Dato Observado a la Distribución de Probabilidad

Alejandra Tabares Pozos

Índice

1. Motivación: la distribución importa **3**
1.1. El coeficiente de variación como indicador clave . . . 3

2. Proceso metodológico **4**

3. Un conjunto de datos para todo el recorrido **4**

4. Recolección y calidad de datos **5**
4.1. Tamaño de muestra . . . 5
4.2. Independencia de las observaciones . . . 5
4.2.1. Autocorrelación lagueada (Pearson lagueada) . . . 5
4.2.2. Correlograma (ACF) . . . 6
4.2.3. Prueba de rachas (runs test) . . . 6
4.3. Homogeneidad temporal (estacionariedad) . . . 7

5. Exploración gráfica **7**
5.1. Histograma . . . 7
5.2. Función de distribución empírica (ECDF) . . . 8
5.3. Gráfico Q-Q (cuantil–cuantil) . . . 8

6. Familias de distribuciones para sistemas de colas **9**
6.1. Exponencial — base de referencia Markoviana . . . 9
6.2. Erlang-k — servicio en fases regulares . . . 10
6.3. Hiperexponencial-k — mezcla de tipos de servicio . . . 10
6.4. Gamma . . . 10
6.5. Weibull — tasa de falla no constante . . . 10

6.6. Log-normal — fenómenos multiplicativos 11
6.7. Tabla resumen y guía por coeficiente de variación 11

7. Estimación de parámetros 11
7.1. Máxima verosimilitud (MLE) 11
7.2. Método de momentos (MM) 12

8. Pruebas de bondad de ajuste 12
8.1. Prueba χ^2 13
8.2. Prueba de Kolmogorov–Smirnov (KS) 13
8.3. Prueba de Anderson–Darling (AD) 14
8.4. Interpretación del p-value 15

9. Criterios de selección de modelos 16
9.1. Criterio de información de Akaike (AIC) 16
9.2. Criterio de información bayesiano (BIC) 16

10. Ejemplo integrador: banco completo 17
10.1. Tiempos entre llegadas 17
10.2. Tiempos de servicio 17
10.3. Impacto en el modelo de colas 18

11. Ejemplo escalado: taller de reparación de equipos industriales 18
11.1. Tiempos entre llegadas 18
11.2. Tiempos de reparación 18
11.3. Impacto en el modelo de colas 19

12. ¿Qué hacer cuando no hay datos? 19

13. ¿Qué hacer si ninguna distribución ajusta? 20

1. Motivación: la distribución importa

Todo modelo de simulación de eventos discretos (SED) está alimentado por distribuciones de probabilidad que caracterizan la aleatoriedad del sistema: tiempos entre llegadas, tiempos de servicio, tiempos de falla, demandas. El **modelado de entradas** (*input modeling*) es el proceso de transformar datos empíricos en distribuciones parametrizadas que el simulador pueda muestrear. Una distribución mal elegida se propaga como error sistemático a todas las métricas de salida.

Más aún, la distribución elegida determina qué herramientas analíticas están disponibles:

- Cola $M/M/1$: llegadas Poisson, servicio exponencial $\Rightarrow$ solución cerrada exacta.
- Cola $M/G/1$: llegadas Poisson, servicio general $\Rightarrow$ fórmula de Pollaczek–Khinchine.
- Cola $G/G/1$: ambas distribuciones generales $\Rightarrow$ esencialmente solo simulación.

Identificar correctamente las distribuciones puede habilitar análisis analíticos que eviten la simulación, o revelar que la simulación es necesaria.

Principio GIGO

Garbage In, Garbage Out: un modelo computacionalmente sofisticado ajustado con distribuciones incorrectas producirá conclusiones erróneas con alta precisión *aparente*. Los errores de modelado de entradas no se cancelan; se amplifican.

1.1. El coeficiente de variación como indicador clave

El **coeficiente de variación** $\mathrm{CV} = \sigma/\mu$ resume cuán variable es una distribución relativo a su media. Para una cola $M/G/1$ con tráfico $\rho = \lambda\mathbb{E}[S]$, la fórmula de Pollaczek–Khinchine muestra que:

$$W_q^{M/G/1} = \underbrace{\frac{\rho}{\mu(1-\rho)}}_{W_q^{M/M/1}} \cdot \frac{1+\mathrm{CV}_S^2}{2}$$

La misma media, cinco W_q distintos

Bajo $\rho = 0{,}8$ y $\mathbb{E}[S] = 1$ min (por lo que $W_q^{M/M/1} = 4$ min):

Distribución de servicio	**Notación**	CV_S	W_q (min)
Determinista	D	0	2,0
Erlang-2	E_2	$1/\sqrt{2} \approx 0{,}71$	3,0
Exponencial	M	1	4,0
Weibull ($k = 0{,}8$)	G	$\approx 1{,}3$	5,3
Hiperexponencial (CV=2)	H_2	2	10,0

Con la misma media del servicio, ignorar la variabilidad real puede distorsionar el tiempo en cola en un factor de **5**. Asumir exponencial "porque es fácil" es el error más caro del modelado.

2. Proceso metodológico

Metodología de modelado de entradas — 5 pasos

1. **Recolección de datos**: registrar observaciones del sistema real; verificar homogeneidad temporal e independencia entre observaciones.
2. **Exploración gráfica**: histograma, función de distribución empírica (ECDF) y gráfico Q-Q; identificar forma, asimetría, colas y posibles valores atípicos.
3. **Identificación de la familia**: usar el CV, el soporte del dato y el conocimiento del proceso físico para seleccionar distribuciones candidatas.
4. **Estimación de parámetros**: máxima verosimilitud (MLE) o método de momentos.
5. **Prueba de bondad de ajuste**: χ^2, Kolmogorov–Smirnov o Anderson–Darling; aceptar o rechazar el candidato con nivel de significancia α.

La secuencia es iterativa: un rechazo en el paso 5 suele mandar de regreso al paso 3 para probar otra familia de distribuciones. En cada sección de este documento presentamos el concepto teórico seguido, inmediatamente, por su *ejemplo resuelto*.

3. Un conjunto de datos para todo el recorrido

A lo largo de la lectura usaremos un *mismo* conjunto de 15 tiempos de atención (minutos) registrados en una ventanilla bancaria. La pregunta que guía todo el tema es: **¿se puede modelar la ventanilla como $M/M/1$?**

Datos del banco pequeño ($n = 15$)

0,7 0,8 0,9 1,1 1,2 1,5 1,6 1,8 2,1 2,4 2,8 3,1 3,4 4,2 5,6

Estadísticos muestrales:

$$n = 15, \quad \bar{x} = 2{,}213 \text{ min}, \quad s = 1{,}397 \text{ min}, \quad \text{CV} = \tfrac{s}{\bar{x}} = 0{,}631$$

El coeficiente de variación $0{,}63 < 1$ ya sugiere que los datos son *más regulares* que la exponencial; la guía por CV apunta a una Erlang-k con $k \approx 1/0{,}63^2 \approx 2{,}5$.

4. Recolección y calidad de datos

4.1. Tamaño de muestra

El tamaño de muestra n afecta directamente el poder de las pruebas de bondad de ajuste y la precisión de los estimadores. Como guía:

- $n < 20$: insuficiente para distinguir distribuciones con confianza; las pruebas formales tienen muy bajo poder. La exploración gráfica y el juicio experto dominan.
- $20 \leq n < 50$: permite ajuste razonable de distribuciones de 1–2 parámetros. Las pruebas KS son aplicables pero poco potentes.
- $50 \leq n < 200$: rango adecuado para la mayoría de aplicaciones. Las pruebas χ^2 y KS tienen poder moderado.
- $n \geq 200$: excelente para ajuste; sin embargo, con muestras muy grandes las pruebas formales rechazan casi cualquier distribución (detectan desviaciones irrelevantes).

Paradoja de las muestras grandes

Con $n \geq 500$, la prueba χ^2 o KS puede rechazar una distribución que ajusta muy bien en la práctica, porque detecta discrepancias estadísticamente significativas pero prácticamente despreciables. En este caso, la inspección visual (Q-Q plot) y los criterios de información (AIC/BIC) son más informativos que el p-value.

4.2. Independencia de las observaciones

Las fórmulas de MLE y las pruebas de bondad de ajuste asumen que las observaciones $X_1, X_2, \ldots, X_n$ son independientes. Esta hipótesis debe verificarse antes de cualquier ajuste.

4.2.1. Autocorrelación lagueada (Pearson lagueada)

La versión lagueada del coeficiente de correlación de Pearson mide la dependencia temporal entre observaciones separadas k pasos:

$$r_k = \frac{\sum_{t=k+1}^{n}(X_t - \bar{X})(X_{t-k} - \bar{X})}{\sum_{t=1}^{n}(X_t - \bar{X})^2}.$$

Bajo $H_0 : \rho_k = 0$ y muestra grande,

$$r_k \approx \mathcal{N}\Big(0,\ \tfrac{1}{n}\Big),$$

por lo que las **bandas de confianza al** 95 % son $\pm 1{,}96/\sqrt{n}$. Si r_k cae fuera de las bandas, se rechaza la independencia en el rezago k.

Caso especial: lag 1. El criterio más usado en modelado de entradas es la autocorrelación de orden uno: si $|\hat{\rho}_1| > 2/\sqrt{n}$, hay evidencia de autocorrelación.

4.2.2. Correlograma (ACF)

Graficando r_k vs. k junto con las bandas de confianza obtenemos la **función de autocorrelación** o correlograma. Barras que sobresalen de las bandas marcan los rezagos con dependencia significativa.

Serie independiente vs. serie AR(1)

Sobre dos series simuladas con $n = 80$: una exponencial i.i.d. y una $X_t = 0{,}2 + 0{,}85\, X_{t-1} + \varepsilon_t$ (autoregresiva de orden 1):

Serie	r_1	r_2	r_3	**Banda** $\pm 1{,}96/\sqrt{80}$
Independiente	$-0{,}03$	$-0{,}01$	$+0{,}04$	$\pm 0{,}22$
AR(1), $\rho = 0{,}85$	$+0{,}75$	$+0{,}56$	$+0{,}39$	$\pm 0{,}22$

Los tres primeros rezagos de la serie AR(1) están muy por encima del umbral 0,22: se rechaza independencia de forma contundente. Ajustar una distribución exponencial (o cualquier otra) sobre esos datos sin modelar la dependencia invalida las pruebas de bondad y los MLE.

4.2.3. Prueba de rachas (runs test)

Se clasifica cada observación como "+" si $X_i > \tilde{X}$ (mediana) y "−" si $X_i < \tilde{X}$. Sea R el número de rachas (secuencias consecutivas del mismo signo). Bajo independencia, R tiene distribución aproximadamente normal con:

$$\mathbb{E}[R] = \frac{2n_+n_-}{n} + 1, \qquad \mathrm{Var}[R] = \frac{2n_+n_-(2n_+n_- - n)}{n^2(n-1)}$$

donde n_+ y n_- son los conteos por encima y por debajo de la mediana. Se rechaza independencia al 5 % si $|Z| = |R - \mathbb{E}[R]|/\sqrt{\mathrm{Var}[R]} > 1{,}96$.

Autocorrelación en datos de servicio

En sistemas reales, los tiempos de servicio consecutivos pueden estar correlacionados si un mismo operador se fatiga, si las tareas son similares por lotes, o si el sistema tiene retroalimentación. Si se detecta autocorrelación, considerar: (a) usar un proceso autoregresivo como entrada, (b) submuestrear (tomar cada k-ésima observación), o (c) modelar la dependencia explícitamente.

4.3. Homogeneidad temporal (estacionariedad)

Los datos deben provenir de un proceso estacionario (sin tendencias ni cambios de régimen). Se verifica con el gráfico de serie de tiempo (X_i vs. i, buscando tendencias o ciclos), comparando medias de subgrupos (ANOVA, Kruskal–Wallis), y ajustando distribuciones separadas por franja horaria cuando haya efectos de hora del día.

5. Exploración gráfica

5.1. Histograma

El histograma divide el rango en k intervalos y estima la densidad empírica en cada uno. Los pasos para su construcción son:

Construcción de un histograma

1. **Rango**: $R = x_{\text{máx}} - x_{\text{mín}}$.
2. **Número de intervalos** k. Reglas prácticas:
   - Sturges: $k = \lceil 1 + 3{,}322 \log_{10}(n) \rceil$.
   - Raíz cuadrada: $k \approx \sqrt{n}$.
   - Scott: anchura óptima $h = 3{,}49\, s\, n^{-1/3}$.
3. **Amplitud**: $w = R/k$.
4. **Frecuencias**: contar cuántas observaciones caen en $[a_j, a_j + w)$.
5. **Graficar** barras adyacentes (altura = frecuencia absoluta o relativa).

Histograma de los 15 tiempos del banco

$R = 5{,}6 - 0{,}7 = 4{,}9$; Sturges da $k = \lceil 1 + 3{,}322 \log_{10}(15) \rceil = 5$; amplitud $w = 4{,}9/5 = 0{,}98$.

Intervalo	**Frecuencia** f_j
[0,70; 1,68)	7
[1,68; 2,66)	3
[2,66; 3,64)	3
[3,64; 4,62)	1
[4,62; 5,60)	1
Total	15

La forma asimétrica a la derecha es compatible con una distribución positiva del tipo exponencial o Erlang. El histograma es, sin embargo, la *primera impresión*; con n pequeño es sensible a k.

5.2. Función de distribución empírica (ECDF)

La ECDF estima $F(x) = \mathbb{P}(X \leq x)$ sin suponer ninguna forma paramétrica:

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^{n} \mathbf{1}_{[X_i \leq x]}.$$

Si los datos se ordenan como $X_{(1)} \leq X_{(2)} \leq \cdots \leq X_{(n)}$, entonces $\hat{F}_n(X_{(i)}) = i/n$. El teorema de Glivenko–Cantelli garantiza $\sup_x |\hat{F}_n(x) - F(x)| \xrightarrow{c.s.} 0$. Superponer la ECDF con la CDF teórica $F(x; \hat{\theta})$ permite una inspección visual global del ajuste.

ECDF de los 15 tiempos vs. exponencial

Con $\hat{\lambda} = 1/\bar{x} = 0{,}452$, la CDF teórica es $F_0(x) = 1 - e^{-0{,}452\,x}$. Los primeros valores de comparación entre $\hat{F}_n(X_{(i)}) = i/n$ y $F_0(X_{(i)})$:

i	$X_{(i)}$	i/n	$F_0(X_{(i)})$	diferencia
1	0,70	0,067	0,271	−0,205
2	0,80	0,133	0,303	−0,170
3	0,90	0,200	0,334	−0,134
8	1,80	0,533	0,557	−0,023
15	5,60	1,000	0,920	+0,080

La ECDF sube *por encima* de F_0 en la parte central y queda *por debajo* en los extremos: hay menos valores pequeños y menos valores grandes de lo que la exponencial predice. Este patrón anticipa el resultado de las pruebas formales.

5.3. Gráfico Q-Q (cuantil–cuantil)

Compara los cuantiles empíricos con los cuantiles teóricos. Si el ajuste es correcto, los puntos se alinean en la recta $y = x$.

Construcción del gráfico Q-Q

1. Ordenar: $X_{(1)} \leq \cdots \leq X_{(n)}$.
2. Probabilidades de trazado: $p_i = (i - 0{,}5)/n$ (fórmula de Hazen).
3. Cuantiles teóricos: $q_i = F^{-1}(p_i; \hat{\theta})$.
4. Graficar $(q_i,\, X_{(i)})$; observar alineación con la diagonal.

Cálculo manual de un Q-Q exponencial con $n = 3$

Sea la muestra $\{2{,}1;\ 0{,}5;\ 1{,}2\}$ y la distribución teórica $\mathrm{Exp}(\lambda = 1)$. La inversa de la CDF es $q = -\ln(1 - p)$.

i	$x_{(i)}$	$p_i = (i - 0{,}5)/3$	$q_i = -\ln(1 - p_i)$
1	0,5	0,167	0,182
2	1,2	0,500	0,693
3	2,1	0,833	1,792

Los puntos a graficar son $(0{,}182;\ 0{,}5)$, $(0{,}693;\ 1{,}2)$ y $(1{,}792;\ 2{,}1)$, que se comparan con la recta $y = x$.

Patrones de desviación:

- Puntos *sobre* la diagonal en la cola derecha: datos con colas más pesadas que el modelo.
- Curvatura en "S": los datos son más simétricos o menos asimétricos que el modelo.
- Pendiente distinta de 1: parámetro de escala mal estimado.

Q-Q exponencial de los 15 tiempos del banco

Con $\hat{\lambda} = 0{,}452$ y $p_i = (i - 0{,}5)/15$:

i	$x_{(i)}$	p_i	$q_i = -\ln(1 - p_i)/0{,}452$
1	0,70	0,033	0,075
5	1,20	0,300	0,789
8	1,80	0,500	1,534
12	3,10	0,767	3,221
15	5,60	0,967	7,528

Graficados $(q_i, x_{(i)})$, los puntos muestran *curvatura en S*: en la cola izquierda quedan sobre la diagonal (el modelo predice valores más pequeños de los observados), en la cola derecha quedan por debajo (el modelo predice valores más grandes). Este patrón es consistente con CV < 1 y descarta la exponencial a favor de Erlang o Gamma.

6. Familias de distribuciones para sistemas de colas

6.1. Exponencial — base de referencia Markoviana

$X \sim \text{Exp}(\lambda)$: $f(x) = \lambda e^{-\lambda x}$, $\mathbb{E}[X] = 1/\lambda$, CV $= 1$.

Propiedad de ausencia de memoria: $\mathbb{P}(X > s + t \mid X > s) = \mathbb{P}(X > t)$. Esta propiedad hace que los sistemas con llegadas y servicios exponenciales sean CMTC, tractables analíticamente. Es el único justificativo para el modelo $M/M/c$.

Cuándo aparece

Tiempos entre llegadas a un centro de atención donde los clientes son independientes entre sí (proceso de Poisson). Si empíricamente CV ≈ 1 y además la prueba de rachas no rechaza independencia, la exponencial es la primera candidata.

6.2. Erlang-k — servicio en fases regulares

$X \sim E_k(\mu)$ es la suma de k exponenciales i.i.d. con tasa μ: $X = S_1 + \cdots + S_k$. $\mathbb{E}[X] = k/\mu$, $\mathrm{CV} = 1/\sqrt{k}$. A mayor k, menor variabilidad y, según Pollaczek–Khinchine, menor tiempo en cola.

Ventanilla bancaria: tres etapas

Un trámite consta de (1) saludo y consulta, (2) transacción, (3) despedida. Si cada etapa es exponencial con la misma tasa μ, el tiempo total sigue $E_3(\mu)$ con $\mathrm{CV} = 1/\sqrt{3} \approx 0{,}58$. Esto justifica por qué los datos del banco (con CV $\approx 0{,}63$) encajan en una Erlang-3 más que en una exponencial.

6.3. Hiperexponencial-k — mezcla de tipos de servicio

Se genera eligiendo exponencial i con probabilidad p_i y muestreando $X \sim \mathrm{Exp}(\lambda_i)$. Su densidad es:

$$f(x) = \sum_{i=1}^{k} p_i \lambda_i e^{-\lambda_i x}, \qquad \sum_{i=1}^{k} p_i = 1.$$

Siempre CV > 1 si los λ_i difieren. Adecuada para poblaciones heterogéneas.

Taller con reparaciones rápidas y complejas

En un taller, 80 % de las intervenciones son diagnósticos rápidos ($\lambda_1 = 2$/h, media 0,5 h) y 20 % son revisiones completas ($\lambda_2 = 0{,}2$/h, media 5 h). La hiperexponencial resultante tiene media $0{,}8 \cdot 0{,}5 + 0{,}2 \cdot 5 = 1{,}4$ h y CV > 1. Una sola exponencial no captura esta heterogeneidad.

6.4. Gamma

$X \sim \mathrm{Gamma}(\alpha, \beta)$: $\mathbb{E}[X] = \alpha/\beta$, $\mathrm{CV} = 1/\sqrt{\alpha}$. La Erlang-$k$ es un caso especial con $\alpha = k \in \mathbb{N}$. El parámetro α no requiere ser entero, lo que da mayor flexibilidad.

6.5. Weibull — tasa de falla no constante

$X \sim \mathrm{Weibull}(k, \lambda)$: $f(x) = \frac{k}{\lambda}\left(\frac{x}{\lambda}\right)^{k-1} e^{-(x/\lambda)^k}$. La tasa de falla (hazard) es $h(x) = \frac{k}{\lambda}(x/\lambda)^{k-1}$:

- $k < 1$: tasa decreciente (mortalidad infantil — equipos nuevos).
- $k = 1$: tasa constante (exponencial, Markoviano).
- $k > 1$: tasa creciente (desgaste — equipos envejecidos).

Reparaciones del taller: $k = 1{,}28$

Si el ajuste empírico de reparaciones arroja $\hat{k} = 1{,}28 > 1$, la tasa de falla es creciente: la probabilidad de que la reparación termine aumenta con el tiempo ya invertido. Físicamente: las reparaciones simples se terminan rápido; las complejas, una vez "trabadas", avanzan progresivamente hasta resolverse. Este valor de $\hat{k}$ es incompatible con una exponencial ($k = 1$).

6.6. Log-normal — fenómenos multiplicativos

$X \sim \text{LogNormal}(\mu, \sigma^2)$ si $\ln X \sim \mathcal{N}(\mu, \sigma^2)$. $\mathbb{E}[X] = e^{\mu+\sigma^2/2}$, $\text{CV} = \sqrt{e^{\sigma^2} - 1}$. Natural cuando el tiempo de servicio resulta de muchos factores multiplicativos (diagnóstico, negociación, resolución de incidencias), por aplicación del teorema central del límite a $\ln X$.

6.7. Tabla resumen y guía por coeficiente de variación

Distribución	**Soporte**	CV	**Tasa de falla**	**Uso típico**
Determinista (D)	$\{d\}$	0	—	Procesos automatizados
Erlang-k (E_k)	$(0, \infty)$	$1/\sqrt{k}$	Creciente	Servicio en etapas
Exponencial (M)	$(0, \infty)$	1	Constante	Baseline Markoviano
Gamma (α, β)	$(0, \infty)$	$1/\sqrt{\alpha}$	Flexible	Modelado general
Weibull (k, λ)	$(0, \infty)$	Variable	Flexible	Fallas, mantenimiento
Log-normal (μ, σ)	$(0, \infty)$	Variable	Unimodal	Actividades humanas
Hiperexponencial	$(0, \infty)$	> 1	Decreciente	Poblaciones mixtas

Guía rápida de selección por CV

- $\text{CV} = 0$: determinista.
- $0 < \text{CV} < 1$: Erlang-k (con $k \approx 1/\text{CV}^2$) o Gamma.
- $\text{CV} = 1$: exponencial (primera candidata) o Weibull con $k \approx 1$.
- $\text{CV} > 1$: hiperexponencial, Weibull con $k < 1$, o Log-normal.

7. Estimación de parámetros

7.1. Máxima verosimilitud (MLE)

Sea $x_1, \ldots, x_n$ una muestra i.i.d. con densidad $f(x; \theta)$. El estimador MLE es:

$$\hat{\theta} = \arg\max_{\theta} \ell(\theta), \qquad \ell(\theta) = \sum_{i=1}^{n} \ln f(x_i; \theta).$$

Los MLE son asintóticamente eficientes (mínima varianza) y consistentes.

Derivación para la exponencial. Sea $X_i \sim \text{Exp}(\lambda)$:

$$\ell(\lambda) = \sum_{i=1}^{n} \ln(\lambda e^{-\lambda x_i}) = n \ln \lambda - \lambda \sum_{i=1}^{n} x_i,$$
$$\frac{d\ell}{d\lambda} = \frac{n}{\lambda} - \sum_{i=1}^{n} x_i = 0 \quad \Rightarrow \quad \hat{\lambda} = \frac{1}{\bar{x}}.$$

La segunda derivada $-n/\lambda^2 < 0$ confirma que es un máximo; la varianza asintótica es $\text{Var}[\hat{\lambda}] \approx \lambda^2/n$, obtenida de la información de Fisher.

MLE exponencial sobre los 15 tiempos

$$\bar{x} = \frac{0{,}7 + 0{,}8 + \cdots + 5{,}6}{15} = 2{,}213 \quad \Rightarrow \quad \hat{\lambda} = \frac{1}{2{,}213} = 0{,}452 \text{ min}^{-1}.$$

MLE para distribuciones comunes:

Distribución	**MLE**	**Forma cerrada**
Exponencial(λ)	$\hat{\lambda} = 1/\bar{x}$	Sí
Normal(μ, σ^2)	$\hat{\mu} = \bar{x}$, $\hat{\sigma}^2 = S^2$	Sí
Log-normal(μ, σ^2)	$\hat{\mu} = \overline{\ln x}$, $\hat{\sigma}^2 = S^2_{\ln x}$	Sí
Gamma(α, β)	ec. transcendental en $\hat{\alpha}$ (digamma)	No
Weibull(k, λ)	sistema de ecuaciones no lineal	No

7.2. Método de momentos (MM)

Iguala los momentos muestrales $\bar{x}^{(r)} = n^{-1} \sum x_i^r$ con los momentos teóricos $\mathbb{E}[X^r]$.

Gamma: $\mathbb{E}[X] = \alpha/\beta$ y $\text{Var}[X] = \alpha/\beta^2$ implican $\hat{\alpha} = \bar{x}^2/s^2$ y $\hat{\beta} = \bar{x}/s^2$.

Weibull: $\hat{k}$ y $\hat{\lambda}$ se obtienen del sistema $\mathbb{E}[X] = \lambda\,\Gamma(1+1/k)$, $\text{Var}[X] = \lambda^2[\Gamma(1+2/k) - \Gamma^2(1+1/k)]$.

Estrategia práctica

Estimar siempre con MLE cuando sea factible; usar momentos como valor inicial de la optimización numérica. Si el soporte de los datos incluye cero o hay una masa puntual, considerar distribuciones mixtas o truncadas.

8. Pruebas de bondad de ajuste

Una vez ajustada la distribución, se verifica si los datos son estadísticamente consistentes con $H_0 : F = F_0(\cdot; \hat{\theta})$.

8.1. Prueba χ^2

Agrupa los datos en k celdas con frecuencias observadas O_j y esperadas $E_j = n[F_0(b_j) - F_0(a_j)]$:

$$\chi^2 = \sum_{j=1}^{k} \frac{(O_j - E_j)^2}{E_j} \xrightarrow{H_0} \chi^2_{k-1-p}$$

donde p es el número de parámetros estimados. Se rechaza H_0 si $\chi^2 > \chi^2_{\alpha,\, k-1-p}$.

Requisito: $E_j \geq 5$ en cada celda (fusionar celdas adyacentes si no se cumple).

χ^2 sobre los 15 tiempos del banco

Con $\hat{\lambda} = 0{,}452$ y $F_0(x) = 1 - e^{-0{,}452\,x}$, dividimos el soporte en tres intervalos de ancho fijo:

Intervalo	O_j	$p_j = F_0(b_j) - F_0(a_j)$	$E_j = 15 \cdot p_j$	$(O_j - E_j)^2/E_j$
$[0,\ 2)$	8	$F_0(2) - F_0(0) = 0{,}595$	8,92	0,096
$[2,\ 4)$	5	$F_0(4) - F_0(2) = 0{,}241$	3,62	0,531
$[4,\ \infty)$	2	$1 - F_0(4) = 0{,}164$	2,46	0,087
Total	15	1,000	15,00	$\boxed{0{,}713}$

Grados de libertad $\nu = k-1-p = 3-1-1 = 1$; valor crítico $\chi^2_{0{,}05,\,1} = 3{,}84$. Como $0{,}713 < 3{,}84$, **no se rechaza** la exponencial.

8.2. Prueba de Kolmogorov–Smirnov (KS)

Compara la ECDF con la CDF teórica:

$$D_n = \sup_x \left|\hat{F}_n(x) - F_0(x;\hat{\theta})\right| = \max_i \max\left(\frac{i}{n} - F_0(X_{(i)}),\ F_0(X_{(i)}) - \frac{i-1}{n}\right).$$

La prueba KS es más sensible que la χ^2 para distribuciones continuas. Los valores críticos estándar asumen que los parámetros de F_0 son conocidos; cuando se estiman de los datos la prueba es anticonservativa y convendría usar Lilliefors o Anderson–Darling.

KS sobre los 15 tiempos del banco — tabla completa

i	$X_{(i)}$	$F_0(X_{(i)})$	i/n	$(i-1)/n$	d_i^+	d_i^-
1	0,70	0,271	0,067	0,000	−0,205	**0,271**
2	0,80	0,303	0,133	0,067	−0,170	0,237
3	0,90	0,334	0,200	0,133	−0,134	0,201
4	1,10	0,392	0,267	0,200	−0,125	0,192
5	1,20	0,419	0,333	0,267	−0,085	0,152
6	1,50	0,492	0,400	0,333	−0,092	0,159
7	1,60	0,515	0,467	0,400	−0,048	0,115
8	1,80	0,557	0,533	0,467	−0,023	0,090
9	2,10	0,613	0,600	0,533	−0,013	0,080
10	2,40	0,662	0,667	0,600	+0,005	0,062
11	2,80	0,718	0,733	0,667	+0,016	0,051
12	3,10	0,754	0,800	0,733	+0,046	0,020
13	3,40	0,785	0,867	0,800	+0,082	−0,015
14	4,20	0,850	0,933	0,867	+0,083	−0,017
15	5,60	0,920	1,000	0,933	+0,080	−0,013

$D_n = 0{,}271$ (alcanzado en $i = 1$). Valor crítico de tabla KS para $n = 15$ y $\alpha = 0{,}05$: $D^*_{15;\,0{,}05} = 0{,}338$. Como $0{,}271 < 0{,}338$, **no se rechaza** la exponencial.

8.3. Prueba de Anderson–Darling (AD)

La prueba AD pondera las discrepancias en las colas, donde la χ^2 y la KS son menos sensibles:

$$A^2 = -n - \frac{1}{n}\sum_{i=1}^{n}(2i-1)\big[\ln F_0(X_{(i)}) + \ln(1 - F_0(X_{(n+1-i)}))\big].$$

El peso implícito es $1/[F_0(x)(1 - F_0(x))]$, que explota en las colas. Los valores críticos dependen de la distribución específica bajo H_0:

Distribución (parámetros estimados)	$\alpha = 0{,}10$	$\alpha = 0{,}05$	$\alpha = 0{,}01$
Exponencial ($\hat{\lambda}$)	1,06	1,32	1,96
Normal ($\hat{\mu}, \hat{\sigma}$)	0,63	0,75	1,04
Log-normal ($\hat{\mu}, \hat{\sigma}$)	0,63	0,75	1,04
Weibull ($\hat{k}, \hat{\lambda}$)	0,64	0,76	1,05

Anderson–Darling sobre los 15 tiempos — paso a paso

Para cada i calculamos $F_0(X_{(i)})$, $\ln F_0(X_{(i)})$ y $\ln\big(1 - F_0(X_{(n+1-i)})\big)$:

i	$X_{(i)}$	F_i	$X_{(n+1-i)}$	$1-F_{n+1-i}$	$\ln F_i$	$\ln(1-F_{n+1-i})$
1	0,70	0,271	5,60	0,080	−1,305	−2,530
2	0,80	0,303	4,20	0,150	−1,193	−1,898
3	0,90	0,334	3,40	0,215	−1,096	−1,536
4	1,10	0,392	3,10	0,246	−0,937	−1,401
5	1,20	0,419	2,80	0,282	−0,871	−1,265
6	1,50	0,492	2,40	0,338	−0,709	−1,084
7	1,60	0,515	2,10	0,387	−0,664	−0,949
8	1,80	0,557	1,80	0,443	−0,586	−0,813
9	2,10	0,613	1,60	0,485	−0,490	−0,723
10	2,40	0,662	1,50	0,508	−0,413	−0,678
11	2,80	0,718	1,20	0,581	−0,332	−0,542
12	3,10	0,754	1,10	0,608	−0,283	−0,497
13	3,40	0,785	0,90	0,666	−0,242	−0,407
14	4,20	0,850	0,80	0,696	−0,162	−0,361
15	5,60	0,920	0,70	0,729	−0,083	−0,316

Sumando los términos $(2i-1)/n \cdot [\ln F_i + \ln(1-F_{n+1-i})]$ se obtiene $S = -16{,}207$. Entonces

$$A^2 = -n - S = -15 - (-16{,}207) = 1{,}207.$$

Valor crítico para exponencial con parámetro estimado al 5 %: $A^{2*} = 1{,}32$. Como $1{,}207 < 1{,}32$, **no se rechaza** la exponencial, aunque marginalmente.

8.4. Interpretación del p-value

p-value

El p-value es la probabilidad de observar un estadístico de prueba al menos tan extremo como el observado, bajo H_0. **No** es la probabilidad de que H_0 sea verdadera.

- $p > 0{,}10$: no hay evidencia contra H_0; la distribución es consistente con los datos.
- $0{,}05 < p \leq 0{,}10$: evidencia débil contra H_0; verificar con gráficos.
- $p \leq 0{,}05$: rechazar H_0 al nivel 5 %.

¿Cuál prueba elegir?

La χ^2 es versátil (discreta y continua) y robusta con parámetros estimados, pero requiere celdas con $E_j \geq 5$. La KS es más poderosa para distribuciones continuas pero sus valores críticos estándar suponen parámetros conocidos. La AD es la más potente en las colas. Usar al menos dos pruebas como diagnóstico complementario; el gráfico Q-Q siempre como referencia visual.

Lo que aprendimos del banco pequeño

Las tres pruebas *no rechazan* la exponencial con $n = 15$: $\chi^2 = 0{,}71$ vs. 3,84; $D_n = 0{,}271$ vs. 0,338; $A^2 = 1{,}207$ vs. 1,32. Sin embargo, las tres están cerca del umbral y el coeficiente de variación $0{,}63 < 1$ junto con la curvatura en "S" del Q-Q plot advierten que con más datos probablemente se rechazará. **Con $n = 15$ ninguna prueba tiene suficiente potencia.**

9. Criterios de selección de modelos

Cuando varias distribuciones pasan las pruebas de bondad de ajuste, se necesitan criterios para elegir la mejor.

9.1. Criterio de información de Akaike (AIC)

$$\mathrm{AIC} = -2\,\ell(\hat{\theta}) + 2p,$$

donde $\ell(\hat{\theta})$ es la log-verosimilitud evaluada en el MLE y p es el número de parámetros. El AIC penaliza la complejidad del modelo: entre dos modelos que ajustan igualmente bien, se prefiere el más parsimonioso.

9.2. Criterio de información bayesiano (BIC)

$$\mathrm{BIC} = -2\,\ell(\hat{\theta}) + p \ln n.$$

El BIC penaliza más fuertemente la complejidad que el AIC cuando $n > 7$ (ya que $\ln n > 2$).

Uso de AIC/BIC

1. Ajustar todas las distribuciones candidatas con MLE.
2. Calcular AIC (o BIC) para cada una.
3. Seleccionar la distribución con el **menor** AIC (o BIC).
4. Si la diferencia $\Delta\mathrm{AIC} < 2$ entre dos modelos, ambos son estadísticamente indistinguibles; preferir el más simple o el más interpretable físicamente.

AIC en el banco completo ($n = 80$)

Tres candidatas ajustadas por MLE sobre 80 tiempos de servicio:

Distribución	**Parámetros**	$\ell(\hat{\theta})$	AIC
Exponencial	$\hat{\lambda} = 0{,}459$	$-148{,}3$	298,6
Erlang-3	$\hat{\mu}_f = 1{,}376$	$-137{,}1$	**276,2**
Gamma	$\hat{\alpha} = 2{,}65$, $\hat{\beta} = 1{,}22$	$-136{,}4$	276,8

La exponencial queda muy por detrás ($\Delta\text{AIC} > 20$). Entre Erlang-3 y Gamma, $\Delta\text{AIC} = 0{,}6 < 2$: son indistinguibles. Se elige la Erlang-3 por parsimonia (1 parámetro) y por su interpretación física (saludo, transacción, despedida).

10. Ejemplo integrador: banco completo

Sistema

Se amplía el estudio del banco. Durante una semana se registran 80 tiempos entre llegadas y 80 tiempos de servicio en la misma ventanilla. El objetivo es determinar las distribuciones de entrada para un modelo de simulación de la cola, identificando si el sistema es $M/M/1$, $M/G/1$ o $G/G/1$.

10.1. Tiempos entre llegadas

Estadísticos: $n_A = 80$, $\bar{A} = 3{,}2$ min, $s_A = 3{,}1$ min, $\text{CV}_A = 0{,}97$.

El CV cercano a 1 es consistente con la exponencial. La prueba de rachas arroja $R = 39$, $\mathbb{E}[R] = 41$, $Z = -0{,}4$ ($p = 0{,}69$): no se rechaza independencia. La autocorrelación lag-1 es $\hat{\rho}_1 = 0{,}04$, dentro del intervalo $\pm 2/\sqrt{80} = \pm 0{,}22$.

MLE: $\hat{\lambda} = 1/3{,}2 = 0{,}3125$ clientes/min.

Prueba KS: $D_{80} = 0{,}07 < D^*_{80;\,0{,}05} \approx 0{,}15$. **Anderson–Darling**: $A^2 = 0{,}41 < 1{,}32$. Ninguna rechaza.

Conclusión de llegadas: $A \sim \text{Exp}(0{,}3125)$, proceso de Poisson con $\lambda \approx 18{,}75$ clientes/h. Letra de llegada M.

10.2. Tiempos de servicio

Estadísticos: $n_S = 80$, $\bar{S} = 2{,}18$ min, $s_S = 1{,}34$ min, $\text{CV}_S = 0{,}61$.

El CV confirma lo observado en el banco pequeño. La guía por CV sugiere $k \approx 1/0{,}61^2 \approx 2{,}7$: Erlang-3 o Gamma. El ajuste por AIC (ver ejemplo de la sección anterior) elige **Erlang-3**.

10.3. Impacto en el modelo de colas

Con $\lambda = 0{,}3125$, $\mathbb{E}[S] = 2{,}18$, $\rho = 0{,}68$:

$$\mathbb{E}[S^2] = (0{,}61 \cdot 2{,}18)^2 + 2{,}18^2 = 1{,}77 + 4{,}75 = 6{,}52.$$

Modelo	**Fórmula**	W_q (min)
$M/M/1$ (si usáramos exponencial)	$\dfrac{\rho}{\mu(1-\rho)}$	4,63
$M/E_3/1$ (distribución correcta)	$\dfrac{\lambda\mathbb{E}[S^2]}{2(1-\rho)}$	3,18

Conclusión del banco completo

El sistema es $M/E_3/1$: llegadas Poisson ($\lambda = 0{,}3125$ cl/min) y servicio Erlang-3 ($\mathbb{E}[S] = 2{,}18$ min). Usar incorrectamente $M/M/1$ sobreestimaría el tiempo en cola en un **46 %** (4,63 vs. 3,18 min). Con $n = 80$ sí se logra discriminar; con $n = 15$ no.

11. Ejemplo escalado: taller de reparación de equipos industriales

Sistema

Un taller de mantenimiento atiende equipos industriales que llegan de diferentes líneas de producción. El gerente quiere determinar cuántos técnicos necesita. Durante dos semanas se registran 50 tiempos entre llegadas sucesivas y 50 tiempos de reparación. A diferencia del banco (servicio en etapas regulares), aquí las reparaciones son heterogéneas: algunas son diagnósticos rápidos y otras son revisiones completas.

11.1. Tiempos entre llegadas

$\bar{A} = 4{,}8$ h, $\mathrm{CV}_A = 0{,}96 \approx 1$, $\hat{\rho}_1 = 0{,}02$. La prueba KS con $\hat{\lambda} = 0{,}208\ \mathrm{h}^{-1}$ arroja $D_{50} = 0{,}08 < 0{,}19$, y $A^2 = 0{,}52 < 1{,}32$. No se rechaza Poisson por ninguna prueba.

Conclusión de llegadas: $A \sim \mathrm{Exp}(0{,}208)$, proceso de Poisson con $\lambda = 0{,}208$ equipos/h.

11.2. Tiempos de reparación

$\bar{S} = 3{,}6$ h, $\mathrm{CV}_S = 0{,}86$.

El histograma muestra asimetría pronunciada a la derecha con una cola pesada: la mayoría de reparaciones toman 1–4 horas, pero hay varias de 8–10 horas. El Q-Q exponencial exhibe puntos *sobre* la diagonal en la cola superior, indicando que la exponencial subestima las colas.

Cuatro candidatas ajustadas por MLE:

Distribución	**Parámetros MLE**	D_{50}	A^2	$\ell(\hat{\theta})$	**AIC**
Exponencial	$\hat{\lambda} = 0{,}278\ \mathrm{h}^{-1}$	0,13	1,85	−120,8	243,6
Gamma	$\hat{\alpha} = 1{,}42$, $\hat{\beta} = 0{,}39$	0,09	0,72	−117,1	238,2
Weibull	$\hat{k} = 1{,}28$, $\hat{\lambda}_W = 3{,}97$ h	0,06	0,35	−115,2	**234,4**
Log-normal	$\hat{\mu} = 1{,}05$, $\hat{\sigma} = 0{,}74$	0,08	0,54	−116,3	236,6

Análisis:

- Exponencial **rechazada** por AD ($1{,}85 > 1{,}32$) y marginalmente por KS.
- Gamma, Weibull y Log-normal pasan ambas pruebas.
- Weibull tiene el menor AIC (234,4); $\hat{k} = 1{,}28 > 1$ indica tasa de falla creciente, coherente con el proceso físico.

Conclusión de servicio: $S \sim \mathrm{Weibull}(1{,}28;\ 3{,}97)$ h.

11.3. Impacto en el modelo de colas

Con $\lambda = 0{,}208$, $\mathbb{E}[S] = 3{,}6$, $\rho = 0{,}75$:

$$\mathrm{Var}[S] = (0{,}86 \cdot 3{,}6)^2 = 9{,}59, \qquad \mathbb{E}[S^2] = 9{,}59 + 12{,}96 = 22{,}55.$$

Modelo	**Fórmula**	W_q
$M/M/1$ (servicio exponencial)	$\dfrac{\rho}{\mu(1-\rho)}$	10,8 h
$M/G/1$ (servicio Weibull)	$\dfrac{\lambda \mathbb{E}[S^2]}{2(1-\rho)}$	9,4 h

Usar $M/M/1$ sobreestimaría el tiempo en cola en un 15 %. El efecto es menor que en el banco porque $\mathrm{CV} = 0{,}86$ está cerca de 1.

Conclusión del taller

Sistema $M/G/1$ con llegadas Poisson ($\lambda = 0{,}208\ \mathrm{h}^{-1}$) y servicio Weibull ($k = 1{,}28$; $\lambda_W = 3{,}97$ h). La elección correcta reduce el error de predicción del tiempo de espera en $\approx 15\,\%$ respecto al supuesto Markoviano.

12. ¿Qué hacer cuando no hay datos?

En la práctica, frecuentemente no se dispone de datos suficientes. Estrategias alternativas:

- **Elicitación de expertos**: preguntar al operador o gerente por los valores mínimo (a), más

probable (m) y máximo (b) del proceso. Usar la distribución triangular $\mathrm{Tri}(a, m, b)$ o la PERT:

$$\mathbb{E}[X] = \frac{a + 4m + b}{6}, \qquad \mathrm{Var}[X] = \frac{(b-a)^2}{36}.$$

- **Valores de literatura**: publicaciones y benchmarks industriales proporcionan rangos típicos para tiempos de servicio, tasas de falla, etc.
- **Análisis de sensibilidad**: si la entrada es incierta, simular con varias distribuciones y parámetros plausibles para evaluar cuán sensible es la salida a la elección de entrada.
- **Distribución uniforme**: cuando sólo se conocen los límites $[a, b]$, la uniforme es la distribución de máxima entropía y la elección menos sesgada.

La triangular no es un sustituto permanente

La distribución triangular es útil para prototipos rápidos y análisis preliminares, pero no para el modelo final. Sus colas son lineales (no exponenciales), lo que la hace inadecuada para representar tiempos de servicio o falla realistas. Siempre buscar datos reales para el modelo definitivo.

13. ¿Qué hacer si ninguna distribución ajusta?

Si todas las distribuciones candidatas son rechazadas por las pruebas de bondad de ajuste:

1. **Verificar los datos**: ¿hay errores de registro, valores atípicos, o datos de periodos distintos mezclados?
2. **Considerar distribuciones mixtas**: si el histograma es bimodal, una mezcla de dos distribuciones puede ajustar: $f(x) = p\, f_1(x) + (1-p) f_2(x)$.
3. **Distribución empírica**: usar la ECDF directamente como entrada del simulador, muestreando con interpolación lineal. Esto sacrifica la generalización pero respeta los datos.
4. **Transformaciones**: si $\ln X$ se ajusta a una distribución conocida, usar esa transformación.

Referencias

[1] Law, A. M. (2015). *Simulation Modeling and Analysis*, 5th ed. McGraw-Hill. Cap. 6.

[2] Banks, J., Carson, J. S., Nelson, B. L. & Nicol, D. M. (2014). *Discrete-Event System Simulation*, 5th ed. Pearson. Cap. 9.

[3] Leemis, L. M. & Park, S. K. (2006). *Discrete-Event Simulation: A First Course*. Pearson. Cap. 6.

[4] D'Agostino, R. B. & Stephens, M. A. (1986). *Goodness-of-Fit Techniques*. Marcel Dekker.

[5] Kelton, W. D., Sadowski, R. P. & Zupick, N. B. (2015). *Simulation with Arena*, 6th ed. McGraw-Hill. Cap. 4.

[6] Ross, S. M. (2014). *Introduction to Probability Models*, 11th ed. Academic Press. Cap. 1–2.