Universidad de los Andes

Departamento de Ingeniería Industrial · Modelado de Sistemas bajo Incertidumbre

Análisis de Salida: Simulaciones Terminales

Alejandra Tabares Pozos

Índice

1. Taxonomía de simulaciones por horizonte temporal **2**

2. El problema estadístico de la salida de simulación **2**

3. Método de réplicas independientes **3**

4. Inferencia estadística con réplicas **3**

4.1. Estimación puntual . . . 3

4.2. Intervalo de confianza . . . 3

4.3. Precisión relativa . . . 3

5. Determinación del número de réplicas **4**

6. Sesgo de inicialización en simulaciones terminales **4**

7. Ejemplo básico: cola $M/G/1$ en una cafetería universitaria **5**

7.1. Ejecución del piloto ($n_0 = 15$ réplicas) . . . 5

7.2. Determinación de n^* para $\delta = 0{,}5$ min . . . 5

7.3. Interpretación . . . 6

8. Ejemplo escalado: urgencias hospitalarias (mañana) **6**

8.1. Configuración del estudio . . . 6

8.2. Piloto: $n_0 = 10$ réplicas . . . 7

8.3. Cálculo de n^* para cada métrica (objetivo: $r \leq 5\,\%$) . . . 7

8.4. Resultados con $n = 59$ réplicas . . . 7

1. Taxonomía de simulaciones por horizonte temporal

Toda simulación de eventos discretos opera bajo uno de dos regímenes:

Simulación terminal (horizonte finito)

El sistema opera durante un periodo bien definido que termina cuando ocurre un evento natural de cierre: fin del turno, cierre del banco, agotamiento del inventario. Las condiciones iniciales (p.ej. sistema vacío al abrir) son parte integral del modelo.

Simulación de estado estacionario (horizonte infinito)

El interés está en el comportamiento a largo plazo del sistema, independiente de las condiciones iniciales. No existe un evento de cierre natural. El problema central es el sesgo de inicialización, tratado en el Tema 3.4.

Ejemplos:

- **Terminal**: urgencias de 8h–20h, simulación de un día de bolsa, un turno de manufactura.
- **Estacionaria**: fábrica con producción continua 24/7, red de telecomunicaciones, central de llamadas permanente.

Error frecuente

Modelar un sistema con condiciones iniciales relevantes como si fuera estacionario puede introducir un sesgo grande. En una farmacia que abre con 0 clientes, las primeras horas del día son estadísticamente distintas de las del mediodía, y no deben promediarse con el largo plazo.

2. El problema estadístico de la salida de simulación

La salida de un simulador es una secuencia de observaciones $Y_1, Y_2, \ldots, Y_m$ (p.ej. tiempo de espera del cliente i). Estas observaciones tienen dos características que invalidan la estadística clásica:

1. **Autocorrelación**: el tiempo de espera del cliente $i+1$ depende del estado del sistema después de que el cliente i es atendido. Las observaciones *no son independientes*.
2. **No-estacionariedad**: al inicio, el sistema está vacío; la distribución de Y_i cambia con i.

Por estas razones, el promedio muestral $\bar{Y}_m = m^{-1} \sum_{i=1}^{m} Y_i$ de una única corrida *no* puede tratarse como si viniera de m observaciones i.i.d., y la fórmula estándar $S/\sqrt{m}$ subestima el error estándar real.

Solución: el **método de réplicas independientes**, que genera independencia entre corridas a través de diferentes semillas del generador de números aleatorios.

3. Método de réplicas independientes

Se ejecutan n réplicas de la simulación bajo el *mismo* modelo pero con *diferentes* semillas. Cada réplica produce un único número resumen Y_j de la métrica de interés (p.ej. el promedio de los tiempos de espera en esa corrida).

$$Y_j = \frac{1}{m_j} \sum_{i=1}^{m_j} W_i^{(j)}, \qquad j = 1, \ldots, n$$

donde m_j es el número de observaciones en la réplica j (clientes atendidos en ese turno).

Clave: $Y_1, Y_2, \ldots, Y_n$ *sí son* i.i.d. porque las réplicas son independientes entre sí. El análisis estadístico clásico (media, varianza, t-student) es aplicable sobre $\{Y_j\}$.

4. Inferencia estadística con réplicas

4.1. Estimación puntual

$$\hat{\theta}_n = \bar{Y}_n = \frac{1}{n} \sum_{j=1}^{n} Y_j$$

Por el TLC, $\bar{Y}_n \xrightarrow{d} \mathcal{N}(\theta, \sigma^2/n)$ cuando n es suficientemente grande.

4.2. Intervalo de confianza

Con varianza desconocida, se usa la distribución t de Student:

$$\boxed{IC_{1-\alpha}(\theta) = \bar{Y}_n \ \pm \ t_{\alpha/2,\, n-1} \cdot \frac{S_n}{\sqrt{n}}}$$

donde $S_n^2 = \frac{1}{n-1} \sum_{j=1}^{n} (Y_j - \bar{Y}_n)^2$ y la **semiancho** es $h_n = t_{\alpha/2, n-1} \cdot S_n/\sqrt{n}$.

Para $n \geq 30$ puede usarse el cuantil normal $z_{\alpha/2}$; para $n < 30$, la t_{n-1} es imprescindible.

4.3. Precisión relativa

La precisión relativa del estimador es:

$$r_n = \frac{h_n}{|\bar{Y}_n|} = \frac{t_{\alpha/2, n-1} \cdot S_n}{\sqrt{n}\, |\bar{Y}_n|}$$

Se suele reportar como porcentaje; un objetivo de $r_n \leq 0{,}05$ (5 %) es común en estudios de ingeniería.

5. Determinación del número de réplicas

El número mínimo de réplicas para lograr un semiancho δ (error absoluto) se estima en dos etapas:

Procedimiento secuencial para n^*

1. Ejecutar un **piloto** de $n_0 \geq 10$ réplicas y calcular $S_{n_0}^2$.
2. Estimar: $n^* = \text{máx}\left(n_0, \left\lceil \frac{t^2_{\alpha/2,\, n_0-1} \cdot S^2_{n_0}}{\delta^2} \right\rceil\right)$.
3. Ejecutar $n^* - n_0$ réplicas adicionales y recalcular $\bar{Y}_{n^*}$ y h_{n^*}.
4. Verificar que $h_{n^*} \leq \delta$ (si no, repetir desde el paso 2 con $n_0 \leftarrow n^*$).

Para un criterio de **precisión relativa** r, se sustituye $\delta = r\,|\bar{Y}_{n_0}|$:

$$n^* = \left\lceil \frac{t^2_{\alpha/2, n_0-1} \cdot S^2_{n_0}}{r^2 \cdot \bar{Y}^2_{n_0}} \right\rceil$$

6. Sesgo de inicialización en simulaciones terminales

En muchas simulaciones terminales, las condiciones iniciales son parte del modelo: una farmacia abre con 0 clientes, un almacén inicia el turno con 0 órdenes pendientes. No hay sesgo de inicialización *si esas condiciones son las condiciones reales de inicio del sistema.*

Sin embargo, en algunos casos el sistema puede comenzar en un estado que *no* es el estado inicial real (por ejemplo, si se simula el pico de la tarde pero el sistema ya tiene clientes acumulados desde la mañana). En ese caso:

- **Opción 1 — Warm-up manual**: hacer correr el modelo hasta que el estado inicial deseado se logre, y luego empezar a recoger estadísticas.
- **Opción 2 — Estado inicial condicionado**: muestrear el estado inicial de una distribución estacionaria (si se conoce).
- **Opción 3 — Modelo extendido**: simular desde el inicio del día completo si el horizonte lo permite.

Distinción con estacionario

En simulaciones terminales, el problema de sesgo inicial es conceptualmente distinto al de las simulaciones de estado estacionario (Tema 3.4). En la terminal, la condición inicial es parte del problema; en la estacionaria, es un artefacto que hay que eliminar.

7. Ejemplo básico: cola $M/G/1$ en una cafetería universitaria

Sistema

La cafetería universitaria opera el turno de almuerzo de 12:00 a 14:00 (2 horas). Los clientes llegan según un proceso de Poisson con $\lambda = 15$ clientes/h. El tiempo de atención (pedir + pagar) sigue una distribución Erlang-2 con $\mathbb{E}[S] = 3$ min. El sistema inicia cada réplica vacío. Interesa estimar el tiempo promedio de espera en cola W_q con 95 % de confianza y precisión de 0,5 min.

Parámetros y referencia analítica:

$$\lambda = \frac{15}{60} = 0{,}25 \text{ cl/min}, \quad \mathbb{E}[S] = 3 \text{ min}, \quad \mu_{\text{fase}} = \frac{2}{3} \text{ fase/min}$$

$$\text{Var}[S] = \frac{2}{\mu_{\text{fase}}^2} = \frac{2}{(2/3)^2} = 4{,}5 \text{ min}^2, \quad \mathbb{E}[S^2] = 4{,}5 + 9 = 13{,}5 \text{ min}^2$$

$$\rho = 0{,}25 \times 3 = 0{,}75$$

Referencia P-K (útil para validación del simulador, no para reemplazarlo):

$$W_q^{\text{P-K}} = \frac{\lambda \mathbb{E}[S^2]}{2(1-\rho)} = \frac{0{,}25 \times 13{,}5}{2 \times 0{,}25} = \frac{3{,}375}{0{,}5} = 6{,}75 \text{ min}$$

7.1. Ejecución del piloto ($n_0 = 15$ réplicas)

Cada réplica simula las 2 horas de turno. El resumen Y_j es el tiempo promedio en cola de todos los clientes atendidos en esa réplica.

j	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
Y_j	7,1	5,8	6,4	8,3	6,0	7,5	5,4	6,9	7,8	6,2	5,9	8,1	6,7	7,3	6,5

$$\bar{Y}_{15} = 6{,}79 \text{ min}, \quad S_{15} = 0{,}85 \text{ min}$$

IC 95 % con $t_{0{,}025,14} = 2{,}145$:

$$h_{15} = 2{,}145 \times \frac{0{,}85}{\sqrt{15}} = 2{,}145 \times 0{,}219 = 0{,}47 \text{ min}$$

$$IC_{95\,\%}: \quad [6{,}32;\ 7{,}26] \text{ min}$$

7.2. Determinación de n^* para $\delta = 0{,}5$ min

$$n^* = \left\lceil \frac{(2{,}145)^2 \times (0{,}85)^2}{(0{,}5)^2} \right\rceil = \left\lceil \frac{4{,}60 \times 0{,}72}{0{,}25} \right\rceil = \lceil 13{,}2 \rceil = 14$$

Como $14 < n_0 = 15$, las réplicas del piloto son suficientes. El semiancho de 0,47 min ya cumple el criterio $\leq 0{,}5$ min.

7.3. Interpretación

Resultado

Con 15 réplicas del turno de almuerzo, el tiempo promedio de espera en cola se estima en $\bar{W}_q = 6{,}79$ min con IC 95 % [6,32; 7,26] min (semiancho 0,47 min $<$ 0,5 min). El valor analítico P-K de 6,75 min cae dentro del intervalo, confirmando la validez del simulador.

Variabilidad entre réplicas y distribución del turno

Nótese que Y_j varía entre 5,4 y 8,3 min, un rango considerable. Esta variabilidad es real: depende de la secuencia aleatoria de llegadas y tiempos de servicio en cada turno. El intervalo de confianza cuantifica esta incertidumbre; no es un error del simulador.

8. Ejemplo escalado: urgencias hospitalarias (mañana)

Sistema

El servicio de urgencias de un hospital opera el turno de mañana (7:00–15:00, 8 horas). Los pacientes se clasifican en tres niveles de prioridad al triaje. El sistema tiene 3 médicos (*recursos*), una sala de espera común y una cola con prioridad no expulsiva (non-preemptive). Las distribuciones de servicio son **no exponenciales**.

Nivel	**Fracción**	**Distribución de S**	$\mathbb{E}[S]$ (min)	CV_S
P1 (urgente)	15 %	Exponencial($\mu = 0{,}1$)	10	1,00
P2 (moderado)	55 %	Erlang-3($\mu_f = 0{,}1$)	30	0,58
P3 (leve)	30 %	Log-normal($\mu_L = 3{,}4$, $\sigma_L = 0{,}5$)	35	0,53

Llegadas totales: Poisson con $\lambda = 20$ pacientes/h. El sistema inicia vacío. Interesa estimar tres métricas con 95 % de confianza y precisión relativa ≤ 5 %:

1. W_q^{P2}: tiempo de espera promedio de pacientes P2.
2. $P(W_q > 30 \text{ min} \mid P3)$: fracción de pacientes leves con espera > 30 min.
3. ρ: utilización promedio de los médicos.

8.1. Configuración del estudio

Tráfico del sistema. La tasa de llegadas efectiva de cada tipo y su aporte a la carga:

$$\lambda_{P1} = 0{,}15 \times 20 = 3{,}0 \text{ pac/h}, \qquad \text{carga}_{P1} = 3{,}0 \times \tfrac{10}{60} = 0{,}50$$
$$\lambda_{P2} = 0{,}55 \times 20 = 11{,}0 \text{ pac/h}, \qquad \text{carga}_{P2} = 11{,}0 \times \tfrac{30}{60} = 5{,}50$$
$$\lambda_{P3} = 0{,}30 \times 20 = 6{,}0 \text{ pac/h}, \qquad \text{carga}_{P3} = 6{,}0 \times \tfrac{35}{60} = 3{,}50$$

Carga total $= 0{,}50 + 5{,}50 + 3{,}50 = 9{,}50$ pac·médico^{-1}h^{-1}, con 3 médicos: $\rho = 9{,}50/(3 \times 60) \approx 0{,}79$.

8.2. Piloto: $n_0 = 10$ réplicas

Cada réplica simula el turno completo de 8 horas. Resultados del piloto:

Métrica	$\bar{Y}_{10}$	S_{10}	$\hat{r}_{10}$ (%)
W_q^{P2} (min)	28,4	4,7	5,2 %
$P(W_q > 30\text{min} \mid P3)$	0,342	0,058	5,3 %
ρ	0,787	0,018	0,7 %

8.3. Cálculo de n^* para cada métrica (objetivo: $r \leq 5\,\%$)

$$n^*_{W_q^{P2}} = \left\lceil \frac{(2{,}262)^2 \times (4{,}7)^2}{(0{,}05 \times 28{,}4)^2} \right\rceil = \left\lceil \frac{112{,}9}{2{,}02} \right\rceil = \lceil 55{,}9 \rceil = 56$$

$$n^*_{P(W>30)} = \left\lceil \frac{(2{,}262)^2 \times (0{,}058)^2}{(0{,}05 \times 0{,}342)^2} \right\rceil = \left\lceil \frac{0{,}01723}{0{,}000292} \right\rceil = \lceil 59{,}0 \rceil = 59$$

La métrica más exigente es $P(W_q > 30 \text{ min} \mid P3)$; se necesitan $n^* = 59$ réplicas para todas las métricas.

8.4. Resultados con $n = 59$ réplicas

Métrica	$\bar{Y}_{59}$	IC 95 %	r (%)	**Interpretación**
W_q^{P2} (min)	29,1	[27,9; 30,3]	4,1 %	Espera media: ∼29 min
$P(W_q > 30 \text{ min} \mid P3)$	0,348	[0,331; 0,365]	4,9 %	35 % de P3 esperan >30 min
ρ	0,789	[0,784; 0,794]	0,3 %	Utilización 78,9 %

Conclusiones del estudio terminal

En el turno de mañana, aproximadamente 1 de cada 3 pacientes de nivel P3 espera más de 30 minutos. La utilización del médico del 79 % indica un sistema cercano a la saturación; pequeños incrementos en la demanda (λ) pueden disparar los tiempos de espera de manera no lineal. Este

estudio cuantifica el riesgo de incumplir el objetivo de servicio y provee la base para evaluar la contratación de un cuarto médico (comparación de alternativas, Tema 3.4).

No-Markovianidad y análisis de salida

El sistema de urgencias modela servicios con distribuciones Erlang-3 y Log-normal, ambas no exponenciales. No existe solución analítica exacta para la distribución del tiempo de espera ni para $P(W_q > 30 \text{ min})$ bajo prioridades no expulsivas con múltiples servidores y distribuciones mixtas. La simulación es la única herramienta de análisis que permite estimar estas métricas con intervalos de confianza.