Cadenas de Markov de Tiempo Continuo

Modelado de Sistemas bajo Incertidumbre

Alejandra Tabares Pozos
Universidad de los Andes
Departamento de Ingeniería Industrial

Contenido

Metodología de modelamiento

Escenario 1: Cola M/M/1 (una variable)

Escenario 2: Cola M/M/1/K (capacidad finita)

Escenario 3: Cola M/M/c (múltiples servidores)

Escenario 4: Modelo de reparación de máquinas (dos variables)

Escenario 5: Red de colas con dos estaciones (dos variables)

Del modelo explícito al implícito

Síntesis y ejercicio propuesto

Objetivo de la sesión

Meta

Dada una **descripción textual** de un sistema estocástico, construir sistemáticamente su modelo como **Cadena de Markov de Tiempo Continuo** (CTMC).

Pasos del proceso:

1. Identificar las **variables aleatorias** relevantes.
2. Definir el **espacio de estados** de cada variable.
3. Construir la **variable de estado conjunta** y su espacio.
4. Identificar las **transiciones posibles** y sus tasas.
5. Ensamblar la **matriz generadora** Q.

Progresión

Avanzaremos de escenarios simples (una variable) a escenarios complejos (dos variables), y de matrices **explícitas** a representaciones **implícitas**.

Definición

Un proceso estocástico $\{X(t), t \geq 0\}$ con espacio de estados $\mathcal{S}$ finito o numerable es una CTMC si:

$$\mathbb{P}\big(X(t+h) = j \mid X(t) = i,\ X(s),\ 0 \leq s < t\big) = \mathbb{P}\big(X(t+h) = j \mid X(t) = i\big)$$

La **matriz generadora** (o de tasas) $\mathrm{Q} = [q_{ij}]$ satisface:

$$q_{ij} \geq 0 \quad (i \neq j), \qquad q_{ii} = -\sum_{j \neq i} q_{ij}$$

Interpretación:

- q_{ij} $(i \neq j)$: tasa de transición del estado i al estado j.
- $|q_{ii}|$: tasa total de salida del estado i.
- Tiempo de permanencia en i: $\mathrm{Exp}(|q_{ii}|)$.

Proceso de modelamiento – Diagrama

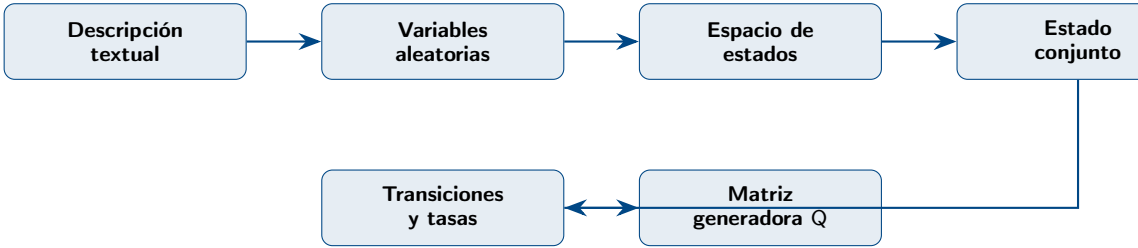

Descripción del sistema

Un pequeño restaurante tiene **un solo cajero**. Los clientes llegan de forma aleatoria con una tasa promedio de $\lambda = 3$ clientes por minuto. El cajero atiende a cada cliente en un tiempo aleatorio con tasa promedio de $\mu = 5$ clientes por minuto. Los clientes que llegan y encuentran al cajero ocupado esperan en una **fila sin límite** de capacidad. Se desea modelar la dinámica del número de clientes en el sistema.

Preguntas guía:

- ¿Qué cantidad cambia aleatoriamente en el tiempo?
- ¿Qué valores puede tomar?
- ¿Qué eventos provocan cambios y con qué tasas?

Identificación

La única cantidad que evoluciona aleatoriamente es:

$$N(t) = \text{número de clientes en el sistema en el instante } t$$

¿Por qué una sola variable?

- Solo hay un servidor $\Rightarrow$ su estado (ocupado/libre) queda determinado por $N(t)$:
  - $N(t) = 0 \Rightarrow$ servidor libre.
  - $N(t) \geq 1 \Rightarrow$ servidor ocupado.
- No necesitamos una variable adicional para el servidor.

Espacio de estados de $N(t)$

$$\mathcal{S}_N = \{0, 1, 2, 3, \ldots\} = \mathbb{N}_0$$

No hay límite superior (cola infinita).

Como solo hay **una variable**, el estado conjunto coincide:

$$\mathcal{S} = \mathcal{S}_N = \mathbb{N}_0$$

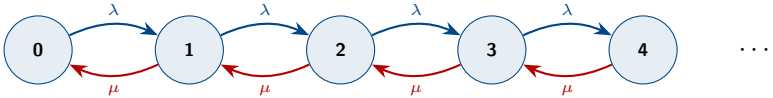

Proceso de **nacimiento y muerte**: transiciones solo entre estados adyacentes.

Eventos posibles desde el estado n:

- **Llegada** (nacimiento): $n \to n+1$ con tasa λ.
- **Servicio** (muerte): $n \to n-1$ con tasa μ (solo si $n \geq 1$).

Matriz generadora (forma explícita):

$$Q = \begin{pmatrix} -\lambda & \lambda & 0 & 0 & \cdots \\ \mu & -(\lambda+\mu) & \lambda & 0 & \cdots \\ 0 & \mu & -(\lambda+\mu) & \lambda & \cdots \\ 0 & 0 & \mu & -(\lambda+\mu) & \cdots \\ \vdots & \vdots & \vdots & \vdots & \ddots \end{pmatrix}$$

Forma implícita (como función de índices):

$$q_{n,n+1} = \lambda, \qquad q_{n,n-1} = \mu\, \mathbb{1}(n \geq 1), \qquad q_{nn} = -\lambda - \mu\, \mathbb{1}(n \geq 1)$$

Escenario 1 – Resumen del modelo

Elemento	Resultado
Variable aleatoria	$N(t)$: clientes en el sistema
Espacio de estados	$\mathcal{S} = \{0, 1, 2, \ldots\}$
Parámetros	$\lambda = 3$, $\mu = 5$
Tipo	Proceso nacimiento–muerte (M/M/1)
Transiciones	$q_{n,n+1} = \lambda, \quad q_{n,n-1} = \mu \mathbb{1}(n \geq 1)$

Observación clave

En la cola M/M/1 las tasas de nacimiento y muerte son **constantes** e independientes del estado (salvo que no hay muertes en el estado 0). Esto la hace el caso más simple de proceso nacimiento–muerte.

Descripción del sistema

Una pequeña clínica dental tiene **un dentista** y una **sala de espera con 3 sillas** (capacidad total $K = 4$, incluyendo el paciente en atención). Los pacientes llegan con tasa $\lambda = 2$ pacientes/hora. El dentista atiende con tasa $\mu = 3$ pacientes/hora. Si un paciente llega y el sistema está lleno (K pacientes), **se va y no regresa**.

¿Qué cambia respecto al Escenario 1?

- El espacio de estados ahora es **finito**.
- Las llegadas se "bloquean" cuando el sistema está lleno.
- La matriz Q es de dimensión finita $(K + 1) \times (K + 1)$.

Variable y espacio:

$$N(t) \in \mathcal{S} = \{0, 1, 2, 3, 4\}$$

Transiciones:

$$\begin{aligned} q_{n,n+1} &= \lambda \cdot \mathbb{1}(n < K) \\ q_{n,n-1} &= \mu \cdot \mathbb{1}(n \geq 1) \\ q_{nn} &= -(q_{n,n+1} + q_{n,n-1}) \end{aligned}$$

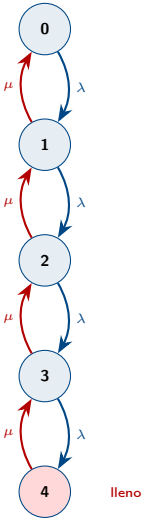

Con $K = 4$, $\lambda = 2$, $\mu = 3$:

$$Q = \begin{pmatrix} -2 & 2 & 0 & 0 & 0 \\ 3 & -5 & 2 & 0 & 0 \\ 0 & 3 & -5 & 2 & 0 \\ 0 & 0 & 3 & -5 & 2 \\ 0 & 0 & 0 & 3 & -3 \end{pmatrix}$$

Comparación con M/M/1

- La última fila refleja que en el estado $K = 4$ **no hay llegadas** ($q_{4,5}$ no existe).
- La primera fila refleja que en el estado 0 **no hay servicio**.
- Las filas intermedias son idénticas a la M/M/1.

Descripción del sistema

Un centro de llamadas tiene $c = 3$ operadores idénticos. Las llamadas llegan con tasa $\lambda = 10$ llamadas/minuto. Cada operador resuelve una llamada con tasa $\mu = 4$ llamadas/minuto. Si todos los operadores están ocupados, las llamadas esperan en una cola (sin límite). Se quiere modelar el número total de llamadas en el sistema.

Novedad: la tasa de servicio total **depende del estado**:

- Si $n \leq c$: hay n operadores activos $\Rightarrow$ tasa de servicio $= n\mu$.
- Si $n > c$: los c operadores están activos $\Rightarrow$ tasa de servicio $= c\mu$.

Variable: $N(t)$ = llamadas en el sistema. $\mathcal{S} = \{0, 1, 2, \ldots\}$.

Tasas dependientes del estado:

$$\lambda_n = \lambda \quad \forall\, n, \qquad \mu_n = \text{mín}(n, c) \cdot \mu$$

Forma implícita de Q**:**

$$q_{n,n+1} = \lambda, \qquad q_{n,n-1} = \text{mín}(n, c) \cdot \mu, \qquad q_{nn} = -\lambda - \text{mín}(n, c) \cdot \mu$$

Matriz explícita (primeras filas, $c = 3$, $\mu = 4$, $\lambda = 10$):

$$\mathrm{Q} = \begin{pmatrix} -10 & 10 & 0 & 0 & 0 & \cdots \\ 4 & -14 & 10 & 0 & 0 & \cdots \\ 0 & 8 & -18 & 10 & 0 & \cdots \\ 0 & 0 & 12 & -22 & 10 & \cdots \\ 0 & 0 & 0 & 12 & -22 & \cdots \\ \vdots & & & & & \ddots \end{pmatrix}$$

Nota: a partir de la fila $n = c = 3$ la tasa de muerte se estabiliza en $c\mu = 12$.

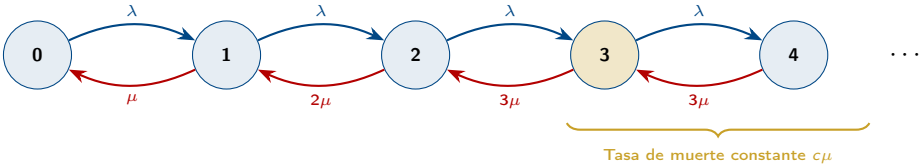

Lectura clave

Es un proceso nacimiento–muerte con tasas de muerte **dependientes del estado**. La tasa de muerte crece linealmente hasta $n = c$ y luego se satura.

Descripción del sistema

Una fábrica tiene $M = 2$ máquinas idénticas y $R = 1$ técnico de reparación. Cada máquina funciona independientemente hasta que falla; el tiempo hasta la falla es exponencial con tasa $\alpha = 0.5$ fallas/hora. Cuando una máquina falla, el técnico la repara con tasa $\beta = 2$ reparaciones/hora. Si ambas máquinas están dañadas, el técnico repara **una a la vez**. Se quiere modelar la dinámica del sistema.

¿Una o dos variables?

Aquí podríamos usar **una sola variable** ($F(t) =$ número de máquinas dañadas, $\mathcal{S} = \{0, 1, 2\}$) porque las máquinas son idénticas. Pero primero lo modelaremos con **dos variables** para ilustrar el método general, y luego mostraremos la reducción.

Definimos el estado de cada máquina individualmente:

$$X_i(t) = \begin{cases} 0 & \text{máquina } i \text{ funcionando} \\ 1 & \text{máquina } i \text{ dañada} \end{cases}, \quad i = 1, 2$$

Espacios individuales:

$$\mathcal{S}_{X_1} = \mathcal{S}_{X_2} = \{0, 1\}$$

Variable de estado conjunta:

$$\boldsymbol{X}(t) = \big(X_1(t),\, X_2(t)\big)$$

Espacio de estados conjunto:

$$\mathcal{S} = \mathcal{S}_{X_1} \times \mathcal{S}_{X_2} = \{(0,0),\ (0,1),\ (1,0),\ (1,1)\}$$

$|\mathcal{S}| = 4$ estados.

Desde cada estado, ¿qué eventos pueden ocurrir?

Estado	Destino	Evento	Tasa
$(0,0)$	$(1,0)$	Máquina 1 falla	α
$(0,0)$	$(0,1)$	Máquina 2 falla	α
$(1,0)$	$(0,0)$	Reparan máquina 1	β
$(1,0)$	$(1,1)$	Máquina 2 falla	α
$(0,1)$	$(0,0)$	Reparan máquina 2	β
$(0,1)$	$(1,1)$	Máquina 1 falla	α
$(1,1)$	$(0,1)$	Reparan máquina 1	$\beta/1^*$
$(1,1)$	$(1,0)$	Reparan máquina 2	–

*Con un solo técnico y máquinas idénticas, desde $(1,1)$ la reparación ocurre con tasa β y puede ir a $(0,1)$ o $(1,0)$ con igual probabilidad: tasa $\beta/2$ a cada una.

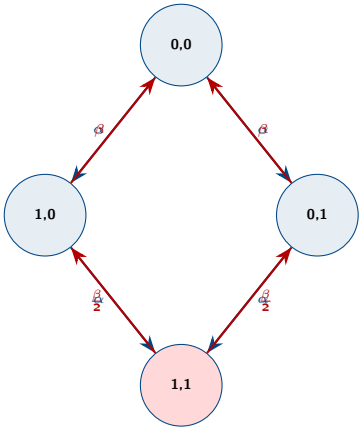

Orden de estados: $(0,0), (0,1), (1,0), (1,1)$.

$$Q = \begin{pmatrix} -2\alpha & \alpha & \alpha & 0 \\ \beta & -(\alpha+\beta) & 0 & \alpha \\ \beta & 0 & -(\alpha+\beta) & \alpha \\ 0 & \frac{\beta}{2} & \frac{\beta}{2} & -\beta \end{pmatrix}$$

Con $\alpha = 0.5$, $\beta = 2$:

$$Q = \begin{pmatrix} -1 & 0.5 & 0.5 & 0 \\ 2 & -2.5 & 0 & 0.5 \\ 2 & 0 & -2.5 & 0.5 \\ 0 & 1 & 1 & -2 \end{pmatrix}$$

Observación

Como las máquinas son **idénticas e intercambiables**, los estados $(1,0)$ y $(0,1)$ son equivalentes. Podemos agregar:

$$F(t) = X_1(t) + X_2(t) = \text{número de máquinas dañadas}$$

$\mathcal{S}_F = \{0,1,2\}$ con tasas:

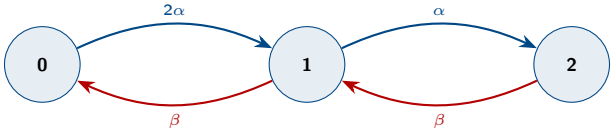

$$Q_{\text{reducida}} = \begin{pmatrix} -2\alpha & 2\alpha & 0 \\ \beta & -(\alpha+\beta) & \alpha \\ 0 & \beta & -\beta \end{pmatrix} = \begin{pmatrix} -1 & 1 & 0 \\ 2 & -2.5 & 0.5 \\ 0 & 2 & -2 \end{pmatrix}$$

Tasa de falla en estado f: $(M-f)\alpha$ (máquinas funcionando). Tasa reparación: $\text{mín}(f,R)\beta$.

Modelo general: M máquinas, R técnicos

Variable reducida: $F(t)$ = máquinas dañadas, $\mathcal{S} = \{0, 1, \ldots, M\}$.

Tasas como función del estado f:

$$\lambda_f = (M - f)\,\alpha \qquad \text{(tasa de falla: máquinas operativas)}$$
$$\mu_f = \text{mín}(f, R)\,\beta \qquad \text{(tasa de reparación: técnicos activos)}$$

Matriz generadora implícita:

$$\boxed{q_{f,f+1} = (M - f)\alpha, \quad q_{f,f-1} = \text{mín}(f, R)\,\beta, \quad q_{ff} = -\big[(M - f)\alpha + \text{mín}(f, R)\beta\big]}$$

Ventaja del modelo implícito

Con una sola fórmula cubrimos cualquier combinación de M y R sin escribir la matriz elemento por elemento. Es fácilmente programable.

Descripción del sistema

Un taller de reparación de bicicletas tiene **dos estaciones** en serie:

- **Estación A** (diagnóstico): 1 técnico, tasa de servicio $\mu_A = 4$/hora.
- **Estación B** (reparación): 1 técnico, tasa de servicio $\mu_B = 3$/hora.

Las bicicletas llegan con tasa $\lambda = 2$/hora. Tras completar la estación A, pasan a la B. Cada estación tiene espacio para **máximo 2 bicicletas** (incluyendo la que está en servicio). Si la estación A está llena, las bicicletas no entran. Si la estación B está llena, la bicicleta terminada en A **espera bloqueando** la estación A.

Ahora necesitamos obligatoriamente dos variables: el número de bicicletas en cada estación no se puede reducir a una sola variable porque las tasas de transición dependen del estado de *ambas* estaciones.

Variables aleatorias:

$$N_A(t) = \text{bicicletas en estación A}, \qquad N_B(t) = \text{bicicletas en estación B}$$

Espacios individuales:

$$\mathcal{S}_{N_A} = \{0, 1, 2\}, \qquad \mathcal{S}_{N_B} = \{0, 1, 2\}$$

Estado conjunto:

$$\boldsymbol{X}(t) = \big(N_A(t),\, N_B(t)\big), \qquad \mathcal{S} = \mathcal{S}_{N_A} \times \mathcal{S}_{N_B}$$

$$\mathcal{S} = \{(0,0),\ (0,1),\ (0,2),\ (1,0),\ (1,1),\ (1,2),\ (2,0),\ (2,1),\ (2,2)\}$$

$|\mathcal{S}| = 9$ estados.

Desde el estado (a, b), tres tipos de eventos:

Evento	Destino	Tasa	Condición
Llegada externa	$(a{+}1, b)$	λ	$a < 2$
Servicio en A (pasa a B)	$(a{-}1, b{+}1)$	μ_A	$a \geq 1$ y $b < 2$ (B no está llena)
Servicio en B (sale del sistema)	$(a, b{-}1)$	μ_B	$b \geq 1$

Bloqueo

Si $b = 2$ (estación B llena), la estación A **no puede despachar** bicicletas aunque tenga. Esto acopla las dos variables: la tasa de transición depende de *ambos* componentes del estado.

Tasas como funciones de los subíndices (a, b):

$$
\begin{aligned}
q_{(a,b),\,(a+1,b)} &= \lambda \cdot \mathbb{1}(a < 2) \\
q_{(a,b),\,(a-1,b+1)} &= \mu_A \cdot \mathbb{1}(a \geq 1) \cdot \mathbb{1}(b < 2) \\
q_{(a,b),\,(a,b-1)} &= \mu_B \cdot \mathbb{1}(b \geq 1) \\
q_{(a,b),(a,b)} &= -\left[\lambda \mathbb{1}(a<2) + \mu_A \mathbb{1}(a\geq 1)\mathbb{1}(b<2) + \mu_B \mathbb{1}(b\geq 1)\right]
\end{aligned}
$$

Ventaja de la forma implícita

- Compacta: 4 fórmulas en vez de una matriz 9×9.
- General: si cambiamos capacidades, solo ajustamos los límites.
- Programable: se puede generar Q automáticamente con un bucle.

Escenario 5 – Diagrama de transiciones

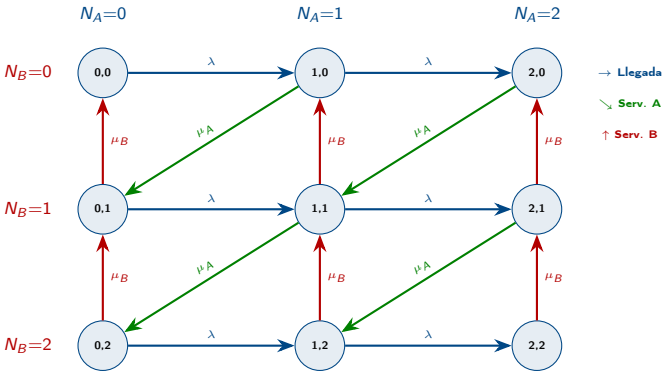

Orden lexicográfico: $(0,0),(0,1),(0,2),(1,0),(1,1),(1,2),(2,0),(2,1),(2,2)$.
Con $\lambda = 2$, $\mu_A = 4$, $\mu_B = 3$:

$$Q = \begin{pmatrix} -2 & 0 & 0 & 2 & 0 & 0 & 0 & 0 & 0 \\ 3 & -5 & 0 & 0 & 2 & 0 & 0 & 0 & 0 \\ 0 & 3 & -3 & 0 & 0 & 2 & 0 & 0 & 0 \\ 4 & 0 & 0 & -6 & 0 & 0 & 2 & 0 & 0 \\ 0 & 4 & 0 & 3 & -9 & 0 & 0 & 2 & 0 \\ 0 & 0 & 0 & 0 & 3 & -5 & 0 & 0 & 2 \\ 0 & 0 & 0 & 4 & 0 & 0 & -4 & 0 & 0 \\ 0 & 0 & 0 & 0 & 4 & 0 & 3 & -7 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 3 & -3 \end{pmatrix}$$

Observe: en $(1,2)$ no hay transición por servicio A (B llena $\Rightarrow$ bloqueo), y en $(2,2)$ tampoco hay llegadas (A llena) ni servicio de A.

Explícito vs. Implícito: ¿Cuándo usar cada uno?

	Modelo explícito	**Modelo implícito**
Definición	Matriz Q escrita elemento por elemento	Tasas como funciones de los subíndices
Ventaja	Visual, verificable a mano	Compacto, generalizable, programable
Desventaja	Crece rápidamente con $\lvert\mathcal{S}\rvert$	Requiere cuidado con condiciones
Uso típico	Espacios pequeños ($\lvert\mathcal{S}\rvert \leq 10$)	Espacios grandes o parametrizados
Ejemplo	Cola M/M/1/4: matriz 5×5	Cola M/M/c/K con c, K generales

En la práctica

Se suele comenzar con el modelo implícito (fórmulas) y luego generar la matriz explícita numéricamente mediante código (Python, MATLAB, etc.).

Receta para escribir Q en forma implícita:

1. **Enumerar los tipos de eventos** que pueden ocurrir.
2. Para cada tipo de evento k:
   (a) Definir el **vector de cambio** $\boldsymbol{\delta}_k$ (cómo cambia el estado).
   (b) Definir la **tasa** $r_k(\boldsymbol{x})$ como función del estado actual.
   (c) Definir la **condición de activación** (cuándo es posible).
3. Las entradas de Q:

$$q_{\boldsymbol{x},\,\boldsymbol{x}+\boldsymbol{\delta}_k} = r_k(\boldsymbol{x}) \cdot \mathbb{1}\big(\text{condición}_k(\boldsymbol{x})\big)$$

$$q_{\boldsymbol{x},\boldsymbol{x}} = -\sum_k r_k(\boldsymbol{x}) \cdot \mathbb{1}\big(\text{condición}_k(\boldsymbol{x})\big)$$

Ejemplo: Escenario 5 – Red de colas

Evento k	$\boldsymbol{\delta}_k$	$r_k(a,b)$	Condición
Llegada	$(+1,0)$	λ	$a<2$
Servicio A	$(-1,+1)$	μ_A	$a\geq 1$ y $b<2$
Servicio B	$(0,-1)$	μ_B	$b\geq 1$

Código: generando Q desde el modelo implícito

Python – Escenario 5

```
import numpy as np

lam, muA, muB = 2, 4, 3
capA, capB = 2, 2
states = [(a,b) for a in range(capA+1) for b in range(capB+1)]
idx = {s: i for i, s in enumerate(states)}
n = len(states)
Q = np.zeros((n, n))

events = [  # (delta, rate_fn, condition_fn)
    ((1,0),  lambda a,b: lam, lambda a,b: a < capA),
    ((-1,1), lambda a,b: muA, lambda a,b: a >= 1 and b < capB),
    ((0,-1), lambda a,b: muB, lambda a,b: b >= 1),
]

for (a, b) in states:
    for (da, db), rate, cond in events:
        if cond(a, b):
            dest = (a+da, b+db)
            Q[idx[(a,b)], idx[dest]] = rate(a, b)
    Q[idx[(a,b)], idx[(a,b)]] = -Q[idx[(a,b)]].sum()
```

Resumen comparativo de los escenarios

	Esc. 1	**Esc. 2**	**Esc. 3**	**Esc. 4**	**Esc. 5**
Sistema	M/M/1	M/M/1/K	M/M/c	Reparación	Red de colas
Variables	1	1	1	1 (2→1)	2
$\lvert\mathcal{S}\rvert$	∞	$K{+}1$	∞	$M{+}1$	$(c_A{+}1)(c_B{+}1)$
Tasas	Ctes.	Ctes. + borde	Dep. estado	Dep. estado	Dep. estado
Acople	–	–	–	–	Sí (bloqueo)

Progresión de complejidad:

1. Tasas constantes $\rightarrow$ tasas dependientes del estado.
2. Espacio infinito $\rightarrow$ espacio finito (con bloqueo).
3. Una variable $\rightarrow$ dos variables con interacción.
4. Modelo explícito $\rightarrow$ modelo implícito parametrizado.

Problema

Un hospital tiene una **sala de urgencias** con 2 camas y un **quirófano** con 1 mesa de operación. Los pacientes llegan a urgencias con tasa $\lambda = 1/\text{hora}$. En urgencias, un paciente es atendido con tasa $\mu_1 = 0.5/\text{hora}$. Con probabilidad $p = 0.4$ el paciente requiere cirugía y pasa al quirófano (si hay espacio); con probabilidad $1 - p$ es dado de alta. En el quirófano, la cirugía toma un tiempo exponencial con tasa $\mu_2 = 0.3/\text{hora}$. Si urgencias está llena, los pacientes se derivan a otro hospital.

Tareas:

1. Identifique las variables aleatorias y sus espacios.
2. Construya el espacio de estados conjunto.
3. Escriba las transiciones en forma implícita (tabla de eventos).
4. Construya la matriz generadora explícita.

Variables:

$$U(t) = \text{pacientes en urgencias} \in \{0,1,2\}, \quad Q(t) = \text{pacientes en quirófano} \in \{0,1\}$$

Estado conjunto: $(u,q) \in \{0,1,2\} \times \{0,1\}, \quad |\mathcal{S}| = 6.$

Tabla de eventos:

Evento	δ	Tasa	Condición
Llegada	$(+1,0)$	λ	$u < 2$
Alta directa	$(-1,0)$	$(1-p)\,\mu_1 \cdot \text{mín}(u,1)$	$u \geq 1$
Pasa a quirófano	$(-1,+1)$	$p\,\mu_1 \cdot \text{mín}(u,1)$	$u \geq 1,\ q = 0$
Fin cirugía	$(0,-1)$	μ_2	$q = 1$

Nota

La tasa de servicio en urgencias usa $\text{mín}(u,1)$ porque solo hay 1 médico (modelo implícito ampliable a más médicos). El factor p divide el flujo de salida de urgencias en dos ramas.

¿Preguntas?

Modelado de Sistemas bajo Incertidumbre

AIA Lab – Universidad de los Andes