Monte Carlo en práctica: distribuciones, réplicas, salida y TLC (con ejemplos financieros e inventario)

Alejandra Tabares Pozos

Universidad de los Andes
Departamento de Ingeniería Industrial

21 de marzo de 2026

La plantilla única (para todos los ejemplos)

Formalismo mínimo

Trabajamos sobre un espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{P})$.

$$\xi : \Omega \to \mathbb{R}^d \quad \text{(entrada aleatoria)}, \qquad Y = g(\xi) \quad \text{(salida / resultado de una réplica)}.$$

Tres tipos de preguntas (funcionales de la distribución de salida)

Sea $F_Y(y) = \mathbb{P}(Y \leq y)$ la CDF inducida por el sistema.

$$\underbrace{\mu = \mathbb{E}[Y]}_{\text{promedio / costo esperado}} \quad , \quad \underbrace{\pi(\tau) = \mathbb{P}(Y > \tau) = 1 - F_Y(\tau)}_{\text{cola / evento}}, \quad \underbrace{q_\alpha(Y) = \inf\{y : F_Y(y) \geq \alpha\}}_{\text{cuantil (VaR)}}$$

y, cuando interesa cola extrema,

$$\mathrm{CVaR}_\alpha(Y) = \mathbb{E}\Big[\, Y \mid Y \geq q_\alpha(Y) \,\Big].$$

Idea guía

Cada ejemplo seguirá el mismo guion: **(i) contexto**, **(ii) modelo + pasos**, **(iii) mini-corrida (15 datos)**, **(iv) TLC para estimadores**.

TLC: cuándo aparece y qué te permite reportar

Caso A: estimar una esperanza $\theta = \mathbb{E}[h(Y)]$

Si $Y_1, \ldots, Y_N$ son i.i.d. (réplicas) y $\mathrm{Var}(h(Y)) < \infty$, entonces

$$\widehat{\theta}_N = \frac{1}{N}\sum_{i=1}^{N} h(Y_i), \qquad \sqrt{N}\,\frac{\widehat{\theta}_N - \theta}{\sigma_h} \Rightarrow \mathcal{N}(0,1), \quad \sigma_h^2 = \mathrm{Var}(h(Y)).$$

IC 95 % (aprox.): $\theta \in \widehat{\theta}_N \pm 1{,}96\,\dfrac{s_h}{\sqrt{N}}$, s_h^2 varianza muestral de $h(Y_i)$.

Caso B: estimar una probabilidad $\pi(\tau) = \mathbb{P}(Y > \tau)$

Usa $h(Y) = \mathbf{1}\{Y > \tau\}$ (Bernoulli). Entonces

$$\widehat{\pi}_N = \frac{1}{N}\sum_{i=1}^{N} \mathbf{1}\{Y_i > \tau\}, \qquad \sqrt{N}\left(\widehat{\pi}_N - \pi(\tau)\right) \Rightarrow \mathcal{N}\big(0, \pi(1-\pi)\big).$$

Advertencia (importante en finanzas)

Si $h(Y)$ tiene varianza infinita (colas demasiado pesadas), el TLC clásico puede fallar o requerir N enormes.

Ejemplo 1 (Finanzas, nivel 1): pérdidas por *default* en una cartera pequeña

Contexto (prosa)

Un equipo de riesgo evalúa pérdidas mensuales de una cartera de **créditos pequeños**. Cada cliente puede entrar en **default** en el mes (evento raro), y si ocurre default, la pérdida depende de la **severidad** (LGD: *loss given default*) que vive en $[0, 1]$.

Pregunta(s) de interés

- **Pérdida esperada mensual** de la cartera: $\mu = \mathbb{E}[Y]$.
- **Probabilidad de pérdida positiva** (al menos un default): $\pi = \mathbb{P}(Y > 0)$.

Dónde está el repaso de distribuciones

Bernoulli para el evento (default / no default) y **Beta** para LGD (severidad acotada).

Ejemplo 1: modelo probabilístico y pasos de simulación

Modelo (entrada ξ y salida $Y = g(\xi)$)

Cartera de $m = 15$ obligores, EAD fija $= 10{,}000$.

$$D_i \sim \mathrm{Bernoulli}(p), \quad p = 0{,}08, \qquad \mathrm{LGD}_i \sim \mathrm{Beta}(2,5), \quad \text{indep.}$$

La pérdida mensual total (una réplica del sistema) es

$$Y = \sum_{i=1}^{m} \underbrace{\mathrm{EAD}}_{10{,}000} \cdot \mathrm{LGD}_i \cdot D_i.$$

Pasos (Monte Carlo)

1. Para $i = 1, \ldots, m$: generar $U_i \sim \mathrm{Unif}(0,1)$ y poner $D_i = \mathbf{1}\{U_i < p\}$.
2. Generar $\mathrm{LGD}_i \sim \mathrm{Beta}(2,5)$.
3. Calcular pérdidas individuales y sumar $\Rightarrow Y$.
4. Repetir N meses simulados para estimar $\mu = \mathbb{E}[Y]$ y $\pi = \mathbb{P}(Y > 0)$.

Implementación (esqueleto)

```
U = np.random.rand(m)
D = (U < p).astype(int)
```

Ejemplo 1: una corrida ilustrativa (15 datos = 15 obligores)

Una réplica del mes: (obligores 1–8)

i	U_i	D_i	LGD_i	Loss_i
1	0.5118	0	0.387	0.0
2	0.9505	0	0.249	0.0
3	0.1442	0	0.668	0.0
4	0.9486	0	0.186	0.0
5	0.3118	0	0.054	0.0
6	0.4233	0	0.123	0.0
7	0.8277	0	0.400	0.0
8	0.4092	0	0.334	0.0

(obligores 9–15)

i	U_i	D_i	LGD_i	Loss_i
9	0.5496	0	0.137	0.0
10	0.0276	1	0.182	1824.2
11	0.7535	0	0.120	0.0
12	0.5381	0	0.264	0.0
13	0.3297	0	0.189	0.0
14	0.7884	0	0.320	0.0
15	0.3032	0	0.168	0.0

Salida de esta réplica

$Y = \sum_i \text{Loss}_i = 1824{,}2$; **evento**: $Y > 0$ (hubo default).

Ejemplo 1: TLC para $\mu = \mathbb{E}[Y]$ y $\pi = \mathbb{P}(Y > 0)$

Estimadores Monte Carlo (con N meses simulados)

$$\widehat{\mu}_N = \frac{1}{N}\sum_{j=1}^{N} Y^{(j)}, \qquad \widehat{\pi}_N = \frac{1}{N}\sum_{j=1}^{N} \mathbf{1}\{Y^{(j)} > 0\}.$$

TLC e IC 95 % (aprox.)

Si $\mathrm{Var}(Y) < \infty$:

$$\widehat{\mu}_N \approx \mathcal{N}\left(\mu, \frac{\sigma_Y^2}{N}\right), \qquad \mu \in \widehat{\mu}_N \pm 1{,}96\,\frac{s_Y}{\sqrt{N}}.$$

Para la probabilidad (Bernoulli):

$$\widehat{\pi}_N \approx \mathcal{N}\left(\pi, \frac{\pi(1-\pi)}{N}\right), \qquad \pi \in \widehat{\pi}_N \pm 1{,}96\sqrt{\frac{\widehat{\pi}_N(1-\widehat{\pi}_N)}{N}}.$$

Lectura pedagógica

La distribución de salida describe pérdidas del mes (Y). **El TLC** describe la variabilidad del *estimador* por usar N finito.

Ejemplo 2 (Finanzas, nivel 2): precio de una opción europea por Monte Carlo

Contexto (prosa)

Una mesa de derivados quiere valorar una **opción Call europea** con vencimiento T. Bajo el supuesto Black–Scholes, el precio terminal S_T es **lognormal**. La salida de una réplica es el **payoff descontado** de la opción.

Pregunta(s) de interés

- **Precio** $C = \mathbb{E}\left[e^{-rT}(S_T - K)_+\right]$ (esperanza).
- **Probabilidad de terminar in-the-money** $\mathbb{P}(S_T > K)$ (evento).

Repaso de distribuciones

Normal $\Rightarrow$ transformación exponencial $\Rightarrow$ Lognormal.

Ejemplo 2: modelo y pasos de simulación

Modelo (una réplica)

Parámetros: $S_0 = 100$, $K = 105$, $r = 0{,}03$, $\sigma = 0{,}25$, $T = 0{,}5$.

$$Z \sim \mathcal{N}(0,1), \qquad S_T = S_0 \exp\Big(\big(r - \tfrac{1}{2}\sigma^2\big)T + \sigma\sqrt{T}\,Z\Big).$$

Salida (una réplica):

$$Y = e^{-rT}(S_T - K)_+.$$

Pasos (Monte Carlo)

1. Generar $Z^{(i)} \sim \mathcal{N}(0,1)$.
2. Transformar $\Rightarrow S_T^{(i)}$ (lognormal).
3. Calcular $Y_i = e^{-rT}(S_T^{(i)} - K)_+$.
4. Estimar $C = \mathbb{E}[Y]$ por promedio; estimar $\mathbb{P}(S_T > K)$ con indicadores.

Esqueleto (Python)

```
Z = np.random.randn(N)
ST = S0*np.exp((r-0.5*sigma**2)*T + sigma*np.sqrt(T)*Z)
Y  = np.exp(-r*T)*np.maximum(ST-K,0.0)
```

Ejemplo 2: mini-corrida (15 réplicas) para ver qué se está promediando

Réplicas 1–8

i	Z	S_T	$(S_T - K)_+$	Y
1	0.189	103.33	0.00	0.00
2	-0.523	91.12	0.00	0.00
3	-0.413	92.90	0.00	0.00
4	-2.441	65.21	0.00	0.00
5	1.800	137.20	32.20	31.72
6	1.144	122.17	17.17	16.92
7	-0.325	94.40	0.00	0.00
8	0.774	114.78	9.78	9.63

Réplicas 9–15

i	Z	S_T	$(S_T - K)_+$	Y
9	0.281	104.93	0.00	0.00
10	-0.554	90.62	0.00	0.00
11	0.978	119.64	14.64	14.43
12	-0.311	94.64	0.00	0.00
13	-0.329	94.33	0.00	0.00
14	-0.792	86.87	0.00	0.00
15	0.455	108.78	3.78	3.72

Qué se estima con estos 15 datos

$$\widehat{C}_{15} = \frac{1}{15}\sum_{i=1}^{15} Y_i \approx 5{,}02; \quad \widehat{\mathbb{P}}(S_T > K) = \frac{1}{15}\sum \mathbf{1}\{Y_i > 0\} = 0{,}40.$$

Ejemplo 2: TLC para el precio $C = \mathbb{E}[Y]$

Estimador y varianza

$$\widehat{C}_N = \frac{1}{N}\sum_{i=1}^{N} Y_i, \qquad \mathrm{Var}(\widehat{C}_N) = \frac{\mathrm{Var}(Y)}{N}.$$

TLC $\Rightarrow$ IC 95 %

Si $\mathrm{Var}(Y) < \infty$,

$$\widehat{C}_N \approx \mathcal{N}\left(C, \frac{\sigma_Y^2}{N}\right) \Rightarrow C \in \widehat{C}_N \pm 1{,}96\,\frac{s_Y}{\sqrt{N}}.$$

Con la mini-corrida ($N = 15$) se obtiene $s_Y \approx 9{,}32$ (gran variabilidad porque hay muchos ceros y pocos payoffs grandes).

Lectura

En derivados, Y puede ser **muy asimétrico** (masa en 0 + cola derecha). Por eso, para reducir el error por factor 2 necesitas ≈ 4 veces más réplicas.

Ejemplo 3 (Finanzas, nivel 3): pérdida diaria de un portafolio correlacionado

Contexto (prosa)

Un área de **riesgo de mercado** monitorea pérdidas diarias de un portafolio con dos activos. El punto central no es la media (cercana a 0) sino **la cola**: *¿qué tan grande puede ser una pérdida mala?* Aquí aparecen cuantiles: VaR.

Pregunta(s) de interés

- **VaR** al nivel α: $\mathrm{VaR}_\alpha = q_\alpha(L)$ donde L es pérdida.
- **Probabilidad de exceder un umbral** $\mathbb{P}(L > \ell)$ (evento).

Repaso

Normal multivariada + correlación (Cholesky) + funcional no lineal (cuantil).

Ejemplo 3: modelo y pasos (correlación explícita)

Modelo (retornos correlacionados)

Retornos diarios (media 0):

$$\boldsymbol{R} = (R_1, R_2)^\top \sim \mathcal{N}(\mathbf{0}, \Sigma), \quad \Sigma = \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}, \ \sigma_1 = 0{,}015, \ \sigma_2 = 0{,}02, \ \rho = 0{,}3.$$

Portafolio con valor $V_0 = 10^6$ y pesos $w_1 = 0{,}6, w_2 = 0{,}4$. Pérdida diaria:

$$L = -V_0(w_1 R_1 + w_2 R_2).$$

Pasos (Monte Carlo con Cholesky)

1. Generar $\boldsymbol{Z} \sim \mathcal{N}(\mathbf{0}, I_2)$.
2. Construir $\boldsymbol{R} = A\boldsymbol{Z}$ donde $AA^\top = \Sigma$ (Cholesky).
3. Calcular $L = -V_0 \boldsymbol{w}^\top \boldsymbol{R}$.
4. Repetir N veces y estimar: (i) $\mathbb{P}(L > \ell)$; (ii) $\mathrm{VaR}_\alpha = q_\alpha(L)$.

Ejemplo 3: mini-corrida (15 escenarios) y lectura de VaR

Escenarios 1–8

i	R_1	R_2	L (COP)
1	3.06 %	0.48 %	-20,284
2	-3.83 %	-0.61 %	25,457
3	0.63 %	-0.20 %	-2,946
4	-0.84 %	-2.48 %	14,985
5	-2.74 %	-3.37 %	31,677
6	-1.07 %	-2.13 %	17,240
7	-1.55 %	-0.05 %	9,336
8	0.75 %	-0.14 %	-3,936

Escenarios 9–15

i	R_1	R_2	L (COP)
9	-0.39 %	-0.15 %	3,124
10	2.31 %	1.27 %	-18,776
11	0.72 %	0.28 %	-5,432
12	3.26 %	1.38 %	-22,649
13	2.16 %	1.52 %	-18,035
14	-1.52 %	-3.14 %	25,331
15	5.20 %	2.23 %	-36,487

Lectura (cuantil en muestra pequeña)

Con estos 15 valores, el cuantil empírico: $\widehat{\mathrm{VaR}}_{0,95} = \widehat{q}_{0,95}(L) \approx 17{,}240$. Aquí *se ve* que cuantiles altos son muy sensibles a N pequeño.

Ejemplo 3: TLC y cuantiles (VaR) – idea asintótica

Probabilidad (sí es TLC directo)

Para $\pi(\ell) = \mathbb{P}(L > \ell)$:

$$\widehat{\pi}_N(\ell) = \frac{1}{N}\sum_{i=1}^{N} \mathbf{1}\{L_i > \ell\}, \qquad \sqrt{N}\big(\widehat{\pi}_N(\ell) - \pi(\ell)\big) \Rightarrow \mathcal{N}(0, \pi(1-\pi)).$$

VaR (cuantil): normalidad asintótica (derivada del CLT para la CDF empírica)

Sea $q_\alpha = q_\alpha(L)$ y $f_L(q_\alpha)$ la densidad de L en el cuantil. Entonces,

$$\sqrt{N}\big(\widehat{q}_\alpha - q_\alpha\big) \Rightarrow \mathcal{N}\left(0, \ \frac{\alpha(1-\alpha)}{f_L(q_\alpha)^2}\right).$$

Interpretación: si $f_L(q_\alpha)$ es pequeña (cola plana), el error del cuantil crece.

Consecuencia práctica

Percentiles altos (0.95, 0.99) requieren N mucho mayor que una media, porque estiman comportamiento en una región con poca masa y densidad pequeña.

Ejemplo 4 (Inventario, nivel 4): Newsvendor con demanda Gamma

Contexto (prosa)

Un e-commerce decide cuánto ordenar (Q) para mañana. La demanda D es positiva y asimétrica: la mayoría de los días es moderada, pero hay algunos días con demanda alta. Ese patrón es típico de distribuciones **Gamma**.

Pregunta(s) de interés

- **Utilidad esperada**: $\mu(Q) = \mathbb{E}[\Pi(Q, D)]$.
- **Nivel de servicio**: $\pi(Q) = \mathbb{P}(D > Q)$ (probabilidad de quiebre/stockout).

Repaso

Gamma (soporte positivo, asimetría) + función no lineal min/max en la utilidad.

Ejemplo 4: modelo y pasos de simulación

Modelo

Demanda:

$$D \sim \mathrm{Gamma}(k, \theta), \quad k = 4,\ \theta = 25 \Rightarrow \mathbb{E}[D] = 100.$$

Decisión $Q = 110$. Precio $p = 12$, costo $c = 7$, salvamento $v = 3$. Utilidad por día:

$$\Pi(Q, D) = p\,\mathrm{mín}(D, Q) + v(Q - \mathrm{mín}(D, Q)) - cQ.$$

Salida (una réplica): $Y = \Pi(Q, D)$.

Pasos (Monte Carlo)

1. Simular $D^{(i)} \sim \mathrm{Gamma}(k, \theta)$.
2. Calcular $Y_i = \Pi(Q, D^{(i)})$.
3. Estimar $\mu(Q) = \mathbb{E}[Y]$ con promedio; $\pi(Q) = \mathbb{P}(D > Q)$ con indicador.

Esqueleto (Python)

```
D = np.random.gamma(k, theta, N)
sales = np.minimum(D, Q)
profit = p*sales + v*(Q-sales) - c*Q
mu_hat = profit.mean()
pi_hat = np.mean(D > Q)
```

Ejemplo 4: mini-corrida (15 días) para ver D y la salida Y

Días 1–8

i	D	$\Pi(Q, D)$	$\mathbf{1}\{D > Q\}$
1	63.9	134.8	0
2	196.6	550.0	1
3	33.4	-139.4	0
4	87.6	288.8	0
5	106.4	513.6	0
6	109.0	546.0	0
7	150.6	550.0	1
8	86.1	271.2	0

Días 9–15

i	D	$\Pi(Q, D)$	$\mathbf{1}\{D > Q\}$
9	62.6	119.2	0
10	108.8	535.2	0
11	196.2	550.0	1
12	57.0	52.0	0
13	70.6	215.2	0
14	136.0	550.0	1
15	87.1	281.2	0

Qué se estima con estos 15 datos

$$\widehat{\mu}_{15} \approx 246{,}3; \quad \widehat{\pi}_{15} = \frac{4}{15} \approx 0{,}2667.$$

Ejemplo 4: TLC para utilidad esperada y nivel de servicio

Estimadores

$$\widehat{\mu}_N(Q) = \frac{1}{N}\sum_{i=1}^{N} \Pi(Q, D^{(i)}), \qquad \widehat{\pi}_N(Q) = \frac{1}{N}\sum_{i=1}^{N} \mathbf{1}\{D^{(i)} > Q\}.$$

TLC (dos veces, dos lecturas)

$$\widehat{\mu}_N(Q) \approx \mathcal{N}\left(\mu(Q), \frac{\sigma_\Pi^2(Q)}{N}\right), \quad \mu(Q) \in \widehat{\mu}_N(Q) \pm 1{,}96\,\frac{s_\Pi(Q)}{\sqrt{N}}.$$

$$\widehat{\pi}_N(Q) \approx \mathcal{N}\left(\pi(Q), \frac{\pi(Q)(1-\pi(Q))}{N}\right).$$

Interpretación geométrica mínima

El **promedio** es un funcional lineal de la distribución de salida. La **probabilidad de stockout** es un promedio de indicadores (Bernoulli) $\Rightarrow$ mismo TLC, distinta varianza.

Ejemplo 5 (Finanzas, nivel 5): pérdida anual operacional (Poisson compuesto)

Contexto (prosa)

Un banco modela pérdidas anuales por eventos operacionales: fraudes, fallas, sanciones. Hay dos incertidumbres: **frecuencia** de eventos en el año y **severidad** de cada evento. El resultado anual es una **suma aleatoria** (*compound process*).

Pregunta(s) de interés

- **Stop-loss premium** (capa de seguro): $\theta = \mathbb{E}[(Y - d)_+]$.
- **Probabilidad de exceder capital** d: $\pi = \mathbb{P}(Y > d)$.

Repaso

Poisson (conteo) + Lognormal (severidad positiva con cola) $\Rightarrow$ suma aleatoria.

Ejemplo 5: modelo y pasos de simulación

Modelo (una réplica anual)

$$N \sim \mathrm{Poisson}(\lambda),\ \lambda = 2, \qquad X_j \sim \mathrm{Lognormal}(\mu, \sigma^2),\ \mu = 8{,}5,\ \sigma = 0{,}7,$$

independientes, y la pérdida agregada anual:

$$Y = \sum_{j=1}^{N} X_j.$$

Capa (deducible) $d = 15{,}000$. Salida para seguro: $h(Y) = (Y - d)_+$.

Pasos (Monte Carlo)

1. Generar $N^{(i)} \sim \mathrm{Poisson}(\lambda)$.
2. Generar severidades $X_1, \ldots, X_{N^{(i)}}$ y sumar $\Rightarrow Y_i$.
3. Calcular $h(Y_i) = (Y_i - d)_+$ y el indicador $\mathbf{1}\{Y_i > d\}$.
4. Promediar sobre N años simulados.

Esqueleto (Python)

```
N = np.random.poisson(lam, size=Nsim)
Y = np.array([np.random.lognormal(mu,sigma,k).sum() if k>0 else 0.0 for k in N])
```

Ejemplo 5: mini-corrida (15 años) para ver suma aleatoria y cola

Años 1–8

año	N	Y	$(Y-d)_+$	$\mathbf{1}\{Y>d\}$
1	3	20,480	5,480	1
2	0	0	0	0
3	2	8,219	0	0
4	0	0	0	0
5	3	11,319	0	0
6	5	28,309	13,309	1
7	0	0	0	0
8	2	6,175	0	0

Años 9–15

año	N	Y	$(Y-d)_+$	$\mathbf{1}\{Y>d\}$
9	0	0	0	0
10	2	16,279	1,279	1
11	2	34,278	19,278	1
12	1	7,703	0	0
13	2	17,732	2,732	1
14	2	7,894	0	0
15	1	12,648	0	0

Qué se estima con estos 15 datos

$$\widehat{\theta}_{15} = \mathbb{E}[(\widehat{Y-d})_+] \approx 2805; \quad \widehat{\pi}_{15} = \frac{5}{15} \approx 0{,}333.$$

Ejemplo 5: TLC para stop-loss y excedencia

Aplicación directa del TLC (esperanza)

Con $h(Y) = (Y - d)_+$:

$$\widehat{\theta}_N = \frac{1}{N}\sum_{i=1}^{N} h(Y_i), \qquad \widehat{\theta}_N \approx \mathcal{N}\left(\theta, \frac{\sigma_h^2}{N}\right).$$

IC 95 %: $\theta \in \widehat{\theta}_N \pm 1{,}96\,\dfrac{s_h}{\sqrt{N}}$.

Probabilidad de exceder d

$$\widehat{\pi}_N = \frac{1}{N}\sum_{i=1}^{N} \mathbf{1}\{Y_i > d\} \approx \mathcal{N}\left(\pi, \frac{\pi(1-\pi)}{N}\right).$$

Comentario técnico (cola pesada)

Si la severidad tuviera cola Pareto con exponente $\alpha \leq 2$, la varianza podría ser infinita. En ese caso: (i) el TLC clásico no aplica; (ii) la simulación sigue siendo posible, pero el error baja más lento y es más errático.

Ejemplo 6 (Finanzas, nivel 6): opción barrera (path-dependent) con monitoreo discreto

Contexto (prosa)

Una opción **Up-and-Out Call** paga como una Call *solo si* el precio nunca supera una barrera B antes del vencimiento. Esto introduce **dependencia de trayectoria**: la salida no depende solo de S_T, sino del *máximo* en el camino.

Pregunta(s) de interés

- **Precio**: $C = \mathbb{E}\left[e^{-rT}(S_T - K)_+ \mathbf{1}\{\text{máx}_{t \leq T} S_t < B\}\right]$.
- **Probabilidad de knock-out**: $\mathbb{P}(\text{máx}_{t \leq T} S_t \geq B)$.

Repaso

Increments normales (Browniano discretizado) + no linealidad extrema (máximo + indicador) $\Rightarrow$ masa en 0.

Ejemplo 6: modelo y pasos (GBM discretizado, 15 pasos)

Modelo (discretización Euler exacta en log-precio)

Parámetros: $S_0 = 100$, $K = 100$, $B = 130$, $r = 0{,}02$, $\sigma = 0{,}2$, $T = 1$. Monitoreo en $m = 15$ fechas, $\Delta t = T/m$.

$$Z_t \sim \mathcal{N}(0,1) \text{ i.i.d.}, \qquad S_{t+\Delta t} = S_t \exp\Big((r - \tfrac{1}{2}\sigma^2)\Delta t + \sigma\sqrt{\Delta t}\, Z_t\Big).$$

Salida (una réplica = una trayectoria):

$$Y = e^{-rT}(S_T - K)_+ \cdot \mathbf{1}\Big\{\max_{k=1,\dots,m} S_{k\Delta t} < B\Big\}.$$

Pasos (Monte Carlo)

1. Simular $Z_1, \dots, Z_m$ y construir el camino $S_{k\Delta t}$.
2. Evaluar el evento de barrera (máximo) y el payoff final.
3. Repetir N trayectorias para estimar precio y probabilidad de knock-out.

Ejemplo 6: una réplica (15 pasos) para ver *trayectoria* y knock-out

Pasos 1–8

t	Z_t	S_t	$\mathbf{1}\{S_t < B\}$
1	1.053	105.59	1
2	1.776	115.73	1
3	-2.553	101.44	1
4	-0.138	100.72	1
5	1.014	106.13	1
6	1.352	113.81	1
7	0.654	118.28	1
8	-0.678	114.03	1

Pasos 9–15

t	Z_t	S_t	$\mathbf{1}\{S_t < B\}$
9	1.000	121.05	1
10	0.551	132.82	0
11	0.179	134.05	0
12	-0.169	132.13	0
13	-0.220	129.56	1
14	-0.271	126.43	1
15	-0.061	125.56	1

Salida de esta réplica

Se superó la barrera (máx $S_t \approx 134{,}05 > B$) $\Rightarrow$ **knock-out** $\Rightarrow$ $Y = 0$. Esta es la fuente de la **masa en 0** en la distribución de salida.

Ejemplo 6: TLC para el precio y para la probabilidad de knock-out

Precio (esperanza) $\Rightarrow$ TLC estándar

Con Y_i payoff descontado de la trayectoria i:

$$\widehat{C}_N = \frac{1}{N}\sum_{i=1}^{N} Y_i \approx \mathcal{N}\left(C, \frac{\sigma_Y^2}{N}\right), \quad C \in \widehat{C}_N \pm 1{,}96\frac{s_Y}{\sqrt{N}}.$$

Probabilidad de knock-out (evento) $\Rightarrow$ TLC Bernoulli

Defina $K_i = \mathbf{1}\{\text{máx}_t\, S_t^{(i)} \geq B\}$.

$$\widehat{p}_{KO} = \frac{1}{N}\sum_{i=1}^{N} K_i \approx \mathcal{N}\left(p_{KO}, \frac{p_{KO}(1-p_{KO})}{N}\right).$$

Lectura

Aquí el sistema es dinámico (trayectoria), pero la estadística final sigue siendo: **promedios de i.i.d.** $\Rightarrow$ TLC para el error Monte Carlo.

Cierre: qué repasa cada ejemplo (y qué mirar en la salida)

Seis contextos, seis familias de distribuciones

- Ej.1 Crédito: Bernoulli (evento) + Beta (severidad en $[0, 1]$).
- Ej.2 Opción europea: Normal $\rightarrow$ Lognormal (transformación).
- Ej.3 Portafolio: Normal multivariada + correlación (Cholesky) + cuantil (VaR).
- Ej.4 Inventario: Gamma (positiva, asimétrica) + no linealidad min/max.
- Ej.5 Operacional: Poisson compuesto (suma aleatoria) + Lognormal (cola).
- Ej.6 Barrera: incrementos normales + máximo + indicador (masa en 0).

Checklist mínimo al simular

1. Definir claramente ξ, $g(\cdot)$ y $Y = g(\xi)$.
2. Distinguir: **distribución de salida** (Y) vs **distribución del estimador** ($\widehat{\theta}_N$).
3. Reportar: estimación + **barra de error** (TLC) + diagnóstico (histograma/ECDF).