Monte Carlo en práctica: distribuciones, réplicas, salida y TLC (con ejemplos financieros e inventario)

Alejandra Tabares Pozos
Universidad de los Andes
Departamento de Ingeniería Industrial

La plantilla única (para todos los ejemplos)

Formalismo mínimo

Trabajamos sobre un espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{P})$.

$$\xi : \Omega \to \mathbb{R}^d \quad \text{(entrada aleatoria)}, \qquad Y = g(\xi) \quad \text{(salida / resultado de una réplica)}.$$

Tres tipos de preguntas (funcionales de la distribución de salida)

Sea $F_Y(y) = \mathbb{P}(Y \leq y)$ la CDF inducida por el sistema.

$$\underbrace{\mu = \mathbb{E}[Y]}_{\text{promedio / costo esperado}}, \qquad \underbrace{\pi(\tau) = \mathbb{P}(Y > \tau) = 1 - F_Y(\tau)}_{\text{cola / evento}}, \qquad \underbrace{q_\alpha(Y) = \inf\{y : F_Y(y) \geq \alpha\}}_{\text{cuantil (VaR)}}$$

y, cuando interesa cola extrema,

$$\mathrm{CVaR}_\alpha(Y) = \mathbb{E}\big[\, Y \mid Y \geq q_\alpha(Y) \,\big].$$

Idea guía

Cada ejemplo seguirá el mismo guion: **(i) contexto**, **(ii) modelo + pasos**, **(iii) mini-corrida (15 datos)**, **(iv) TLC para estimadores**.

TLC: cuándo aparece y qué te permite reportar

Caso A: estimar una esperanza $\theta = \mathbb{E}[h(Y)]$

Si $Y_1, \ldots, Y_N$ son i.i.d. (réplicas) y $\mathrm{Var}(h(Y)) < \infty$, entonces

$$\widehat{\theta}_N = \frac{1}{N}\sum_{i=1}^{N} h(Y_i), \qquad \sqrt{N}\,\frac{\widehat{\theta}_N - \theta}{\sigma_h} \Rightarrow \mathcal{N}(0,1), \quad \sigma_h^2 = \mathrm{Var}(h(Y)).$$

IC 95 % (aprox.): $\theta \in \widehat{\theta}_N \pm 1.96\,\dfrac{s_h}{\sqrt{N}}$, s_h^2 varianza muestral de $h(Y_i)$.

Caso B: estimar una probabilidad $\pi(\tau) = \mathbb{P}(Y > \tau)$

Usa $h(Y) = 1\{Y > \tau\}$ (Bernoulli). Entonces

$$\widehat{\pi}_N = \frac{1}{N}\sum_{i=1}^{N} 1\{Y_i > \tau\}, \qquad \sqrt{N}\,\big(\widehat{\pi}_N - \pi(\tau)\big) \Rightarrow \mathcal{N}\big(0, \pi(1-\pi)\big).$$

Advertencia (importante en finanzas)

Si $h(Y)$ tiene varianza infinita (colas demasiado pesadas), el TLC clásico puede fallar o requerir N enormes.

Ejemplo 1 (Finanzas, nivel 1): pérdidas por *default* en una cartera pequeña

Contexto (prosa)

Un equipo de riesgo evalúa pérdidas mensuales de una cartera de **créditos pequeños**. Cada cliente puede entrar en **default** en el mes (evento raro), y si ocurre default, la pérdida depende de la **severidad** (LGD: *loss given default*) que vive en $[0, 1]$.

Pregunta(s) de interés

- **Pérdida esperada mensual** de la cartera: $\mu = \mathbb{E}[Y]$.
- **Probabilidad de pérdida positiva** (al menos un default): $\pi = \mathbb{P}(Y > 0)$.

Dónde está el repaso de distribuciones

Bernoulli para el evento (default / no default) y **Beta** para LGD (severidad acotada).

Modelo (entrada ξ y salida $Y = g(\xi)$)

Cartera de $m = 15$ obligores, EAD fija $= 10{,}000$.

$$D_i \sim \mathrm{Bernoulli}(p), \quad p = 0.08, \qquad \mathrm{LGD}_i \sim \mathrm{Beta}(2,5), \quad \text{indep.}$$

La pérdida mensual total (una réplica del sistema) es

$$Y = \sum_{i=1}^{m} \underbrace{\mathrm{EAD}}_{10{,}000} \cdot \mathrm{LGD}_i \cdot D_i.$$

Pasos (Monte Carlo)

1. Para $i = 1, \ldots, m$: generar $U_i \sim \mathrm{Unif}(0,1)$ y poner $D_i = 1\{U_i < p\}$.
2. Generar $\mathrm{LGD}_i \sim \mathrm{Beta}(2,5)$.
3. Calcular pérdidas individuales y sumar $\Rightarrow Y$.
4. Repetir N meses simulados para estimar $\mu = \mathbb{E}[Y]$ y $\pi = \mathbb{P}(Y > 0)$.

Implementación (esqueleto)

Ejemplo 1: una corrida ilustrativa (15 datos = 15 obligores)

Una réplica del mes: (obligores 1–8)

i	U_i	D_i	LGD_i	Loss_i
1	0.5118	0	0.387	0.0
2	0.9505	0	0.249	0.0
3	0.1442	0	0.668	0.0
4	0.9486	0	0.186	0.0
5	0.3118	0	0.054	0.0
6	0.4233	0	0.123	0.0
7	0.8277	0	0.400	0.0
8	0.4092	0	0.334	0.0

(obligores 9–15)

i	U_i	D_i	LGD_i	Loss_i
9	0.5496	0	0.137	0.0
10	0.0276	1	0.182	1824.2
11	0.7535	0	0.120	0.0
12	0.5381	0	0.264	0.0
13	0.3297	0	0.189	0.0
14	0.7884	0	0.320	0.0
15	0.3032	0	0.168	0.0

Salida de esta réplica

$Y = \sum_i \text{Loss}_i = 1824.2$; **evento**: $Y > 0$ (hubo default).

Ejemplo 1: TLC para $\mu = \mathbb{E}[Y]$ y $\pi = \mathbb{P}(Y > 0)$

Estimadores Monte Carlo (con N meses simulados)

$$\widehat{\mu}_N = \frac{1}{N}\sum_{j=1}^{N} Y^{(j)}, \qquad \widehat{\pi}_N = \frac{1}{N}\sum_{j=1}^{N} 1\{Y^{(j)} > 0\}.$$

TLC e IC 95 % (aprox.)

Si $\mathrm{Var}(Y) < \infty$:

$$\widehat{\mu}_N \approx \mathcal{N}\left(\mu, \frac{\sigma_Y^2}{N}\right), \qquad \mu \in \widehat{\mu}_N \pm 1.96\,\frac{s_Y}{\sqrt{N}}.$$

Para la probabilidad (Bernoulli):

$$\widehat{\pi}_N \approx \mathcal{N}\left(\pi, \frac{\pi(1-\pi)}{N}\right), \qquad \pi \in \widehat{\pi}_N \pm 1.96\sqrt{\frac{\widehat{\pi}_N(1-\widehat{\pi}_N)}{N}}.$$

Lectura pedagógica

La distribución de salida describe pérdidas del mes (Y). **El TLC** describe la variabilidad del *estimador* por usar N finito.

Ejemplo 2 (Finanzas, nivel 2): precio de una opción europea por Monte Carlo

Contexto (prosa)

Una mesa de derivados quiere valorar una **opción Call europea** con vencimiento T. Bajo el supuesto Black–Scholes, el precio terminal S_T es **lognormal**. La salida de una réplica es el **payoff descontado** de la opción.

Pregunta(s) de interés

- **Precio** $C = \mathbb{E}\left[e^{-rT}(S_T - K)_+\right]$ (esperanza).
- **Probabilidad de terminar in-the-money** $\mathbb{P}(S_T > K)$ (evento).

Repaso de distribuciones

Normal $\Rightarrow$ transformación exponencial $\Rightarrow$ Lognormal.

Modelo (una réplica)

Parámetros: $S_0 = 100$, $K = 105$, $r = 0.03$, $\sigma = 0.25$, $T = 0.5$.

$$Z \sim \mathcal{N}(0,1), \qquad S_T = S_0 \exp\Big((r - \tfrac{1}{2}\sigma^2)T + \sigma\sqrt{T}\,Z\Big).$$

Salida (una réplica):

$$Y = e^{-rT}(S_T - K)_+.$$

Pasos (Monte Carlo)

1. Generar $Z^{(i)} \sim \mathcal{N}(0,1)$.
2. Transformar $\Rightarrow S_T^{(i)}$ (lognormal).
3. Calcular $Y_i = e^{-rT}(S_T^{(i)} - K)_+$.
4. Estimar $C = \mathbb{E}[Y]$ por promedio; estimar $\mathbb{P}(S_T > K)$ con indicadores.

Esqueleto (Python)

Ejemplo 2: mini-corrida (15 réplicas) para ver qué se está promediando

Réplicas 1–8

i	Z	S_T	$(S_T - K)_+$	Y
1	0.189	103.33	0.00	0.00
2	-0.523	91.12	0.00	0.00
3	-0.413	92.90	0.00	0.00
4	-2.441	65.21	0.00	0.00
5	1.800	137.20	32.20	31.72
6	1.144	122.17	17.17	16.92
7	-0.325	94.40	0.00	0.00
8	0.774	114.78	9.78	9.63

Réplicas 9–15

i	Z	S_T	$(S_T - K)_+$	Y
9	0.281	104.93	0.00	0.00
10	-0.554	90.62	0.00	0.00
11	0.978	119.64	14.64	14.43
12	-0.311	94.64	0.00	0.00
13	-0.329	94.33	0.00	0.00
14	-0.792	86.87	0.00	0.00
15	0.455	108.78	3.78	3.72

Qué se estima con estos 15 datos

$\widehat{C}_{15} = \frac{1}{15}\sum_{i=1}^{15} Y_i \approx 5.02; \quad \widehat{\mathbb{P}}(S_T > K) = \frac{1}{15}\sum 1\{Y_i > 0\} = 0.40.$

Ejemplo 2: TLC para el precio $C = \mathbb{E}[Y]$

Estimador y varianza

$$\widehat{C}_N = \frac{1}{N}\sum_{i=1}^{N} Y_i, \qquad \mathrm{Var}(\widehat{C}_N) = \frac{\mathrm{Var}(Y)}{N}.$$

TLC $\Rightarrow$ IC 95 %

Si $\mathrm{Var}(Y) < \infty$,

$$\widehat{C}_N \approx \mathcal{N}\left(C, \frac{\sigma_Y^2}{N}\right) \Rightarrow C \in \widehat{C}_N \pm 1.96\,\frac{s_Y}{\sqrt{N}}.$$

Con la mini-corrida ($N = 15$) se obtiene $s_Y \approx 9.32$ (gran variabilidad porque hay muchos ceros y pocos payoffs grandes).

Lectura

En derivados, Y puede ser **muy asimétrico** (masa en 0 + cola derecha). Por eso, para reducir el error por factor 2 necesitas ≈ 4 veces más réplicas.

Ejemplo 3 (Finanzas, nivel 3): pérdida diaria de un portafolio correlacionado

Contexto (prosa)

Un área de **riesgo de mercado** monitorea pérdidas diarias de un portafolio con dos activos. El punto central no es la media (cercana a 0) sino **la cola**: *¿qué tan grande puede ser una pérdida mala?* Aquí aparecen cuantiles: VaR.

Pregunta(s) de interés

- **VaR** al nivel α: $\mathrm{VaR}_\alpha = q_\alpha(L)$ donde L es pérdida.
- **Probabilidad de exceder un umbral** $\mathbb{P}(L > \ell)$ (evento).

Repaso

Normal multivariada + correlación (Cholesky) + funcional no lineal (cuantil).

Modelo (retornos correlacionados)

Retornos diarios (media 0):

$$\boldsymbol{R} = (R_1, R_2)^\top \sim \mathcal{N}(0, \Sigma), \quad \Sigma = \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}, \ \sigma_1 = 0.015, \ \sigma_2 = 0.02, \ \rho = 0.3.$$

Portafolio con valor $V_0 = 10^6$ y pesos $w_1 = 0.6, w_2 = 0.4$. Pérdida diaria:

$$L = -V_0(w_1 R_1 + w_2 R_2).$$

Pasos (Monte Carlo con Cholesky)

1. Generar $\boldsymbol{Z} \sim \mathcal{N}(0, I_2)$.
2. Construir $\boldsymbol{R} = A\boldsymbol{Z}$ donde $AA^\top = \Sigma$ (Cholesky).
3. Calcular $L = -V_0 \boldsymbol{w}^\top \boldsymbol{R}$.
4. Repetir N veces y estimar: (i) $\mathbb{P}(L > \ell)$; (ii) $\mathrm{VaR}_\alpha = q_\alpha(L)$.

Ejemplo 3: mini-corrida (15 escenarios) y lectura de VaR

Escenarios 1–8

i	R_1	R_2	L (COP)
1	3.06 %	0.48 %	-20,284
2	-3.83 %	-0.61 %	25,457
3	0.63 %	-0.20 %	-2,946
4	-0.84 %	-2.48 %	14,985
5	-2.74 %	-3.37 %	31,677
6	-1.07 %	-2.13 %	17,240
7	-1.55 %	-0.05 %	9,336
8	0.75 %	-0.14 %	-3,936

Escenarios 9–15

i	R_1	R_2	L (COP)
9	-0.39 %	-0.15 %	3,124
10	2.31 %	1.27 %	-18,776
11	0.72 %	0.28 %	-5,432
12	3.26 %	1.38 %	-22,649
13	2.16 %	1.52 %	-18,035
14	-1.52 %	-3.14 %	25,331
15	5.20 %	2.23 %	-36,487

Lectura (cuantil en muestra pequeña)

Con estos 15 valores, el cuantil empírico:
$\widehat{\mathrm{VaR}}_{\mathbf{0.95}} = \widehat{q}_{\mathbf{0.95}}(L) \approx 17{,}240$. Aquí *se ve* que cuantiles altos son muy sensibles a N pequeño.

Probabilidad (sí es TLC directo)

Para $\pi(\ell) = \mathbb{P}(L > \ell)$:

$$\widehat{\pi}_N(\ell) = \frac{1}{N}\sum_{i=1}^{N} 1\{L_i > \ell\}, \qquad \sqrt{N}\big(\widehat{\pi}_N(\ell) - \pi(\ell)\big) \Rightarrow \mathcal{N}(0, \pi(1-\pi)).$$

VaR (cuantil): normalidad asintótica (derivada del CLT para la CDF empírica)

Sea $q_\alpha = q_\alpha(L)$ y $f_L(q_\alpha)$ la densidad de L en el cuantil. Entonces,

$$\sqrt{N}\big(\widehat{q}_\alpha - q_\alpha\big) \Rightarrow \mathcal{N}\left(0,\ \frac{\alpha(1-\alpha)}{f_L(q_\alpha)^2}\right).$$

Interpretación: si $f_L(q_\alpha)$ es pequeña (cola plana), el error del cuantil crece.

Consecuencia práctica

Percentiles altos (0.95, 0.99) requieren N mucho mayor que una media, porque estiman comportamiento en una región con poca masa y densidad pequeña.

Ejemplo 4 (Inventario, nivel 4): Newsvendor con demanda Gamma

Contexto (prosa)

Un e-commerce decide cuánto ordenar (Q) para mañana. La demanda D es positiva y asimétrica: la mayoría de los días es moderada, pero hay algunos días con demanda alta. Ese patrón es típico de distribuciones **Gamma**.

Pregunta(s) de interés

- **Utilidad esperada**: $\mu(Q) = \mathbb{E}[\Pi(Q, D)]$.
- **Nivel de servicio**: $\pi(Q) = \mathbb{P}(D > Q)$ (probabilidad de quiebre/stockout).

Repaso

Gamma (soporte positivo, asimetría) + función no lineal min/max en la utilidad.

Ejemplo 4: modelo y pasos de simulación

Modelo

Demanda:

$$D \sim \mathrm{Gamma}(k, \theta), \quad k = 4,\ \theta = 25 \Rightarrow \mathbb{E}[D] = 100.$$

Decisión $Q = 110$. Precio $p = 12$, costo $c = 7$, salvamento $v = 3$. Utilidad por día:

$$\Pi(Q, D) = p\,\text{mín}(D, Q) + v(Q - \text{mín}(D, Q)) - cQ.$$

Salida (una réplica): $Y = \Pi(Q, D)$.

Pasos (Monte Carlo)

1. Simular $D^{(i)} \sim \mathrm{Gamma}(k, \theta)$.
2. Calcular $Y_i = \Pi(Q, D^{(i)})$.
3. Estimar $\mu(Q) = \mathbb{E}[Y]$ con promedio; $\pi(Q) = \mathbb{P}(D > Q)$ con indicador.

Esqueleto (Python)

Ejemplo 4: mini-corrida (15 días) para ver D y la salida Y

Días 1–8

i	D	$\Pi(Q, D)$	$1\{D > Q\}$
1	63.9	134.8	0
2	196.6	550.0	1
3	33.4	-139.4	0
4	87.6	288.8	0
5	106.4	513.6	0
6	109.0	546.0	0
7	150.6	550.0	1
8	86.1	271.2	0

Días 9–15

i	D	$\Pi(Q, D)$	$1\{D > Q\}$
9	62.6	119.2	0
10	108.8	535.2	0
11	196.2	550.0	1
12	57.0	52.0	0
13	70.6	215.2	0
14	136.0	550.0	1
15	87.1	281.2	0

Qué se estima con estos 15 datos

$\widehat{\mu}_{15} \approx 246.3; \quad \widehat{\pi}_{15} = \frac{4}{15} \approx 0.2667.$

Ejemplo 4: TLC para utilidad esperada y nivel de servicio

Estimadores

$$\widehat{\mu}_N(Q) = \frac{1}{N}\sum_{i=1}^{N} \Pi(Q, D^{(i)}), \qquad \widehat{\pi}_N(Q) = \frac{1}{N}\sum_{i=1}^{N} 1\{D^{(i)} > Q\}.$$

TLC (dos veces, dos lecturas)

$$\widehat{\mu}_N(Q) \approx \mathcal{N}\left(\mu(Q), \frac{\sigma_\Pi^2(Q)}{N}\right), \quad \mu(Q) \in \widehat{\mu}_N(Q) \pm 1.96\frac{s_\Pi(Q)}{\sqrt{N}}.$$

$$\widehat{\pi}_N(Q) \approx \mathcal{N}\left(\pi(Q), \frac{\pi(Q)(1-\pi(Q))}{N}\right).$$

Interpretación geométrica mínima

El **promedio** es un funcional lineal de la distribución de salida. La **probabilidad de stockout** es un promedio de indicadores (Bernoulli) $\Rightarrow$ mismo TLC, distinta varianza.

Ejemplo 5 (Finanzas, nivel 5): pérdida anual operacional (Poisson compuesto)

Contexto (prosa)

Un banco modela pérdidas anuales por eventos operacionales: fraudes, fallas, sanciones. Hay dos incertidumbres: **frecuencia** de eventos en el año y **severidad** de cada evento. El resultado anual es una **suma aleatoria** (*compound process*).

Pregunta(s) de interés

- **Stop-loss premium** (capa de seguro): $\theta = \mathbb{E}[(Y - d)_+]$.
- **Probabilidad de exceder capital** d: $\pi = \mathbb{P}(Y > d)$.

Repaso

Poisson (conteo) + Lognormal (severidad positiva con cola) $\Rightarrow$ suma aleatoria.

Modelo (una réplica anual)

$$N \sim \mathrm{Poisson}(\lambda),\ \lambda = 2, \qquad X_j \sim \mathrm{Lognormal}(\mu, \sigma^2),\ \mu = 8.5,\ \sigma = 0.7,$$

independientes, y la pérdida agregada anual:

$$Y = \sum_{j=1}^{N} X_j.$$

Capa (deducible) $d = 15{,}000$. Salida para seguro: $h(Y) = (Y - d)_+$.

Pasos (Monte Carlo)

1. Generar $N^{(i)} \sim \mathrm{Poisson}(\lambda)$.
2. Generar severidades $X_1, \ldots, X_{N^{(i)}}$ y sumar $\Rightarrow Y_i$.
3. Calcular $h(Y_i) = (Y_i - d)_+$ y el indicador $1\{Y_i > d\}$.
4. Promediar sobre N años simulados.

Esqueleto (Python)

Ejemplo 5: mini-corrida (15 años) para ver suma aleatoria y cola

Años 1–8

año	N	Y	$(Y-d)_+$	$1\{Y>d\}$
1	3	20,480	5,480	1
2	0	0	0	0
3	2	8,219	0	0
4	0	0	0	0
5	3	11,319	0	0
6	5	28,309	13,309	1
7	0	0	0	0
8	2	6,175	0	0

Años 9–15

año	N	Y	$(Y-d)_+$	$1\{Y>d\}$
9	0	0	0	0
10	2	16,279	1,279	1
11	2	34,278	19,278	1
12	1	7,703	0	0
13	2	17,732	2,732	1
14	2	7,894	0	0
15	1	12,648	0	0

Qué se estima con estos 15 datos

$\widehat{\theta}_{\mathbf{15}} = \mathbb{E}[\widehat{(Y-d)_+}] \approx 2805; \quad \widehat{\pi}_{\mathbf{15}} = \frac{\mathbf{5}}{\mathbf{15}} \approx 0.333.$

Aplicación directa del TLC (esperanza)

Con $h(Y) = (Y - d)_+$:

$$\widehat{\theta}_N = \frac{1}{N}\sum_{i=1}^{N} h(Y_i), \qquad \widehat{\theta}_N \approx \mathcal{N}\left(\theta, \frac{\sigma_h^2}{N}\right).$$

IC 95 %: $\theta \in \widehat{\theta}_N \pm 1.96\,\frac{s_h}{\sqrt{N}}$.

Probabilidad de exceder d

$$\widehat{\pi}_N = \frac{1}{N}\sum_{i=1}^{N} 1\{Y_i > d\} \approx \mathcal{N}\left(\pi, \frac{\pi(1-\pi)}{N}\right).$$

Comentario técnico (cola pesada)

Si la severidad tuviera cola Pareto con exponente $\alpha \leq 2$, la varianza podría ser infinita. En ese caso: (i) el TLC clásico no aplica; (ii) la simulación sigue siendo posible, pero el error baja más lento y es más errático.

Ejemplo 6 (Finanzas, nivel 6): opción barrera (path-dependent) con monitoreo discreto

Contexto (prosa)

Una opción **Up-and-Out Call** paga como una Call *solo si* el precio nunca supera una barrera B antes del vencimiento. Esto introduce **dependencia de trayectoria**: la salida no depende solo de S_T, sino del *máximo* en el camino.

Pregunta(s) de interés

- **Precio**: $C = \mathbb{E}\big[e^{-rT}(S_T - K)_+ 1\{\text{máx}_{t \le T} S_t < B\}\big]$.
- **Probabilidad de knock-out**: $\mathbb{P}(\text{máx}_{t \le T} S_t \ge B)$.

Repaso

Increments normales (Browniano discretizado) + no linealidad extrema (máximo + indicador) $\Rightarrow$ masa en 0.

Ejemplo 6: modelo y pasos (GBM discretizado, 15 pasos)

Modelo (discretización Euler exacta en log-precio)

Parámetros: $S_0 = 100$, $K = 100$, $B = 130$, $r = 0.02$, $\sigma = 0.2$, $T = 1$. Monitoreo en $m = 15$ fechas, $\Delta t = T/m$.

$$Z_t \sim \mathcal{N}(0,1) \text{ i.i.d.}, \qquad S_{t+\Delta t} = S_t \exp\Big((r - \tfrac{1}{2}\sigma^2)\Delta t + \sigma\sqrt{\Delta t}\, Z_t\Big).$$

Salida (una réplica = una trayectoria):

$$Y = e^{-rT}(S_T - K)_+ \cdot 1\Big\{\max_{k=1,\dots,m} S_{k\Delta t} < B\Big\}.$$

Pasos (Monte Carlo)

1. Simular $Z_1, \dots, Z_m$ y construir el camino $S_{k\Delta t}$.
2. Evaluar el evento de barrera (máximo) y el payoff final.
3. Repetir N trayectorias para estimar precio y probabilidad de knock-out.

Ejemplo 6: una réplica (15 pasos) para ver *trayectoria* y knock-out

Pasos 1–8

t	Z_t	S_t	$1\{S_t < B\}$
1	1.053	105.59	1
2	1.776	115.73	1
3	-2.553	101.44	1
4	-0.138	100.72	1
5	1.014	106.13	1
6	1.352	113.81	1
7	0.654	118.28	1
8	-0.678	114.03	1

Pasos 9–15

t	Z_t	S_t	$1\{S_t < B\}$
9	1.000	121.05	1
10	0.551	132.82	0
11	0.179	134.05	0
12	-0.169	132.13	0
13	-0.220	129.56	1
14	-0.271	126.43	1
15	-0.061	125.56	1

Salida de esta réplica

Se superó la barrera ($\max S_t \approx 134.05 > B$) $\Rightarrow$ **knock-out** $\Rightarrow$ $Y = 0$. Esta es la fuente de la **masa en 0** en la distribución de salida.

Ejemplo 6: TLC para el precio y para la probabilidad de knock-out

Precio (esperanza) $\Rightarrow$ TLC estándar

Con Y_i payoff descontado de la trayectoria i:

$$\widehat{C}_N = \frac{1}{N}\sum_{i=1}^{N} Y_i \approx \mathcal{N}\left(C, \frac{\sigma_Y^2}{N}\right), \quad C \in \widehat{C}_N \pm 1.96\frac{s_Y}{\sqrt{N}}.$$

Probabilidad de knock-out (evento) $\Rightarrow$ TLC Bernoulli

Defina $K_i = 1\{\text{máx}_t\, S_t^{(i)} \geq B\}$.

$$\widehat{p}_{KO} = \frac{1}{N}\sum_{i=1}^{N} K_i \approx \mathcal{N}\left(p_{KO}, \frac{p_{KO}(1-p_{KO})}{N}\right).$$

Lectura

Aquí el sistema es dinámico (trayectoria), pero la estadística final sigue siendo: **promedios de i.i.d.** $\Rightarrow$ TLC para el error Monte Carlo.

Cierre: qué repasa cada ejemplo (y qué mirar en la salida)

Seis contextos, seis familias de distribuciones

- Ej.1 Crédito: Bernoulli (evento) + Beta (severidad en $[0, 1]$).
- Ej.2 Opción europea: Normal $\rightarrow$ Lognormal (transformación).
- Ej.3 Portafolio: Normal multivariada + correlación (Cholesky) + cuantil (VaR).
- Ej.4 Inventario: Gamma (positiva, asimétrica) + no linealidad min/max.
- Ej.5 Operacional: Poisson compuesto (suma aleatoria) + Lognormal (cola).
- Ej.6 Barrera: incrementos normales + máximo + indicador (masa en 0).

Checklist mínimo al simular

1. Definir claramente ξ, $g(\cdot)$ y $Y = g(\xi)$.
2. Distinguir: **distribución de salida** (Y) vs **distribución del estimador** ($\widehat{\theta}_N$).
3. Reportar: estimación + **barra de error** (TLC) + diagnóstico (histograma/ECDF).