Pensamiento Sistémico e Introducción a la Simulación

Alejandra Tabares Pozos

Universidad de los Andes
Departamento de Ingeniería Industrial

21 de marzo de 2026

Contexto del Curso

- **Curso:** Modelado Bajo Incertidumbre.
- **Rol en Ingeniería Industrial:** puente entre probabilidad (formal) y decisiones en sistemas reales (logística, manufactura, finanzas, energía).
- **Herramientas:**
  - Teoría: variables aleatorias, procesos estocásticos, (nociones de) Markov.
  - Práctica: simulación computacional en Python.
- **Filosofía:** usar la computación para *operacionalizar* el pensamiento probabilístico (no para reemplazarlo).

Objetivos de Aprendizaje (Semana 1)

Al finalizar la sesión, el estudiante podrá:

1. Diferenciar formalmente entre sistemas determinísticos y estocásticos.
2. Definir simulación y justificar cuándo es apropiada (y cuándo no).
3. Identificar componentes del sistema: entidades, atributos, estado.
4. Estimar numéricamente una métrica bajo incertidumbre con Monte Carlo (incluyendo error estadístico).

Definición de Sistema

Definición (operativa)

Un **sistema** es un conjunto de objetos que interactúan bajo reglas, con el fin de cumplir un propósito.

Componentes clave:

- **Entidades:** objetos de interés (clientes, máquinas, vehículos, generadores).
- **Atributos:** propiedades de entidades (prioridad, velocidad, capacidad, estado de carga).
- **Actividades/eventos:** mecanismos de cambio (atender, fallar, producir, despachar).

El Estado del Sistema

El **estado** es el conjunto mínimo de variables que permite describir el sistema en tiempo t respecto al objetivo del estudio.

Sea $S(t)$ el vector de estado:

$$S(t) = (x_1(t), x_2(t), \ldots, x_n(t)).$$

Ejemplo (inventario):

$$S(t) = (\text{inventario disponible},\ \text{órdenes en tránsito},\ \text{tiempo hasta próxima revisión}).$$

Ejemplo de sistema 1: Microred con PV + batería + compra/venta a red

Propósito del estudio: operación horaria para minimizar costo y riesgo de déficit.

Entidades (objetos del sistema):

- **Activos físicos:** Generación FV (PV), batería (BESS), carga agregada, punto de acople a red.
- **Agente de decisión:** EMS (controlador) que elige acciones a_t.

Atributos (parámetros):

- PV: potencia nominal $\bar{P}^{\text{pv}}$, eficiencia/curva de disponibilidad.
- BESS: capacidad $E_{\text{máx}}$, límites $\bar{P}^{\text{ch}}, \bar{P}^{\text{dis}}$, eficiencias $\eta_{\text{ch}}, \eta_{\text{dis}}$, SoC mínimo/máximo.
- Red: precio p_t (compra/venta), límite de intercambio $\bar{P}^{\text{grid}}$.

Ejemplo de sistema 1: Microred con PV + batería + compra/venta a red

Estado (vector mínimo en t):

$$S_t = \left(\mathrm{SoC}_t,\ \tilde{G}_t,\ \tilde{L}_t,\ p_t\right),$$

donde $\tilde{G}_t$ (recurso solar) y $\tilde{L}_t$ (demanda) son entradas exógenas estocásticas (p.ej. Markov o AR).
Eventos/actualización (modelo dinámico en pasos Δt):

$$\mathrm{SoC}_{t+1} = \mathrm{SoC}_t + \eta_{\mathrm{ch}} P_t^{\mathrm{ch}} \Delta t - \frac{1}{\eta_{\mathrm{dis}}} P_t^{\mathrm{dis}} \Delta t.$$

Decisiones y métricas:

$$a_t = (P_t^{\mathrm{ch}}, P_t^{\mathrm{dis}}, P_t^{\mathrm{grid}}), \qquad J = \mathbb{E}\Big[\sum_t p_t\, P_t^{\mathrm{grid}} \Delta t + \lambda\, \mathrm{ENS}_t\Big].$$

Ejemplo de sistema 2: Centro de distribución (fulfillment) con picking y packing

Propósito del estudio: dimensionar recursos y política de asignación para reducir tiempo de ciclo y atrasos.

Entidades:

- **Órdenes** (jobs), **operarios** (pickers/packers), **estaciones** (picking/packing), **racks** y **transportador** (si aplica).

Atributos:

- Orden i: tamaño n_i, prioridad π_i, fecha promesa d_i, zona(s) de picking.
- Operario k: velocidad v_k, habilidad, ubicación $loc_k(t)$.
- Estación m: capacidad (1 servidor), tasa de servicio dependiente del trabajo $T_m(\cdot)$.

Ejemplo de sistema 2: Centro de distribución (fulfillment) con picking y packing

Estado (DES: simulación de eventos discretos):

$$S(t) = \Big(Q^{\text{pick}}(t),\ Q^{\text{pack}}(t),\ \{loc_k(t)\}_k,\ \{b_m(t)\}_m\Big),$$

donde $Q^{\text{pick}}, Q^{\text{pack}}$ son colas y $b_m(t) \in \{0,1\}$ indica si la estación m está ocupada.

Eventos (saltos en el estado):

- Llegada de orden, inicio/fin de picking, traslado entre zonas, inicio/fin de packing, despacho.

Reglas de decisión (políticas):

$$a(t) = \text{asignación}(\text{orden} \to \text{operario/estación}) \quad \text{(p.ej. FIFO, prioridad, batching).}$$

Métricas de desempeño:

$$\text{CycleTime}_i = C_i - A_i, \quad \text{Tardiness}_i = (C_i - d_i)_+, \quad \mathbb{E}[\text{WIP}(t)],\ \mathbb{P}(\text{atraso} > 0).$$

Sistemas: Determinísticos vs. Estocásticos

Determinístico

- Sin aleatoriedad (o aleatoriedad despreciada).
- Misma entrada $\Rightarrow$ misma salida.
- Modelo: $Y = f(x)$.
- Útil si la variabilidad es irrelevante para la decisión.

Estocástico

- Al menos una variable aleatoria relevante.
- Salidas son variables aleatorias.
- Modelo: $Y = f(x, \xi)$, con ξ aleatoria.
- Requiere inferencia estadística (promedios, intervalos, riesgo).

Formalismo mínimo: ¿qué significa "aleatorio"?

Trabajamos sobre un espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{P})$.

- Una **entrada aleatoria** es una función $\xi : \Omega \to \mathbb{R}^d$.
- Un **resultado de interés** es $Y = g(x, \xi)$ (p.ej. costo, utilidad, tiempo).
- En simulación, buscamos típicamente **esperanzas**:

$$\mathbb{E}[Y] = \int_\Omega g(\xi(\omega))\, d\mathbb{P}(\omega).$$

Idea central

La simulación reemplaza integrales/esperanzas difíciles por promedios muestrales.

Ejemplo 1 (básico): lanzar una moneda

Experimento aleatorio: lanzar una moneda una vez.

Espacio de resultados:

$$\Omega = \{C, S\} \quad \text{(Cara, Sello)}.$$

Evento: $\{C\} \in \mathcal{F}$ ("sale cara"). **Probabilidad:** $\mathbb{P}(C) = p,\ \mathbb{P}(S) = 1 - p$.

Entrada aleatoria (variable aleatoria):

$$\xi : \Omega \to \mathbb{R}, \qquad \xi(C) = 1,\ \xi(S) = 0.$$

Interpretación: ξ codifica el resultado del experimento en un número.

Resultado de interés: $Y = g(\xi)$. Por ejemplo, "ganancia":

$$g(x) = 2x - 1 \quad \Rightarrow \quad Y = \begin{cases} +1, & \text{si sale cara} \\ -1, & \text{si sale sello.} \end{cases}$$

Ejemplo 1 (básico): lanzar una moneda

Esperanza (promedio teórico):

$$\mathbb{E}[Y] = \sum_{\omega \in \Omega} g(\xi(\omega))\, \mathbb{P}(\omega) = (+1)\, p + (-1)(1-p) = 2p - 1.$$

Pregunta

Si la expresión del valor esperado es muy díficil de cálcular que hacemos?.

Ejemplo 2: demanda aleatoria y costo de inventario

Situación: mañana la demanda D puede ser baja o alta.

Espacio de resultados:

$$\Omega = \{\text{baja},\ \text{alta}\}.$$

Probabilidades: $\mathbb{P}(\text{alta}) = 0{,}3$, $\mathbb{P}(\text{baja}) = 0{,}7$.

Entrada aleatoria:

$$\xi : \Omega \to \mathbb{R}, \qquad \xi(\text{baja}) = 80,\ \xi(\text{alta}) = 120.$$

Aquí ξ es literalmente la demanda aleatoria D.

Decisión fija: ordenar $Q = 100$ unidades.

Resultado de interés (costo por faltantes):

$$Y = g(\xi) = c_s\,(\xi - Q)_+, \qquad (x)_+ = \text{máx}\{x, 0\}, \qquad c_s = 10.$$

Interpretación: si la demanda supera Q, pagas 10 por cada unidad que faltó; si no, el costo es 0.

Ejemplo 2: demanda aleatoria y costo de inventario

Situación: mañana la demanda D puede ser baja o alta.

Esperanza (promedio teórico):

$$\mathbb{E}[Y] = \sum_{\omega \in \Omega} g(\xi(\omega))\, \mathbb{P}(\omega) = 0 \cdot 0{,}7 + \big(10(120 - 100)\big) \cdot 0{,}3 = 60.$$

Pregunta

De que otra manera abordariamos esta situación?.

¿Por qué fallan los modelos "promedio"? (Jensen)

Punto matemático

Para X aleatoria y f no lineal, en general:

$$\mathbb{E}[f(X)] \neq f(\mathbb{E}[X]).$$

Jensen:

- Si f es **convexa**: $\mathbb{E}[f(X)] \geq f(\mathbb{E}[X])$.
  Lectura típica: costos/penalizaciones convexas $\Rightarrow$ usar promedios **subestima** costo/riesgo.
- Si f es **cóncava**: $\mathbb{E}[f(X)] \leq f(\mathbb{E}[X])$.
  Lectura típica: utilidades con saturación/capacidad $\Rightarrow$ usar promedios **sobreestima** ganancia.

Ejemplo concreto de Jensen (convexa y cóncava, con números)

Sea X una variable aleatoria con dos posibles valores:

$$X = \begin{cases} 0 & \text{con prob. } 0{,}5, \\ 2 & \text{con prob. } 0{,}5. \end{cases} \qquad \Rightarrow \qquad \mathbb{E}[X] = 1.$$

Caso 1: f convexa (costo)
Tome $f(x) = x^2$.

$$\mathbb{E}[f(X)] = \mathbb{E}[X^2] = 0{,}5(0^2) + 0{,}5(2^2) = 2.$$
$$f(\mathbb{E}[X]) = (\mathbb{E}[X])^2 = 1^2 = 1.$$

Conclusión

$$\mathbb{E}[X^2] = 2 \ > \ 1 = (\mathbb{E}[X])^2.$$

Si el "costo" crece de forma convexa (p.ej. penalización por retraso), usar el promedio ($X = 1$) **subestima** el costo real esperado.

Caso 2: f cóncava (ganancia)
Tome $f(x) = \sqrt{x}$.

$$\mathbb{E}[f(X)] = \mathbb{E}[\sqrt{X}] = 0{,}5\sqrt{0} + 0{,}5\sqrt{2} = 0{,}707.$$
$$f(\mathbb{E}[X]) = \sqrt{\mathbb{E}[X]} = \sqrt{1} = 1.$$

Conclusión

$$\mathbb{E}[\sqrt{X}] = 0{,}707 \ < \ 1 = \sqrt{\mathbb{E}[X]}.$$

Si la "ganancia" se satura (rendimientos decrecientes), usar el promedio **sobreestima** la ganancia esperada.

Definición de Simulación

> *"La simulación es la imitación de la operación de un proceso o sistema del mundo real a lo largo del tiempo."* — *Banks et al.*

Implica:

- generar una **historia artificial** del sistema (trayectorias, escenarios);
- observar esa historia para estimar métricas (promedios, cuantiles, probabilidades);
- entender que el resultado es **numérico** y **estadístico** (con error).

Video de apoyo

Video (YouTube): Simulación y aleatoriedad

Abrir el video en YouTube

https://www.youtube.com/watch?v=FCoLgj2ioJY

Cuándo es apropiada la simulación

1. El sistema es complejo (interacciones, restricciones, no linealidad).
2. Hay incertidumbre relevante (variabilidad afecta la decisión).
3. No hay solución analítica simple o ésta es frágil a supuestos.
4. Se desea experimentar con diseños/políticas sin costo real.
5. Se requiere estimar riesgo: $\mathbb{P}(Y > \tau)$, VaR, cuantiles, colas.

Cuándo NO es apropiada la simulación

1. El problema se resuelve con sentido común (o regla simple robusta).
2. Hay solución analítica directa y suficiente (p.ej. EOQ simple bajo supuestos fuertes).
3. Experimentar en el sistema real es más fácil/barato y seguro.
4. No hay datos mínimos ni forma razonable de elicitar supuestos.
5. El sistema no está bien definido: objetivos ambiguos, fronteras y métricas no claras.

Ejemplo mental: capacidad vs. variabilidad

Problema: planear capacidad C para cubrir demanda aleatoria D (energía, inventario, producción).

- Enfoque "promedio": fijar $C = \mathbb{E}[D]$ y concluir "faltantes esperados = 0".
- Realidad: el faltante es
$$L(D) = (D - C)_+ = \text{máx}\{D - C, 0\},$$
que es una función **convexa** de D.

Conclusión inmediata

Aunque $C = \mathbb{E}[D]$, se tiene $\mathbb{E}[(D - C)_+] > 0$ si $\mathrm{Var}(D) > 0$.

Cálculo explícito (Normal): faltante esperado positivo

Suponga $D \sim \mathcal{N}(\mu, \sigma^2)$ y planee $C = \mu$.

$$\mathbb{E}[(D-\mu)_+] = \sigma\,\varphi(0) = \frac{\sigma}{\sqrt{2\pi}},$$

donde φ es la pdf Normal estándar.

Ejemplo numérico: $\mu = 100$, $\sigma = 30$:

$$\mathbb{E}[(D-100)_+] \approx \frac{30}{\sqrt{2\pi}} \approx 11{,}97.$$

Lectura: "en promedio" faltan ≈ 12 unidades por periodo, aun cuando la capacidad iguala la media. Esto es **variabilidad pura + convexidad** (Jensen).

Ventajas de la simulación

- **Control del tiempo:** compresión/expansión temporal.
- **Control experimental:** comparar políticas con mismas realizaciones aleatorias (CRN).
- **Seguridad:** experimentar sin intervenir el sistema real.
- **Riqueza de métricas:** no solo medias, también cuantiles, colas y probabilidades.

Desventajas de la simulación

- Requiere habilidad en modelado, probabilidad y programación.
- Resultados son **estimaciones** (con error); interpretar requiere estadística.
- Construir un modelo **válido** toma tiempo (y datos).
- Riesgo de *"Garbage In, Garbage Out"*: supuestos malos producen conclusiones falsas.

El universo de la simulación: ¿qué significa "tipo" de simulación?

Un **tipo de simulación** nace de **cómo representamos la evolución del sistema**.

Decisión 1: ¿hay evolución temporal?

- **Simulación estática (sin tiempo):** el sistema se estudia en un "instante/escenario".
- **Simulación dinámica (con tiempo):** existe un estado $S(t)$ que cambia.

Decisión 2 (si es dinámica): ¿cómo cambia el estado?

- **Eventos discretos (DES):** $S(t)$ cambia solo cuando ocurre un evento (saltos).
- **Por pasos de tiempo:** $S_{t+1} = F(S_t, \dots)$ en periodos ($t = 0, 1, 2, \dots$).
- **Continuo:** $S(t)$ cambia continuamente (ecuaciones diferenciales).
- **Basada en agentes / híbrida:** reglas locales (agentes) y/o mezcla de mecanismos.

Idea clave

DES/continuo/pasos/agentes describen **la mecánica del modelo** (cómo evoluciona el sistema).

¿De dónde salen los tipos? (se crean al definir estado + tiempo)

Para construir un simulador siempre se hacen estas elecciones:

1. **Definir el estado** (variables mínimas para describir el sistema):

$$S(t) = (x_1(t), \ldots, x_n(t)).$$

2. **Definir la regla de evolución (el "reloj" del modelo):**
   - **DES:** el tiempo avanza al *siguiente evento* (llegada, fin de servicio, falla).
   - **Pasos:** el tiempo avanza en incrementos fijos Δt (hora a hora, día a día).
   - **Continuo:** el tiempo es continuo y $S(t)$ sigue una dinámica (ODE/SDE).
3. **Definir qué es aleatorio** (entradas inciertas):

$$\xi \text{ (demanda, tiempos, fallas, clima, comportamiento).}$$

4. **Definir qué se mide** (salida de interés):

$$Y = g(\text{modelo}, \xi) \quad \text{(costo, tiempo, utilidad, riesgo).}$$

Lectura

El **tipo** queda determinado por (estado + forma de avanzar el tiempo). La **incertidumbre** se incorpora en ξ.

¿Dónde entra Monte Carlo ?

Una vez definido el modelo (estático o dinámico), suele interesarnos una métrica **promedio o de riesgo**.

Preguntas típicas

$$\mathbb{E}[Y] \quad \text{(costo/tiempo/utilidad promedio)}, \qquad \mathbb{P}(Y > \tau) \quad \text{(riesgo)}, \qquad q_\alpha(Y) \quad \text{(percentiles)}.$$

Monte Carlo

Monte Carlo es el procedimiento de:

- generar muchas realizaciones de la incertidumbre $(\xi^{(1)}, \ldots, \xi^{(N)})$,
- obtener la salida en cada una $(Y^{(i)})$,
- y promediar/contar para estimar lo que queremos.

$$\mathbb{E}[Y] \approx \frac{1}{N} \sum_{i=1}^{N} Y^{(i)}.$$

¿Que veremos en el curso respecto a la simulación?

Lo que haremos en el curso

- **Simulación Monte Carlo** (escenarios/réplicas para estimar promedios y riesgo).
- **Simulación de eventos discretos (DES)** (modelos dinámicos cuyo estado cambia en eventos).

Caso de estudio: Newsvendor (vendedor de periódicos)

Decisión: escoger cantidad Q de producto perecedero para vender mañana.

- Costo por unidad: $c = 20$.
- Precio: $p = 50$.
- Salvamento: $s = 0$.

Demanda: D aleatoria. Suponga:

$$D \sim \mathcal{N}(\mu = 100, \sigma = 30).$$

Utilidad:

$$\Pi(D, Q) = p\,\text{mín}(D, Q) + s(Q - \text{mín}(D, Q)) - cQ = (p - s)\,\text{mín}(D, Q) + (s - c)Q.$$

Enfoque ingenuo: fijar demanda a la media

Heurística "promedio": asumir $D = \mu$ y pedir $Q = \mu = 100$.

$$\Pi(\mu, \mu) = (p - c)\mu = (50 - 20) \cdot 100 = 3000.$$

Problema

Ese número no es $\mathbb{E}[\Pi(D, Q)]$. Es la utilidad de un mundo sin incertidumbre (o con información perfecta).

Por qué la esperanza baja: concavidad en la demanda

Para Q fijo, $\Pi(D, Q)$ como función de D es:

$$\Pi(D, Q) = p\,\text{mín}(D, Q) - cQ,$$

una función **cóncava** en D (pendiente p hasta Q y luego pendiente 0).

Jensen aplicado

Como $\Pi(\cdot, Q)$ es cóncava:

$$\mathbb{E}[\Pi(D, Q)] \leq \Pi(\mathbb{E}[D], Q).$$

Lectura: el "promedio" tiende a **sobreestimar** ganancias cuando hay saturación/capacidad.

Solución analítica (óptimo estocástico)

En newsvendor clásico:

$$F(Q^\star) = \frac{p-c}{p-s} = \frac{50-20}{50-0} = 0{,}6.$$

Si $D \sim \mathcal{N}(\mu, \sigma^2)$,

$$Q^\star = \mu + \sigma z_{0,6}, \quad z_{0,6} \approx 0{,}2533 \Rightarrow Q^\star \approx 100 + 30(0{,}2533) \approx 107{,}6.$$

Interpretación: se ordena por encima de la media porque el costo de escasez (margen perdido) supera el costo de exceso.

Cálculo analítico rápido: $\mathbb{E}[\text{mín}(D, Q)]$ (Normal)

Sea $D \sim \mathcal{N}(\mu, \sigma^2)$ y defina $z = \frac{Q-\mu}{\sigma}$. Entonces:

$$\mathbb{E}[\text{mín}(D, Q)] = \mu\Phi(z) - \sigma\varphi(z) + Q\big(1 - \Phi(z)\big),$$

donde Φ y φ son la cdf/pdf de la Normal estándar.

Con $\mu = 100$, $\sigma = 30$, $Q = 100$ ($z = 0$):

$$\mathbb{E}[\text{mín}(D, 100)] = 100 - 30\varphi(0) \approx 100 - 30(0{,}3989) \approx 88{,}03.$$

Por tanto:

$$\mathbb{E}[\Pi(D, 100)] = p\,\mathbb{E}[\text{mín}(D, 100)] - c \cdot 100 \approx 50(88{,}03) - 2000 \approx 2401{,}6.$$

Métricas estándar: EEV, RP, VSS, EVPI

Definiciones (clásicas en programación estocástica):

- **EEV:** evaluar la solución del "valor esperado" (aquí $Q = \mu = 100$):

$$\text{EEV} = \mathbb{E}[\Pi(D, 100)] \approx 2401{,}6.$$

- **RP:** valor óptimo estocástico (aquí $Q^\star \approx 107{,}6$):

$$\text{RP} = \mathbb{E}[\Pi(D, Q^\star)] \approx 2420{,}5.$$

- **VSS:** valor de resolver el problema estocástico:

$$\text{VSS} = \text{RP} - \text{EEV} \approx 18{,}9.$$

- **EVPI:** valor de información perfecta:

$$\text{EVPI} = \mathbb{E}\big[\operatorname*{máx}_Q \Pi(D, Q)\big] - \text{RP}.$$

  Con información perfecta y $s = 0$, $\operatorname{máx}_Q \Pi(D, Q) = (p - c)D$, así $\mathbb{E}[(p - c)D] = 3000$ y $\text{EVPI} \approx 3000 - 2420{,}5 \approx 579{,}5$.

Diagrama de flujo (Monte Carlo)

Para $i = 1, \ldots, N$:

1. Generar $d_i \sim \mathcal{N}(100, 30)$ (o variante factible no-negativa).
2. Calcular ventas $v_i = \text{mín}(d_i, Q)$.
3. Calcular utilidad $\pi_i = pv_i - cQ$.

Estimador:

$$\widehat{\mathbb{E}[\Pi]} = \bar{\pi}_N = \frac{1}{N} \sum_{i=1}^{N} \pi_i.$$

Error estadístico (CLT)

$$\bar{\pi}_N \pm z_{0,975} \frac{s_\pi}{\sqrt{N}}$$

da un intervalo de confianza aproximado al 95 %.

Implementación en Python: simulación + chequeo analítico

```python
import numpy as np
from math import erf, sqrt, pi, exp

# Parametros del problema
mu, sigma = 100.0, 30.0
p, c = 50.0, 20.0
Q = 100.0
N = 10000

# Normal estandar: pdf y cdf (sin SciPy, autocontenido)
def phi(z):
    return exp(-0.5*z*z) / sqrt(2*pi)

def Phi(z):
    return 0.5*(1.0 + erf(z/sqrt(2.0)))

# ---- Calculo analitico rapido: E[min(D,Q)] ----
z = (Q - mu)/sigma
E_sales = mu*Phi(z) - sigma*phi(z) + Q*(1.0 - Phi(z))
E_profit = p*E_sales - c*Q

print("E[ventas] analitico:", E_sales)
print("E[utilidad] analitico:", E_profit)
```

Implementación en Python: simulación + chequeo analítico

```python

# ---- Monte Carlo ----
np.random.seed(42)
D = np.random.normal(mu, sigma, N)

# Si se requiere factibilidad no-negativa:
# (El recorte afecta poco porque P(D<0) es muy pequena con mu=100,sigma=30)
D = np.clip(D, 0.0, None)

sales = np.minimum(D, Q)
profit = p*sales - c*Q
```

Implementación en Python: estimación + intervalo de confianza

```python
# Estimacion Monte Carlo
profit_mean = profit.mean()
profit_std  = profit.std(ddof=1)

# IC 95% por CLT: mean +/- 1.96 * s/sqrt(N)
half_width = 1.96 * profit_std / np.sqrt(N)

prob_loss = np.mean(profit < 0.0)

print(f"MC mean: {profit_mean:.2f}  (IC95% +/- {half_width:.2f})")
print(f"Prob(perder dinero): {prob_loss:.4f}")

# Comparacion con "mundo sin incertidumbre" (D=mu, Q=mu)
profit_no_uncertainty = (p - c) * mu
print(f"Utilidad sin incertidumbre (benchmark): {profit_no_uncertainty:.2f}")
print(f"Gap vs MC mean: {profit_no_uncertainty - profit_mean:.2f}")
```

Resultados

Con los parámetros $\mu = 100, \sigma = 30, Q = 100, p = 50, c = 20$:

- **Benchmark sin incertidumbre:** $\Pi(\mu, \mu) = (p - c)\mu = 3000$.
- **Esperanza analítica:** $\mathbb{E}[\Pi(D, 100)] \approx 2401{,}6$.
- **Monte Carlo típico (semilla 42, $N = 10^4$):**

$$\widehat{\mathbb{E}[\Pi]} \approx 2399{,}0 \quad \text{con IC95 \%} \ \pm 17{,}2.$$

- **Pérdida:** $\mathbb{P}(\Pi < 0) = \mathbb{P}(D < 40) \approx \Phi(-2) \approx 0{,}0228$ (coincide con MC $\approx 0{,}023$).

Mensaje

El promedio "optimista" (3000) ignora saturación y riesgo a la baja; la ganancia esperada real cae cerca de ~ 2400 (brecha ~ 600, $\sim 20\,\%$).

Visualización de la distribución de utilidades

```python
import matplotlib.pyplot as plt

plt.figure(figsize=(10,6))
plt.hist(profit, bins=40, alpha=0.8, edgecolor='black')
plt.axvline(profit_mean, linestyle='dashed', linewidth=2,
            label=f'Media MC: {profit_mean:.0f}')
plt.axvline(E_profit, linestyle='dashed', linewidth=2,
            label=f'Media analitica: {E_profit:.0f}')
plt.axvline((p-c)*mu, linestyle='dashed', linewidth=2,
            label='Benchmark sin incertidumbre: 3000')
plt.title('Distribucion de utilidades (Q=100)')
plt.xlabel('Utilidad')
plt.ylabel('Frecuencia')
plt.legend()
plt.show()
```

Interpretación (qué mirar en el histograma)

- **Truncamiento a la derecha:** para $D > Q$ las ventas se saturan en Q y la utilidad se "aplana".
- **Cola izquierda:** eventos de demanda baja generan utilidades mucho menores; esa asimetría reduce la media.
- **Error Monte Carlo:** el ancho del IC decrece como $O(1/\sqrt{N})$; pedir más precisión requiere muchas más corridas.

Preguntas guía:

- ¿Qué pasa con la media si σ sube a 50?
- ¿Cómo cambia $Q^\star$ cuando cambia $(p - c)$ o $(c - s)$?

Ejercicio: ¿Dónde está la incertidumbre? (identificar variables aleatorias)

En cada situación, responda **tres cosas**:

(i) ¿Qué es aleatorio? (ii) ¿Qué se observa? (iii) ¿Qué métrica importa?

1. **Cafetería:** llegan estudiantes y hay 1 caja. A veces se forma fila.
2. **Inventario:** una tienda decide Q unidades para mañana; no sabe cuántas venderá.
3. **Transporte:** un mensajero tarda distinto según tráfico.

Ejercicio: Modelar la incertidumbre (Casos A–D)

Caso A

En una ventanilla, atender a un cliente siempre requiere completar **tres pasos consecutivos** (verificar datos, registrar, confirmar pago). Cada paso toma tiempo positivo y el tiempo total observado suele concentrarse alrededor de un valor típico, con variabilidad moderada.

Caso B

En un punto de información, los visitantes llegan sin coordinación. A veces llegan varios casi seguidos; otras veces hay pausas. El tiempo entre llegadas es siempre positivo y no se observa un "máximo" claro.

Caso C

Durante cada hora, un call center registra un **número de llamadas entrantes**. Se trata de un conteo (0,1,2,...) y el equipo quiere modelar cuántas llamadas llegan por hora para dimensionar turnos.

Caso D

Una empacadora llena bolsas con una máquina calibrada a 500 g. El peso final varía ligeramente por vibraciones y tolerancias: algunas bolsas quedan por encima y otras por debajo; la mayoría queda cerca del objetivo y los extremos son poco frecuentes.

Ejercicio: Modelar la incertidumbre (Casos E–H)

Caso E

El tiempo de reparación de un equipo suele ser corto cuando el diagnóstico es directo, pero ocasionalmente se alarga mucho por espera de repuesto, recalibración o retrabajo. La variable es positiva y se observan pocos valores muy grandes.

Caso F

Se estudia la vida útil de un componente que se degrada con el uso. Al inicio casi no falla, pero a medida que envejece la probabilidad de falla aumenta. Se registra el tiempo hasta falla (positivo) para planear mantenimiento.

Caso G

Un bus interno recorre siempre la misma ruta dentro del campus. Por restricciones de distancia, velocidad y semáforos, el tiempo de viaje está siempre entre 12 y 18 minutos, y no hay evidencia clara de que algún valor dentro del rango sea "especialmente más probable".

Caso H

Para una actividad de proyecto (instalar un módulo), un experto da tres estimaciones: **optimista** (si todo sale perfecto), **más probable** (lo usual) y **pesimista** (si aparece un problema común). Se quiere modelar la duración con esa información.

Ejercicio: distinguir *variables* vs *parámetros* (y qué es aleatorio)

Objetivo: en cada situación, clasifique cada símbolo en una de estas categorías:

(V) variable de decisión/estado **(PA)** parámetro aleatorio (variable aleatoria) **(PD)** parámetro determinístico

Situación 1: Inventario (un solo día)

Una tienda decide Q unidades para mañana. La demanda del día es D. Precio $p = 50$, costo $c = 20$, salvamento $s = 0$. Utilidad: $\Pi(D, Q) = p\,\text{mín}(D, Q) + s(Q - \text{mín}(D, Q)) - cQ$.
Clasifique: $Q,\ D,\ p,\ c,\ s,\ \Pi(D, Q)$.

Situación 2: Caja de supermercado (servicio)

Llegan clientes. El tiempo entre llegadas es A (min) y el tiempo de servicio es S (min). El sistema tiene una sola caja.
Clasifique: $A,\ S,\ \lambda,\ \mu,\ \rho,\ N(t)$, donde:

- λ = tasa promedio de llegadas (clientes/min),
- μ = tasa promedio de servicio (clientes/min),
- $\rho = \lambda/\mu$ = utilización,
- $N(t)$ = número de clientes en el sistema en el tiempo t.

Referencias bibliográficas

- Banks, J., Carson, J. S., Nelson, B. L., & Nicol, D. M. (2010). *Discrete-Event System Simulation*. Prentice Hall.
- Law, A. M. (2015). *Simulation Modeling and Analysis*. McGraw-Hill.
- Kulkarni, V. G. (2011). *Introduction to Modeling and Analysis of Stochastic Systems*. Springer.
- Ross, S. M. (2013). *Simulation*. Academic Press. (Monte Carlo, CLT, intervalos)