Simulación Monte Carlo: estimación, error y distribución de salida

Alejandra Tabares Pozos
Universidad de los Andes
Departamento de Ingeniería Industrial

¿Dónde encaja Monte Carlo en lo que ya vimos?

Recordatorio conceptual (de la clase anterior)

Modelamos incertidumbre con una entrada aleatoria ξ y definimos un resultado de interés

$$Y = g(\xi).$$

En problemas reales, el "cálculo exacto" suele ser una integral o esperanza:

$$\mathbb{E}[Y] = \int_{\Omega} g(\xi(\omega))\, d\mathbb{P}(\omega).$$

La idea de Monte Carlo

Reemplazar una esperanza difícil por un promedio muestral construido a partir de réplicas del experimento aleatorio.

En esta clase vamos a hacer explícitas tres capas: *(i) qué se estima*, *(ii) con qué error*, y *(iii) qué nos dice la distribución de salida (no solo la media)*.

Qué es una réplica

Una **réplica** es una realización independiente de la entrada aleatoria ξ:

$$\xi^{(1)}, \xi^{(2)}, \ldots, \xi^{(N)} \quad \text{i.i.d.}$$

y produce una colección de salidas:

$$Y_i = g\left(\xi^{(i)}\right), \qquad i = 1, \ldots, N.$$

Cada Y_i es un número (una "corrida") pero, como $\xi^{(i)}$ es aleatoria, Y_i también lo es.

Qué es un estimador

Si el parámetro de interés es $\mu = \mathbb{E}[Y]$, el estimador Monte Carlo es el promedio:

$$\widehat{\mu}_N = \frac{1}{N} \sum_{i=1}^{N} Y_i.$$

Definición (operativa)

La **simulación Monte Carlo** es un método numérico que aproxima cantidades probabilísticas (*esperanzas, probabilidades, cuantiles*) mediante **muestreo repetido** del modelo aleatorio.

Marco matemático: sea ξ una entrada aleatoria y $Y = g(\xi)$ la salida (costo, tiempo, utilidad). Queremos una cantidad como θ:

$$\theta \in \Big\{ \mathbb{E}[Y],\ \mathbb{P}(Y > \tau),\ q_\alpha(Y) \Big\}.$$

Principio de Monte Carlo

Generar réplicas i.i.d. $\xi^{(1)}, \ldots, \xi^{(N)}$ y calcular $Y_i = g(\xi^{(i)})$. Luego reemplazar la cantidad teórica por su análogo muestral:

$$\mathbb{E}[Y] \approx \widehat{\mu}_N = \frac{1}{N}\sum_{i=1}^{N} Y_i, \qquad \mathbb{P}(Y > \tau) \approx \frac{1}{N}\sum_{i=1}^{N} 1\{Y_i > \tau\}, \qquad q_\alpha(Y) \approx Y_{(\lceil \alpha N \rceil)}.$$

Esqueleto del método

Para estimar $\mathbb{E}[g(\xi)]$:

1. Especificar el modelo probabilístico de ξ (distribuciones y parámetros).
2. Repetir N veces: generar $\xi^{(i)}$ y calcular $Y_i = g(\xi^{(i)})$.
3. Reportar $\widehat{\mu}_N$ y una medida de error (IC o error estándar).

Tres salidas típicas (no solo medias)

A partir de $\{Y_i\}$, usualmente queremos:

$$\mathbb{E}[Y], \qquad \mathbb{P}(Y > \tau), \qquad q_\alpha(Y) \text{ (percentiles).}$$

La misma nube de simulaciones sirve para las tres, pero *la precisión no cuesta igual*.

Punto probabilístico central

Como $Y = g(\xi)$ es una variable aleatoria, tiene una distribución inducida:

$$F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}\big(g(\xi) \leq y\big).$$

.

Qué estima Monte Carlo además de la media

Con una muestra $\{Y_i\}$ podemos construir la **distribución empírica**:

$$\widehat{F}_N(y) = \frac{1}{N} \sum_{i=1}^{N} 1\{Y_i \leq y\}.$$

De ella salen naturalmente probabilidades $\widehat{\mathbb{P}}(Y > \tau) = 1 - \widehat{F}_N(\tau)$ y cuantiles por ordenamiento.

Mensaje

La media resume; la distribución explica (riesgo, colas, percentiles). En Monte Carlo, *la distribución de salida es parte del producto*.

Ejemplo numérico (1 día): demanda incierta $\Rightarrow$ costo por faltante

Decisión fija: ordenar $Q = 100$ unidades. **Costo por faltante:** $c_s = 10$.

Modelo probabilístico de la entrada

La demanda D toma dos valores (dos escenarios):

$$D = \begin{cases} 80 & \text{con prob. } 0.7, \\ 120 & \text{con prob. } 0.3. \end{cases}$$

Esto define la entrada aleatoria $\xi := D$.

Salida (función del azar): $Y = g(\xi)$

Definimos el costo por faltante:

$$Y = g(D) = c_s(D - Q)_+ = 10\,\text{máx}\{D - 100, 0\}.$$

Así, si $D = 80$ entonces $Y = 0$; si $D = 120$ entonces $Y = 10 \cdot 20 = 200$.

Una réplica es un sorteo independiente de D (y por tanto de $Y = g(D)$).

Diez réplicas (simulación manual)

i	1	2	3	4	5	6	7	8	9	10
$D^{(i)}$	80	120	80	80	120	80	80	120	80	80
$Y_i = 10(D^{(i)} - 100)_+$	0	200	0	0	200	0	0	200	0	0

Estimador Monte Carlo de la media

$$\widehat{\mu}_{10} = \frac{1}{10}\sum_{i=1}^{10} Y_i = \frac{0+200+0+0+200+0+0+200+0+0}{10} = \frac{600}{10} = 60.$$

Lectura

Con pocas réplicas el estimador puede variar, pero ya vemos el mecanismo: *repetir y promediar*.

Definición de Monte Carlo (en el ejemplo): media, probabilidad y cuantil

En este ejemplo, la nube $\{Y_i\}_{i=1}^N$ permite estimar varias cantidades:

(1) Media: costo esperado

$$\mathbb{E}[Y] \approx \widehat{\mu}_N = \frac{1}{N}\sum_{i=1}^{N} Y_i.$$

Con $N = 10$: $\widehat{\mu}_{10} = 60$.

(2) Probabilidad: "día con costo alto"

Para un umbral $\tau = 0$, por ejemplo:

$$\mathbb{P}(Y > 0) \approx \widehat{\pi}_N = \frac{1}{N}\sum_{i=1}^{N} 1\{Y_i > 0\}.$$

En la tabla, hay 3 valores de 200 entre 10: $\widehat{\pi}_{10} = 3/10 = 0.3$.

Definición de Monte Carlo (en el ejemplo): media, probabilidad y cuantil

(3) Cuantil: percentil α

Ordenamos $Y_{(1)} \leq \cdots \leq Y_{(N)}$ y definimos

$$\widehat{q}_\alpha = Y_{(\lceil \alpha N \rceil)}.$$

Con $N = 10$, el cuantil 0.9 es $Y_{(\lceil 9 \rceil)} = Y_{(9)} = 200$.

Algoritmo Monte Carlo (mapeado al ejemplo)

Paso 1: especificar el modelo de ξ

Aquí $\xi = D$ con dos escenarios (80 con 0.7; 120 con 0.3).

Paso 2: repetir (generar y evaluar)

Para $i = 1, \ldots, N$:

1. Generar $D^{(i)} \in \{80, 120\}$ según las probabilidades dadas.
2. Calcular $Y_i = g(D^{(i)}) = 10(D^{(i)} - 100)_+$.

Paso 3: reportar estimaciones

$$\widehat{\mathbb{E}[Y]} = \widehat{\mu}_N, \qquad \widehat{\mathbb{P}}(Y > \tau) = \widehat{\pi}_N, \qquad \widehat{q}_\alpha = Y_{(\lceil \alpha N \rceil)}.$$

Distribución verdadera en este ejemplo

Como $Y = g(D)$ toma solo dos valores:

$$Y = \begin{cases} 0 & \text{con prob. } 0.7, \\ 200 & \text{con prob. } 0.3, \end{cases}$$

la cdf verdadera es

$$F_Y(y) = \mathbb{P}(Y \leq y) = \begin{cases} 0, & y < 0, \\ 0.7, & 0 \leq y < 200, \\ 1, & y \geq 200. \end{cases}$$

Distribución empírica con $N = 10$ (de la tabla)

$$\widehat{F}_{10}(y) = \frac{1}{10} \sum_{i=1}^{10} 1\{Y_i \leq y\}.$$

En nuestra muestra: hay 7 ceros y 3 doses-cientos. Entonces

$$\widehat{F}_{10}(y) = \begin{cases} 0, & y < 0, \\ 0.7, & 0 \leq y < 200, \\ 1, & y \geq 200, \end{cases}$$

Dos cosas aleatorias distintas

1) La distribución del sistema (salida)

$$Y = g(\xi) \quad \Rightarrow \quad F_Y(y) = \mathbb{P}(Y \leq y).$$

Esto describe **qué tan variable es el resultado** (colas, percentiles, riesgo).

2) La distribución del estimador (error por muestreo)

Cuando calculamos

$$\widehat{\mu}_N = \frac{1}{N} \sum_{i=1}^{N} Y_i,$$

$\widehat{\mu}_N$ **también es aleatorio**, porque depende de la muestra. Su distribución (si repitiéramos el experimento completo muchas veces) se llama *distribución de muestreo* de $\widehat{\mu}_N$.

Monte Carlo produce una **muestra de** Y (para estimar F_Y) y, al mismo tiempo, produce un **estimador** (para estimar $\mu = \mathbb{E}[Y]$) con error.

LLN (consistencia del promedio)

Si $Y_1, \ldots, Y_N$ son i.i.d. y $\mathbb{E}[|Y|] < \infty$, entonces:

$$\widehat{\mu}_N \xrightarrow{a.s.} \mu = \mathbb{E}[Y] \qquad (N \to \infty).$$

Qué NO te da la LLN

LLN no te dice:

- **cuánto puede estar errado** $\widehat{\mu}_N$ para un N concreto,
- ni cómo construir una "barra de error" con cobertura 95 %.

Para eso necesitamos el **Teorema Central del Límite**.

Lectura

LLN: "si simulas mucho, te acercas". Pero no cuantifica el *tamaño típico del error*.

CLT (forma operativa)

Si $Y_1, \ldots, Y_N$ son i.i.d., $\mathbb{E}[Y] = \mu$ y $\mathrm{Var}(Y) = \sigma_Y^2 < \infty$, entonces

$$\frac{\sqrt{N}\,(\widehat{\mu}_N - \mu)}{\sigma_Y} \Rightarrow \mathcal{N}(0,1).$$

Equivalentemente (para N grande):

$$\widehat{\mu}_N \approx \mathcal{N}\left(\mu, \frac{\sigma_Y^2}{N}\right).$$

Por qué siempre aparece $1/\sqrt{N}$

$$\mathrm{Var}(\widehat{\mu}_N) = \frac{\sigma_Y^2}{N} \quad \Rightarrow \quad \mathrm{SE}(\widehat{\mu}_N) = \frac{\sigma_Y}{\sqrt{N}}.$$

Intervalo de confianza: qué cubre (y qué NO cubre)

IC 95 % para la media $\mu = \mathbb{E}[Y]$ (por CLT)

Aproximadamente,

$$\mathbb{P}\left(|\widehat{\mu}_N - \mu| \leq 1.96\,\frac{\sigma_Y}{\sqrt{N}}\right) \approx 0.95.$$

Como σ_Y es desconocida, usamos s_Y (desviación muestral):

$$\boxed{\mu \in \widehat{\mu}_N \pm 1.96\,\frac{s_Y}{\sqrt{N}}} \qquad \text{(aprox. 95 \%)}$$

Distinción crítica

Este IC es sobre μ, no sobre un resultado individual Y.

- IC: incertidumbre del **estimador** (promedio).
- Percentiles/histograma: incertidumbre y forma de la **salida** Y.

Mini-ejemplo numérico (mismo de la simulación a mano): ahora con error

En el ejemplo: $Y \in \{0, 200\}$ con $\mathbb{P}(Y = 200) = 0.3$.

La verdad (para entender qué estima MC)

$$\mu = \mathbb{E}[Y] = 0 \cdot 0.7 + 200 \cdot 0.3 = 60.$$
$$\sigma_Y^2 = \mathrm{Var}(Y) = \mathbb{E}[Y^2] - \mu^2 = (200^2) \cdot 0.3 - 60^2 = 12000 - 3600 = 8400.$$
$$\sigma_Y = \sqrt{8400} \approx 91.65.$$

Qué predice CLT sobre el error para un N dado

$$\mathrm{SE}(\widehat{\mu}_N) = \frac{\sigma_Y}{\sqrt{N}}.$$

Por ejemplo, si $N = 10$:

$$\mathrm{SE}(\widehat{\mu}_{10}) \approx \frac{91.65}{\sqrt{10}} \approx 29.0, \quad \Rightarrow \quad \text{IC95 \% ancho } \approx \pm 1.96(29.0) \approx \pm 56.8.$$

Con $N = 10$ es *normal* ver promedios que fluctúan bastante: LLN dice "converge"; CLT cuantifica **cuánto** y por qué baja como $1/\sqrt{N}$.

Cómo se lee el producto de Monte Carlo (dos salidas, dos preguntas)

Salida A: distribución empírica $\widehat{F}_N$ (riesgo)

De la muestra $\{Y_i\}$:

$$\widehat{F}_N(y) = \frac{1}{N}\sum_{i=1}^{N} 1\{Y_i \le y\} \Rightarrow \widehat{\mathbb{P}}(Y > \tau),\ \widehat{q}_\alpha,\ \text{histograma}.$$

Pregunta que responde: **¿cómo se comporta el sistema?** (colas, percentiles, eventos raros).

Salida B: IC para μ (precisión del promedio)

$$\widehat{\mu}_N \pm 1.96\,\frac{s_Y}{\sqrt{N}}.$$

Pregunta que responde: **¿qué tan confiable es mi estimación de la media?**

No mezclamos objetos: *distribución de salida* describe al sistema; *IC* describe el error del estimador.

Ejemplo 2: costo por atraso en una intervención

Piense en una **intervención técnica** (mantenimiento correctivo/instalación) para devolver un activo a operación. Hay una **fecha compromiso** (SLA) y una **penalización** si la intervención termina tarde.

Entrada aleatoria: dos fuentes de incertidumbre

$$\xi = (L, S),$$

donde:

- $L =$ **retraso logístico** (repuesto, permiso, transporte): $L > 0$ y con **cola derecha** (ocasionalmente se demora mucho).
- $S =$ **tiempo en sitio** (diagnóstico + reparación): $S > 0$, típicamente suma de varias etapas.

Modelo probabilístico usado en la simulación (independencia como primer supuesto)

$$\log L \sim \mathcal{N}(\mu_{\log}, \sigma^2_{\log}), \quad \sigma_{\log} = 0.30, \quad \mathbb{E}[L] = 2.3 \;\Rightarrow\; \mu_{\log} = \ln(2.3) - \tfrac{1}{2}(0.30)^2 \approx 0.788,$$

$$S \sim \mathrm{Gamma}(k, \theta), \quad k = 3,\ \theta = 1 \;\Rightarrow\; \mathbb{E}[S] = k\theta = 3.$$

(Así, *en promedio* $T = L + S$ está cerca de $2.3 + 3 = 5.3$.)

Salida (duración y costo)

$$T = L + S, \qquad Y = g(\xi) = c_0 + c_d\,(T - d)_+, \qquad (x)_+ = \text{máx}\{x, 0\},$$

con números:

$$d = 6, \qquad c_0 = 10{,}000, \qquad c_d = 2{,}000 \;\; \text{(costo por unidad de atraso)}.$$

Como $(T - d)_+$ es **no lineal**, Y queda con **masa en** c_0 (si $T \le d$) y **cola derecha** (si $T > d$): muchos escenarios sin penalización y pocos escenarios con penalizaciones grandes. En clase estimaremos no solo $\mathbb{E}[Y]$, sino también $\mathbb{P}(T > d)$ y cuantiles de Y usando $N = 150{,}000$ réplicas (semilla 7).

Distribución de salida: histograma de Y (lo que Monte Carlo *produce*)

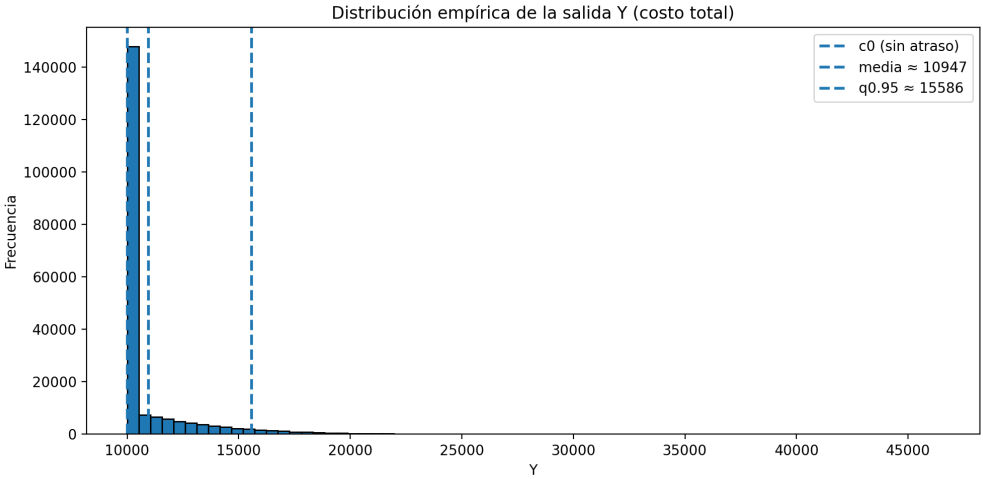

Mensaje conceptual

En Monte Carlo, el resultado no es solo $\widehat{\mathbb{E}[Y]}$; también es una aproximación a la **distribución inducida** de $Y = g(\xi)$ (y por tanto a su **riesgo**).

Distribución de salida: CDF empírica y cuantiles (VaR como cuantil)

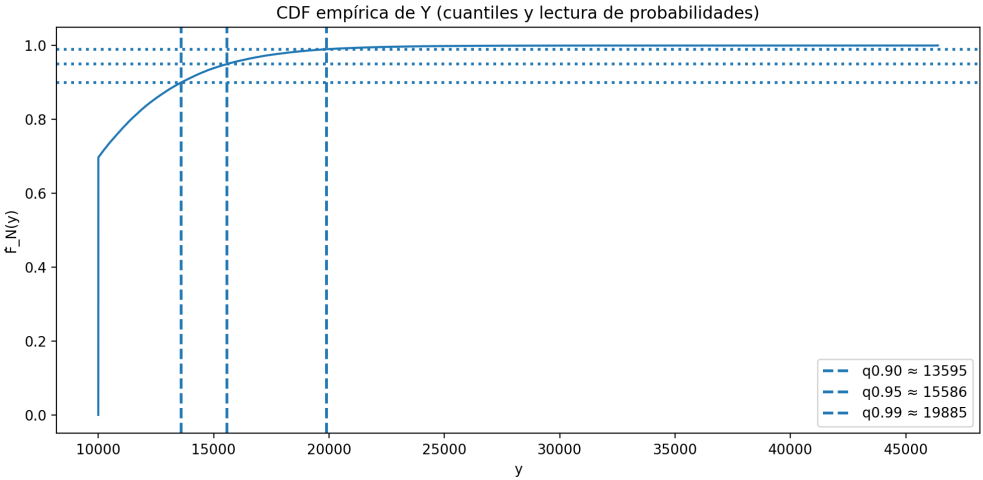

Interpretación

La CDF empírica $\widehat{F}_N(y)$ permite leer directamente:

$$q_{0.90}(Y),\ q_{0.95}(Y),\ \mathbb{P}(Y > \tau) = 1 - \widehat{F}_N(\tau).$$

En particular, $q_{0.95}(Y)$ es el **percentil 95** (en finanzas se le llama $\mathrm{VaR}_{0.95}$).

Parámetros usados en el ejemplo (días y costo):

$$d = 6, \quad c_0 = 10000, \quad c_d = 2000, \qquad L \sim \text{Lognormal}(\cdot, \sigma_{\log} = 0.3), \quad S \sim \text{Gamma}(k = 3, \theta = 1).$$

Estimaciones Monte Carlo típicas (p.ej. $N = 2 \cdot 10^5$, semilla fija)

- **Media:** $\widehat{\mu} = \widehat{\mathbb{E}[Y]} \approx 10947$.
- **Desv. estándar:** $\widehat{\sigma}_Y \approx 2138$.
- **Probabilidad de atraso:** $\widehat{\mathbb{P}}(T > d) \approx 0.303$.
- **Cuantiles:** $\widehat{q}_{0.90}(Y) \approx 13595$, $\widehat{q}_{0.95}(Y) \approx 15586$, $\widehat{q}_{0.99}(Y) \approx 19885$.
- **Medida de cola (CVaR$_{0.95}$):** $\mathbb{E}[Y \mid \widehat{Y \geq q_{0.95}}] \approx 18280$.

Media = costo esperado. Cuantiles/CVaR = **compromisos de servicio y riesgo** ("días malos típicos" y "cola extrema").

Error vs. N: por qué $1/\sqrt{N}$ aparece siempre

Ley de los grandes números (consistencia)

Si $Y_1, \ldots, Y_N$ son i.i.d. y $\mathbb{E}[|Y|] < \infty$, entonces

$$\widehat{\mu}_N \longrightarrow \mu \quad \text{cuando } N \to \infty.$$

Esto garantiza convergencia, pero no dice *qué tan rápido*.

Tamaño típico del error (intuición)

La variabilidad de $\widehat{\mu}_N$ se reduce como

$$\mathrm{Var}(\widehat{\mu}_N) = \frac{\mathrm{Var}(Y)}{N} \qquad \Rightarrow \qquad \mathrm{SE}(\widehat{\mu}_N) = \frac{\sigma_Y}{\sqrt{N}}.$$

Regla práctica

Para mejorar precisión por un factor 2, necesitas aproximadamente 4 veces más réplicas.

Convergencia vs n: no solo la media (media, probabilidad y cuantil)

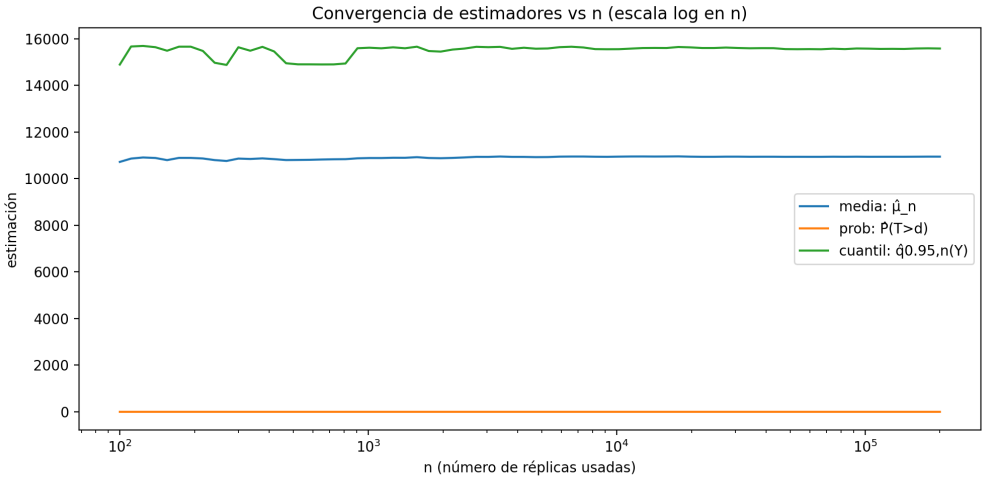

Convergencia vs. n (cuatro estimadores, misma simulación)

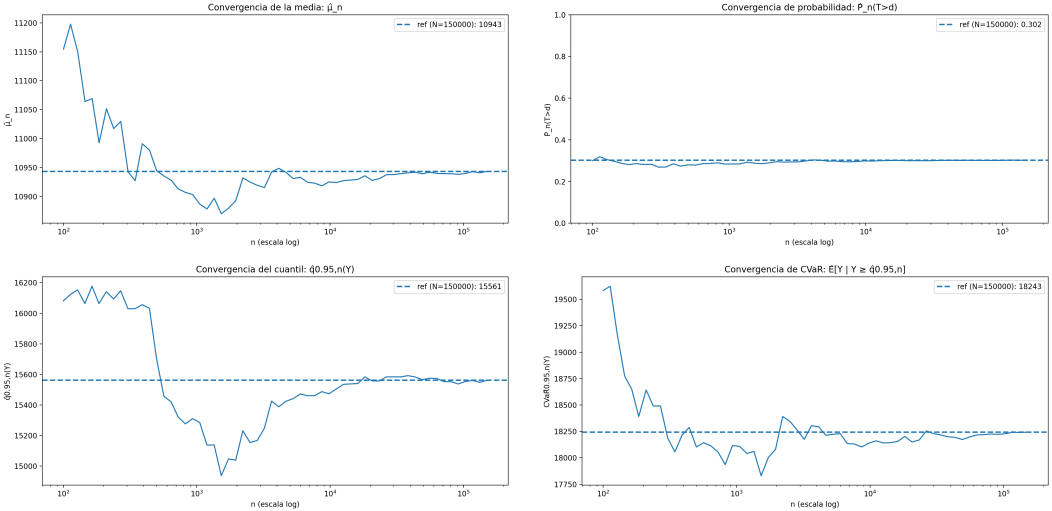

Dos objetos aleatorios distintos: salida Y vs. estimador $\widehat{\theta}_N$

1) Distribución de salida (incertidumbre del sistema)

$$Y = g(\xi) \quad \Rightarrow \quad F_Y(y) = \mathbb{P}(Y \leq y).$$

Aquí Y **es el resultado** de *un día / un escenario* (una corrida).

¿Cómo se mira? Con histograma o CDF empírica $\widehat{F}_N$ construida con $\{Y_i\}$.

¿Qué deriva de F_Y?

$$\mathbb{E}[Y], \qquad \mathbb{P}(Y > \tau), \qquad q_\alpha(Y), \qquad \mathrm{CVaR}_\alpha(Y).$$

2) Distribución del estimador (error Monte Carlo)

$$\widehat{\theta}_N = \widehat{\theta}_N(Y_1, \ldots, Y_N) \text{ también es aleatorio.}$$

Porque cambia si vuelves a simular con *otra* muestra i.i.d.

Idea clave: si repites el experimento completo muchas veces (**muchos "Monte Carlo de Monte Carlo"**), obtienes una **distribución de muestreo** de $\widehat{\theta}_N$.

Eso justifica barras de error, error estándar e intervalos de confianza.

La nube $\{Y_i\}$ describe el sistema. La variabilidad de $\widehat{\theta}_N$ describe tu incertidumbre por usar N finito.

Dos objetos aleatorios distintos: salida Y vs estimador $\widehat{\theta}_N$

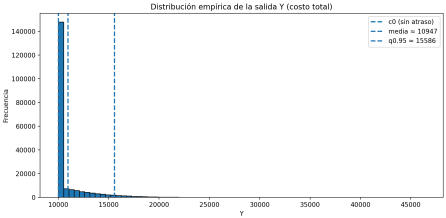

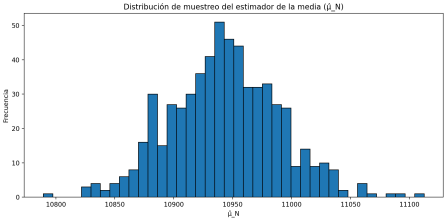

Distribución del estimador: ejemplo con un cuantil

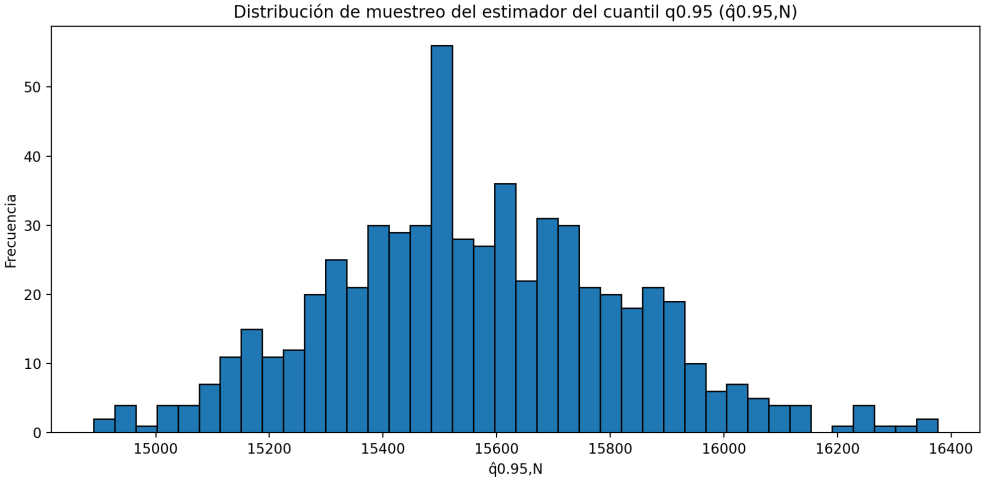

Mensaje práctico

El cuantil (p.ej. $q_{0.95}$) es un funcional de cola: su variabilidad muestral puede ser alta si N no es grande. Por eso **percentiles altos** necesitan **muchas más réplicas** que la media.

Distribución del estimador: media vs probabilidad (repetir el MC completo)

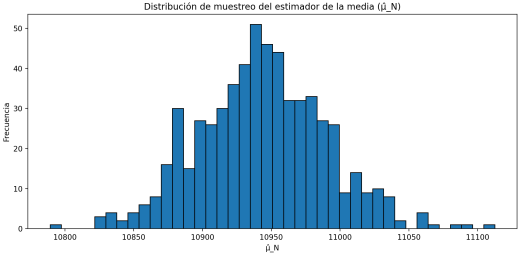

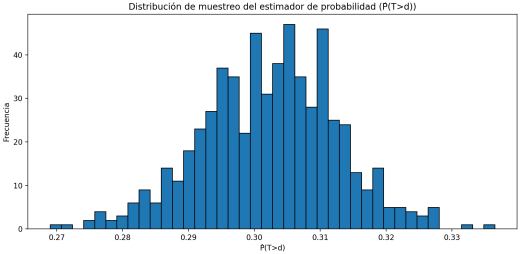

Qué controla una semilla

El generador pseudoaleatorio produce una secuencia determinista larga. Fijar seed significa:

$$\text{misma semilla} \Rightarrow \text{misma secuencia} \Rightarrow \text{mismos } Y_1, \ldots, Y_N.$$

Esto es crucial para **reproducibilidad** y depuración.

Qué NO garantiza una semilla

Una semilla no "hace más verdadero" el resultado; solo lo hace replicable. La validez estadística depende de (i) independencia aproximada, (ii) modelo probabilístico, (iii) tamaño muestral.

Buena práctica mínima

Reportar: semilla, N, y definición exacta de $Y = g(\xi)$ (para que el experimento sea replicable).

Ruta A: generadores directos (`numpy.random`)

Cuando existe un generador implementado, se usa directamente: Normal, Poisson, Exponencial, Uniforme, etc.

Ruta B: transformaciones (construir desde algo simple)

Si $U \sim \mathrm{Unif}(0,1)$:

$$X = a + (b-a)U \sim \mathrm{Unif}(a,b).$$

Si $X_1, \ldots, X_k$ son Exponenciales i.i.d., su suma es Gamma/Erlang (modelo de "k etapas").

Ruta C: método inverso (principio general)

Si $U \sim \mathrm{Unif}(0,1)$ y F es una cdf, entonces $X = F^{-1}(U)$ tiene distribución F. *Ejemplo:* si $X \sim \mathrm{Exp}(\lambda)$, entonces $F^{-1}(u) = -\frac{1}{\lambda}\ln(1-u)$.

Ejemplo 1 (simple): Bernoulli y el IC que "se ve"

Situación: un componente pasa una prueba con probabilidad desconocida p. Definimos $X = 1$ si pasa y 0 si falla. Entonces $X \sim \mathrm{Bernoulli}(p)$ y $\mu = \mathbb{E}[X] = p$.

Interpretación

El IC se estrecha como $1/\sqrt{N}$: si quieres la mitad del ancho, necesitas $\approx 4N$.

Ejemplo 2 (Ing. Industrial): faltantes en inventario (media, prob, cuantil)

Situación: se ordena una cantidad fija Q para mañana. La demanda D es incierta. El costo por faltante es c_s por unidad:

$$Y = c_s(D - Q)_+.$$

Aquí Y es la **salida** y su distribución suele ser **muy asimétrica** (muchos ceros, cola derecha).

Lectura

La media resume costo esperado; $\mathbb{P}(Y > \tau)$ captura riesgo operacional; $q_{0.90}$ responde "¿qué tan malo es un día malo típico?".

Diagnóstico básico: histograma y convergencia de la media

Monte Carlo no solo entrega números: también exige **diagnósticos** mínimos.

Dos diagnósticos que siempre deberían existir

(1) Histograma (forma/colas) $\Rightarrow$ te recuerda que Y tiene distribución.
(2) Media corrida $\widehat{\mu}_n$ vs. n $\Rightarrow$ te muestra estabilidad del estimador.

Ejercicio 1: modelar la incertidumbre y elegir *qué* preguntar

En Monte Carlo, el paso más difícil (y más importante) suele ser **antes** de simular: **definir el modelo** y **definir qué pregunta cuantitativa** se quiere responder.

Tres situaciones

Para **una** de las siguientes situaciones (escoja la que prefiera):

1. **Turnos en un servicio:** llegan clientes y se forman filas; le preocupa el nivel de espera.
2. **Transporte urbano:** el tiempo de viaje cambia por tráfico e incidentes; hay hora de llegada compromiso.
3. **Mantenimiento industrial:** una máquina puede fallar; hay tiempo de reparación y costo por paro.

Tarea: proponer un modelo (pensar, no copiar)

Defina, en palabras y en símbolos:

$$\xi \text{ (fuentes de incertidumbre)} \quad \Rightarrow \quad Y = g(\xi) \text{ (salida de interés).}$$

Regla: use al menos **dos** componentes aleatorios en ξ (p.ej. llegada + servicio; tráfico + incidentes; falla + reparación). No necesita poner distribuciones exactas todavía: basta con justificar *qué* es aleatorio y por qué.

Ejercicio 2: LLN vs CLT vs IC (¿qué te da cada uno?)

Después de simular obtienes números $Y_1, \ldots, Y_N$.

Parte A (conceptual)

Marque con **V/F** y justifique en una línea:

1. "La LLN me dice el ancho del intervalo de confianza." ( )
2. "El CLT justifica aproximar la distribución de $\widehat{\mu}_N$ por una Normal." ( )
3. "Un IC para μ también es un IC para un día típico Y." ( )

Parte B (operativa)

Si quiere **mitad** del ancho del IC de μ, ¿cuántas réplicas necesita en términos de N?

$$\text{ancho} \propto \frac{1}{\sqrt{N}} \qquad \Rightarrow \qquad N_{\text{nuevo}} = ?$$

Ejercicio 3: dos distribuciones distintas (y dos gráficas distintas)

En Monte Carlo conviven dos objetos aleatorios:

1) Distribución de salida

La muestra $\{Y_i\}$ aproxima F_Y (histograma, CDF empírica, cuantiles, colas).

2) Distribución del estimador

El número $\widehat{\mu}_N$ cambia si repites el experimento completo $\Rightarrow$ tiene distribución de muestreo.

Tarea

1. Escriba una frase: **¿qué pregunta contesta** el histograma de Y?
2. Escriba una frase: **¿qué pregunta contesta** el histograma de $\widehat{\mu}_N$?
3. En el ejemplo del atraso: ¿cuál de las dos distribuciones usaría para hablar de **riesgo** y por qué?

Ejercicio 4: Bernoulli en Python (rellenar huecos + IC)

Objetivo: estimar $p = \mathbb{E}[X]$ con $X \sim \text{Bernoulli}(p)$ y reportar IC 95 %.

Preguntas

(i) ¿Qué cambia si N pasa de 2000 a 8000? (ii) ¿Por qué aquí el IC se puede construir con CLT?

Ejercicio 5: inventario (continuo) + 3 métricas

Modelo: $D \sim \mathcal{N}(\mu, \sigma^2)$ truncada a no-negativa.

$$Y = c_s(D - Q)_+.$$

Use: $\mu = 100,\ \sigma = 30,\ Q = 100,\ c_s = 10,\ N = 30000.$

Tarea

Cambie SOLO una cosa a la vez: (i) $\sigma = 50$ (ii) $Q = 120$ (iii) $\tau = 400$. Explique en palabras qué cambia en (a), (b), (c).

Ejercicio 6: diagnósticos mínimos (2 gráficos obligatorios)

Objetivo: producir **dos gráficos** para el ejercicio anterior: (1) histograma de Y, (2) media corrida $\widehat{\mu}_n$.

Preguntas

(i) ¿Qué te dice el histograma que la media NO te dice? (ii) ¿Cómo se ve la convergencia si duplicas N?

Ejercicio 7: depuración (encuentre y corrija 4 errores)

Este código **pretende** estimar $\mathbb{E}[Y]$ para $Y = c_s(D - Q)_+$, pero tiene errores.

Tarea

Identifique y corrija **cuatro** errores. Luego corra y reporte $E[Y]$.

Ejercicio 8: modelar ξ (¿qué distribución usarías y por qué?)

En cada caso, proponga una distribución para la **entrada aleatoria** y justifique con **dos razones** (soporte, forma, mecanismo, cola, discreto/continuo).

1. Caso A: tiempo entre llegadas a una ventanilla; hay pausas y ráfagas.
2. Caso B: duración total de una tarea con 3 etapas consecutivas.
3. Caso C: número de llamadas por hora en un call center.
4. Caso D: duración estimada por experto con (optimista, más probable, pesimista).

Regla

Primero describa el soporte y el mecanismo; **luego** proponga distribución.