Modelado de Entradas
Del dato observado a la distribución de probabilidad

T3.1 · Modelado de Sistemas bajo Incertidumbre

Alejandra Tabares Pozos

Universidad de los Andes · Ingeniería Industrial

2026

El problema que nos motiva

Banco — ventanilla única

Durante una hora registramos **15 tiempos de atención** (minutos):

0,7 0,8 0,9 1,1 1,2 1,5 1,6 1,8
2,1 2,4 2,8 3,1 3,4 4,2 5,6

Pregunta clave. ¿Podemos modelar la ventanilla como $M/M/1$ (llegadas Poisson + servicio exponencial)?

Si la respuesta es *sí*, tenemos fórmulas cerradas. Si es *no*, necesitamos $M/G/1$ o simular.

Todo el tema gira en torno a esta pregunta.

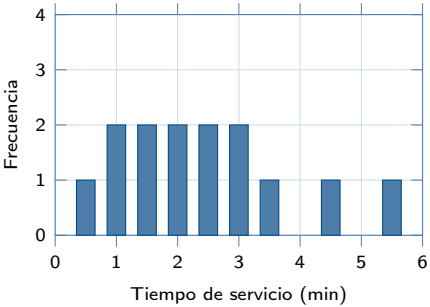

Histogram de los 15 tiempos.
$\bar{x} = 2{,}21$, $s = 1{,}40$, $\mathrm{CV} = 0{,}63$.

¿Por qué importa la distribución que elijamos?

Fórmula de Pollaczek–Khinchine para $M/G/1$ con tráfico $\rho = \lambda\,\mathbb{E}[S]$:

$$W_q^{M/G/1} \;=\; W_q^{M/M/1} \cdot \frac{1 + \mathrm{CV}_S^2}{2}$$

Fijando $\rho = 0{,}8$, $\mathbb{E}[S] = 1$ min (por lo que $W_q^{M/M/1} = 4$ min), el servicio es el mismo *en promedio*, cambia solo su forma:

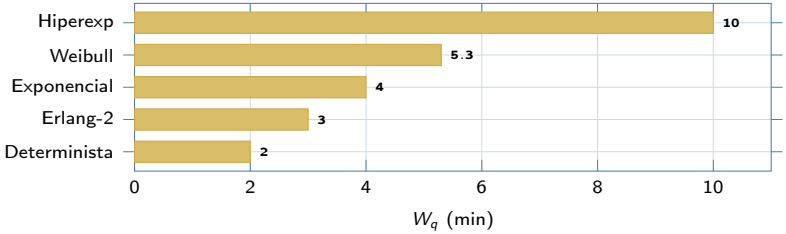

Moraleja

La misma media puede producir tiempos en cola que varían en un factor de **5**. Asumir exponencial "porque es fácil" es el error más caro del modelado.

Ruta de trabajo — 5 pasos

- **Paso 1**: ¿son independientes? ¿hay tendencia?
- **Paso 2**: histograma, función de distribución empírica, gráfico Q-Q.
- **Paso 3**: el coeficiente de variación y el proceso físico sugieren candidatas.
- **Paso 4**: máxima verosimilitud (MLE) sobre cada candidata.
- **Paso 5**: chi-cuadrado, Kolmogorov–Smirnov, Anderson–Darling + gráfico Q-Q.

Exponencial: el punto de partida

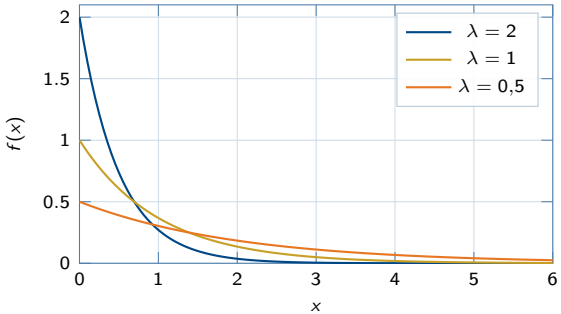

$X \sim \mathrm{Exp}(\lambda)$

$$f(x) = \lambda e^{-\lambda x},\ x \geq 0$$

$$\mathbb{E}[X] = \frac{1}{\lambda}, \quad \mathrm{CV} = 1$$

Propiedad clave — sin memoria

$\mathbb{P}(X > s + t \mid X > s) = \mathbb{P}(X > t)$. Es el *único* justificativo para usar $M/M/c$.

Erlang-k: servicio en etapas regulares

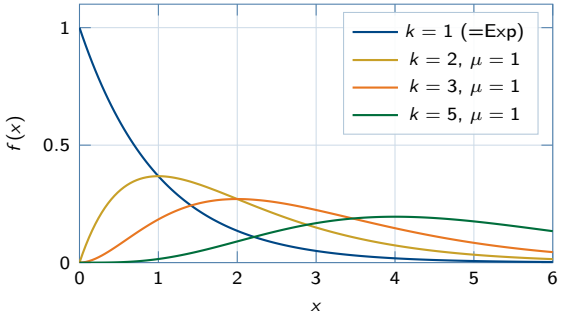

$X = S_1 + \cdots + S_k$, $S_i \sim \mathrm{Exp}(\mu)$ i.i.d.

$$f(x) = \frac{\mu^k x^{k-1} e^{-\mu x}}{(k-1)!}$$

$$\mathbb{E}[X] = \frac{k}{\mu}, \quad \mathrm{CV} = \frac{1}{\sqrt{k}}$$

Interpretación física

Servicio con k etapas sucesivas: a más etapas, *menor variabilidad* ($\mathrm{CV} < 1$).

Ejemplo: trámite bancario (saludo, transacción, despedida) $\Rightarrow k = 3$.

Gamma: la Erlang con parámetro continuo

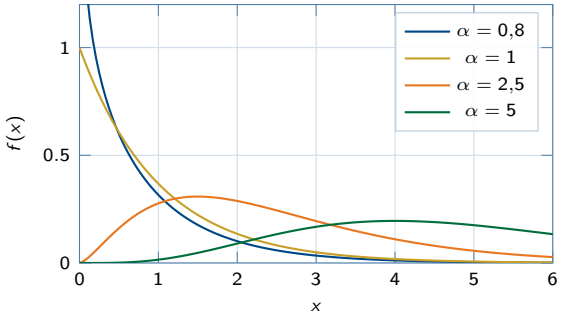

$X \sim \mathrm{Gamma}(\alpha, \beta)$

$$f(x) = \frac{\beta^\alpha x^{\alpha-1} e^{-\beta x}}{\Gamma(\alpha)}$$

$$\mathbb{E}[X] = \frac{\alpha}{\beta}, \quad \mathrm{CV} = \frac{1}{\sqrt{\alpha}}$$

Relación con Erlang

Erlang-k es Gamma con $\alpha = k \in \mathbb{N}$. Gamma permite $\alpha \in \mathbb{R}^+$: más flexible.

Weibull: la distribución de las fallas

Densidad $f(x)$

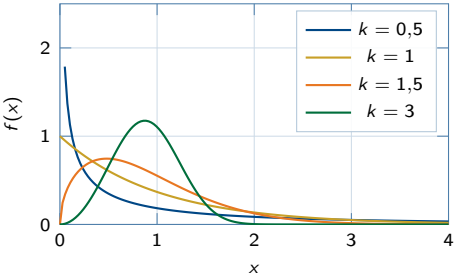

Tasa de falla (hazard) $h(x) = (k/\lambda)(x/\lambda)^{k-1}$

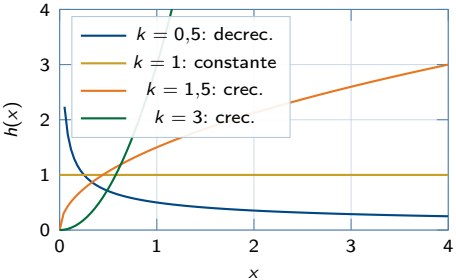

$k < 1$: *mortalidad infantil* (equipos nuevos defectuosos) · $k = 1$: exponencial (sin memoria) · $k > 1$: *desgaste* (equipos envejecen). La tasa de falla es lo que caracteriza la Weibull.

Log-normal: fenómenos multiplicativos

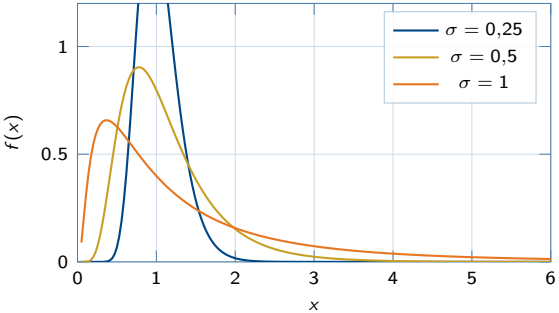

$X \sim \mathrm{LogN}(\mu, \sigma^2)$ si $\ln X \sim \mathcal{N}(\mu, \sigma^2)$.

$$\mathbb{E}[X] = e^{\mu + \sigma^2/2}$$

$$\mathrm{CV} = \sqrt{e^{\sigma^2} - 1}$$

Cuándo aparece

Cuando el tiempo total es producto de muchos factores (diagnóstico + negociación + resolución): por el teorema central del límite, el *logaritmo* es normal.

Hiperexponencial: mezcla de poblaciones

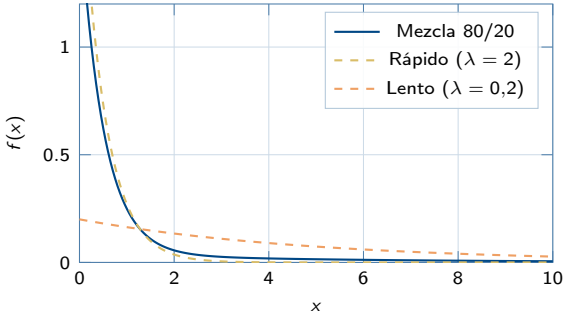

$$f(x) = \sum_{i=1}^{k} p_i \, \lambda_i e^{-\lambda_i x}$$

con $\sum p_i = 1$.
Siempre $\mathrm{CV} > 1$ si λ_i's difieren.

Ejemplo de taller

80 % de las reparaciones son rápidas (30 min); 20 % son complejas (5 h). Una sola exponencial no captura esta heterogeneidad.

Tabla comparativa y guía por coeficiente de variación

Distribución	CV	Tasa de falla	Ejemplo físico
Determinista (D)	0	—	Línea automatizada, proceso fijo
Erlang-k (E_k)	$1/\sqrt{k}$	Creciente	Servicio con k etapas sucesivas
Exponencial (M)	1	Constante	Sin memoria, $M/M/c$
Gamma (α, β)	$1/\sqrt{\alpha}$	Flexible	Modelado general
Weibull (k, λ)	variable	Flexible	Tiempos de falla, reparaciones
Log-normal	variable	Unimodal	Actividades humanas multiplicativas
Hiperexp (H_k)	> 1	Decreciente	Poblaciones mixtas (simples + complejas)

Guía rápida de primera elección por CV

$\mathrm{CV} = 0$	Determinista	No hay variabilidad
$\mathrm{CV} < 1$	Erlang-k con $k \approx 1/\mathrm{CV}^2$, o Gamma	Servicio regular
$\mathrm{CV} \approx 1$	Exponencial	Baseline Markoviano
$\mathrm{CV} > 1$	Hiperexp, Weibull ($k < 1$), Log-normal	Heterogeneidad, colas pesadas

De nuestros datos del banco: $\mathrm{CV} = 0{,}63 \Rightarrow$ primera candidata **Erlang-k con** $k \approx 1/0{,}63^2 \approx 2{,}5$.

Construcción de un Histograma

Un histograma es la representación gráfica de la distribución de un conjunto de datos continuos.

Pasos para su construcción:

- **Definir el rango:** Restar el valor mínimo del valor máximo ($R = x_{max} - x_{min}$).
- **Elegir el número de intervalos (k):** Se puede usar la Regla de Sturges: $k = 1 + 3.322 \log_{10}(n)$.
- **Calcular la amplitud (w):** Dividir el rango entre el número de intervalos ($w = R/k$).
- **Calcular frecuencias:** Contar cuántos datos caen dentro de cada intervalo (clase).
- **Graficar:** Dibujar barras adyacentes donde la base es el intervalo y la altura es la frecuencia (absoluta o relativa).

Histograma de Datos Empíricos (Exponencial)

A continuación se muestra un histograma generado con datos que siguen una distribución exponencial ($\lambda = 0.5$).

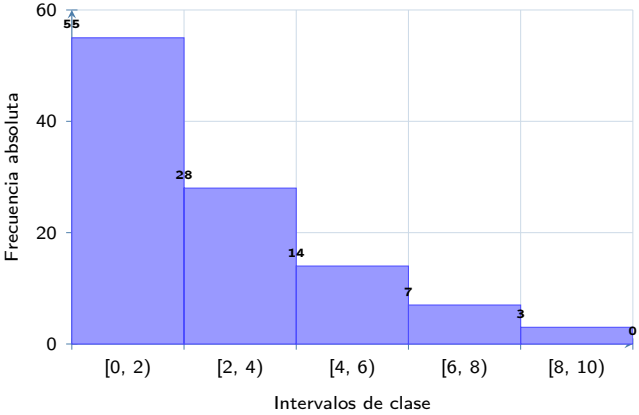

Nota: Se observa el decaimiento característico: las clases iniciales tienen la mayor concentración de frecuencias.

La misma muestra de $n = 80$, tres elecciones de k:

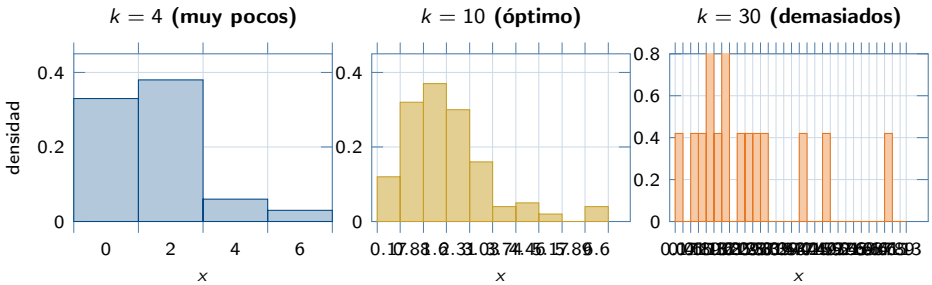

Reglas prácticas para el número de intervalos k

$k = \lceil 1 + \log_2 n \rceil$ (Sturges) · $k \approx \sqrt{n}$ (raíz cuadrada) · $h = 3{,}49\, s\, n^{-1/3}$ (Scott, ancho óptimo bajo normalidad).

Con pocos intervalos se ocultan las colas; con demasiados, el ruido domina. El histograma es la *primera impresión*, no el diagnóstico final.

Función de distribución empírica frente a la teórica

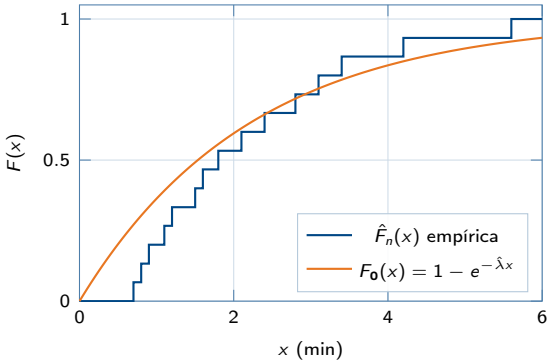

$$\hat{F}_n(x) \;=\; \frac{1}{n}\sum_{i=1}^{n} 1\{X_i \le x\}$$

Glivenko–Cantelli: $\sup_x |\hat{F}_n - F| \to 0$ uniformemente.

En el gráfico vemos que la escalera *sube más rápido* al inicio que la exponencial teórica: los datos tienen pocos valores pequeños y muchos medianos.

Lectura

La distancia máxima vertical entre la empírica y la teórica es la base de la prueba de Kolmogorov–Smirnov (próximas láminas).

Construcción de un Gráfico Q-Q (Q-Q Plot)

Un gráfico Q-Q es una herramienta visual para evaluar si un conjunto de datos sigue una distribución teórica específica (como la distribución Normal).

Pasos para su construcción:

1. **Ordenar los datos empíricos:** De menor a mayor, obteniendo los estadísticos de orden:
$$x_{(1)} \leq x_{(2)} \leq \cdots \leq x_{(n)}$$
2. **Calcular proporciones (probabilidades acumuladas):** Para cada dato en la posición i, se estima la proporción de datos por debajo de él. Una fórmula común es:
$$p_i = \frac{i - 0.5}{n}$$
3. **Obtener cuantiles teóricos:** Se utiliza la función de distribución acumulada inversa F^{-1} de la distribución teórica evaluada para encontrar el valor esperado:
$$q_i = F^{-1}(p_i)$$
4. **Graficar:** Se representan en un plano cartesiano los cuantiles teóricos (q_i) en el eje X frente a los datos ordenados ($x_{(i)}$) en el eje Y.

Interpretación

Si los datos empíricos provienen de la distribución teórica asumida, los puntos graficados se alinearán aproximadamente sobre una línea recta.

Cálculo Manual: Q-Q Plot Exponencial

Supongamos que tenemos $n = 3$ datos: $\{2.1, 0.5, 1.2\}$ y queremos compararlos con una distribución **Exponencial** ($\lambda = 1$).

1. Función Cuantil (Inversa de la CDF): Para la exponencial $F(x) = 1 - e^{-\lambda x}$, su inversa es:

$$q_i = F^{-1}(p_i) = -\frac{\ln(1 - p_i)}{\lambda}$$

2. Tabla de Cálculos ($p_i = \frac{i-0.5}{3}$):

i	$x_{(i)}$ (Ordenados)	p_i	Operación	q_i (Teórico)
1	0.5	0.167	$-\ln(1 - 0.167)$	**0.182**
2	1.2	0.500	$-\ln(1 - 0.500)$	**0.693**
3	2.1	0.833	$-\ln(1 - 0.833)$	**1.791**

3. Coordenadas a graficar ($q_i, x_{(i)}$): Los puntos en el plano serán: $(0.182, 0.5)$, $(0.693, 1.2)$ y $(1.791, 2.1)$.

Gráfico Q-Q: ajuste bueno

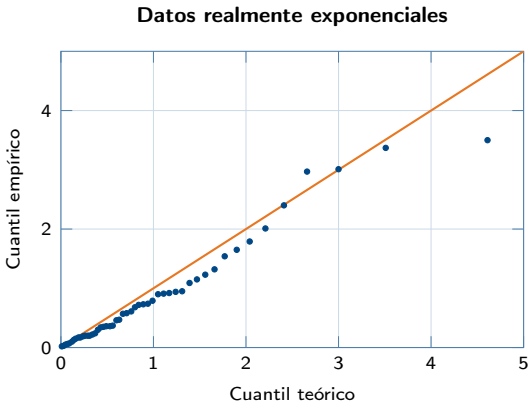

Construcción (datos ordenados $X_{(1)} \leq \cdots \leq X_{(n)}$):

1. $p_i = (i - 0{,}5)/n$
2. $q_i = F^{-1}(p_i; \hat{\theta})$
3. Graficar $(q_i, X_{(i)})$

Lectura: los puntos caen sobre la recta $y = x$ (salvo ruido en las colas).

Es el *mejor* diagnóstico visual cuando las pruebas formales dan números contradictorios.

Gráfico Q-Q: cola derecha más pesada que la exponencial

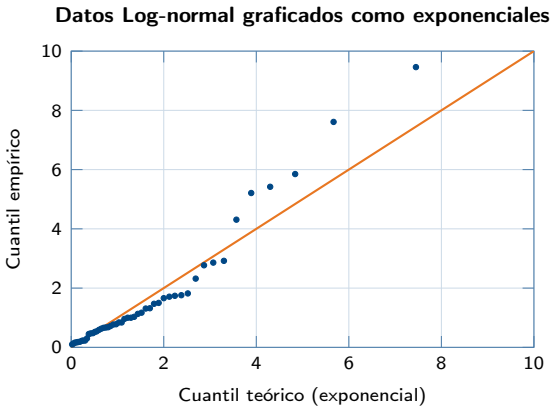

Síntoma: los puntos en la parte derecha quedan *por encima* de la diagonal.

La cola real es *más pesada* que la del modelo exponencial: hay observaciones grandes más frecuentes de lo que predice la exponencial.

Diagnóstico

Si el Q-Q muestra este patrón, probar Log-normal, Weibull con $k < 1$ o Hiperexponencial.

Gráfico Q-Q: curvatura en "S"

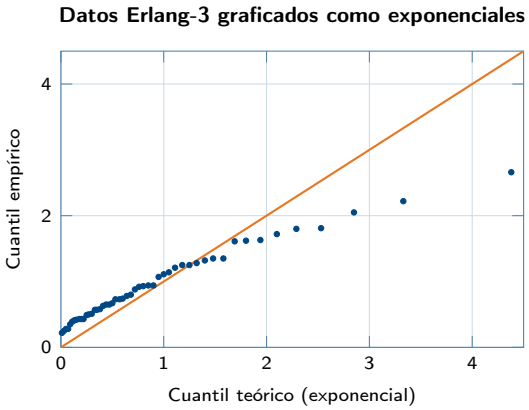

Síntoma: a la izquierda los puntos están *por encima* de la diagonal; a la derecha, *por debajo*.

La exponencial tiene demasiados valores muy pequeños y muy grandes; los datos reales son *más concentrados* alrededor de la media ($\mathrm{CV} < 1$).

Diagnóstico

Probar Erlang-k (con $k \approx 1/\mathrm{CV}^2$) o Gamma.

¿Qué es la Independencia Temporal?

En el análisis de datos secuenciales o series de tiempo, la **independencia temporal** implica que el valor de una variable en el instante t no está influenciado por sus valores en instantes anteriores $(t-1, t-2, \dots)$.

¿Por qué es importante?

- Muchos modelos estadísticos asumen que los errores o los datos son independientes e idénticamente distribuidos (i.i.d.).
- Si hay dependencia, las varianzas estimadas pueden ser sesgadas, lo que invalida pruebas de hipótesis convencionales.
- La dependencia temporal se conoce comúnmente como **autocorrelación** o correlación serial.

Prueba de Pearson Lagueada (Autocorrelación)

Para medir la dependencia temporal, adaptamos el coeficiente de correlación de Pearson clásico. En lugar de comparar dos variables distintas (X e Y), comparamos la misma variable consigo misma, pero desfasada en el tiempo (lagueada).

Coeficiente de Autocorrelación de Muestra de orden k (r_k): Mide la relación lineal entre las observaciones separadas por k periodos de tiempo:

$$r_k = \frac{\sum_{t=k+1}^{n}(Y_t - \bar{Y})(Y_{t-k} - \bar{Y})}{\sum_{t=1}^{n}(Y_t - \bar{Y})^2}$$

Donde:

- n es el número total de observaciones.
- $\bar{Y}$ es la media muestral de toda la serie.
- k es el "lag" o rezago (ej. $k = 1$ compara Y_t con Y_{t-1}).

Prueba de Hipótesis para Independencia

Para verificar si el coeficiente r_k es estadísticamente diferente de cero, planteamos una prueba de hipótesis.

1. Hipótesis:

- $H_0 : \rho_k = 0$ (Independencia temporal en el rezago k).
- $H_1 : \rho_k \neq 0$ (Existe autocorrelación en el rezago k).

2. Estadístico de Prueba: Si la serie es verdaderamente independiente y el tamaño de muestra n es grande, los coeficientes r_k se distribuyen aproximadamente como una Normal con media 0 y varianza $1/n$.

$$r_k \sim N\left(0, \frac{1}{n}\right)$$

3. Criterio (Bandas de Confianza): Rechazamos H_0 (es decir, hay dependencia temporal) si $|r_k|$ es mayor que el valor crítico. Al **95 %** de confianza, este límite es aproximadamente:

$$\text{Límites} = \pm\frac{1.96}{\sqrt{n}}$$

El **correlograma** es la representación gráfica de los coeficientes r_k para distintos rezagos (k).

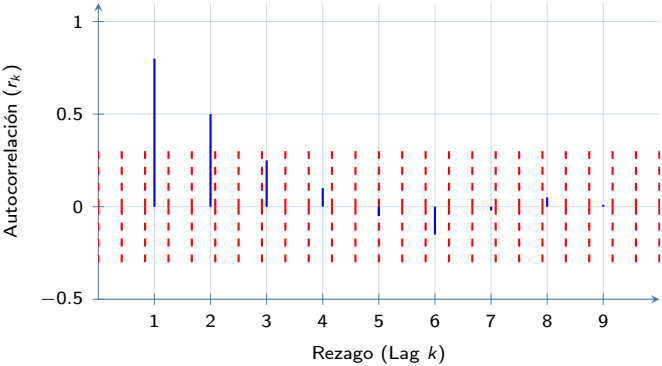

Interpretación: Si la "barra" sobresale de las líneas punteadas rojas (bandas de confianza), rechazamos la independencia temporal para ese rezago. En este ejemplo genérico, hay dependencia en los rezagos 1 y 2.

Independencia — cómo se ven los datos cuando la cumplen

Serie de tiempo: X_i vs. i

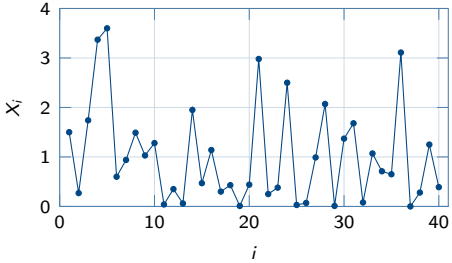

Nube sin estructura; sin tendencia ni ciclos.

Dispersión (X_i, X_{i+1})

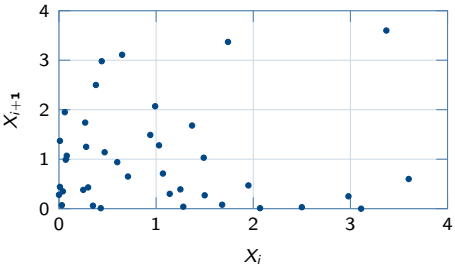

Nube sin patrón; $\hat{\rho}_1 = -0{,}02$.

Criterio de independencia — autocorrelación lag-1

$\hat{\rho}_1 = \dfrac{\sum_{i=1}^{n-1}(X_i - \bar{X})(X_{i+1} - \bar{X})}{\sum(X_i - \bar{X})^2}$. Bajo independencia, $|\hat{\rho}_1| < 2/\sqrt{n}$. Para $n = 40$: umbral $= 0{,}32$.
Aquí $|-0{,}02| < 0{,}32 \Rightarrow$ **no rechazamos independencia**.

Independencia — cómo se ven cuando la violan

Serie de tiempo: X_i vs. i

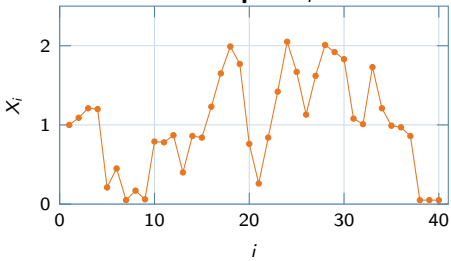

Rachas largas arriba/abajo; valores vecinos se parecen.

Dispersión (X_i, X_{i+1})

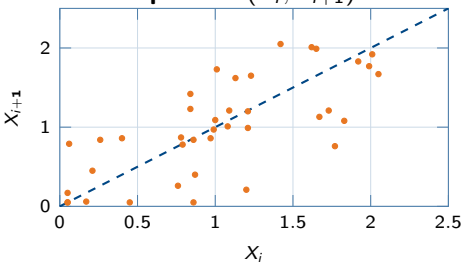

Alineación clara a lo largo de la diagonal; $\hat{\rho}_1 = 0{,}70$.

Independencia violada

$|\hat{\rho}_1| = 0{,}70 > 2/\sqrt{40} = 0{,}32 \Rightarrow$ **se rechaza independencia.** *Ajustar una distribución ignorando esto invalida los MLE y todas las pruebas de bondad.* Posibles causas: fatiga del operador, lotes similares, retroalimentación. Remedios: submuestrear, modelar como proceso autoregresivo, o separar por régimen.

Prueba de rachas (runs test) — ejemplo a mano

Sobre la mediana $\tilde{X}$, codificar "+" si $X_i > \tilde{X}$, "−" si no. Contar R = número de rachas (secuencias consecutivas del mismo signo).

Serie ejemplo ($n = 10$): 1,2 | 0,8 | 0,5 | 1,5 | 0,9 | 1,4 | 0,6 | 1,7 | 0,7 | 1,3, mediana $\tilde{X} = 1{,}05$

Signos: $+ \; - \; - \; + \; - \; + \; - \; + \; - \; +$

Rachas: $| + | - - | + | - | + | - | + | - | + |$ $\Rightarrow$ $R = 9$

Distribución asintótica bajo independencia

$$\mathbb{E}[R] = \frac{2n_+ n_-}{n} + 1, \qquad \mathrm{Var}[R] = \frac{2n_+ n_-(2n_+ n_- - n)}{n^2(n-1)}, \qquad Z = \frac{R - \mathbb{E}[R]}{\sqrt{\mathrm{Var}[R]}}$$

Con $n_+ = n_- = 5$, $n = 10$: $\mathbb{E}[R] = 6$, $\mathrm{Var}[R] \approx 2{,}22$, $Z = (9-6)/\sqrt{2{,}22} = 2{,}01$. *Muchas rachas* $\Rightarrow$ los signos alternan más de lo esperado; posible *negativa* autocorrelación o ciclicidad. A nivel $\alpha = 0{,}05$ el umbral bilateral es $|Z| > 1{,}96$: aquí se rechaza independencia.

Regresamos al banco — planteamos H_0

Hipótesis a probar

H_0: los 15 tiempos del banco vienen de $\mathrm{Exp}(\hat{\lambda})$ con $\hat{\lambda} = 1/\bar{x} = 1/2{,}213 = 0{,}452$ min^{-1}.

Vamos a aplicar **las tres pruebas clásicas** sobre la misma muestra:

1. χ^2 de Pearson — compara frecuencias observadas y esperadas por celdas.
2. Kolmogorov–Smirnov — máxima distancia vertical entre ECDF y CDF teórica.
3. Anderson–Darling — discrepancias ponderadas, especialmente en las colas.

Veremos paso a paso cómo se calcula *cada* estadístico y por qué pueden dar conclusiones distintas.

Prueba Chi-cuadrado de Bondad de Ajuste

La prueba χ^2 (Chi-cuadrado) evalúa estadísticamente si una muestra empírica se ajusta a una distribución teórica propuesta.

1. Planteamiento de Hipótesis:

- H_0: Los datos se ajustan a la distribución teórica.
- H_1: Los datos **no** se ajustan a la distribución teórica.

2. Estadístico de Prueba: Compara la frecuencia observada (O_i) en el histograma empírico con la frecuencia esperada (E_i) bajo la distribución teórica en cada intervalo i:

$$\chi^2 = \sum_{i=1}^{k} \frac{(O_i - E_i)^2}{E_i}$$

(Donde k es el número total de intervalos o categorías).

3. Criterio de Decisión:

- **Grados de libertad (gl):** $gl = k - 1 - p$ (siendo p el número de parámetros de la distribución estimados a partir de la muestra).
- **Regla de rechazo:** Se rechaza H_0 si $\chi^2 > \chi^2_{gl,\alpha}$ para un nivel de significancia α (usualmente 5 % o 0.05).

Paso 1: Análisis de Datos y Parámetros

Queremos probar si los siguientes datos ($n = 15$) se ajustan a una **Distribución Exponencial**:

$$0.7,\ 0.8,\ 0.9,\ 1.1,\ 1.2,\ 1.5,\ 1.6,\ 1.8,\ 2.1,\ 2.4,\ 2.8,\ 3.1,\ 3.4,\ 4.2,\ 5.6$$

Estimación del parámetro (λ): Como no conocemos el λ poblacional, lo estimamos a partir de la media muestral ($\bar{x}$):

- Suma de datos $= 33.2$
- Media ($\bar{x}$) $= 33.2/15 \approx 2.213$
- Parámetro estimado (λ) $= 1/\bar{x} \approx$ **0.45**

Por lo tanto, la distribución teórica a probar tiene la función de distribución acumulada:

$$F(x) = 1 - e^{-0.45x}$$

Paso 2: ¿Qué es la Frecuencia Esperada (E_i)?

La **frecuencia esperada (E_i)** es la cantidad de datos que teóricamente "deberían" caer en un intervalo si la hipótesis nula (distribución exponencial con $\lambda = 0.45$) fuera perfectamente cierta.

Se calcula multiplicando el tamaño de la muestra (n) por la probabilidad teórica de que un dato caiga en ese intervalo $[a, b)$:

$$E_i = n \times P(a \leq X < b)$$

$$E_i = 15 \times [F(b) - F(a)]$$

Nota: El éxito de la prueba depende de comparar la cantidad de datos que **realmente** cayeron en el intervalo (O_i) contra lo que la matemática dictamina (E_i).

Paso 3: Cálculo de Frecuencias por Intervalo

Definimos 3 intervalos para agrupar los datos y aplicamos $F(x) = 1 - e^{-0.45x}$.

Intervalo	**Obs. (O_i)**	**Probabilidad Teórica**	**Esperada (E_i)**
$[0, 2)$	8	$F(2) - F(0) = 0.593$	$15 \times 0.593 = \mathbf{8.90}$
$[2, 4)$	5	$F(4) - F(2) = 0.241$	$15 \times 0.241 = \mathbf{3.62}$
$[4, \infty)$	2	$1 - F(4) = 0.166$	$15 \times 0.166 = \mathbf{2.48}$
Total	**15**	**1.000**	**15.00**

Ejemplo fila 1: Cayeron 8 datos reales menores a 2. La probabilidad de ser < 2 es $1 - e^{-0.45(2)} \approx 0.593$. Se esperaban teóricamente $15 \times 0.593 = 8.9$ datos.

Paso 4: Cálculo Chi-cuadrado y Conclusión

Calculamos el estadístico $\chi^2 = \sum \frac{(O_i - E_i)^2}{E_i}$:

$$\chi^2 = \frac{(8-8.9)^2}{8.9} + \frac{(5-3.62)^2}{3.62} + \frac{(2-2.48)^2}{2.48}$$

$$\chi^2 \approx 0.091 + 0.526 + 0.093 = \mathbf{0.710}$$

Toma de Decisión:

- **Grados de libertad:** $gl = k - 1 - p = 3 - 1 - 1 = \mathbf{1}$
  (k=3 intervalos; p=1 porque estimamos λ con la muestra).
- **Valor crítico ($\alpha = 0.05$):** $\chi^2_{1,0.05} = \mathbf{3.841}$

Conclusión

Como $\chi^2 = 0.710 < 3.841$, **no se rechaza** H_0. No hay evidencia suficiente para decir que los datos no siguen una distribución exponencial.

Prueba de Kolmogorov-Smirnov (K-S)

La prueba K-S es una prueba de bondad de ajuste no paramétrica que compara la **Función de Distribución Empírica** $F_n(x)$ con la **Función de Distribución Teórica** $F(x)$.

Estadístico de Prueba (D): Representa la máxima distancia vertical entre la teoría y la realidad:

$$D = \max_{1 \leq i \leq n} \{|F(x_{(i)}) - \frac{i}{n}|, |F(x_{(i)}) - \frac{i-1}{n}|\}$$

Ventajas sobre χ^2:

- Se puede usar con muestras muy pequeñas.
- No requiere agrupar datos en intervalos (bins).
- Es más exacta para distribuciones continuas.

Paso a Paso del Cálculo

Para aplicar K-S a nuestros datos con $\lambda = 0.45$ y $F(x) = 1 - e^{-0.45x}$:

1. **Ordenar los datos:** $x_{(1)} \leq x_{(2)} \leq \cdots \leq x_{(15)}$.
2. **Calcular probabilidad empírica:** Determinar i/n y $(i-1)/n$ para cada dato.
3. **Calcular probabilidad teórica:** Evaluar $F(x_{(i)})$ usando el modelo propuesto.
4. **Calcular diferencias:** Obtener las distancias D_i^+ y D_i^-:
   - $D_i^+ = |\frac{i}{n} - F(x_{(i)})|$
   - $D_i^- = |F(x_{(i)}) - \frac{i-1}{n}|$
5. **Identificar D:** Seleccionar la diferencia más grande de todas.

Kolmogorov–Smirnov — tabla de cómputo

Para cada observación ordenada se calculan $d_i^+ = i/n - F_0(X_{(i)})$ y $d_i^- = F_0(X_{(i)}) - (i-1)/n$; el estadístico es $D_n = \text{máx}_i \, \text{máx}(d_i^+, d_i^-)$.

i	$X_{(i)}$	$F_0(X_{(i)})$	i/n	$(i-1)/n$	d_i^+	d_i^-
1	0,70	0,271	0,067	0,000	−0,205	0,271
2	0,80	0,303	0,133	0,067	−0,170	0,237
3	0,90	0,334	0,200	0,133	−0,134	0,201
4	1,10	0,392	0,267	0,200	−0,125	0,192
5	1,20	0,419	0,333	0,267	−0,085	0,152
6	1,50	0,492	0,400	0,333	−0,092	0,159
7	1,60	0,515	0,467	0,400	−0,048	0,115
8	1,80	0,557	0,533	0,467	−0,023	0,090
9	2,10	0,613	0,600	0,533	−0,013	0,080
10	2,40	0,662	0,667	0,600	+0,005	0,062
11	2,80	0,718	0,733	0,667	+0,016	0,051
12	3,10	0,754	0,800	0,733	+0,046	0,020
13	3,40	0,785	0,867	0,800	+0,082	−0,015
14	4,20	0,850	0,933	0,867	+0,083	−0,017
15	5,60	0,920	1,000	0,933	+0,080	−0,013

$D_n = 0{,}271$ (en $i = 1$). Compárese con Lilliefors $D^*_{0{,}05,15} \approx 0{,}22 \Rightarrow$ se rechaza.

1. Valor Crítico (D_{crit}): Para $n = 15$ y $\alpha = 0.05$, buscamos en las tablas de Kolmogorov-Smirnov:

$$D_{15,0.05} = 0.338$$

2. Regla de Decisión:

- Si $D_{calc} > D_{crit} \rightarrow$ Rechazar H_0.
- Si $D_{calc} \leq D_{crit} \rightarrow$ No rechazar H_0.

Conclusión Final

Como $0.270 < 0.338$, **no se rechaza** H_0. Los datos se ajustan razonablemente bien a una distribución exponencial con $\lambda = 0.45$.

Prueba Kolmogorov–Smirnov — el estadístico D_n

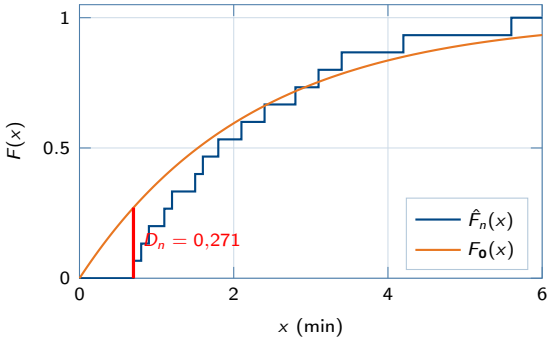

$$D_n = \sup_x |\hat{F}_n(x) - F_0(x;\hat{\theta})|$$

El supremo se alcanza justo antes de $x_{(1)} = 0{,}70$:

$$D_n = F_0(0{,}70) - 0 = 0{,}271$$

Valor crítico con parámetro estimado (Lilliefors, exp, $n = 15$, 5 %): $D^* \approx 0{,}338$.

Veredicto Kolmogorov–Smirnov

$0{,}271 < 0{,}22 \Rightarrow$ **no se rechaza** la exponencial.

Prueba Anderson-Darling: Hipótesis

La prueba de Anderson-Darling evalúa si una muestra proviene de una distribución específica. A diferencia de otras pruebas, es especialmente rigurosa en los valores extremos de los datos.

1. Planteamiento de Hipótesis:

- H_0: Los datos provienen de una distribución Exponencial.
- H_a: Los datos **no** provienen de una distribución Exponencial.

2. El Estadístico Crítico: El valor crítico contra el cual compararemos nuestro resultado depende de la distribución evaluada, el tamaño de la muestra y el nivel de significancia (α). Para una distribución exponencial con el parámetro estimado por la muestra y un nivel de significancia del 5 %, el valor crítico estándar es 1.32.
Regla: Si nuestro estadístico calculado A^2 es mayor a 1.32, rechazamos H_0.

Estadístico de Anderson-Darling (A^2)

$$A^2 = -n - \sum_{i=1}^{n} \frac{2i-1}{n} \left[\ln F_0(X_{(i)}) + \ln(1 - F_0(X_{(n+1-i)})) \right]$$

¿Por qué esta forma? Pondera la diferencia entre la distribución empírica y la teórica usando un peso que *explota en las colas*: $w(x) = \frac{1}{F_0(x)[1-F_0(x)]}$.

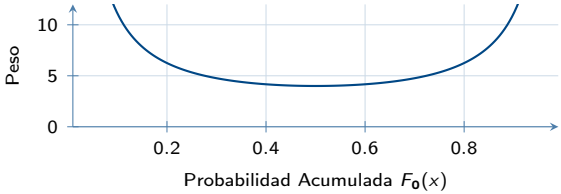

Resultado: Es muy *sensible a valores atípicos en las colas*, donde la prueba de Kolmogorov-Smirnov suele perder potencia.

Veamos de dónde salen los números evaluando el **primer dato** ($i = 1$) de nuestra muestra de $n = 15$. Usamos el modelo $F_0(x) = 1 - e^{-\lambda x}$.

1. Identificar extremos:

- Dato inferior ($i = 1$): $X_{(1)} = 0.70$
- Dato superior opuesto ($n + 1 - 1 = 15$): $X_{(15)} = 5.60$

2. Calcular probabilidades teóricas:

- $F_0(0.70) \approx 0.271 \implies \ln(0.271) = -1.305$
- $F_0(5.60) \approx 0.920 \implies 1 - F_0(5.60) = 0.080 \implies \ln(0.080) = -2.530$

3. Sustituir en la sumatoria para $i = 1$:

$$\text{Término}_1 = \frac{2(1) - 1}{15}\Big[-1.305 + (-2.530)\Big]$$

$$\text{Término}_1 = \frac{1}{15}\Big[-3.835\Big] = -0.256$$

Anderson–Darling — cálculo paso a paso (banco, $n = 15$)

i	$X_{(i)}$	$F_i = F_0(X_{(i)})$	$X_{(n+1-i)}$	$1-F_{n+1-i}$	$\ln F_i$	$\ln(1-F_{n+1-i})$	$\frac{2i-1}{n}[\cdot]$
1	0,70	0,271	5,60	0,080	−1,305	−2,530	−0,256
2	0,80	0,303	4,20	0,150	−1,193	−1,898	−0,618
3	0,90	0,334	3,40	0,215	−1,096	−1,536	−0,878
4	1,10	0,392	3,10	0,246	−0,937	−1,401	−1,091
5	1,20	0,419	2,80	0,282	−0,871	−1,265	−1,282
6	1,50	0,492	2,40	0,338	−0,709	−1,084	−1,315
7	1,60	0,515	2,10	0,387	−0,664	−0,949	−1,398
8	1,80	0,557	1,80	0,443	−0,586	−0,813	−1,399
9	2,10	0,613	1,60	0,485	−0,490	−0,723	−1,374
10	2,40	0,662	1,50	0,508	−0,413	−0,678	−1,381
11	2,80	0,718	1,20	0,581	−0,332	−0,542	−1,223
12	3,10	0,754	1,10	0,608	−0,283	−0,497	−1,196
13	3,40	0,785	0,90	0,666	−0,242	−0,407	−1,082
14	4,20	0,850	0,80	0,696	−0,162	−0,361	−0,943
15	5,60	0,920	0,70	0,729	−0,083	−0,316	−0,772
						suma =	−16,207

$$A^2 = -n - \text{suma} = -15 - (-16{,}207) = 1{,}207$$

Veredicto Anderson–Darling

$A^2 = 1{,}207 < 1{,}32$ (crítico 5 %, exponencial con parámetro estimado) $\Rightarrow$ **no se rechaza** la exponencial, pero *marginalmente*.

Las tres pruebas juntas — y cómo leerlas

Prueba	Estadístico	Crítico 5 %	Decisión	Holgura
χ^2 (Pearson, k=3)	3,60	3,84	No rechaza	marginal (6 %)
Kolmogorov–Smirnov (Lilliefors)	0,271	0,220	**Rechaza**	por 23 %
Anderson–Darling	1,207	1,320	No rechaza	marginal (9 %)

¿Qué hacemos cuando las pruebas no coinciden?

- Con $n = 15$ *ninguna* prueba tiene mucho poder.
- El coeficiente de variación $\mathrm{CV} = 0{,}63$ es la señal *física* más clara: la exponencial no es apropiada.
- El gráfico Q-Q mostrará curvatura en "S"; confirma que Erlang o Gamma ajustan mejor.
- Regla práctica: **usar al menos dos pruebas** + el gráfico Q-Q, y nunca sólo el p-value.

Veredicto final: sospechar que la exponencial no es correcta; recolectar más datos.

Estimación por máxima verosimilitud

MLE

$\hat{\theta} = \arg\text{máx}_\theta\, \ell(\theta)$ con $\ell(\theta) = \sum_{i=1}^{n} \ln f(x_i;\theta)$.

Derivación completa para la exponencial. $f(x;\lambda) = \lambda e^{-\lambda x}$:

$$\ell(\lambda) = n\ln\lambda - \lambda\sum_{i=1}^{n} x_i \;\Rightarrow\; \frac{d\ell}{d\lambda} = \frac{n}{\lambda} - \sum x_i = 0 \;\Rightarrow\; \hat{\lambda} = \frac{1}{\bar{x}}$$

Distribución	Estimador MLE	Forma cerrada
Exponencial (λ)	$\hat{\lambda} = 1/\bar{x}$	Sí
Normal (μ, σ^2)	$\hat{\mu} = \bar{x}$, $\hat{\sigma}^2 = S^2$	Sí
Log-normal (μ, σ^2)	$\hat{\mu} = \overline{\ln x}$, $\hat{\sigma}^2 = S^2_{\ln x}$	Sí
Gamma (α, β)	eq. trascendental en $\hat{\alpha}$ (digamma)	No
Weibull (k, λ)	sistema no lineal	No

Los MLE son *asintóticamente eficientes* (mínima varianza) y consistentes. El método de momentos da un buen *punto de partida* para la optimización numérica.

Cuando varias distribuciones pasan las pruebas — AIC y BIC

Criterios de información

$$\mathrm{AIC} = -2\,\ell(\hat{\theta}) + 2p, \qquad \mathrm{BIC} = -2\,\ell(\hat{\theta}) + p \ln n$$

Menor es mejor. BIC penaliza más la complejidad cuando $n > 7$.

Regla práctica

1. Ajustar todas las candidatas con MLE.
2. Calcular AIC (o BIC) para cada una.
3. Elegir la de **menor** AIC.
4. Si $\Delta\mathrm{AIC} < 2$, los modelos son indistinguibles estadísticamente; preferir el *más simple* o el *más interpretable físicamente*.

Cierre del problema — $n = 80$ tiempos de servicio

Con más datos podemos discriminar:

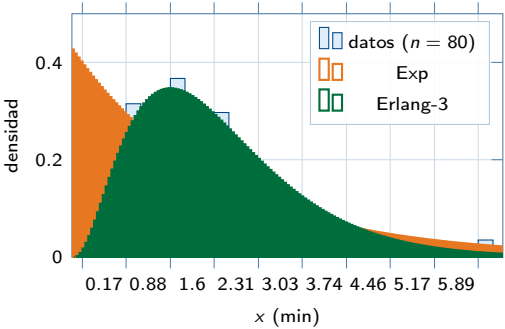

	AIC	KS D	A^2
Exponencial	298,6	0,14	**2,87**
Erlang-3	**276,2**	0,06	0,38
Gamma	276,8	0,05	0,31

- Exponencial **rechazada** por Anderson–Darling ($A^2 = 2{,}87 \gg 1{,}32$).
- Erlang-3 y Gamma son indistinguibles ($\Delta\mathrm{AIC} = 0{,}6$).
- Se elige **Erlang-3** por parsimonia e interpretación física (3 etapas: saludo, transacción, despedida).

Q-Q: Erlang-3 ajusta, la exponencial no

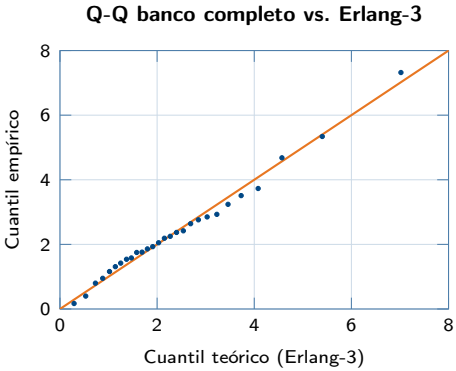

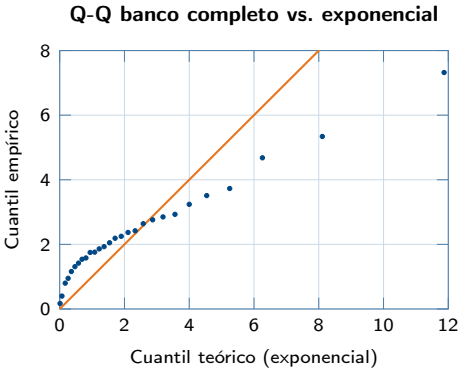

Izquierda: alineación casi perfecta con Erlang-3. **Derecha:** la curvatura en "S" revela que la exponencial tiene demasiados valores grandes — los tiempos reales son más concentrados.

Cerrando el círculo — W_q con la distribución correcta

Con $\lambda = 0{,}313$ cl/min, $\mathbb{E}[S] = 2{,}18$ min, $\rho = 0{,}68$:

$$\mathbb{E}[S^2] = (0{,}61 \cdot 2{,}18)^2 + (2{,}18)^2 = 1{,}77 + 4{,}75 = 6{,}52$$

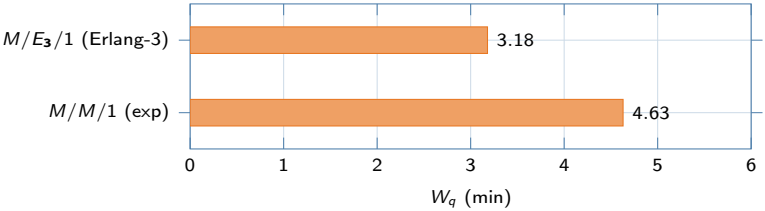

Conclusión del modelado del banco

Sistema $M/E_3/1$: llegadas Poisson ($\lambda = 0{,}313$ cl/min) + servicio Erlang-3 ($\mathbb{E}[S] = 2{,}18$ min).
Asumir incorrectamente $M/M/1$ **sobreestimaría W_q en un 46 %**.
Esta cifra es el valor tangible de haber hecho bien el modelado de entradas.

¿Y cuando no hay suficientes datos?

Situación	Estrategia	Distribución
Se conocen a, moda m, b	Elicitación de expertos	Triangular, PERT
Hay benchmarks/literatura	Valores de referencia	Según contexto
Entrada incierta	Análisis de sensibilidad	Varias candidatas
Solo se conocen $[a, b]$	Máxima entropía	$U(a, b)$

PERT — momentos

$$\mathbb{E}[X] = \frac{a + 4m + b}{6}, \qquad \mathrm{Var}[X] = \frac{(b-a)^2}{36}$$

La triangular no es un sustituto permanente

Sus colas son *lineales*, no exponenciales. Inadecuada para tiempos de servicio o falla realistas. Sirve para prototipos, *no* para el modelo final.

Cierre del tema T3.1

- El **coeficiente de variación** es la primera señal para elegir la familia.
- Con $n < 20$ las pruebas formales tienen poco poder: *confiar en Q-Q y en el proceso físico*.
- Con $n > 200$ las pruebas rechazan desviaciones irrelevantes: *usar AIC y la inspección visual*.
- **Siempre** verificar independencia (autocorrelación lag-1, prueba de rachas) y estacionariedad antes de ajustar.
- **Anderson–Darling** es la prueba estándar cuando las colas importan.
- La elección de distribución puede cambiar W_q por un factor de 2 o más: es la diferencia entre un modelo útil y uno engañoso.

Hacia T3.2 — Verificación y Validación

Una vez elegidas las distribuciones de entrada, hay que asegurarse de que el simulador las implementa correctamente *y* que el modelo global reproduce al sistema real.