Inferencia Estadística con Modelos de Simulación

Estimación en estado estacionario, comparación de sistemas y reducción de varianza

Curso de Pregrado en Simulación de Eventos Discretos

Departamento de Ingeniería Industrial

2 de mayo de 2026

Hoja de ruta

1. **Estimación en estado estacionario.** Sesgo del estado inicial; procedimiento de Welch para el período de calentamiento.
2. **Método de réplicas.** Estimadores, varianza entre réplicas, IC y dimensionamiento.
3. **Método de medias por lotes (*batch means*).** Una sola corrida larga; test de independencia entre lotes.
4. **Comparación de dos sistemas.** Muestreo independiente con prueba t de Welch.
5. **Reducción de varianza con Números Aleatorios Comunes (CRN).** Teorema fundamental, sincronización y comparación pareada.
6. **Eficiencia estadística.** Cuantificación de la ganancia por CRN.
7. **Métodos no paramétricos.** Mann–Whitney y Wilcoxon de rangos con signo.
8. **Decisión bajo incertidumbre.** Error Tipo I y Tipo II, función de potencia, tamaño de muestra.

El problema central

Sea $\{X_t : t \geq 0\}$ el proceso estocástico de interés (e.g., número en cola, tiempo de espera del cliente i). El **parámetro objetivo** es:

$$\mu \;=\; \lim_{t\to\infty} \mathbb{E}\left[\frac{1}{t}\int_0^t X_s\, ds\right] \quad \text{(estado estacionario).}$$

Dos dificultades fundamentales:

1. **Dependencia serial.** Las observaciones de *una sola corrida* están **correlacionadas**. El estimador ingenuo S^2/N subestima $\mathrm{Var}(\bar{X})$:

$$\mathrm{Var}(\bar{X}) \;=\; \frac{\sigma^2}{N}\left[1 + 2\sum_{k=1}^{N-1}\left(1 - \tfrac{k}{N}\right)\rho_k\right],$$

   donde ρ_k es la autocorrelación de orden k. En una M/M/1 con $\rho = 0{,}8$, este factor de inflación supera fácilmente a 30.

2. **Sesgo del estado inicial.** El simulador suele arrancar en estado vacío y ocioso. Las primeras observaciones reflejan esa condición artificial, no la distribución estacionaria.

Período de calentamiento: procedimiento gráfico de Welch

Procedimiento

Algoritmo (Welch, 1983):

1. Ejecutar k réplicas piloto independientes ($k \geq 5$), cada una de longitud T.
2. En cada instante j, calcular el promedio entre réplicas:

$$\bar{Y}_j = \frac{1}{k}\sum_{i=1}^{k} Y_{ij}, \quad j = 1, \ldots, T.$$

3. Suavizar con media móvil de ventana w:

$$\widetilde{Y}_j(w) = \frac{1}{2w+1}\sum_{s=-w}^{w} \bar{Y}_{j+s}, \quad w+1 \leq j \leq T-w.$$

4. Graficar $\widetilde{Y}_j(w)$ contra j y elegir como T_0 el punto a partir del cual la curva se estabiliza visualmente.

Reglas prácticas: w debe ser pequeño frente a T (e.g., $w = T/10$). Si la curva no se estabiliza, aumentar T.

Welch: ilustración para una M/M/1, $\rho = 0{,}8$

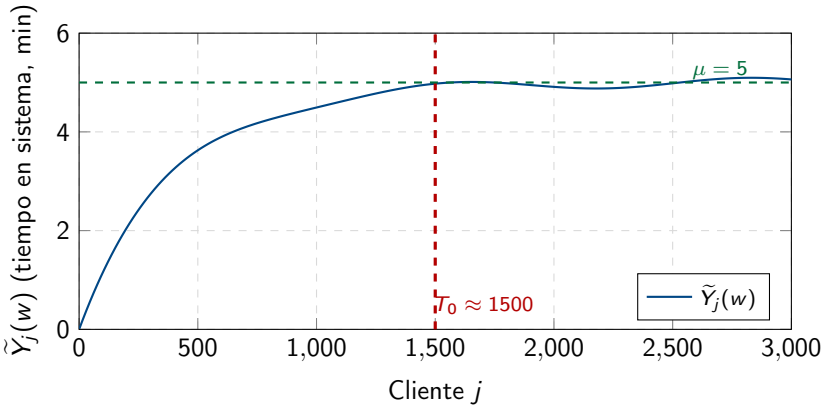

Lectura: las observaciones del cliente 1 al 1500 están sesgadas (sistema arranca vacío). Se descartan; el análisis se hace con los datos a partir del cliente 1501.

Método de réplicas: notación y estimadores

Definición

Se ejecutan n **réplicas independientes** (semillas independientes), cada una de longitud T con calentamiento T_0. Para la réplica i se calcula un estadístico resumen Y_i (por ejemplo, el promedio temporal de X_t sobre $[T_0, T]$).

Propiedades. Por construcción, $Y_1, \ldots, Y_n$ son **i.i.d.**. Si T es lo bastante grande, $\mathbb{E}[Y_i] \approx \mu$ y por TLC $\sqrt{n}(\bar{Y} - \mu) \xrightarrow{d} \mathcal{N}(0, \sigma^2)$.

Estimadores:

$$\bar{Y}(n) \;=\; \tfrac{1}{n}\textstyle\sum_{i=1}^{n} Y_i, \qquad S^2(n) \;=\; \tfrac{1}{n-1}\textstyle\sum_{i=1}^{n}(Y_i - \bar{Y}(n))^2.$$

Error estándar e intervalo de confianza al $100(1-\alpha)\,\%$:

$$\widehat{\mathrm{SE}}(\bar{Y}) \;=\; \frac{S(n)}{\sqrt{n}}, \qquad \bar{Y}(n) \;\pm\; t_{\alpha/2,\,n-1} \cdot \frac{S(n)}{\sqrt{n}}.$$

Ventaja: Y_i son i.i.d. por construcción, así que la teoría clásica del IC para la media aplica sin modificaciones.

Sistema: cajero único. $\lambda = 0{,}8$ clientes/min, $\mu = 1{,}0$ clientes/min. Métrica: tiempo medio en sistema W. Valor teórico $W = 1/(\mu - \lambda) = 5{,}0$ min.

Diseño: $n = 10$ réplicas independientes, $T = 10\,000$ min, $T_0 = 1\,000$ min.

Estadístico por réplica $Y_i = \widehat{W_i}$:

i	1	2	3	4	5	6	7	8	9	10
Y_i	4.78	5.12	4.95	5.23	4.82	5.05	5.18	4.91	5.09	4.87

Cálculos:

$$\bar{Y}(10) = 5{,}000, \qquad S^2(10) = \tfrac{1}{9}\sum(Y_i - 5{,}000)^2 = 0{,}02429, \qquad S(10) = 0{,}1559.$$

$$\widehat{\mathrm{SE}} = 0{,}1559/\sqrt{10} = 0{,}04929, \qquad t_{0{,}025;\,9} = 2{,}262.$$

IC 95 %: $5{,}000 \pm 2{,}262 \cdot 0{,}04929 \;=\; [4{,}888;\; 5{,}112]$ min. (El valor teórico $5{,}000 \in$ IC ✓.)

Tamaño de muestra para precisión absoluta

Objetivo: obtener un IC con semi-anchura h^* prefijada (precisión absoluta).

Aproximación normal (válida cuando n es grande o la distribución de Y_i es aproximadamente normal):

$$n \geq \left(\frac{z_{\alpha/2}\, S}{h^*} \right)^2,$$

con S estimado a partir de una corrida piloto de n_0 réplicas.

Procedimiento iterativo de Stein (con t de Student):

$$n^* = \text{mín}\left\{ n \geq n_0 \;:\; \frac{t_{\alpha/2,\, n-1}\, S(n_0)}{\sqrt{n}} \leq h^* \right\}.$$

Ejemplo trabajado

Ejemplo (continuación M/M/1): con $S(10) = 0{,}1559$, ¿cuántas réplicas se necesitan para $h^* = 0{,}05$ min?

$$n \geq \left(\frac{1{,}96 \cdot 0{,}1559}{0{,}05} \right)^2 = (6{,}111)^2 \approx 37{,}3 \Rightarrow n = 38.$$

Con corrección t (procedimiento de Stein) se llega a $n^* = 42$.

Medias por lotes (*batch means*): motivación y formalización

Idea: en lugar de n corridas independientes, hacer **una sola corrida muy larga** y dividirla en bloques. Si cada bloque es suficientemente grande, los promedios de los bloques son *aproximadamente* independientes.

Definición

Sea $\{X_i\}_{i=1}^{N}$ la secuencia de observaciones tras descartar el calentamiento. Se forman b **lotes** no superpuestos de tamaño m cada uno, con $N = bm$. La media del lote j es:

$$\bar{X}_j \;=\; \tfrac{1}{m}\textstyle\sum_{i=(j-1)m+1}^{jm} X_i, \qquad j = 1, \ldots, b.$$

La media global y el estimador de varianza son:

$$\bar{\bar{X}}(b) \;=\; \tfrac{1}{b}\textstyle\sum_{j=1}^{b} \bar{X}_j, \quad S_b^2 \;=\; \tfrac{1}{b-1}\textstyle\sum_{j=1}^{b}(\bar{X}_j - \bar{\bar{X}}(b))^2.$$

IC bajo independencia aproximada de los lotes:

$$\bar{\bar{X}}(b) \;\pm\; t_{\alpha/2,\, b-1} \cdot \frac{S_b}{\sqrt{b}}.$$

Compromiso: m pequeño $\Rightarrow$ muchos lotes correlacionados (IC inválido). m grande $\Rightarrow$ pocos lotes (IC ancho).

Test formal de independencia entre lotes

Idea: verificar empíricamente que los b lotes pueden tratarse como i.i.d. mediante la **autocorrelación de orden 1** de la sucesión $\{\bar{X}_j\}$.

Estadístico:

$$\widehat{\rho}_1 \;=\; \frac{\sum_{j=1}^{b-1}(\bar{X}_j - \bar{\bar{X}})(\bar{X}_{j+1} - \bar{\bar{X}})}{\sum_{j=1}^{b}(\bar{X}_j - \bar{\bar{X}})^2}.$$

Distribución bajo H_0: si los lotes son independientes, asintóticamente

$$\widehat{\rho}_1 \;\overset{a}{\sim}\; \mathcal{N}\left(-\tfrac{1}{b-1},\; \tfrac{1}{b}\right).$$

Regla de decisión (rechazar independencia si):

$$\sqrt{b}\,\left|\widehat{\rho}_1 + \tfrac{1}{b-1}\right| \;>\; z_{\alpha/2}.$$

Procedimiento de Schmeiser

Si el test **rechaza** independencia, **duplicar el tamaño del lote** ($m \to 2m$, lo cual reduce b a $b/2$) y repetir. Iterar hasta que no se rechace o hasta agotar la corrida.

Sistema: M/M/1 anterior. Una sola corrida $T = 100\,000$ min, $T_0 = 10\,000$.
Tras descartar warm-up: $N = 90\,000$ observaciones. Se forman $b = 20$ lotes de $m = 4\,500$ cada uno.

Medias de lote $\bar{X}_j$ (min):

4.96	5.04	5.08	4.93	5.10	4.97	5.06	5.02	4.95	5.07
5.01	4.99	5.05	4.94	5.08	5.00	4.96	5.03	5.02	4.98

Cálculos:

$$\bar{\bar{X}}(20) = 5{,}012, \quad S_b^2 = 0{,}00262, \quad S_b = 0{,}0512, \quad \widehat{\mathrm{SE}} = 0{,}0512/\sqrt{20} = 0{,}01145.$$

IC 95 % (con $t_{0{,}025;\,19} = 2{,}093$): $5{,}012 \pm 0{,}0240 = [4{,}988;\ 5{,}036]$ min. ✓

Test de independencia: $\widehat{\rho}_1 = 0{,}12$. Umbral $z_{0{,}025}/\sqrt{20} = 1{,}96/4{,}472 = 0{,}438$.
$\sqrt{20}\,|0{,}12 + 1/19| = 4{,}472 \cdot 0{,}173 = 0{,}772 < 1{,}96 \Rightarrow$ no se rechaza independencia; tamaño de lote adecuado.

Réplicas vs. medias por lotes

	Réplicas	**Medias por lotes**
Estructura	n corridas independientes	1 corrida larga partida en b lotes
Independencia	Garantizada por diseño	Aproximada; debe verificarse
Calentamiento	Se descarta en **cada** corrida	Se descarta una sola vez
Eficiencia computacional	Menor (cada corrida paga su warm-up)	Mayor (un solo warm-up)
Uso típico	*Terminating* y estado estacionario	Estado estacionario
Sensibilidad a sesgo inicial	Alta si T pequeño	Baja (warm-up amortizado)
Diagnóstico	Trivial (varianza muestral)	Test de independencia obligatorio

Recomendación práctica (Law, cap. 9): para estado estacionario con corridas costosas, preferir **batch means**. Para estudios donde se puedan paralelizar las réplicas, el método de réplicas suele ser más simple y robusto.

Comparación de dos sistemas: planteamiento

Sistemas: dos configuraciones A y B con medidas de desempeño μ_A y μ_B. Hipótesis:

$$H_0 : \mu_A = \mu_B \quad \text{vs.} \quad H_1 : \mu_A \neq \mu_B.$$

El parámetro de interés es la diferencia $\theta = \mu_A - \mu_B$.

Estrategias muestrales:

1. **Muestreo independiente:** cada réplica de A usa semillas independientes de las de B. Los pares $(X_{A,i}, X_{B,j})$ son no correlacionados.
2. **Muestreo pareado con CRN:** la réplica i de A y la réplica i de B comparten los mismos números aleatorios (*Common Random Numbers*). Induce $\text{Cor}(X_{A,i}, X_{B,i}) > 0$.

Identidad clave de varianzas:

$$\text{Var}(X_A - X_B) \;=\; \text{Var}(X_A) + \text{Var}(X_B) - 2\,\text{Cov}(X_A, X_B).$$

$\Rightarrow$ Inducir covarianza positiva **reduce** la varianza de la diferencia.

Muestreo independiente: prueba t de Welch

Definición

Sean $\{X_{A,i}\}_{i=1}^{n_A}$ y $\{X_{B,j}\}_{j=1}^{n_B}$ muestras independientes con varianzas posiblemente distintas.
Estadístico de Welch:

$$T = \frac{\bar{X}_A - \bar{X}_B}{\sqrt{S_A^2/n_A + S_B^2/n_B}} \overset{a}{\sim} t_\nu,$$

con grados de libertad de Welch–Satterthwaite:

$$\nu = \frac{(S_A^2/n_A + S_B^2/n_B)^2}{\dfrac{(S_A^2/n_A)^2}{n_A - 1} + \dfrac{(S_B^2/n_B)^2}{n_B - 1}}.$$

IC al $100(1-\alpha)\,\%$ **para** $\theta = \mu_A - \mu_B$:

$$(\bar{X}_A - \bar{X}_B) \pm t_{\alpha/2,\,\nu} \cdot \sqrt{S_A^2/n_A + S_B^2/n_B}.$$

Por qué Welch y no la versión *pooled*: en simulación rara vez se cumple $\sigma_A^2 = \sigma_B^2$ (sistemas distintos producen variabilidades distintas); usar varianza común sesga el nivel real de la prueba. Welch es robusto a heterocedasticidad.

Ejemplo: ¿una cola común o colas separadas?

Sistema: dos cajeros idénticos, $\mu = 5$ clientes/h cada uno; tasa total de llegadas $\lambda = 8$/h.

- **Configuración A.** Una sola cola alimenta a los dos cajeros (M/M/2).
- **Configuración B.** Dos colas independientes, una por cajero ($\lambda/2 = 4$ a cada lado, M/M/1).

Métrica: tiempo medio en sistema W (min). Valores teóricos: $W_A = 33{,}3$, $W_B = 60{,}0$.

Datos: $n = 10$ **réplicas independientes de cada configuración,** $T = 8$ **h tras warm-up:**

i	1	2	3	4	5	6	7	8	9	10	$\bar{X}$
$X_{A,i}$	33.71	33.02	34.18	33.45	33.85	32.71	34.02	33.61	33.20	33.25	33.500
$X_{B,i}$	60.49	58.95	60.78	59.32	60.91	58.62	60.04	59.78	60.85	60.26	60.000

Estadísticos: $S_A^2 = 0{,}2134$, $S_B^2 = 0{,}6651$, $\bar{X}_A - \bar{X}_B = -26{,}500$.

$$\widehat{\mathrm{SE}} = \sqrt{0{,}2134/10 + 0{,}6651/10} = \sqrt{0{,}0879} = 0{,}2964.$$

$$T = -26{,}500/0{,}2964 = -89{,}4, \qquad \nu = 14{,}3 \Rightarrow t_{0{,}025;\,14} = 2{,}145.$$

IC 95 % para $\mu_A - \mu_B$: $-26{,}500 \pm 0{,}636 = [-27{,}136;\ -25{,}864]$.
$0 \notin$ IC y diferencia operacionalmente enorme: Configuración A es claramente superior.

Números aleatorios comunes (CRN): teorema fundamental

Idea: ejecutar las dos configuraciones *con los mismos números aleatorios* para los mismos propósitos (mismas llegadas, mismos tiempos de servicio del cliente i, etc.). Esto induce dependencia positiva entre X_A y X_B.

Teorema (Bratley, Fox & Schrage, 1987)

Sean $X_A = g_A(\mathrm{U})$ y $X_B = g_B(\mathrm{U})$ con $\mathrm{U} = (U_1, \ldots, U_d)$ vector de uniformes independientes. Si g_A y g_B son ambas **monótonas no decrecientes** (o ambas no crecientes) en cada componente U_k, entonces:

$$\mathrm{Cov}(X_A, X_B) \;\geq\; 0.$$

Consecuencia. Bajo CRN:

$$\mathrm{Var}(X_A - X_B) \;=\; \mathrm{Var}(X_A) + \mathrm{Var}(X_B) - 2\,\mathrm{Cov}(X_A, X_B) \;\leq\; \mathrm{Var}(X_A) + \mathrm{Var}(X_B).$$

Advertencia. En simulaciones complejas no se puede garantizar la monotonicidad analíticamente, pero CRN es una técnica **empíricamente robusta**: en la inmensa mayoría de los casos prácticos induce $\mathrm{Cov} > 0$ y reduce la varianza de la diferencia.

Implementación correcta requiere dos elementos:

(1) Streams dedicados. Un generador independiente para cada *fuente* de aleatoriedad (no uno solo para todo el modelo):

Fuente	Stream
Tiempos entre llegadas	Stream 1
Tiempos de servicio	Stream 2
Decisiones de *routing*	Stream 3
Fallas de equipo	Stream 4

(2) Sincronización. El i-ésimo número de cada stream se debe usar para la **misma decisión** en ambas configuraciones. Por ejemplo: U_i del Stream 2 genera el tiempo de servicio del cliente i *tanto en* A *como en* B.

Método de generación. La sincronización se preserva mejor con **transformación inversa** ($X = F^{-1}(U)$): un solo U produce un solo X. Métodos como aceptación-rechazo consumen un número aleatorio de uniformes y *rompen* la sincronización entre sistemas.

Reset. Al inicio de la réplica i, ambos sistemas reinician todos los streams al mismo estado.

Comparación pareada con CRN: marco formal

Definición

Bajo CRN, para cada réplica $i = 1, \ldots, n$ se obtiene el par $(X_{A,i}, X_{B,i})$ ejecutado con los mismos streams. Definimos las diferencias:

$$D_i \;=\; X_{A,i} - X_{B,i}, \qquad i = 1, \ldots, n.$$

$D_1, \ldots, D_n$ son i.i.d. con $\mathbb{E}[D_i] = \mu_A - \mu_B$ y varianza:

$$\sigma_D^2 \;=\; \mathrm{Var}(X_A) + \mathrm{Var}(X_B) - 2\,\mathrm{Cov}(X_A, X_B).$$

Estadístico: $\bar{D} = \frac{1}{n}\sum D_i, \quad S_D^2 = \frac{1}{n-1}\sum (D_i - \bar{D})^2.$
Prueba t pareada:

$$T_{\text{par}} \;=\; \frac{\bar{D}}{S_D/\sqrt{n}} \;\sim\; t_{n-1} \quad \text{bajo } H_0:\ \mu_A = \mu_B.$$

IC al $100(1-\alpha)\,\%$ **para** $\theta = \mu_A - \mu_B$: $\quad \bar{D} \;\pm\; t_{\alpha/2,\,n-1} \cdot \dfrac{S_D}{\sqrt{n}}.$

Atención: se usa t_{n-1}, **no** la fórmula de Welch. Las muestras dejan de ser independientes; la varianza relevante es la de las diferencias, no la suma de las varianzas marginales.

CRN: ejemplo trabajado (mismo experimento del ejemplo anterior)

Mismo problema, ahora con CRN: la réplica i usa los *mismos* streams para llegadas y servicios en A y en B.

i	1	2	3	4	5	6	7	8	9	10	$\bar{D}$
$X_{A,i}$	33.71	33.02	34.18	33.45	33.85	32.71	34.02	33.61	33.20	33.25	
$X_{B,i}$	60.12	59.64	60.48	60.00	60.25	59.49	60.34	60.11	59.75	59.77	
D_i	-26.41	-26.62	-26.30	-26.55	-26.40	-26.78	-26.32	-26.50	-26.55	-26.52	-26.500

Cálculos:

$$\bar{D} = -26{,}500, \quad S_D^2 = 0{,}02013, \quad S_D = 0{,}1419, \quad \widehat{\mathrm{SE}}_D = 0{,}1419/\sqrt{10} = 0{,}04488.$$

$$T_{\text{par}} = -26{,}500/0{,}04488 = -590{,}5, \qquad t_{0{,}025;\,9} = 2{,}262.$$

IC 95 % para $\mu_A - \mu_B$: $-26{,}500 \pm 0{,}1015 \;=\; [-26{,}601;\; -26{,}398]$.

Comparación de IC (mismo experimento, mismo tamaño muestral):

- Independiente: semi-anchura $h_{\text{ind}} = 0{,}636$.
- CRN pareado: semi-anchura $h_{\text{CRN}} = 0{,}102$.
- **Razón de anchuras:** $h_{\text{ind}}/h_{\text{CRN}} \approx 6{,}2$.

Eficiencia estadística: cuantificación de la ganancia

Definición. La **eficiencia** de CRN respecto al muestreo independiente es:

$$\eta = \frac{\mathrm{Var}_{\mathrm{ind}}(\bar{X}_A - \bar{X}_B)}{\mathrm{Var}_{\mathrm{CRN}}(\bar{D})}.$$

En el ejemplo:

$$\mathrm{Var}_{\mathrm{ind}} = \frac{S_A^2}{n} + \frac{S_B^2}{n} = \frac{0{,}2134 + 0{,}6651}{10} = 0{,}0879.$$

$$\mathrm{Var}_{\mathrm{CRN}} = \frac{S_D^2}{n} = \frac{0{,}02013}{10} = 0{,}002013.$$

$$\eta = \frac{0{,}0879}{0{,}002013} \approx 43{,}7.$$

Lectura operacional

Con CRN, $n = 10$ réplicas producen un IC tan preciso como $\eta \cdot n \approx 437$ réplicas independientes. **La ganancia computacional es enorme.**

Caveat. CRN puede *aumentar* la varianza si las funciones de respuesta son *anti-monótonas* (subir un U favorece a A y perjudica a B). En la práctica esto es raro pero debe verificarse con un piloto: estimar $\widehat{\mathrm{Cov}}(X_A, X_B)$; si resulta negativa, abandonar CRN.

Cuándo fallan los supuestos paramétricos

La prueba t requiere, vía TLC, que $\bar{D}$ (o $\bar{X}_A - \bar{X}_B$) sea aproximadamente normal. Esto puede fallar cuando:

- n es **pequeño** (digamos $n \leq 8$) y la distribución de D_i es muy asimétrica.
- La métrica tiene **cola pesada** (e.g., tiempo de espera del cliente más perjudicado, máxima cola del día).
- Hay **atípicos** que dominan la varianza muestral.
- La métrica es **ordinal** (rangos, calificaciones).

Alternativas no paramétricas:

Diseño	Prueba	Hipótesis nula
Independiente	Mann–Whitney U (Wilcoxon de suma de rangos)	$F_A = F_B$
Pareado (CRN)	Wilcoxon de rangos con signo	F_D simétrica en torno a 0

Pérdida de potencia bajo normalidad: $\approx 5\,\%$ (eficiencia asintótica relativa $3/\pi \approx 0{,}955$). Vale la pena pagarla cuando la normalidad es dudosa.

Mann–Whitney U: muestreo independiente

Procedimiento

1. Combinar las dos muestras y asignar rangos $1, \ldots, n_A + n_B$ (rangos promedio en empates).
2. R_A = suma de rangos de la muestra A.
3. Calcular $U_A = R_A - n_A(n_A+1)/2$. Análogamente U_B. (Verificación: $U_A + U_B = n_A n_B$.)
4. Estadístico: $U = \text{mín}(U_A, U_B)$. Rechazar H_0 si $U \leq u_{\alpha; n_A, n_B}$ (tabla).
5. Si $n_A, n_B \geq 10$: usar la aproximación normal $Z = (U - \mu_U)/\sigma_U$ con $\mu_U = n_A n_B/2$ y $\sigma_U^2 = n_A n_B(n_A + n_B + 1)/12$.

Ejemplo trabajado

Aplicado a las primeras 10 réplicas de cada configuración del ejemplo: las 10 observaciones de A caen entre 32.71 y 34.18; las de B entre 58.62 y 60.91. Toda observación de A es menor que toda observación de B, así que los rangos de A son $\{1, \ldots, 10\}$.
$R_A = 55$, $U_A = 55 - 55 = 0$, $U_B = 100$, $U = 0$. Valor crítico de tabla: $u_{0{,}05;\,10,10} = 23$.
$0 \leq 23 \Rightarrow$ se rechaza H_0: las distribuciones difieren (coincide con la conclusión paramétrica).

Wilcoxon de rangos con signo: comparación pareada

Procedimiento

1. Calcular las diferencias pareadas $D_i = X_{A,i} - X_{B,i}$. Descartar $D_i = 0$.
2. Asignar rangos a $|D_i|$ (rangos promedio en empates).
3. Sumar los rangos de las $D_i > 0$: W^+. Sumar los rangos de las $D_i < 0$: W^-. Verificación: $W^+ + W^- = n(n+1)/2$.
4. Estadístico: $W = \text{mín}(W^+, W^-)$. Rechazar H_0 si $W \leq w_{\alpha;n}$ (tabla).
5. Para $n \geq 20$: aproximación normal con $\mu_W = n(n+1)/4$ y $\sigma_W^2 = n(n+1)(2n+1)/24$.

Ejemplo trabajado

Diferencias del ejemplo CRN: todas $D_i < 0$, $|D_i|$ entre 26.30 y 26.78 con rangos $1, \ldots, 10$.
$W^+ = 0$, $W^- = 55$, $W = 0$. Valor crítico $w_{0{,}05;\,10} = 8$ (dos colas).
$0 \leq 8 \Rightarrow$ se rechaza H_0: las medianas difieren significativamente (coincide con t pareado).

Toda prueba de hipótesis admite dos tipos de error:

Decisión \ Realidad	H_0 verdadera ($\mu_A = \mu_B$)	H_0 falsa ($\mu_A \neq \mu_B$)
No rechazar H_0	Decisión correcta	**Error Tipo II** (prob. β)
Rechazar H_0	**Error Tipo I** (prob. α)	Decisión correcta (potencia $1 - \beta$)

Asimetría operacional:

- **Error Tipo I.** Concluir que las configuraciones difieren cuando son equivalentes. Costo: invertir en cambiar el sistema sin obtener beneficio.
- **Error Tipo II.** Concluir que son equivalentes cuando A es realmente mejor. Costo: oportunidad perdida; el sistema sigue subóptimo.

El analista controla α (típicamente 0.05) **y** β (típicamente 0.20, i.e., potencia 0.80) **eligiendo el tamaño de muestra**.

Función de potencia y tamaño de muestra

Función de potencia: probabilidad de rechazar H_0 como función de la diferencia real $\theta = \mu_A - \mu_B$:

$$\pi(\theta) \;=\; \mathbb{P}(\text{rechazar } H_0 \mid \mu_A - \mu_B = \theta).$$

$\pi(0) = \alpha$ (nivel) y $\pi(\theta) \to 1$ cuando $|\theta| \to \infty$ (consistencia).

Tamaño de muestra para detectar una diferencia δ con potencia $1-\beta$:

Pareado (CRN)

$$n_{\text{par}} \;\geq\; \left\lceil \frac{(z_{\alpha/2} + z_\beta)^2\, \sigma_D^2}{\delta^2} \right\rceil$$

Independiente, varianza común σ^2

$$n_{\text{ind}} \;\geq\; \left\lceil \frac{2(z_{\alpha/2} + z_\beta)^2\, \sigma^2}{\delta^2} \right\rceil \quad \text{(por grupo)}$$

Ajuste con t: fórmulas anteriores usan aproximación normal. Para n pequeño, iterar reemplazando $z_{\alpha/2} \to t_{\alpha/2,\, n-1}$ y resolver hasta convergencia.

Ejemplo: dimensionar el experimento

Decisión: se quiere detectar una diferencia operacional $\delta = 0{,}5$ min con $\alpha = 0{,}05$ y potencia $1 - \beta = 0{,}80$.
Datos del piloto (10 réplicas previas):

$$S_A^2 = 0{,}21, \quad S_B^2 = 0{,}67, \quad S_D^2 = 0{,}020 \text{ (con CRN)}.$$

Cuantiles: $z_{0{,}025} = 1{,}96$, $z_{0{,}20} = 0{,}84$, $(z_{0{,}025} + z_{0{,}20})^2 = 7{,}84$.

Independiente: usar $\sigma^2 \approx (S_A^2 + S_B^2)/2 = 0{,}44$.

$$n_{\text{ind}} \geq \frac{2 \cdot 7{,}84 \cdot 0{,}44}{0{,}25} = \frac{6{,}90}{0{,}25} = 27{,}6 \Rightarrow n_{\text{ind}} = 28 \text{ por grupo } (\textbf{56 réplicas totales}).$$

CRN pareado: $\sigma_D^2 = 0{,}020$.

$$n_{\text{par}} \geq \frac{7{,}84 \cdot 0{,}020}{0{,}25} = \frac{0{,}157}{0{,}25} = 0{,}63 \Rightarrow n_{\text{par}} = 1.$$

Como n_{par} debe ser razonable para que aplique TLC, fijar $n_{\text{par}} \geq 5$ por convención. **Total: 5 réplicas pareadas.**

Costo computacional: 56 corridas vs. $5 \times 2 = 10$ corridas $\Rightarrow$ **factor 5.6 a favor de CRN**.

Síntesis: la decisión bajo incertidumbre

1. **Estimación.** En estado estacionario, las observaciones están autocorrelacionadas; la varianza muestral ingenua subestima $\mathrm{Var}(\bar{X})$. Hay dos remedios formales: **réplicas** (con calentamiento individual) y **batch means** (una corrida larga + test de independencia).
2. **Comparación.** Si las muestras son independientes, usar **prueba** t **de Welch**. Si están pareadas (CRN), usar **prueba** t **pareada** sobre las diferencias. *Nunca aplicar Welch a datos CRN*: pierde toda la ganancia de varianza.
3. **Reducción de varianza. CRN** es la técnica más simple y eficaz: ganancias típicas de 5–50$\times$ en eficiencia. Requiere *streams dedicados* y *sincronización* cuidadosa.
4. **No paramétricos.** Cuando las muestras son pequeñas y la normalidad es dudosa, **Mann–Whitney** (independiente) y **Wilcoxon de rangos con signo** (pareado) son alternativas robustas que pierden poca potencia.
5. **Diseño experimental.** El tamaño de muestra se elige *antes de correr* fijando α, β y la diferencia mínima detectable δ. La fórmula de potencia es la herramienta central.

Sin análisis estadístico de salidas, una simulación es solo un programa que produce números.

Referencias

Law, A. M. (2015). *Simulation Modeling and Analysis* (5th ed.). McGraw-Hill. **Caps. 9–12.**

Banks, J., Carson, J. S., Nelson, B. L., Nicol, D. M. (2010). *Discrete-Event System Simulation* (5th ed.). Pearson. Caps. 11–12.

Kelton, W. D., Sadowski, R. P., Zupick, N. B. (2015). *Simulation with Arena* (6th ed.). McGraw-Hill. Caps. 6, 12.

Ross, S. M. (2013). *Simulation* (5th ed.). Academic Press. Caps. 7, 9.

Welch, P. D. (1983). The Statistical Analysis of Simulation Results. En *The Computer Performance Modeling Handbook*, Lavenberg (ed.), Academic Press, 268–328.

Schmeiser, B. W. (1982). Batch Size Effects in the Analysis of Simulation Output. *Operations Research*, 30(3), 556–568.

Bratley, P., Fox, B. L., Schrage, L. E. (1987). *A Guide to Simulation* (2nd ed.). Springer-Verlag.

Nelson, B. L. (2013). *Foundations and Methods of Stochastic Simulation*. Springer.

Conover, W. J. (1999). *Practical Nonparametric Statistics* (3rd ed.). Wiley.

¿Preguntas?

Inferencia Estadística con Modelos
de Simulación de Eventos Discretos