Simulación Manual de Sistemas de Colas

Métricas, Ley de Little, Utilización y Costos

Departamento de Ingeniería Industrial

Curso de Simulación de Eventos Discretos

Semestre 2026-I

Contenido

1. La idea central: dos maneras de medir lo mismo
2. Utilizacion y su impacto
3. Costos: convertir metricas en decisiones
4. Simulacion manual completa: el ejemplo paso a paso
5. Verificacion: Ley de Little
6. Costos: aplicación del ejemplo
7. Checklist y ejercicios
8. Conclusiones

Dos lentes para mirar una cola

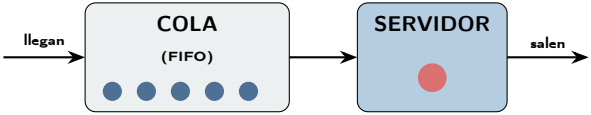

Lente "por tiempo"

¿Cuántos clientes hay en promedio?

$\widehat{L}$, $\widehat{L_Q}$, $\widehat{\rho}$

Little

Lente "por cliente"

¿Cuánto espera cada cliente en promedio?

$\widehat{w}$, $\widehat{w_Q}$

La **Ley de Little** conecta ambas perspectivas: $\widehat{L} = \widehat{\lambda} \cdot \widehat{w}$. Hoy aprenderemos a **calcular todo esto a mano** y verificar que cuadra.

¿Por qué la misma cantidad tiene dos formas?

Piense en un estacionamiento que observamos durante 8 horas:

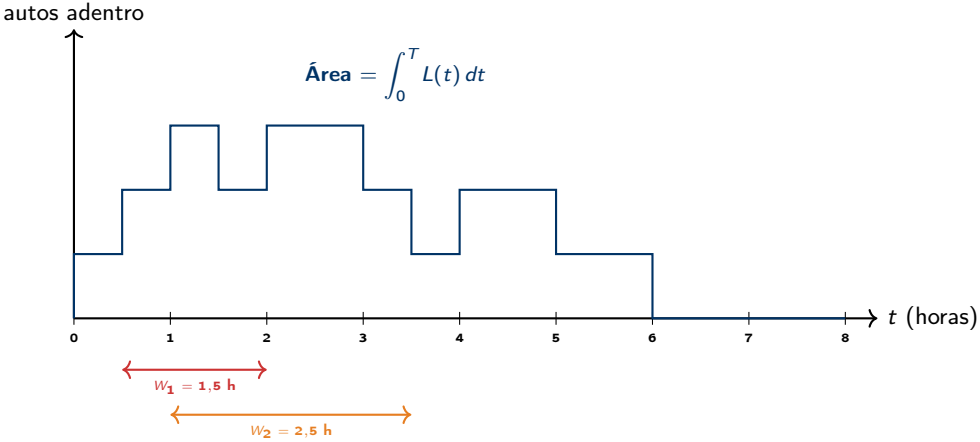

Leer verticalmente (foto en cada instante):
Área bajo $L(t)$ = total de "auto-horas"

$$\widehat{L} = \frac{\text{área}}{T}$$

Leer horizontalmente (seguir a cada auto):
Suma de W_j = el mismo total de "auto-horas"

$$\widehat{w} = \frac{\sum W_j}{N}$$

La identidad que siempre se cumple

Identidad contable (Little operacional)

$$\underbrace{\frac{1}{T}\int_0^T L(t)\,dt}_{\widehat{L}} = \underbrace{\frac{N}{T}}_{\widehat{\lambda}} \times \underbrace{\frac{1}{N}\sum_{j=1}^{N} W_j}_{\widehat{w}}$$

$\widehat{L} = 0{,}77$ $\xleftrightarrow[\text{Ley de Little}]{\times\,\widehat{\lambda} = 0{,}4}$ $\widehat{w} = 1{,}92$

No es una aproximación, no requiere estado estable, no depende de la distribución: es una **tautología matemática**. Funciona siempre que las definiciones sean consistentes.

Utilización ρ: qué fracción del tiempo trabaja el servidor

Definición

$$\widehat{\rho} = \frac{\text{tiempo total que el servidor estuvo ocupado}}{T}$$

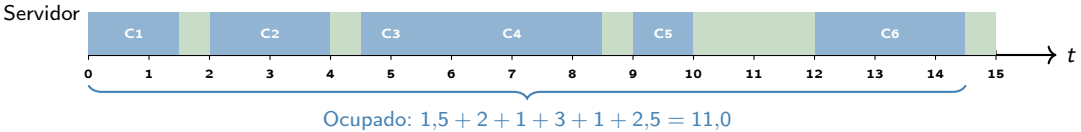

$$\boxed{\widehat{\rho} = 11{,}0 \,/\, 15 = 0{,}733}$$

El servidor estuvo libre solo $15 - 11 = 4$ unidades de tiempo (27 % del horizonte).

¿Por qué importa ρ?

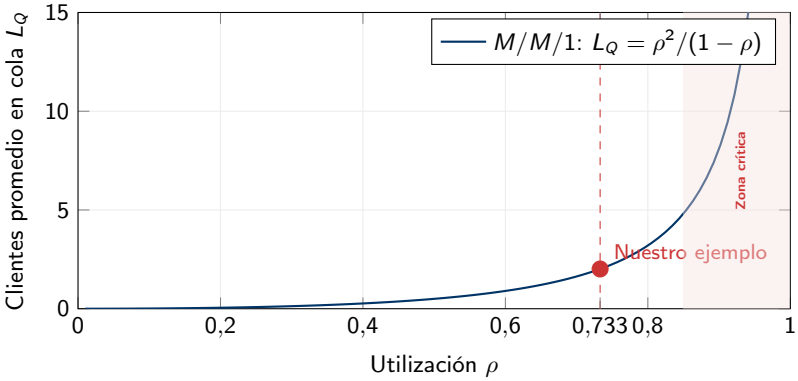

La relación entre ρ y L_Q es **no lineal**: pasar de $\rho = 0{,}7$ a $\rho = 0{,}9$ triplica la cola. Pequeños aumentos de carga cerca de $\rho = 1$ disparan las esperas.

De métricas a dinero: el modelo de costos

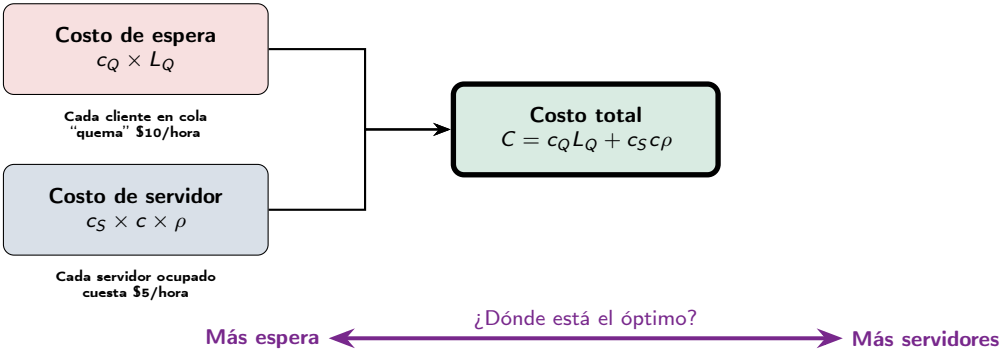

Agregar un servidor **sube** $c_S c \rho$ pero **baja** $c_Q L_Q$. El óptimo está donde la curva total tiene su mínimo.

Ejemplo visual: trade-off de costos

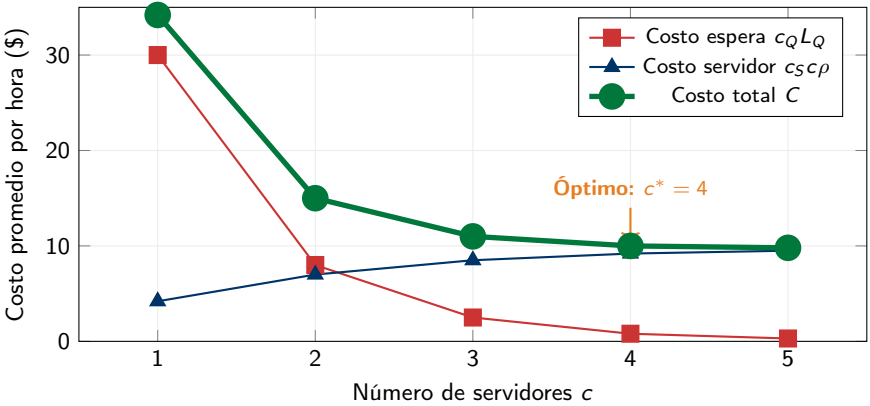

En este ejemplo, $c^* = 4$ servidores minimiza el costo total. Con menos, la espera domina; con más, se paga por capacidad ociosa.

El sistema que simularemos

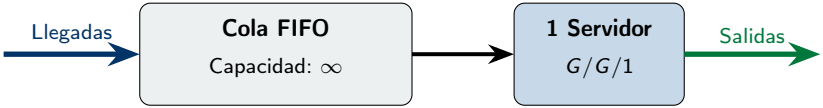

Horizonte: $T = 15$ **u.t.**

Datos de entrada (lo único que nos "dan"):

Cliente j	**Llegada** A_j	**Servicio** S_j
1	0.0	1.5
2	2.0	2.0
3	4.5	1.0
4	5.0	3.0
5	9.0	1.0
6	12.0	2.5

Paso 1: ¿Cuándo empieza cada servicio? (B_j)

Regla operacional

$$B_1 = A_1, \qquad B_j = \text{máx}\{A_j,\ D_{j-1}\} \quad \text{para } j \geq 2$$

Caso A: llega y está libre

✓

$B_j = A_j$ (empieza al llegar)

Caso B: llega y está ocupado

→ **cola**

$B_j = D_{j-1}$ (espera a que termine el anterior)

Ejemplo — Cliente 4: Llega en $A_4 = 5{,}0$, pero C3 termina en $D_3 = 5{,}5$.
$B_4 = \text{máx}\{5{,}0,\ 5{,}5\} = 5{,}5 \Rightarrow$ Debe esperar 0.5 u.t. en cola.

Paso 2: ¿Cuándo sale cada cliente? (D_j)

Fórmula trivial pero fundamental

$$D_j = B_j + S_j$$

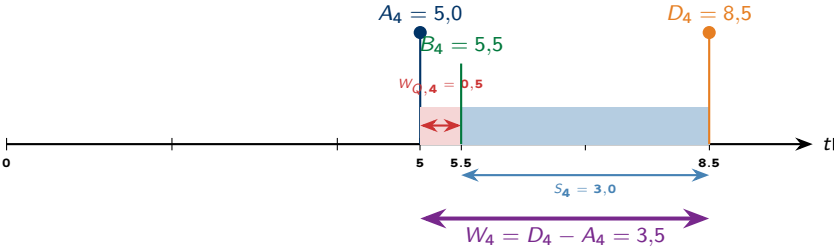

Verificación: $W_4 = W_{Q,4} + S_4 = 0{,}5 + 3{,}0 = 3{,}5$ ✓
Siempre debe cumplirse $W_j = W_{Q,j} + S_j$.

Paso 3: esperas y tiempos de cada cliente

Fórmulas

$$W_{Q,j} = B_j - A_j \quad \text{(espera en cola)}, \qquad W_j = D_j - A_j \quad \text{(tiempo total en sistema)}$$

j	A_j	S_j	B_j	D_j	$W_{Q,j}$	W_j
1	0.0	1.5	0.0	1.5	0.0	1.5
2	2.0	2.0	2.0	4.0	0.0	2.0
3	4.5	1.0	4.5	5.5	0.0	1.0
4	5.0	3.0	**5.5**	**8.5**	**0.5**	**3.5**
5	9.0	1.0	9.0	10.0	0.0	1.0
6	12.0	2.5	12.0	14.5	0.0	2.5
				Suma:	0.5	11.5

Solo el **cliente 4** tuvo que esperar: llegó en $t = 5{,}0$ pero C3 aún estaba en servicio hasta $t = 5{,}5$.

Calendario de eventos y diagrama temporal

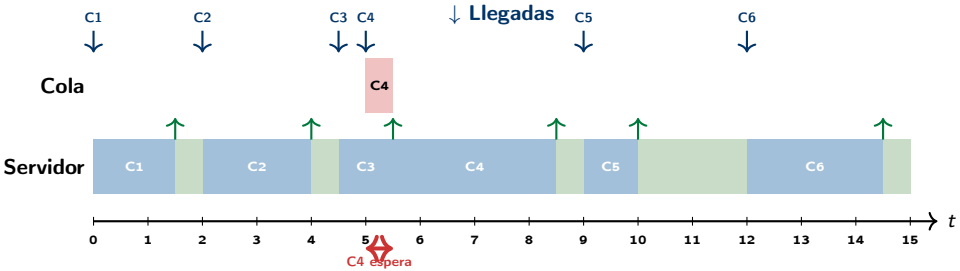

Este diagrama de Gantt muestra **toda la historia** del sistema. Note cómo C4 llega en $t = 5$ pero C3 ocupa el servidor hasta $t = 5{,}5$: la única cola del ejemplo.

La función $L(t)$: clientes en el sistema a cada instante

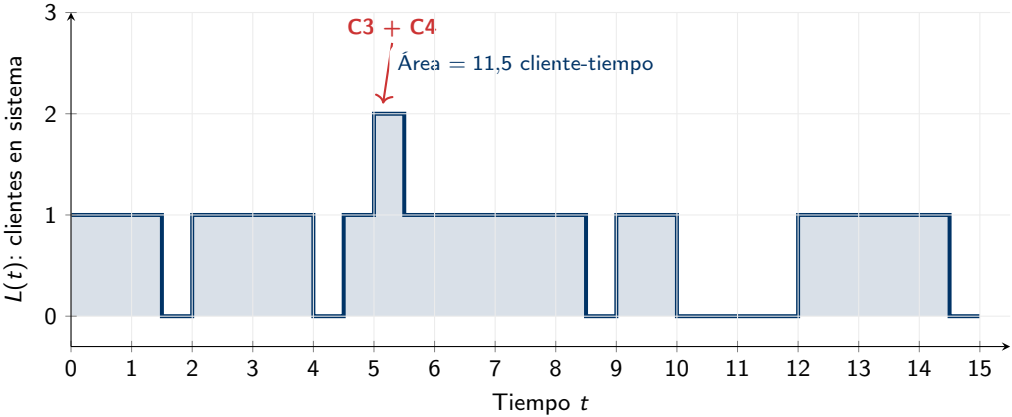

$$\widehat{L} = \frac{\text{área}}{T} = \frac{11{,}5}{15} = 0{,}7667$$

Cálculo detallado del área bajo $L(t)$

Intervalo	**Desde**	**Hasta**	Δt	$L(t)$	**Área** $= L \times \Delta t$
1	0.0	1.5	1.5	1	1.5
2	1.5	2.0	0.5	0	0.0
3	2.0	4.0	2.0	1	2.0
4	4.0	4.5	0.5	0	0.0
5	4.5	5.0	0.5	1	0.5
6	5.0	5.5	0.5	2	1.0
7	5.5	8.5	3.0	1	3.0
8	8.5	9.0	0.5	0	0.0
9	9.0	10.0	1.0	1	1.0
10	10.0	12.0	2.0	0	0.0
11	12.0	14.5	2.5	1	2.5
12	14.5	15.0	0.5	0	0.0
			15.0		**11.5**

El intervalo 6 ($t \in [5, 5{,}5]$) es el único con $L = 2$: C3 en servicio + C4 en cola.

La función $L_Q(t)$: clientes **solo en cola**

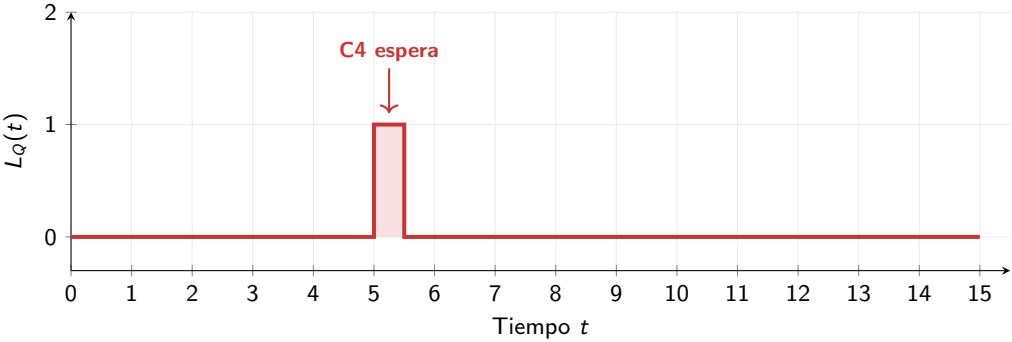

Área bajo $L_Q(t) = 1 \times 0{,}5 = 0{,}5$

$$\widehat{L_Q} = \frac{0{,}5}{15} = 0{,}0333$$

Solo hubo cola durante medio unidad de tiempo en todo el horizonte.

Promedios por cliente: $\widehat{w}$ y $\widehat{w_Q}$

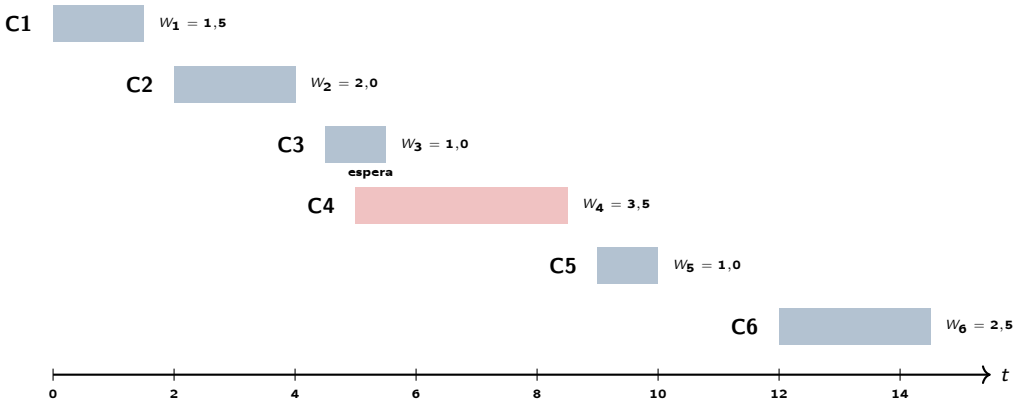

$$\widehat{w} = \frac{\sum W_j}{N} = \frac{1{,}5 + 2{,}0 + 1{,}0 + 3{,}5 + 1{,}0 + 2{,}5}{6} = \frac{11{,}5}{6} = 1{,}9167$$

$$\widehat{w_Q} = \frac{\sum W_{Q,j}}{N} = \frac{0 + 0 + 0 + 0{,}5 + 0 + 0}{6} = \frac{0{,}5}{6} = 0{,}0833$$

Verificación con la Ley de Little

Tasa de llegada observada:

$$\widehat{\lambda} = \frac{N}{T} = \frac{6}{15} = 0{,}4 \text{ clientes/u.t.}$$

Relación	$\widehat{\lambda} \times \widehat{w}$	$=$	$\widehat{L}$
Sistema	$0{,}4 \times 1{,}9167$	$=$	$0{,}7667$ ✓
Cola	$0{,}4 \times 0{,}0833$	$=$	$0{,}0333$ ✓

Usar Little como detector de errores

Si al hacer la tabla manual $\widehat{\lambda} \cdot \widehat{w} \neq \widehat{L}$, hay un error de cálculo. Las causas más comunes: (1) horizonte T inconsistente, (2) clientes contados de más o de menos, (3) área mal calculada.

Resumen visual de todas las métricas

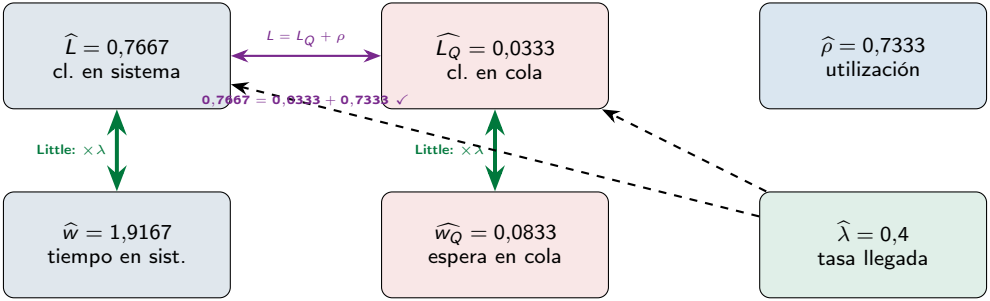

Note la relación adicional: $\widehat{L} = \widehat{L_Q} + \widehat{\rho}$ (los clientes están en cola **o** en servicio). Esto da **otra** verificación independiente.

Costos concretos de nuestro ejemplo

Supuestos: $c_Q = 10$ \$/u.t. por cliente en cola, $c_S = 5$ \$/u.t. por servidor ocupado.

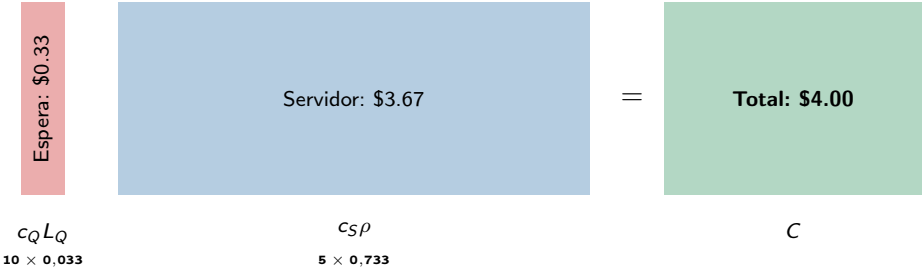

Lectura:

- El 92 % del costo viene del servidor
- Solo 8 % de la espera de clientes
- En este caso, el sistema es eficiente

¿Qué pasaría si $\rho \to 0{,}95$?

- L_Q se dispara (no linealmente)
- El costo de espera dominaría
- Se justificaría agregar servidores

Checklist: antes de simular en computador

Modelado:

- ¿Población finita o infinita?
- ¿Capacidad de cola limitada?
- ¿Llegadas: Poisson, programadas, por lotes?
- ¿Disciplina: FIFO, prioridad, otra?
- ¿Cuántos servidores? ¿Idénticos?
- ¿Distribuciones con datos reales?

Métricas (definir antes):

- ¿$\widehat{w_Q}$ (experiencia del cliente)?
- ¿$\widehat{L_Q}$ (espacio físico)?
- ¿Costos y trade-offs?
- ¿Promedios o percentiles?
- ¿Verificar Little al final?

Regla de oro

Si no puedes hacer la simulación **a mano** para 5–10 clientes, no estás listo para programarla en computador. La tabla manual es el mejor debugger.

Ejercicio 1: ¿Qué pasa si C4 tarda más?

Cambio: S_4 pasa de 3.0 a **5.0** (todo lo demás igual).

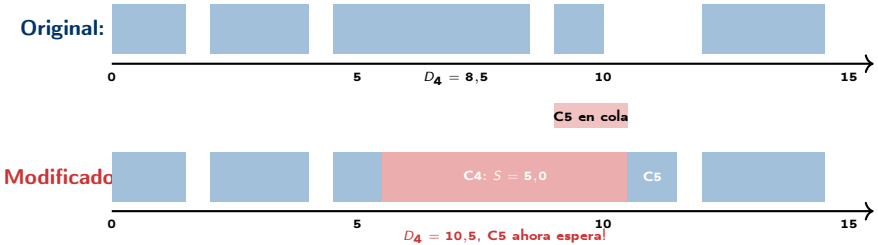

Tarea: Completen la tabla, calculen $\widehat{w_Q}$, $\widehat{L_Q}$ y verifiquen Little. ¿Qué métrica cambia más?

Ejercicio 2: C4 tiene prioridad

Cambio de disciplina: C4 es **prioritario**. Si llega y hay cola, pasa al frente (pero no interrumpe un servicio en curso).

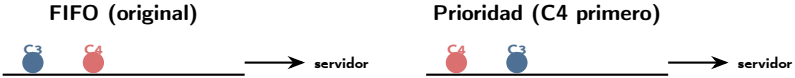

Preguntas:

1. En nuestro ejemplo, ¿cambia algo? (Pista: ¿C3 y C4 están alguna vez *juntos* en cola?)
2. Inventen un escenario con 4 clientes donde la prioridad sí cambie los resultados.
3. En ese nuevo escenario, ¿Little sigue cumpliéndose? ¿Por qué?

Ejercicio 3: diseño óptimo de servidores

Problema: Una clínica tiene $c_Q = 50$ \$/hora por paciente esperando y $c_S = 20$ \$/hora por médico trabajando. Llegadas Poisson($\lambda = 10$/h).

Tarea en grupo (15 min):

1. Completen la tabla para $c = 2, 3, 4$ médicos ($\mu = 4$/h cada uno):

c	ρ	L_Q (aprox.)	Costo espera	Costo médicos	**Total**
2	$10/8 > 1$	∞	∞	—	Inestable
3	?	?	?	?	?
4	?	?	?	?	?

2. ¿Cuál es el c^* óptimo?
3. Si c_Q sube a \$200/hora (urgencias), ¿cambia la respuesta?

Lo más importante de hoy

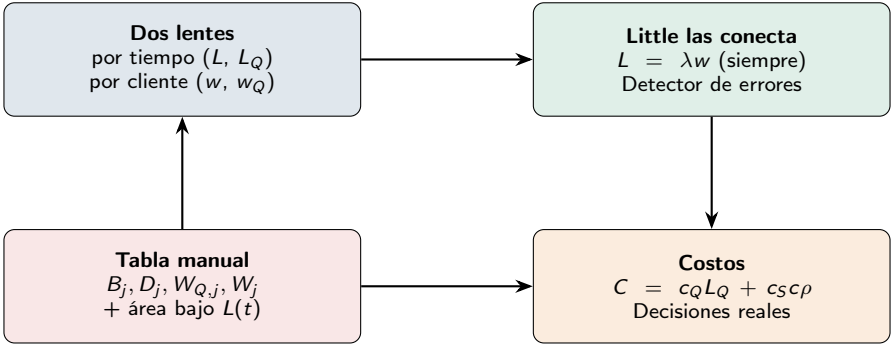

La simulación manual es el **antídoto** contra "aplicar fórmulas sin entender". Si sabe hacer la tabla a mano, sabe exactamente qué hace el computador.

¿Preguntas?

Simulación de Eventos Discretos

"Si no puedes simularlo a mano para 5 clientes,
no estás listo para programarlo."