Simulación de Sistemas de Colas en Estado Estable

Ejemplo con Dos Servidores, Ley de Little y Período Transitorio

Departamento de Ingeniería Industrial

Curso de Simulación de Eventos Discretos

Semestre 2026-I

Contenido

1. Introducción y Motivación
2. Métricas Analíticas del $M/M/2$
3. Ley de Little: Fundamentos
4. Ley de Little: Versión Muestral y Transitorio
5. Diseño de la Simulación
6. Ejemplo Paso a Paso
7. Ejemplo Paso a Paso
8. El Período Transitorio
9. Técnicas para el Transitorio
10. Resultados de la Simulación Completa
11. Análisis Profundo del Transitorio y Little
12. Extensiones y Buenas Prácticas
13. Conclusiones

¿Por qué simular sistemas de colas?

Muchos sistemas reales no tienen soluciones analíticas cerradas:

Limitaciones analíticas:

- Distribuciones no exponenciales
- Disciplinas de cola complejas
- Dependencias entre servidores
- Políticas de enrutamiento

Ventajas de la simulación:

- Flexibilidad total en el modelo
- Análisis del transitorio
- Estimación de métricas arbitrarias
- Validación de aproximaciones

Objetivo de hoy

Simular un sistema $M/M/2$ paso a paso, estimar métricas en estado estable, y entender **cuándo y por qué** la Ley de Little se cumple o no.

El sistema que estudiaremos: $M/M/2$

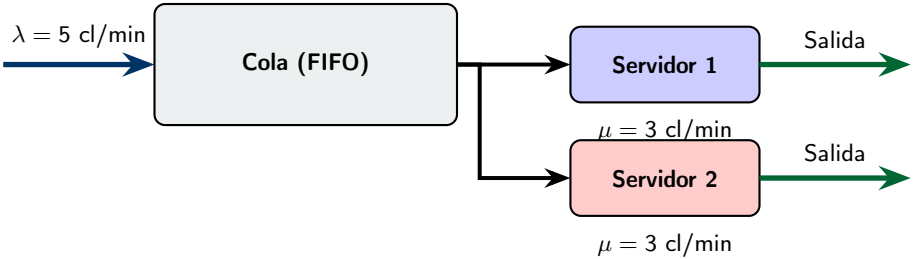

Parámetros:

- Llegadas: Poisson($\lambda = 5$/min)
- Servicio: Exp($\mu = 3$/min) cada servidor
- $c = 2$ servidores idénticos

Intensidad de tráfico:

$$\rho = \frac{\lambda}{c \cdot \mu} = \frac{5}{2 \times 3} = \frac{5}{6} \approx 0{,}833$$

- $\rho < 1$: el sistema es **estable**

Solución analítica del $M/M/2$ (referencia)

Para $M/M/c$ con $c = 2$, $\lambda = 5$, $\mu = 3$:

Probabilidad de estado vacío:

$$P_0 = \left[\sum_{n=0}^{c-1} \frac{(c\rho)^n}{n!} + \frac{(c\rho)^c}{c!} \cdot \frac{1}{1-\rho}\right]^{-1} = \left[1 + \frac{10}{6} + \frac{(10/6)^2}{2} \cdot \frac{1}{1-5/6}\right]^{-1}$$

$$P_0 = \left[1 + 1{,}6\overline{6} + \frac{2{,}7\overline{7}}{2} \cdot 6\right]^{-1} = [1 + 1{,}667 + 8{,}333]^{-1} \approx 0{,}0909$$

Fórmula C de Erlang:

$$C(c, \lambda/\mu) = P(\text{esperar}) = \frac{(c\rho)^c}{c!(1-\rho)} \cdot P_0 = \frac{(10/6)^2}{2 \cdot (1/6)} \cdot 0{,}0909 \approx 0{,}7576$$

Métricas analíticas exactas del $M/M/2$

Métrica	Fórmula	Valor
L_q (clientes en cola)	$\dfrac{C(c, \lambda/\mu) \cdot \rho}{1-\rho}$	3,7879
L (clientes en sistema)	$L_q + \dfrac{\lambda}{\mu}$	5,4545
W_q (espera en cola)	$\dfrac{L_q}{\lambda}$	0,7576 min
W (tiempo en sistema)	$W_q + \dfrac{1}{\mu}$	1,0909 min
ρ (utilización)	$\dfrac{\lambda}{c\mu}$	0,8333

Nota importante

Estos valores son los de **estado estable** ($t \to \infty$). La simulación debe alcanzar estos valores después del período transitorio.

Ley de Little: el resultado más fundamental

Ley de Little (1961)

En **estado estable**, para cualquier sistema de colas:

$$\boxed{L = \lambda \cdot W}$$

donde L = número promedio en el sistema, λ = tasa de llegada efectiva, W = tiempo promedio en el sistema.

Aplicaciones equivalentes:

$$L = \lambda \cdot W \qquad \text{(para todo el sistema)} \tag{1}$$

$$L_q = \lambda \cdot W_q \qquad \text{(solo para la cola)} \tag{2}$$

$$L_s = \lambda \cdot W_s \qquad \text{(solo para el servicio)} \tag{3}$$

Verificación con nuestro ejemplo:

$$L = \lambda \cdot W \;\Rightarrow\; 5{,}4545 = 5 \times 1{,}0909 = 5{,}4545 \;\checkmark$$

$$L_q = \lambda \cdot W_q \;\Rightarrow\; 3{,}7879 = 5 \times 0{,}7576 = 3{,}7879 \;\checkmark$$

¿Qué hace especial a la Ley de Little?

Generalidad extraordinaria:

- No depende de la distribución de llegadas
- No depende de la distribución de servicio
- No depende del número de servidores
- No depende de la disciplina de cola
- No depende del orden de servicio

Única condición fundamental:
El sistema debe estar en **estado estable**.

Ley de Little

$$L = \lambda \cdot W$$

Válida en estado estable
para CUALQUIER sistema

¿Y en el
transitorio?

Pregunta clave de hoy

¿Qué pasa con $L = \lambda W$ **durante el período transitorio**? ¿Se cumple, se viola, bajo qué condiciones?

Ley de Little: versión operacional (muestral)

Definiciones operacionales para un intervalo $[0, T]$:

Sea $A(T)$ el número de llegadas y $D(T)$ el de partidas en $[0, T]$.

$$\bar{L}(T) = \frac{1}{T}\int_0^T N(t)\,dt \quad \text{(promedio temporal de clientes)}$$

$$\bar{W}(T) = \frac{1}{D(T)}\sum_{i=1}^{D(T)} W_i \quad \text{(promedio de tiempos de los que salieron)}$$

$$\bar{\lambda}(T) = \frac{A(T)}{T} \quad \text{(tasa de llegada observada)}$$

Ley de Little operacional

$$\bar{L}(T) = \bar{\lambda}(T) \cdot \bar{W}_A(T)$$

donde $\bar{W}_A(T) = \frac{1}{A(T)}\sum_{i=1}^{A(T)} W_i^*$ con W_i^* incluyendo clientes aún en sistema al tiempo T (tiempo parcial).

¿Cuándo se cumple Little en el transitorio?

SÍ se cumple (exactamente):

La **versión determinística** de Little:

$$\bar{L}(T) = \bar{\lambda}(T) \cdot \bar{W}_A(T)$$

es una **identidad contable** que se cumple **siempre**, para todo T, incluso en el transitorio.

Es una relación entre promedios observados, no requiere estado estable.

NO se cumple (en general):

La versión con $\bar{W}$ basada solo en clientes **completados**:

$$\bar{L}(T) \neq \bar{\lambda}(T) \cdot \bar{W}_D(T)$$

La discrepancia surge porque:

- Clientes en sistema no se cuentan en $\bar{W}_D$
- $\bar{L}$ sí los incluye
- La diferencia es grande al inicio

Clave conceptual

El "fallo" de Little en el transitorio es un problema de **consistencia entre las métricas**, no de la ley en sí.

Visualización: por qué $\bar{L} \neq \bar{\lambda} \cdot \bar{W}_D$ al inicio

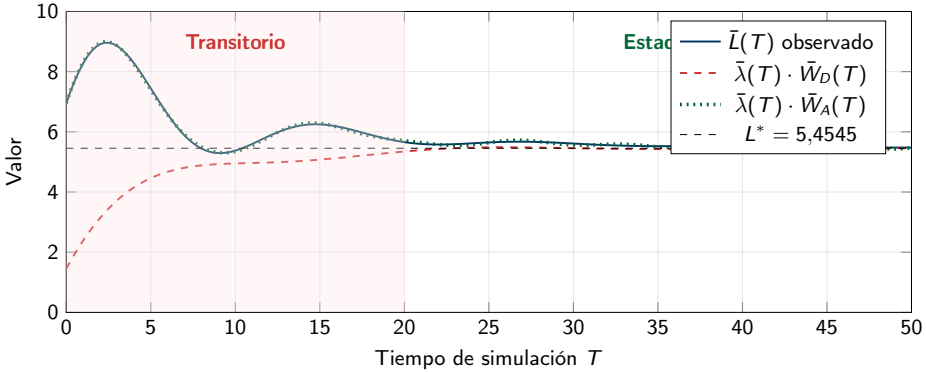

La curva verde (versión completa) coincide con $\bar{L}(T)$. La roja (solo completados) **diverge** en el transitorio.

Resumen: tres versiones de Little

Versión	Fórmula	¿Cuándo se cumple?
Estocástica (límite)	$L = \lambda \cdot W$	Solo en **estado estable** ($t \to \infty$)
Operacional completa	$\bar{L}(T) = \bar{\lambda}(T) \cdot \bar{W}_A(T)$	**Siempre** (identidad contable, $\forall T$)
Operacional parcial	$\bar{L}(T) \approx \bar{\lambda}(T) \cdot \bar{W}_D(T)$	Solo cuando T es grande (transitorio eliminado)

Implicación práctica

En simulación, si usamos $\bar{W}_D$ (promedio solo de clientes que completaron servicio), debemos **descartar el período transitorio** para que la relación de Little sea consistente.

Estructura del simulador de eventos discretos

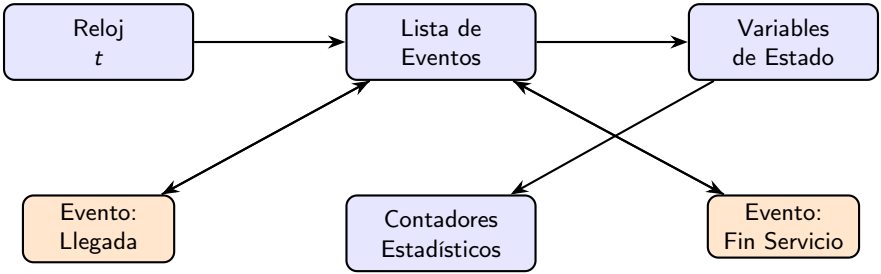

Variables de estado: número en cola, estado de cada servidor (libre/ocupado).
Tipos de eventos: llegada de cliente, fin de servicio en servidor k.

Variables y contadores del simulador

Variables de estado:

- $N_q(t)$: número de clientes en cola en el instante t
- $S_k(t) \in \{0, 1\}$: estado del servidor k ($k = 1, 2$); 0=libre, 1=ocupado
- $N(t) = N_q(t) + S_1(t) + S_2(t)$: total en el sistema

Contadores estadísticos:

- $\mathcal{A}$: área bajo $N(t) \Rightarrow \bar{L} = \mathcal{A}/T$
- $\mathcal{A}_q$: área bajo $N_q(t) \Rightarrow \bar{L}_q = \mathcal{A}_q/T$
- $\sum W_i$: suma de tiempos en sistema $\Rightarrow \bar{W} = \sum W_i / n_{\text{completados}}$
- $\sum W_{q,i}$: suma de esperas en cola $\Rightarrow \bar{W}_q = \sum W_{q,i} / n_{\text{completados}}$
- B_k: tiempo ocupado del servidor $k \Rightarrow \hat{\rho}_k = B_k/T$

Pseudocódigo: rutina de llegada

Evento: LLEGADA al tiempo t;
Generar próxima llegada: programar LLEGADA en $t + \text{Exp}(1/\lambda)$;
Registrar llegada del cliente i: $a_i \leftarrow t$;
if *Servidor 1 libre* ***o*** *Servidor 2 libre* **then**
  Seleccionar servidor libre k (si ambos libres, elegir al azar);
  $S_k \leftarrow 1$ (ocupado);
  Generar tiempo de servicio: $s_i \sim \text{Exp}(1/\mu)$;
  Programar FIN_SERVICIO(k) en $t + s_i$;
  $W_{q,i} \leftarrow 0$;
else
  Agregar cliente i al final de la cola;
  $N_q \leftarrow N_q + 1$;
end
Actualizar contadores de área;

Pseudocódigo: rutina de fin de servicio

Evento: FIN_SERVICIO del servidor k **al tiempo** t;
Cliente i completó servicio;
$W_i \leftarrow t - a_i$ (tiempo en el sistema);
$d_i \leftarrow t$ (tiempo de partida);
$n_{\text{completados}} \leftarrow n_{\text{completados}} + 1$;
if $N_q > 0$ **then**
  Sacar siguiente cliente j de la cola (FIFO);
  $N_q \leftarrow N_q - 1$;
  $W_{q,j} \leftarrow t - a_j$;
  Generar servicio: $s_j \sim \text{Exp}(1/\mu)$;
  Programar FIN_SERVICIO(k) en $t + s_j$;
else
  $S_k \leftarrow 0$ (servidor libre);
end
Actualizar contadores de área y B_k;

Ejemplo: generación de llegadas y servicios

Semilla fija para reproducibilidad. Tiempos generados:

Cliente	Inter-llegada	Llegada a_i	Servicio s_i	Servidor
1	0.12	0.12	0.45	1
2	0.08	0.20	0.28	2
3	0.25	0.45	0.38	— (cola)
4	0.03	0.48	0.55	2 (libre en 0.48)
5	0.15	0.63	0.41	1 (libre en 0.57)
6	0.22	0.85	0.33	— (cola)
7	0.10	0.95	0.29	— (cola)
8	0.18	1.13	0.52	2 (libre en 1.03)
9	0.05	1.18	0.36	1 (libre en 1.04)
10	0.30	1.48	0.44	— (cola)

Inter-llegadas $\sim$ Exp$(1/\lambda)$ = Exp(0,2); Servicios $\sim$ Exp$(1/\mu)$ = Exp(1/3).

Paso 1: inicio y fin de servicio de cada cliente

Regla operacional ($M/M/2$, FIFO)

$$B_j = \begin{cases} A_j & \text{si algún servidor está libre al llegar} \\ \text{mín}(D_{k_1}, D_{k_2}) & \text{si ambos están ocupados (esperar al primero que termine)} \end{cases}$$

$$D_j = B_j + S_j, \qquad W_{Q,j} = B_j - A_j, \qquad W_j = D_j - A_j$$

Caso A

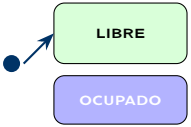

$B_j = A_j$

Caso B

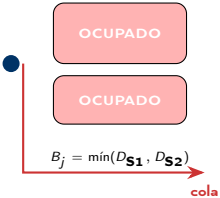

$B_j = \text{mín}(D_{\mathbf{S1}}, D_{\mathbf{S2}})$

Ejemplo – C5:
Llega $A_5 = 0{,}63$
S1 ocup. hasta $D_4 = 1{,}12$
S2 ocup. hasta $D_3 = 0{,}86$
$\Rightarrow B_5 = \text{mín}(1{,}12,\ 0{,}86) = 0{,}86$
$W_{Q,5} = 0{,}86 - 0{,}63 = 0{,}23$

Tabla completa: tiempos de los 10 clientes

j	A_j	S_j	**Serv.**	B_j	D_j	$W_{Q,j}$	W_j
1	0.12	0.45	S1	0.12	0.57	0.00	0.45
2	0.20	0.28	S2	0.20	0.48	0.00	0.28
3	0.45	0.38	S2	**0.48**	0.86	0.03	0.41
4	0.48	0.55	S1	**0.57**	1.12	0.09	0.64
5	0.63	0.41	S2	**0.86**	1.27	0.23	0.64
6	0.85	0.33	S1	**1.12**	1.45	0.27	0.60
7	0.95	0.29	S2	**1.27**	1.56	0.32	0.61
8	1.13	0.52	S1	**1.45**	1.97	0.32	0.84
9	1.18	0.36	S2	**1.56**	1.92	0.38	0.74
10	1.48	0.44	S2	**1.92**	2.36	0.44	0.88
				Suma:		2.08	6.09

Solo C1 y C2 no esperaron. La espera crece progresivamente: el sistema está en fase de **llenado** (transitorio). Note cómo $W_{Q,j}$ aumenta conforme la cola se acumula.

Diagrama de Gantt: los dos servidores

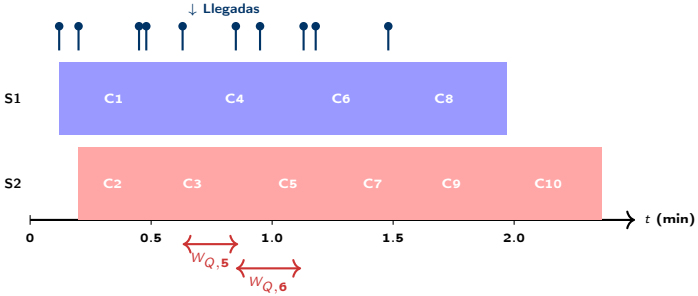

Ambos servidores trabajan casi sin pausa. Los clientes 5–10 deben esperar en cola cada vez más tiempo. La alternancia S1/S2 se da según qué servidor se desocupa primero (FIFO).

Línea temporal detallada: cliente 6

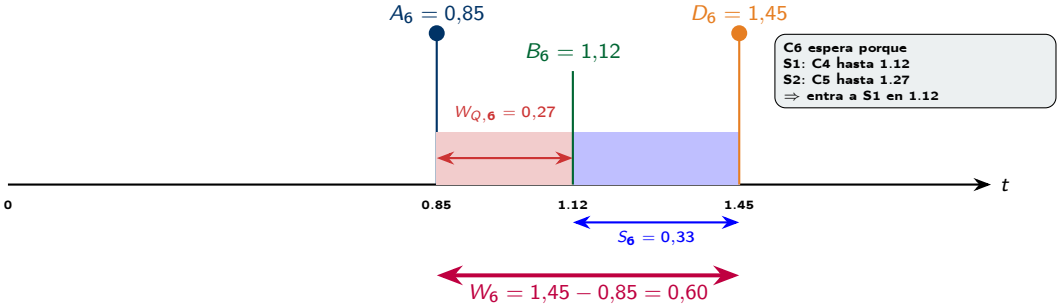

Verificación: $W_6 = W_{Q,6} + S_6 = 0{,}27 + 0{,}33 = 0{,}60$ ✓

Barras de tiempo por cliente (vista horizontal)

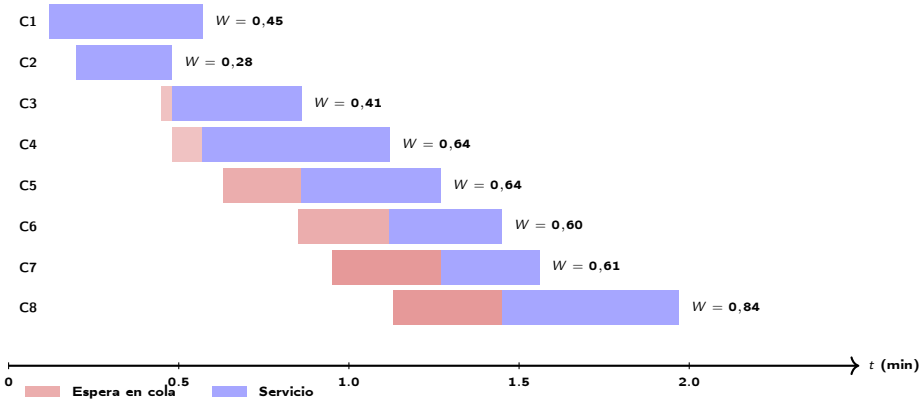

Las barras rojas (espera) crecen progresivamente: el sistema está en **fase de llenado**. En estado estable, las esperas oscilarían alrededor de $W_q^* = 0{,}76$ min.

Métricas parciales en $T = 2$ (transitorio)

Con los 10 clientes y horizonte $T = 2$ min:

Promedios por cliente (8 completados antes de $T = 2$):

$$\widehat{w}_D = \frac{\sum_{j=1}^{9} W_j}{9} = \frac{0{,}45 + 0{,}28 + \cdots + 0{,}84}{9}$$
$$= \frac{5,21}{9} = 0{,}5788$$

$$\widehat{w}_{Q,D} = \frac{\sum_{j=1}^{9} W_{Q,j}}{9} = \frac{1{,}64}{9} = 0{,}1822$$

Valores teóricos (estado estable):

$$W^* = 1{,}091 \text{ min}$$
$$W_q^* = 0{,}758 \text{ min}$$

Error:

$$\text{Error en } W \approx 47\,\%$$
$$\text{Error en } W_q \approx 76\,\%$$

Lección

Con solo 2 minutos de simulación, las estimaciones están **muy lejos** del estado estable. $\widehat{w}_D$ subestima porque los primeros clientes entraron a un sistema vacío y esperaron poco.

Verificación de Little en $T = 2$

Tasa observada: $\widehat{\lambda} = A(2)/2 = 10/2 = 5{,}0$ ✓ (coincide con λ teórica)

	$\widehat{\lambda} \times \widehat{w}$	vs.	$\widehat{L}$ (por área)
Versión completa (W_A, todos)	$5{,}0 \times 0{,}609 = 3{,}05$	$=$	3,05 ✓
Versión parcial (W_D, solo salidos)	$5{,}0 \times 0{,}579 = 2{,}89$	$\neq$	3,05 ×

¿Por qué la discrepancia?
$\widehat{L}$ integra el área bajo $N(t)$, que incluye a C10 aún en el sistema. Pero $\widehat{w}_D$ solo promedia los 9 que ya salieron — ignora al que sigue adentro.

La diferencia se reduce con T:

- $T = 2$: error 8.2 %
- $T = 50$: error < 5 %
- $T = 200$: error < 1 %

Ejemplo: generación de llegadas y servicios

Semilla fija para reproducibilidad. Tiempos generados:

Cliente	Inter-llegada	Llegada a_i	Servicio s_i	Servidor
1	0.12	0.12	0.45	1
2	0.08	0.20	0.28	2
3	0.25	0.45	0.38	— (cola)
4	0.03	0.48	0.55	— (cola)
5	0.15	0.63	0.41	— (cola)
6	0.22	0.85	0.33	— (cola)
7	0.10	0.95	0.29	— (cola)
8	0.18	1.13	0.52	— (cola)
9	0.05	1.18	0.36	— (cola)
10	0.30	1.48	0.44	— (cola)

Inter-llegadas $\sim$ Exp$(1/\lambda)$ = Exp(0,2); Servicios $\sim$ Exp$(1/\mu)$ = Exp(1/3).

Metodología *Event Scheduling*: el ciclo de simulación

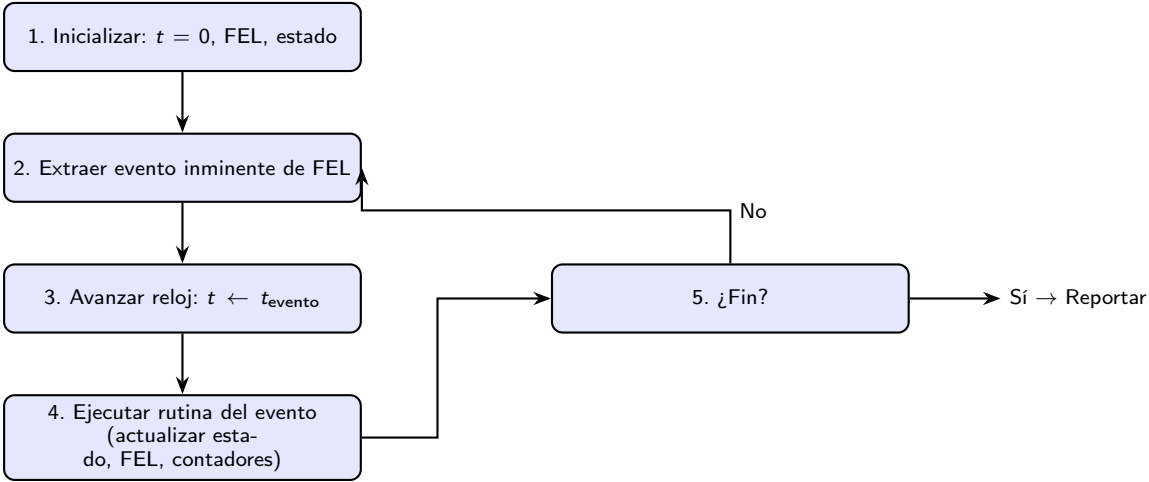

La **FEL** (Future Event List) es el corazón: contiene los eventos futuros **ordenados por tiempo**. Siempre se procesa el de menor tiempo.

Traza FEL — Paso 0: Inicialización ($t = 0$)

Estado inicial: $t = 0$, $N_q = 0$, $S_1 = 0$ (libre), $S_2 = 0$ (libre), $\mathcal{A} = 0$, $\mathcal{A}_q = 0$
Se programa la primera llegada: $a_1 = 0{,}12$.

FEL	
Tiempo	**Evento**
0.12	Llegada C1

Estado			
N_q	S_1	S_2	N
0	0	0	0

Cola: vacía

S1: **libre**

S2: **libre**

Traza FEL — Paso 1: Llegada C1 ($t : 0 \to 0{,}12$)

1. **Extraer:** Llegada C1 (tiempo 0.12). 2. **Avanzar:** $t \leftarrow 0{,}12$.
3. **Actualizar área:** $\mathcal{A} \mathrel{+}= N_{\text{ant}} \times \Delta t = 0 \times 0{,}12 = 0$
4. **Ejecutar rutina LLEGADA:**
   - S1 libre $\Rightarrow$ C1 entra a S1. $S_1 \leftarrow 1$. Generar $s_1 = 0{,}45$.
   - Agregar a FEL: FinServ(S1) en $0{,}12 + 0{,}45 = 0{,}57$.
   - Generar próx. llegada: Agregar a FEL: Llegada C2 en $0{,}12 + 0{,}08 = 0{,}20$.

FEL actualizada	
Tiempo	**Evento**
0.20	Llegada C2
0.57	FinServ S1 (C1)

Estado en $t = 0{,}12$			
N_q	S_1	S_2	N
0	1	0	1

El evento sombreado en amarillo es el **inminente** (próximo a procesar).

Traza FEL — Paso 2: Llegada C2 (t : 0,12 $\rightarrow$ 0,20)

Extraer: Llegada C2. **Avanzar:** $t \leftarrow 0{,}20$.
Área: $\mathcal{A} \mathrel{+}= 1 \times (0{,}20 - 0{,}12) = 0{,}08$
Ejecutar LLEGADA:

- S1 ocupado, S2 libre $\Rightarrow$ C2 entra a S2. $S_2 \leftarrow 1$. Generar $s_2 = 0{,}28$.
- FEL $+$ FinServ(S2) en $0{,}20 + 0{,}28 = 0{,}48$.
- FEL $+$ Llegada C3 en $0{,}20 + 0{,}25 = 0{,}45$.

FEL actualizada	
Tiempo	**Evento**
0.45	Llegada C3
0.48	FinServ S2 (C2)
0.57	FinServ S1 (C1)

Estado en $t = 0{,}20$			
N_q	S_1	S_2	N
0	1	1	2

Ambos servidores ocupados. El próximo cliente que llegue **deberá esperar en cola**.

Traza FEL — Paso 3: Llegada C3 (t : 0,20 $\rightarrow$ 0,45)

Avanzar: $t \leftarrow 0{,}45$. **Área:** $\mathcal{A} \mathrel{+}= 2 \times 0{,}25 = 0{,}50$
Ejecutar LLEGADA:

- S1 y S2 ocupados $\Rightarrow$ **C3 entra a la cola.** $N_q \leftarrow 1$.
- FEL + Llegada C4 en $0{,}45 + 0{,}03 = 0{,}48$.

FEL actualizada	
Tiempo	**Evento**
0.48	FinServ S2 (C2)
0.48	Llegada C4
0.57	FinServ S1 (C1)

Estado en $t = 0{,}45$			
N_q	S_1	S_2	N
1	1	1	3

Empate en $t = 0{,}48$: hay una Llegada y un FinServ. Convención: procesar primero el **FinServ** (prioridad a salidas para no inflar N_q artificialmente).

Traza FEL — Paso 4: FinServ S2, C2 (t : 0,45 $\rightarrow$ 0,48)

Avanzar: $t \leftarrow 0{,}48$. **Área:** $\mathcal{A} \mathrel{+}= 3 \times 0{,}03 = 0{,}09$. $\mathcal{A}_q \mathrel{+}= 1 \times 0{,}03 = 0{,}03$
Ejecutar FIN_SERVICIO:

- C2 sale. $W_2 = 0{,}48 - 0{,}20 = 0{,}28$. Completados $= 1$.
- $N_q = 1 > 0 \Rightarrow$ C3 sale de cola $\rightarrow$ S2. $N_q \leftarrow 0$. $W_{q,3} = 0{,}48 - 0{,}45 = 0{,}03$.
- Generar $s_3 = 0{,}38$. FEL + FinServ(S2) en $0{,}48 + 0{,}38 = 0{,}86$.

FEL actualizada	
Tiempo	**Evento**
0.48	Llegada C4
0.57	FinServ S1 (C1)
0.86	FinServ S2 (C3)

Estado en $t = 0{,}48$			
N_q	S_1	S_2	N
0	1(C1)	1(C3)	2

Note cómo el FinServ de S2 en $t = 0{,}48$ fue reemplazado por uno nuevo (C3 hasta 0.86).

Traza FEL — Pasos 5 y 6: C4 llega, C1 sale

Paso 5 — Llegada C4 ($t = 0{,}48$, mismo instante):

- $\Delta t = 0$, no se acumula área. S1 y S2 ocupados $\Rightarrow$ C4 a cola. $N_q \leftarrow 1$.
- FEL $+$ Llegada C5 en $0{,}48 + 0{,}15 = 0{,}63$.

Paso 6 — FinServ S1, C1 ($t : 0{,}48 \rightarrow 0{,}57$):

- $\mathcal{A} \mathrel{+}= 3 \times 0{,}09 = 0{,}27$. $\mathcal{A}_q \mathrel{+}= 1 \times 0{,}09 = 0{,}09$.
- C1 sale. $W_1 = 0{,}57 - 0{,}12 = 0{,}45$. Completados $= 2$.
- $N_q > 0 \Rightarrow$ C4 $\rightarrow$ S1. $N_q \leftarrow 0$. $W_{q,4} = 0{,}57 - 0{,}48 = 0{,}09$.
- Generar $s_4 = 0{,}55$. FEL $+$ FinServ(S1) en 1,12.

FEL después del paso 6	
Tiempo	**Evento**
0.63	Llegada C5
0.86	FinServ S2 (C3)
1.12	FinServ S1 (C4)

N_q	S_1	S_2	N
0	1(C4)	1(C3)	2

$\mathcal{A} = 0 + 0{,}08 + 0{,}50 + 0{,}09 + 0 + 0{,}27 = 0{,}94$ acumulado hasta $t = 0{,}57$.

Traza FEL — Pasos 7–9: C5, C6 llegan; C3 sale

Paso 7 — Llegada C5 ($t = 0{,}63$): $\mathcal{A} \mathrel{+}= 2 \times 0{,}06 = 0{,}12$. Ambos ocup. $\Rightarrow$ cola. $N_q = 1$.
Paso 8 — Llegada C6 ($t = 0{,}85$): $\mathcal{A} \mathrel{+}= 3 \times 0{,}22 = 0{,}66$. Cola. $N_q = 2$.
Paso 9 — FinServ S2, C3 ($t = 0{,}86$): $\mathcal{A} \mathrel{+}= 4 \times 0{,}01 = 0{,}04$.

- C3 sale. $W_3 = 0{,}41$. C5 (FIFO) $\rightarrow$ S2. $N_q \leftarrow 1$. $W_{q,5} = 0{,}23$.
- FEL + FinServ(S2) en $0{,}86 + 0{,}41 = 1{,}27$.

FEL después del paso 9	
Tiempo	**Evento**
0.95	Llegada C7
1.12	FinServ S1 (C4)
1.27	FinServ S2 (C5)

N_q	S_1	S_2	N
1	1(C4)	1(C5)	3

$\mathcal{A} = 0{,}94 + 0{,}12 + 0{,}66 + 0{,}04 = 1{,}76$ acumulado. Cola: $\langle$C6$\rangle$.

Resumen tabular completo de la traza con FEL

Paso	t	Evento	N_q	S_1	S_2	N	$\Delta\mathcal{A}$	FEL resultante
0	0.00	Inicio	0	0	0	0	—	Lleg C1: 0.12
1	0.12	Lleg C1→S1	0	1	0	1	0.00	Lleg C2: 0.20, FS1: 0.57
2	0.20	Lleg C2→S2	0	1	1	2	0.08	Lleg C3: 0.45, FS2: 0.48, FS1: 0.57
3	0.45	Lleg C3→cola	1	1	1	3	0.50	FS2: 0.48, Lleg C4: 0.48, FS1: 0.57
4	0.48	FinS2(C2); C3→S2	0	1	1	2	0.09	Lleg C4: 0.48, FS1: 0.57, FS2: 0.86
5	0.48	Lleg C4→cola	1	1	1	3	0.00	FS1: 0.57, Lleg C5: 0.63, FS2: 0.86
6	0.57	FinS1(C1); C4→S1	0	1	1	2	0.27	Lleg C5: 0.63, FS2: 0.86, FS1: 1.12
7	0.63	Lleg C5→cola	1	1	1	3	0.12	Lleg C6: 0.85, FS2: 0.86, FS1: 1.12
8	0.85	Lleg C6→cola	2	1	1	4	0.66	FS2: 0.86, Lleg C7: 0.95, FS1: 1.12
9	0.86	FinS2(C3); C5→S2	1	1	1	3	0.04	Lleg C7: 0.95, FS1: 1.12, FS2: 1.27
						Área acumulada $\mathcal{A}(0{,}86)$:	**1.76**	

FS1/FS2 = FinServ S1/S2. La FEL siempre está ordenada y se actualiza en cada paso. Observe cómo crece, se reorganiza y se reemplaza dinámicamente.

Diagrama temporal $N(t)$ — primeros 2 minutos

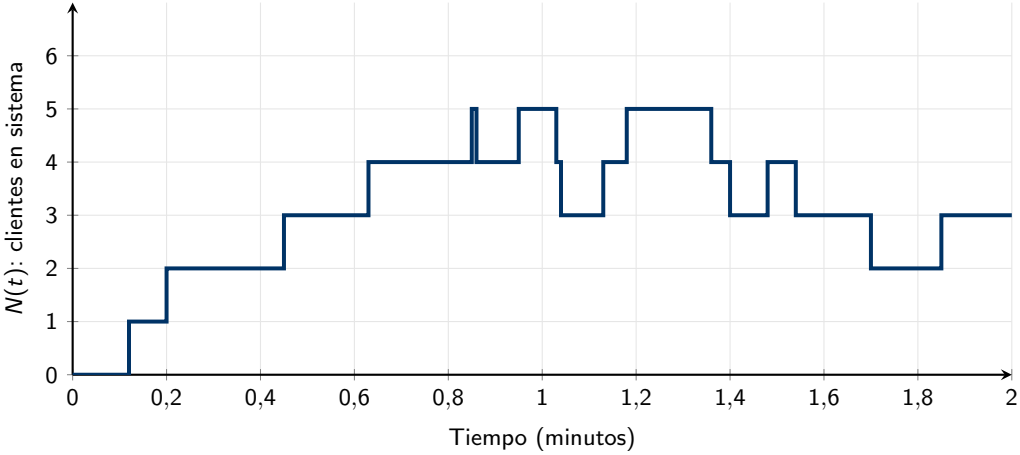

El área bajo esta curva dividida por T nos da $\bar{L}(T)$. En los primeros instantes, $\bar{L}$ es muy variable y no refleja el estado estable.

Cálculo manual de $\bar{L}(T)$ en $T = 1$ minuto

Área bajo $N(t)$ en $[0, 1]$:

$$\begin{aligned}\mathcal{A}(1) &= 0 \times (0{,}12 - 0) + 1 \times (0{,}20 - 0{,}12) + 2 \times (0{,}45 - 0{,}20) \\ &\quad + 3 \times (0{,}48 - 0{,}45) + 3 \times (0{,}57 - 0{,}48) + 3 \times (0{,}63 - 0{,}57) \\ &\quad + 4 \times (0{,}85 - 0{,}63) + 5 \times (0{,}86 - 0{,}85) + 4 \times (0{,}95 - 0{,}86) \\ &\quad + 5 \times (1{,}00 - 0{,}95) \\ &= 0 + 0{,}08 + 0{,}50 + 0{,}09 + 0{,}27 + 0{,}18 + 0{,}88 + 0{,}05 + 0{,}36 + 0{,}25 \\ &= 2{,}66\end{aligned}$$

$$\bar{L}(1) = \frac{\mathcal{A}(1)}{1} = 2{,}66 \quad \text{vs.} \quad L^* = 5{,}4545$$

Observación

$\bar{L}(1) = 2{,}66$ está **muy lejos** del valor teórico 5,45. ¡Estamos en pleno transitorio!

Verificación de Little en $T = 1$: versión completa vs. parcial

En $T = 1$, supongamos 3 clientes completaron servicio (C1, C2, C3):

Versión completa (todos):

$$\bar{\lambda}(1) = \frac{A(1)}{1} = \frac{7}{1} = 7$$

$$\bar{W}_A(1) = \frac{\sum_{i=1}^{7} W_i^*}{7}$$

$$= \frac{2{,}66}{7} = 0{,}38$$

$$\bar{\lambda} \cdot \bar{W}_A = 7 \times 0{,}38 = 2{,}66$$

$$\bar{L}(1) = 2{,}66 = \bar{\lambda} \cdot \bar{W}_A \ \checkmark$$

Versión parcial (solo completados):

$$\bar{W}_D(1) = \frac{W_1 + W_2 + W_3}{3}$$

$$= \frac{0{,}45 + 0{,}28 + 0{,}41}{3} = 0{,}38$$

$$\bar{\lambda} \cdot \bar{W}_D = 7 \times 0{,}38 = 2{,}66$$

Aquí coinciden *por casualidad* porque los tiempos de los que se fueron son similares. En general, **NO coinciden**.

Nota

La versión completa usa $\sum W_i^* = \mathcal{A}(T)$ (incluyendo tiempo parcial de clientes en sistema). Es una identidad, no una aproximación.

¿Qué es el período transitorio?

Definición

El **período transitorio** (o warm-up) es el intervalo inicial de la simulación donde las métricas están influenciadas por las condiciones iniciales y aún no representan el comportamiento de largo plazo.

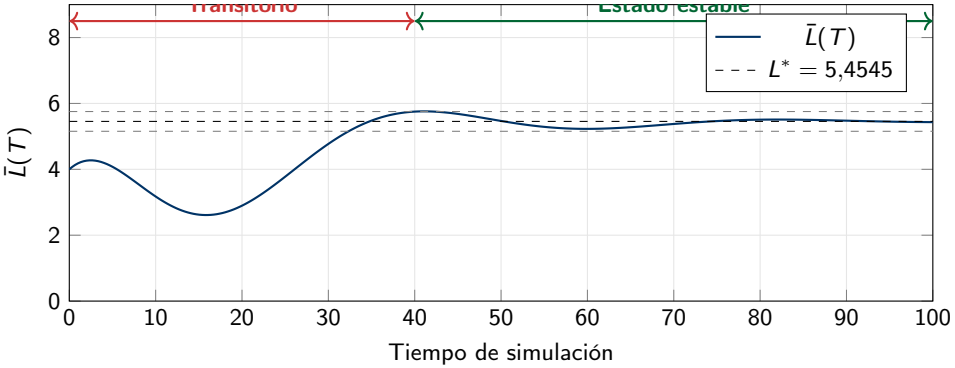

Efecto de las condiciones iniciales

Sistema vacío vs. sistema cargado al inicio:

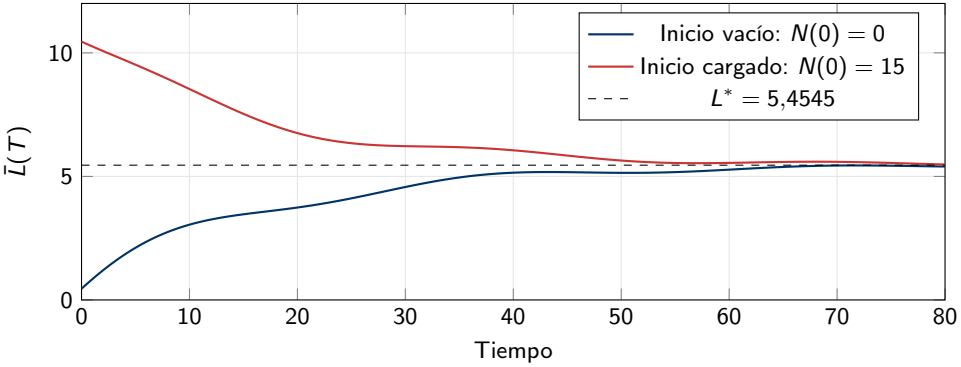

Ambas convergen al mismo valor, pero el sesgo inicial es en direcciones opuestas. Si incluimos el transitorio, nuestras estimaciones estarán sesgadas.

¿Por qué Little "falla" en el transitorio?

No es que la ley sea falsa. El problema es de **consistencia de medición**:

1. $\bar{L}(T)$ integra sobre *todos* los clientes presentes (incluyendo los que no han salido).
2. $\bar{W}_D(T)$ promedia solo sobre clientes *completados* (sesgo de selección: los rápidos salen primero).
3. En el transitorio temprano, muchos clientes aún están en el sistema, así que $\bar{W}_D$ **subestima** el verdadero W.
4. Resultado: $\bar{L}(T) > \bar{\lambda}(T) \cdot \bar{W}_D(T)$ al inicio.

Convergencia

Cuando $T \to \infty$, la fracción de clientes "atrapados" en el sistema se vuelve despreciable respecto al total, y ambas versiones convergen:

$$\bar{W}_D(T) \to \bar{W}_A(T) \to W \quad \Rightarrow \quad \bar{L}(T) \to \lambda \cdot W = L$$

Demostración formal: identidad de Little

Teorema (versión determinística): Sea a_i el tiempo de llegada del cliente i y d_i su tiempo de partida. Definimos $W_i = d_i - a_i$. Para N clientes que llegan en $[0, T]$:

$$\int_0^T N(t)\,dt = \sum_{i=1}^{N} W_i^*$$

donde $W_i^* = \text{mín}(d_i, T) - a_i$ (tiempo en sistema truncado a T).

Prueba: El lado izquierdo cuenta el "área bajo $N(t)$". Cada cliente i contribuye exactamente W_i^* a esa área. La suma de contribuciones individuales es el área total. □

Dividiendo ambos lados por T:

$$\bar{L}(T) = \frac{N}{T} \cdot \frac{\sum W_i^*}{N} = \bar{\lambda}(T) \cdot \bar{W}_A(T)$$

Esta es una **tautología matemática**, válida para todo T, sin condiciones estocásticas.

Condiciones de Little estocástico

Teorema de Little (1961), generalizado por Stidham (1974)

Si el proceso $\{N(t), t \geq 0\}$ es tal que:

1. Los promedios temporales convergen con probabilidad 1:

$$\bar{L} = \lim_{T\to\infty} \frac{1}{T}\int_0^T N(t)\,dt, \quad \bar{\lambda} = \lim_{T\to\infty} \frac{A(T)}{T}, \quad \bar{W} = \lim_{T\to\infty} \frac{1}{A(T)}\sum_{i=1}^{A(T)} W_i$$

2. $\bar{\lambda}$ existe y es finita ($0 < \bar{\lambda} < \infty$)

Entonces $L = \lambda \cdot W$ con probabilidad 1.

Observaciones:

- No se requiere estacionariedad ni independencia
- Se requiere que los límites **existan** (ergodicidad)
- $\rho < 1$ garantiza esto para sistemas estables

Método de Welch para detectar el transitorio

Idea: Hacer R réplicas independientes y promediar $\bar{Y}_j(t)$ entre réplicas para suavizar.

1. Ejecutar R réplicas (e.g., $R = 10$)
2. Para cada réplica r, registrar $Y_r(t)$ (e.g., $N(t)$)
3. Calcular $\bar{Y}(t) = \frac{1}{R}\sum_{r=1}^{R} Y_r(t)$
4. Aplicar media móvil: $\hat{Y}(t) = \frac{1}{2w+1}\sum_{s=t-w}^{t+w} \bar{Y}(s)$
5. Identificar T_0 donde $\hat{Y}(t)$ se estabiliza

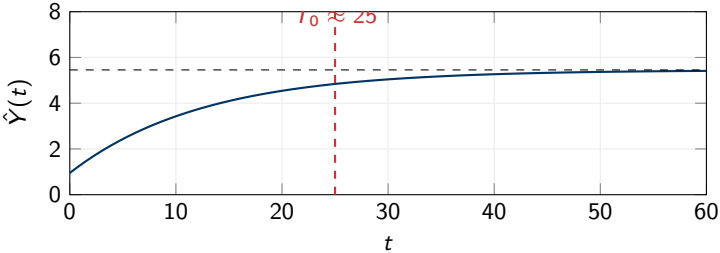

Estrategias para manejar el transitorio

Método	Descripción	Cuándo usar
Truncamiento (Warm-up deletion)	Descartar datos de $[0, T_0]$; recoger estadísticas solo en $[T_0, T]$	Método más común
Corrida larga	Hacer T tan grande que el transitorio sea despreciable	Sistemas simples
Inicio inteligente	Iniciar con $N(0)$ cercano al estado estable	Si se conoce L^* aprox.
Réplicas con truncamiento	R réplicas independientes, cada una con warm-up	Intervalos de confianza
Método batch means	Una sola corrida larga dividida en lotes después de T_0	Corridas muy largas

Para nuestro ejemplo $M/M/2$: con $\rho = 0{,}833$, el transitorio puede durar entre 20 y 50 unidades de tiempo.
Recomendación: $T_0 \geq 30$ minutos, $T \geq 500$ minutos.

Impacto del truncamiento en la estimación

Estimación de L con y sin warm-up (10 réplicas, $T = 200$ min):

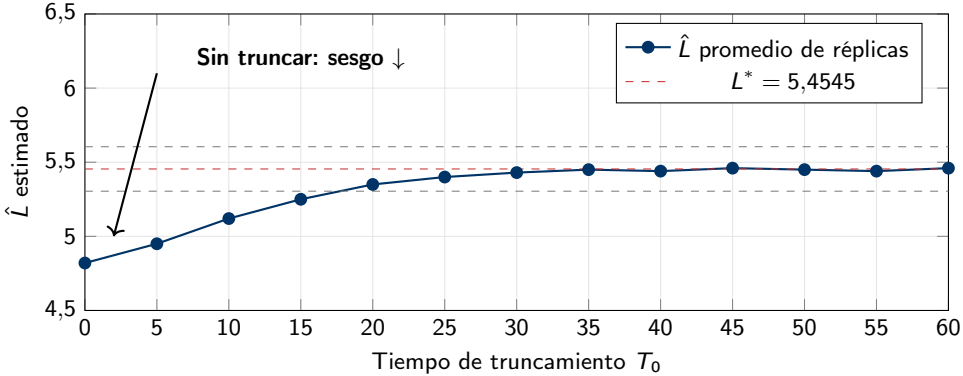

Sin truncamiento ($T_0 = 0$), $\hat{L} \approx 4{,}82$ (sesgo de $-12\,\%$). Con $T_0 = 30$, $\hat{L} \approx 5{,}43$ (sesgo $< 1\,\%$).

Configuración experimental

Parámetros del sistema:

- $\lambda = 5$ clientes/min
- $\mu = 3$ clientes/min por servidor
- $c = 2$ servidores
- Cola FIFO, capacidad infinita

Configuración de simulación:

- $R = 20$ réplicas independientes
- $T = 1000$ minutos por réplica
- $T_0 = 50$ minutos (warm-up)
- Semillas independientes

Métricas a estimar:

- L: clientes promedio en sistema
- L_q: clientes promedio en cola
- W: tiempo promedio en sistema
- W_q: tiempo promedio en cola
- ρ: utilización de servidores

Verificaciones:

- Ley de Little: $L = \lambda W$
- Ley de Little: $L_q = \lambda W_q$
- $\rho = \lambda/(c\mu)$

Resultados: estimaciones puntuales e intervalos de confianza

Métrica	Teórico	Estimación	IC 95 %
L	5.4545	5.48	[5,21, 5,75]
L_q	3.7879	3.81	[3,56, 4,06]
W (min)	1.0909	1.097	[1,042, 1,152]
W_q (min)	0.7576	0.763	[0,714, 0,812]
ρ	0.8333	0.836	[0,824, 0,848]

Observaciones

- Todos los intervalos de confianza contienen el valor teórico
- La estimación de ρ es la más precisa (menor varianza)
- L y L_q tienen mayor variabilidad (dependen de la cola)

Verificación de la Ley de Little en estado estable

Para cada réplica r, calculamos:

$$\Delta_r = \hat{L}_r - \hat{\lambda}_r \cdot \hat{W}_r$$

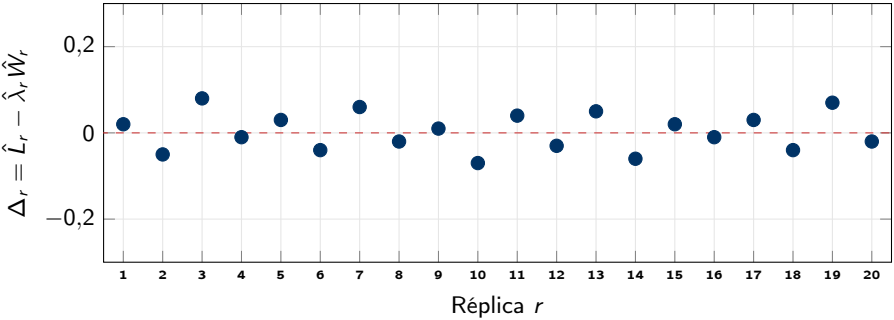

Las desviaciones son pequeñas y centradas en cero. Promedio: $\bar{\Delta} = 0{,}005$. La Ley de Little se satisface con excelente precisión en estado estable.

Evolución temporal: convergencia de las métricas

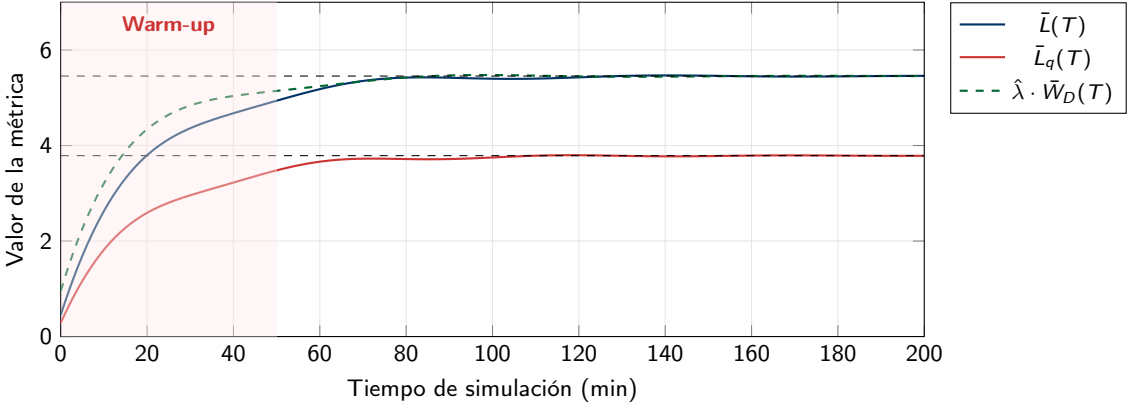

Nótese cómo $\bar{L}(T)$ y $\hat{\lambda} \cdot \bar{W}_D(T)$ **convergen entre sí** después del warm-up.

Evolución del "error de Little" en el tiempo

Definimos: $\epsilon(T) = \frac{|\bar{L}(T) - \bar{\lambda}(T) \cdot \bar{W}_D(T)|}{\bar{L}(T)} \times 100\,\%$

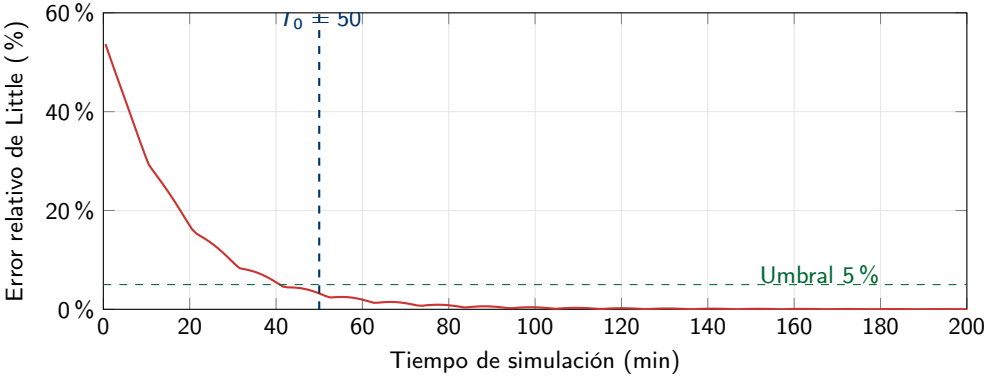

El error de Little (versión parcial) **decrece exponencialmente**. Después de $T_0 = 50$ min, el error es consistentemente $< 5\,\%$ y sigue disminuyendo.

¿Qué observamos en el transitorio exactamente?

Resumen de lo que ocurre en $[0, T_0]$**:**

1. **Fase de llenado** (t muy pequeño): El sistema empieza vacío. $N(t)$ crece rápidamente. $\bar{L}(T) \ll L^*$.
2. **Fase de oscilación**: $N(t)$ oscila alrededor de su nivel de estado estable mientras las condiciones iniciales se "olvidan".
3. **Sesgo en** $\bar{W}_D$: Los primeros clientes que salen son los que entraron al sistema vacío — tuvieron $W_q \approx 0$, lo que sesga $\bar{W}_D$ hacia abajo.
4. **Resultado**: $\bar{L}(T) > \bar{\lambda}(T) \cdot \bar{W}_D(T)$ durante el transitorio, porque $\bar{W}_D$ subestima el tiempo real.

Punto clave

La "violación" de Little no es un fallo de la ley, sino un **artefacto de medir** W **solo con clientes completados** mientras L incluye a todos.

Ejemplo numérico: Little en el transitorio

Valores típicos de una réplica en diferentes instantes:

T	$\bar{L}(T)$	$\bar{\lambda}(T)$	$\bar{W}_D(T)$	$\bar{\lambda}\bar{W}_D$	**Error**	**Fase**
1	2.66	7.0	0.38	2.66	0 %*	Llenado
5	3.80	5.4	0.55	2.97	21.8 %	Transitorio
10	4.25	5.3	0.68	3.60	15.3 %	Transitorio
20	4.75	5.1	0.82	4.18	12.0 %	Transitorio
50	5.20	5.02	0.97	4.87	6.3 %	Transición
100	5.40	5.01	1.05	5.26	2.6 %	Convergencia
200	5.45	5.00	1.08	5.40	0.9 %	Estable
500	5.46	5.00	1.09	5.45	0.2 %	Estable

*En $T = 1$, la coincidencia es casual (pocos datos).

Observe cómo $\bar{W}_D(T)$ es el que más tarda en converger: los primeros clientes tenían tiempos artificialmente bajos.

Interpretación geométrica de la identidad de Little

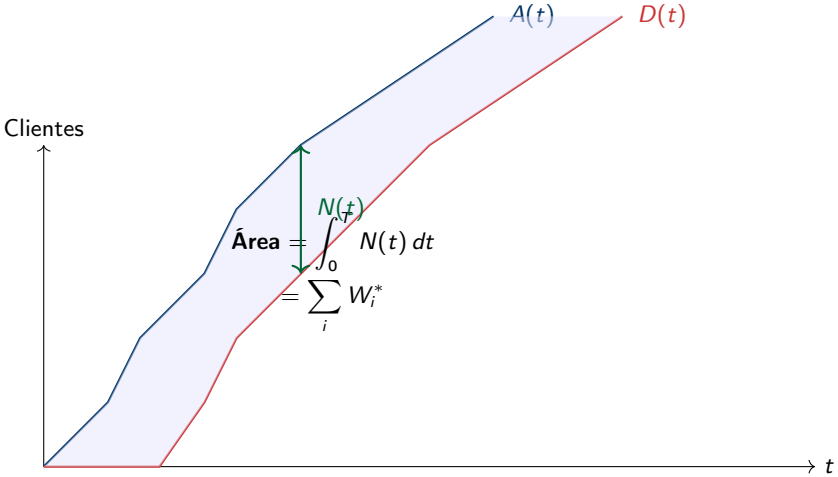

El área entre $A(t)$ y $D(t)$ se puede leer horizontalmente ($\sum W_i$) o verticalmente ($\int N(t)\,dt$). Esta dualidad **es** la Ley de Little.

Resumen: cuándo confiar en las métricas simuladas

En el transitorio:

- $\bar{L}(T) \neq \lambda \cdot \bar{W}_D(T)$
- Las métricas están sesgadas
- Los IC no son válidos
- Solución: truncar warm-up

T_0 →

En estado estable:

- $L = \lambda \cdot W$ se cumple
- Las métricas convergen
- Los IC son confiables
- Todas las versiones coinciden

Siempre cierto:

- $\bar{L}(T) = \bar{\lambda}(T) \cdot \bar{W}_A(T)$
- (Identidad contable)
- Incluye tiempos parciales
- No requiere estado estable

Sensibilidad a ρ: impacto en el transitorio

A mayor ρ, más largo es el transitorio:

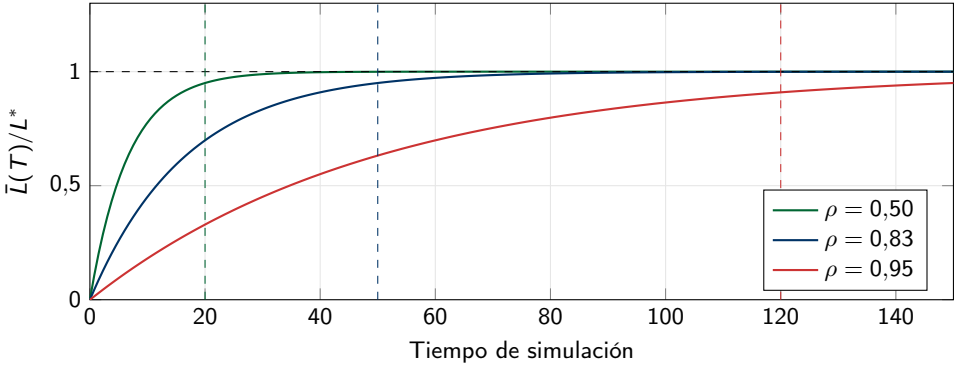

Para $\rho = 0{,}95$, el transitorio puede durar **5–10 veces más** que para $\rho = 0{,}50$. Sistemas muy cargados requieren simulaciones mucho más largas.

Buenas prácticas en simulación de colas

Checklist para un estudio de simulación robusto:

1. **Verificar estabilidad**: Asegurar $\rho < 1$ antes de buscar estado estable.
2. **Detectar el transitorio**: Usar Welch u otro método. No asumir un T_0 arbitrario.
3. **Verificar Little**: Comprobar $\hat{L} \approx \hat{\lambda} \cdot \hat{W}$ como diagnóstico de que el sistema alcanzó estabilidad.
4. **Usar suficientes réplicas**: Mínimo $R \geq 10$ para intervalos de confianza.
5. **Corridas suficientemente largas**: $T \gg T_0$ (al menos $T/T_0 > 10$).
6. **Validar contra lo conocido**: Si existe solución analítica, comparar.
7. **Reportar incertidumbre**: Siempre acompañar estimaciones con intervalos de confianza.

¿Qué pasa si Little no se cumple en mi simulación?

Diagnóstico: si $\hat{L} \neq \hat{\lambda} \cdot \hat{W}$ significativamente...

Posibles causas:

- Período transitorio no eliminado
- Simulación demasiado corta
- Bug en el código (contadores mal actualizados)
- $\bar{W}$ calculado solo con completados
- Sistema inestable ($\rho \geq 1$)

Acciones correctivas:

- Aumentar T_0 (warm-up)
- Aumentar T (largo de corrida)
- Revisar lógica de eventos
- Usar métrica consistente
- Verificar $\hat{\rho}$ observado

Little como herramienta de verificación

La Ley de Little es una de las herramientas más poderosas para **validar** un simulador. Si no se cumple, algo está mal en la simulación o en la recolección de datos.

Conclusiones principales

1. La **simulación de eventos discretos** permite estimar métricas de colas cuando no hay soluciones analíticas.
2. La **Ley de Little** $L = \lambda W$ es fundamental pero requiere estado estable en su forma estocástica.
3. La **versión operacional completa** $\bar{L}(T) = \bar{\lambda}(T) \cdot \bar{W}_A(T)$ es una identidad que siempre se cumple, incluso en el transitorio.
4. La versión con $\bar{W}_D$ (solo completados) **no coincide** con $\bar{L}$ durante el transitorio debido al sesgo de selección.
5. El **período transitorio** debe detectarse y eliminarse para obtener estimaciones insesgadas del estado estable.
6. Para nuestro $M/M/2$ con $\rho = 0{,}833$, la simulación con warm-up de 50 minutos reproduce las métricas teóricas con alta precisión.

Resumen visual

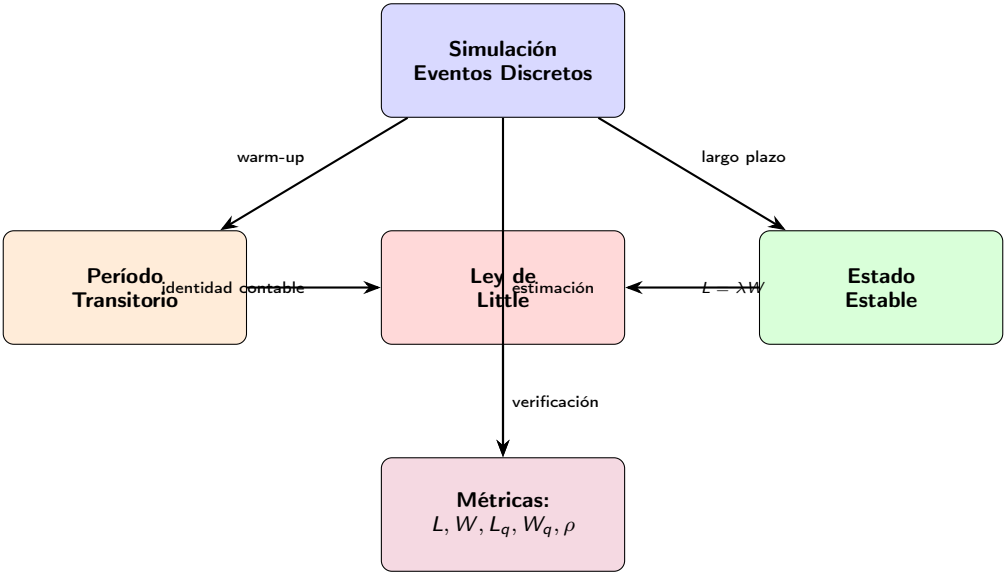

Referencias y lecturas recomendadas

- Law, A.M. (2015). *Simulation Modeling and Analysis*, 5th ed. McGraw-Hill.
- Banks, J., Carson, J.S., Nelson, B.L., Nicol, D.M. (2014). *Discrete-Event System Simulation*, 5th ed. Pearson.
- Little, J.D.C. (1961). A proof for the queuing formula: $L = \lambda W$. *Operations Research*, 9(3), 383–387.
- Stidham, S. (1974). A last word on $L = \lambda W$. *Operations Research*, 22(2), 417–421.
- Whitt, W. (1991). A review of $L = \lambda W$ and extensions. *Queueing Systems*, 9, 235–268.
- Welch, P.D. (1983). The statistical analysis of simulation results. In *The Computer Performance Modeling Handbook*, Academic Press.
- Ross, S.M. (2014). *Introduction to Probability Models*, 11th ed. Academic Press.

¿Preguntas?

Simulación de Eventos Discretos

"Little's Law is the most useful and general result in queueing theory." — S. Stidham

Próxima clase: Análisis de salida y métodos de reducción de varianza