Universidad de los Andes

Departamento de Ingeniería Industrial · Modelado de Sistemas bajo Incertidumbre

Análisis de Salida: Simulaciones Terminales

Alejandra Tabares Pozos

Índice

1. Taxonomía de simulaciones por horizonte temporal **2**

2. El problema estadístico de la salida de simulación **2**

2.1. ¿Por qué la autocorrelación importa? 3

3. Método de réplicas independientes **3**

3.1. Tipos de métricas y cómo calcular Y_j 4

4. Inferencia estadística con réplicas **4**

4.1. Estimación puntual 4

4.2. Intervalo de confianza 4

4.3. Interpretación correcta de la cobertura 5

4.4. Precisión relativa 5

5. Determinación del número de réplicas **5**

6. Sesgo de inicialización en simulaciones terminales **6**

7. Errores comunes en análisis de salida **6**

8. Ejemplo básico: ventanilla bancaria $M/M/1$ terminal **7**

8.1. Ejecución de $n = 10$ réplicas 7

9. Ejemplo intermedio: banco con servicio Erlang y cálculo de n^* **8**

9.1. Piloto: $n_0 = 15$ réplicas 8

9.2. Determinación de n^* para $\delta = 0{,}05$ min 9

9.3. Comparación de modelos 9

10. Ejemplo escalado: urgencias hospitalarias (mañana) **9**

10.1. Configuración del estudio 10
10.2. Piloto: $n_0 = 10$ réplicas 10
10.3. Cálculo de n^* para cada métrica (objetivo: $r \leq 5\,\%$) 11
10.4. Resultados con $n = 59$ réplicas 11
10.5. Análisis de resultados 11

1. Taxonomía de simulaciones por horizonte temporal

Toda simulación de eventos discretos opera bajo uno de dos regímenes:

Simulación terminal (horizonte finito)

El sistema opera durante un periodo bien definido que termina cuando ocurre un evento natural de cierre: fin del turno, cierre del banco, agotamiento del inventario. Las condiciones iniciales (p.ej. sistema vacío al abrir) son parte integral del modelo.

Simulación de estado estacionario (horizonte infinito)

El interés está en el comportamiento a largo plazo del sistema, independiente de las condiciones iniciales. No existe un evento de cierre natural. El problema central es el sesgo de inicialización, tratado en el Tema 3.4.

Ejemplos:

- **Terminal**: urgencias de 8h–20h, simulación de un día de bolsa, un turno de manufactura, un periodo de exámenes.
- **Estacionaria**: fábrica con producción continua 24/7, red de telecomunicaciones, central de llamadas permanente.

La elección del régimen determina completamente el método de análisis estadístico: en la simulación terminal usamos **réplicas independientes**; en la estacionaria, **batch means** o réplicas con calentamiento (Tema 3.4).

Error frecuente

Modelar un sistema con condiciones iniciales relevantes como si fuera estacionario puede introducir un sesgo grande. En una farmacia que abre con 0 clientes, las primeras horas del día son estadísticamente distintas de las del mediodía, y no deben promediarse con el largo plazo.

2. El problema estadístico de la salida de simulación

La salida de un simulador es una secuencia de observaciones $Y_1, Y_2, \ldots, Y_m$ (p.ej. tiempo de espera del cliente i). Estas observaciones tienen dos características que invalidan la estadística clásica:

1. **Autocorrelación**: el tiempo de espera del cliente $i+1$ depende del estado del sistema después de que el cliente i es atendido. Las observaciones *no son independientes*.
2. **No-estacionariedad**: al inicio, el sistema está vacío; la distribución de Y_i cambia con i.

Por estas razones, el promedio muestral $\bar{Y}_m = m^{-1} \sum_{i=1}^{m} Y_i$ de una única corrida *no* puede tratarse como si viniera de m observaciones i.i.d., y la fórmula estándar $S/\sqrt{m}$ subestima el error estándar

real.

2.1. ¿Por qué la autocorrelación importa?

Para un proceso estacionario con autocorrelación $\rho(k) = \mathrm{Corr}(Y_i, Y_{i+k})$, la varianza de la media muestral es:

$$\mathrm{Var}[\bar{Y}_m] = \frac{\sigma^2}{m}\left[1 + 2\sum_{k=1}^{m-1}\left(1 - \frac{k}{m}\right)\rho(k)\right]$$

Si las observaciones fueran independientes ($\rho(k) = 0$ para todo k), tendríamos $\mathrm{Var}[\bar{Y}_m] = \sigma^2/m$. Pero en colas con tráfico moderado a alto, la autocorrelación es **positiva** (un cliente que espera mucho indica congestión, y el siguiente también esperará), por lo que:

$$\mathrm{Var}[\bar{Y}_m] \gg \frac{\sigma^2}{m}$$

Usar S^2/m como estimador de $\mathrm{Var}[\bar{Y}_m]$ subestimaría la varianza real, produciendo intervalos de confianza **demasiado estrechos** (falsa precisión).

Consecuencia práctica

Si se usa $S/\sqrt{m}$ dentro de una sola corrida para construir un IC al 95 %, la cobertura real puede ser del 50–70 % en lugar de 95 %. Esto significa que las conclusiones basadas en ese IC son poco confiables.

3. Método de réplicas independientes

Solución: el método de réplicas independientes genera independencia entre corridas a través de diferentes semillas del generador de números aleatorios.

Se ejecutan n réplicas de la simulación bajo el *mismo* modelo pero con *diferentes* semillas. Cada réplica produce un único número resumen Y_j de la métrica de interés.

$$Y_j = \frac{1}{m_j}\sum_{i=1}^{m_j} W_i^{(j)}, \qquad j = 1, \ldots, n$$

donde m_j es el número de observaciones en la réplica j (clientes atendidos en ese turno).

Independencia entre réplicas

$Y_1, Y_2, \ldots, Y_n$ *son* i.i.d. porque cada réplica usa una semilla diferente del generador de números aleatorios. El estado del sistema al inicio de cada réplica es el mismo (p.ej. sistema vacío), y la

única fuente de variabilidad entre réplicas es la secuencia de números aleatorios.

Como $\{Y_j\}$ son i.i.d., el análisis estadístico clásico (media, varianza, t-Student) es directamente aplicable.

3.1. Tipos de métricas y cómo calcular Y_j

Dependiendo de la métrica de interés, el resumen Y_j de cada réplica se calcula de forma diferente:

- **Métricas por entidad** (tiempo de espera promedio, tiempo en sistema promedio):

$$Y_j = \frac{1}{m_j} \sum_{i=1}^{m_j} W_i^{(j)}$$

  donde $W_i^{(j)}$ es el tiempo de espera del cliente i en la réplica j.

- **Métricas promediadas en el tiempo** (número promedio en cola, utilización):

$$Y_j = \frac{1}{T} \int_0^T N^{(j)}(t)\, dt = \frac{1}{T} \sum_{\text{intervalos}} N_k \cdot \Delta t_k$$

  donde T es la duración del turno y $N^{(j)}(t)$ es el número en cola en la réplica j.

- **Métricas de proporción** (fracción de clientes con espera $> c$ minutos):

$$Y_j = \frac{1}{m_j} \sum_{i=1}^{m_j} \mathbf{1}_{[W_i^{(j)} > c]}$$

4. Inferencia estadística con réplicas

4.1. Estimación puntual

$$\hat{\theta}_n = \bar{Y}_n = \frac{1}{n} \sum_{j=1}^{n} Y_j$$

Por el TLC, $\bar{Y}_n \xrightarrow{d} \mathcal{N}(\theta, \sigma^2/n)$ cuando n es suficientemente grande.

4.2. Intervalo de confianza

Con varianza desconocida, se usa la distribución t de Student:

$$\boxed{IC_{1-\alpha}(\theta) = \bar{Y}_n \ \pm \ t_{\alpha/2,\, n-1} \cdot \frac{S_n}{\sqrt{n}}}$$

donde $S_n^2 = \frac{1}{n-1}\sum_{j=1}^{n}(Y_j - \bar{Y}_n)^2$ y la **semiancho** es $h_n = t_{\alpha/2,n-1} \cdot S_n/\sqrt{n}$.

Para $n \geq 30$ puede usarse el cuantil normal $z_{\alpha/2}$; para $n < 30$, la t_{n-1} es imprescindible.

4.3. Interpretación correcta de la cobertura

Probabilidad de cobertura

Un intervalo de confianza al $100(1-\alpha)\,\%$ **no** significa que "hay una probabilidad $1-\alpha$ de que θ esté en el intervalo". θ es un valor fijo (desconocido). Lo correcto es: si repitiéramos todo el experimento (las n réplicas) muchas veces, el $100(1-\alpha)\,\%$ de los intervalos construidos contendrían θ.

En la práctica, esto significa que si un colega repite el estudio con sus propias n réplicas, su IC será diferente del nuestro, pero ambos tienen la misma probabilidad de contener el verdadero θ.

4.4. Precisión relativa

La precisión relativa del estimador es:

$$r_n = \frac{h_n}{|\bar{Y}_n|} = \frac{t_{\alpha/2,n-1} \cdot S_n}{\sqrt{n}\,|\bar{Y}_n|}$$

Se suele reportar como porcentaje; un objetivo de $r_n \leq 0{,}05$ ($5\,\%$) es común en estudios de ingeniería.

5. Determinación del número de réplicas

El número mínimo de réplicas para lograr un semiancho δ (error absoluto) se estima en dos etapas:

Procedimiento secuencial para n^*

1. Ejecutar un **piloto** de $n_0 \geq 10$ réplicas y calcular $S_{n_0}^2$.
2. Estimar: $n^* = \text{máx}\left(n_0, \left\lceil \frac{t^2_{\alpha/2,\,n_0-1} \cdot S_{n_0}^2}{\delta^2} \right\rceil\right)$.
3. Ejecutar $n^* - n_0$ réplicas adicionales y recalcular $\bar{Y}_{n^*}$ y h_{n^*}.
4. Verificar que $h_{n^*} \leq \delta$ (si no, repetir desde el paso 2 con $n_0 \leftarrow n^*$).

Para un criterio de **precisión relativa** r, se sustituye $\delta = r\,|\bar{Y}_{n_0}|$:

$$n^* = \left\lceil \frac{t^2_{\alpha/2,n_0-1} \cdot S_{n_0}^2}{r^2 \cdot \bar{Y}_{n_0}^2} \right\rceil$$

¿Por qué no fijar n desde el inicio?

El procedimiento secuencial es necesario porque σ^2 es desconocida antes de simular. El piloto proporciona una estimación $S^2_{n_0}$ que permite calcular n^*. Si se sobreestima n^*, se desperdicia tiempo de cómputo; si se subestima, el IC será más ancho de lo deseado. El paso 4 (verificación) protege contra la subestimación.

6. Sesgo de inicialización en simulaciones terminales

En muchas simulaciones terminales, las condiciones iniciales son parte del modelo: una farmacia abre con 0 clientes, un almacén inicia el turno con 0 órdenes pendientes. No hay sesgo de inicialización *si esas condiciones son las condiciones reales de inicio del sistema.*

Sin embargo, en algunos casos el sistema puede comenzar en un estado que *no* es el estado inicial real (por ejemplo, si se simula el pico de la tarde pero el sistema ya tiene clientes acumulados desde la mañana). En ese caso:

- **Opción 1 — Warm-up manual**: hacer correr el modelo hasta que el estado inicial deseado se logre, y luego empezar a recoger estadísticas.
- **Opción 2 — Estado inicial condicionado**: muestrear el estado inicial de una distribución estacionaria (si se conoce).
- **Opción 3 — Modelo extendido**: simular desde el inicio del día completo si el horizonte lo permite.

Distinción con estacionario

En simulaciones terminales, el problema de sesgo inicial es conceptualmente distinto al de las simulaciones de estado estacionario (Tema 3.4). En la terminal, la condición inicial es parte del problema; en la estacionaria, es un artefacto que hay que eliminar.

7. Errores comunes en análisis de salida

1. **Usar una sola corrida larga y tratar cada observación como independiente**: produce ICs demasiado estrechos por la autocorrelación. Solución: usar réplicas.
2. **No hacer suficientes réplicas**: con $n = 3$ o $n = 5$ réplicas, la distribución t_{n-1} tiene colas muy pesadas y los ICs son extremadamente anchos. Con $n < 10$, el IC es poco informativo.
3. **Confundir precisión con exactitud**: un IC estrecho (alta precisión) no implica que el modelo sea correcto (alta exactitud). Si el modelo tiene un error sistemático (falla de validación, Tema 3.2), un IC estrecho simplemente confirma con alta confianza un valor incorrecto.
4. **Reportar solo la media sin IC**: el promedio simulado sin intervalo de confianza no permite

evaluar la calidad del estimador. Siempre reportar $\bar{Y} \pm h$ o el IC completo.

5. **Ignorar la variabilidad entre réplicas**: dos réplicas pueden dar $W_q = 3$ min y $W_q = 12$ min. Esto no indica un bug; es variabilidad natural del sistema estocástico. El IC la cuantifica correctamente.

8. Ejemplo básico: ventanilla bancaria $M/M/1$ terminal

Sistema

Una ventanilla de banco opera el turno de mañana (9:00–13:00, 4 horas). Los clientes llegan según un proceso de Poisson con $\lambda = 2$ clientes/min. El tiempo de servicio es exponencial con $\mu = 3$ clientes/min. El sistema inicia vacío cada mañana. Se quiere estimar el tiempo promedio de espera en cola W_q con 95 % de confianza.

Referencia analítica ($M/M/1$ en estado estacionario, para validación):

$$\rho = \frac{2}{3} = 0{,}667, \qquad W_q^{M/M/1} = \frac{\rho}{\mu(1-\rho)} = \frac{0{,}667}{3 \times 0{,}333} = 0{,}667 \text{ min}$$

Nota: la simulación terminal incluirá el transitorio inicial (sistema vacío), por lo que $\bar{W}_q$ será algo menor que 0,667.

8.1. Ejecución de $n = 10$ réplicas

Cada réplica simula las 4 horas de turno. Y_j es el promedio de W_q de todos los clientes atendidos en esa réplica.

j	1	2	3	4	5	6	7	8	9	10
Y_j (min)	0,58	0,71	0,49	0,82	0,63	0,55	0,74	0,61	0,68	0,52
m_j (clientes)	478	492	486	501	489	475	495	483	490	481

Estadísticos:

$$\bar{Y}_{10} = \frac{0{,}58 + 0{,}71 + \cdots + 0{,}52}{10} = 0{,}633 \text{ min}$$

$$S_{10}^2 = \frac{1}{9}\sum_{j=1}^{10}(Y_j - 0{,}633)^2 = 0{,}01116 \quad \Rightarrow \quad S_{10} = 0{,}1057 \text{ min}$$

IC 95 % con $t_{0{,}025,9} = 2{,}262$:

$$h_{10} = 2{,}262 \times \frac{0{,}1057}{\sqrt{10}} = 2{,}262 \times 0{,}0334 = 0{,}076 \text{ min}$$

$$\boxed{IC_{95\,\%}: \quad [0{,}557;\ 0{,}709] \text{ min}}$$

El valor estacionario de 0,667 cae dentro del intervalo. La media observada (0,633) es ligeramente menor, lo cual es coherente: el período transitorio inicial (sistema vacío) "baja" el promedio del turno.

Resultado del ejemplo básico

Con 10 réplicas del turno de 4 horas, el tiempo promedio de espera se estima en $\bar{W}_q = 0{,}633$ min ≈ 38 segundos, con IC 95 % [0,557; 0,709] min. La precisión relativa es $r_{10} = 0{,}076/0{,}633 = 12\,\%$, que puede ser insuficiente para toma de decisiones. En el ejemplo intermedio mejoraremos la precisión.

9. Ejemplo intermedio: banco con servicio Erlang y cálculo de n^*

Sistema

Se modifica el sistema del ejemplo básico: el banco mantiene las mismas llegadas ($\lambda = 2$ cl/min) pero el servicio ahora es Erlang-2 (dos etapas de atención), con la misma media $\mathbb{E}[S] = 1/3$ min pero $\mathrm{CV}_S = 1/\sqrt{2} \approx 0{,}71$. El modelo es $M/E_2/1$ terminal con turno de 4 horas. Se quiere estimar W_q con precisión absoluta $\delta = 0{,}05$ min al 95 %.

Referencia P-K (estacionaria):

$$\mathbb{E}[S^2] = \mathrm{Var}[S] + (\mathbb{E}[S])^2 = \frac{2}{9^2} + \frac{1}{9} = 0{,}0247 + 0{,}1111 = 0{,}1358 \text{ min}^2$$

$$W_q^{\text{P-K}} = \frac{2 \times 0{,}1358}{2 \times (1 - 2/3)} = \frac{0{,}2716}{0{,}6667} = 0{,}407 \text{ min}$$

El servicio Erlang-2 reduce W_q respecto al $M/M/1$: 0,407 vs. 0,667 min (reducción del 39 %), consistente con la fórmula P-K.

9.1. Piloto: $n_0 = 15$ réplicas

j	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
Y_j	0,38	0,41	0,35	0,44	0,39	0,36	0,42	0,40	0,37	0,43	0,38	0,41	0,36	0,39	0,40

$$\bar{Y}_{15} = 0{,}393 \text{ min}, \quad S_{15} = 0{,}027 \text{ min}$$

IC 95 % con $t_{0{,}025,14} = 2{,}145$:

$$h_{15} = 2{,}145 \times \frac{0{,}027}{\sqrt{15}} = 2{,}145 \times 0{,}00697 = 0{,}015 \text{ min}$$

$$IC_{95\,\%}: \quad [0{,}378;\ 0{,}408] \text{ min}$$

9.2. Determinación de n^* para $\delta = 0{,}05$ min

$$n^* = \left\lceil \frac{(2{,}145)^2 \times (0{,}027)^2}{(0{,}05)^2} \right\rceil = \left\lceil \frac{4{,}601 \times 0{,}000729}{0{,}0025} \right\rceil = \lceil 1{,}34 \rceil = 2$$

Como $2 < n_0 = 15$, las réplicas del piloto son más que suficientes. De hecho, el semiancho actual (0,015 min) ya cumple holgadamente $\delta = 0{,}05$ min.

Comparación con el ejemplo básico

El sistema $M/E_2/1$ tiene menor variabilidad entre réplicas ($S_{15} = 0{,}027$) que el $M/M/1$ ($S_{10} = 0{,}106$). Esto es coherente: la variabilidad del servicio (CV = 0,71 vs. 1) se transmite a la variabilidad entre réplicas. Distribuciones de servicio menos variables producen estimadores más precisos con menos réplicas.

9.3. Comparación de modelos

Sistema	$\bar{W}_q$ (min)	IC 95 %	S_n (min)	Ref. P-K
$M/M/1$ (ej. básico, $n = 10$)	0,633	[0,557; 0,709]	0,106	0,667 ✓
$M/E_2/1$ (ej. intermedio, $n = 15$)	0,393	[0,378; 0,408]	0,027	0,407 ✓

Ambos IC contienen el valor P-K estacionario, y el sistema Erlang tiene espera 38 % menor, como predice la teoría.

Resultado del ejemplo intermedio

Con 15 réplicas, $\bar{W}_q = 0{,}393$ min con IC [0,378; 0,408] min. La precisión ($h = 0{,}015$ min) excede ampliamente el objetivo de $\delta = 0{,}05$ min, gracias a la baja variabilidad del servicio Erlang-2. El procedimiento secuencial muestra que incluso $n = 2$ réplicas bastarían para este objetivo, pero más réplicas dan ICs más estrechos y más confiables.

10. Ejemplo escalado: urgencias hospitalarias (mañana)

Sistema

El servicio de urgencias de un hospital opera el turno de mañana (7:00–15:00, 8 horas). Los pacientes se clasifican en tres niveles de prioridad al triaje. El sistema tiene 3 médicos (*recursos*), una sala de espera común y una cola con prioridad no expulsiva (non-preemptive). Las distribuciones de servicio son **no exponenciales**, determinadas en el modelado de entradas (Tema 3.1).

Nivel	**Fracción**	**Distribución de S**	$\mathbb{E}[S]$ (min)	CV_S
P1 (urgente)	15 %	Exponencial($\mu = 0{,}1$)	10	1,00
P2 (moderado)	55 %	Erlang-3($\mu_f = 0{,}1$)	30	0,58
P3 (leve)	30 %	Log-normal($\mu_L = 3{,}4$, $\sigma_L = 0{,}5$)	35	0,53

Llegadas totales: Poisson con $\lambda = 20$ pacientes/h. El sistema inicia vacío. Interesa estimar tres métricas con 95 % de confianza y precisión relativa $\leq 5\,\%$:

1. W_q^{P2}: tiempo de espera promedio de pacientes P2.
2. $P(W_q > 30 \text{ min} \mid P3)$: fracción de pacientes leves con espera > 30 min.
3. ρ: utilización promedio de los médicos.

A diferencia de los ejemplos anteriores, **no existe solución analítica** para este sistema: tiene múltiples servidores, prioridades no expulsivas, y distribuciones de servicio heterogéneas (Exponencial, Erlang-3 y Log-normal). La simulación es la única herramienta disponible.

10.1. Configuración del estudio

Tráfico del sistema. La tasa de llegadas efectiva de cada tipo y su aporte a la carga:

$$\begin{aligned}
\lambda_{P1} &= 0{,}15 \times 20 = 3{,}0 \text{ pac/h}, & \text{carga}_{P1} &= 3{,}0 \times \tfrac{10}{60} = 0{,}50 \\
\lambda_{P2} &= 0{,}55 \times 20 = 11{,}0 \text{ pac/h}, & \text{carga}_{P2} &= 11{,}0 \times \tfrac{30}{60} = 5{,}50 \\
\lambda_{P3} &= 0{,}30 \times 20 = 6{,}0 \text{ pac/h}, & \text{carga}_{P3} &= 6{,}0 \times \tfrac{35}{60} = 3{,}50
\end{aligned}$$

Carga total $= 0{,}50 + 5{,}50 + 3{,}50 = 9{,}50$ pac·médico^{-1}h^{-1}, con 3 médicos trabajando 60 min/h: $\rho = 9{,}50/(3 \times 60/60) \approx 0{,}79$.

10.2. Piloto: $n_0 = 10$ réplicas

Cada réplica simula el turno completo de 8 horas. Resultados del piloto:

Métrica	$\bar{Y}_{10}$	S_{10}	$\hat{r}_{10}$ (%)
W_q^{P2} (min)	28,4	4,7	5,2 %
$P(W_q > 30\text{min} \mid P3)$	0,342	0,058	5,3 %
ρ	0,787	0,018	0,7 %

Las dos primeras métricas están ligeramente fuera del objetivo ($r > 5\,\%$). La utilización ya cumple holgadamente.

10.3. Cálculo de n^* para cada métrica (objetivo: $r \leq 5\,\%$)

Con $t_{0{,}025,9} = 2{,}262$:

$$n^*_{W_q^{P2}} = \left\lceil \frac{(2{,}262)^2 \times (4{,}7)^2}{(0{,}05 \times 28{,}4)^2} \right\rceil = \left\lceil \frac{112{,}9}{2{,}02} \right\rceil = \lceil 55{,}9 \rceil = 56$$

$$n^*_{P(W>30)} = \left\lceil \frac{(2{,}262)^2 \times (0{,}058)^2}{(0{,}05 \times 0{,}342)^2} \right\rceil = \left\lceil \frac{0{,}01723}{0{,}000292} \right\rceil = \lceil 59{,}0 \rceil = 59$$

La métrica más exigente es $P(W_q > 30 \text{ min} \mid P3)$; se necesitan $n^* = 59$ réplicas para todas las métricas simultáneamente.

10.4. Resultados con $n = 59$ réplicas

Métrica	$\bar{Y}_{59}$	IC 95 %	r (%)	**Interpretación**
W_q^{P2} (min)	29,1	[27,9; 30,3]	4,1 %	Espera media: ∼29 min
$P(W_q > 30 \text{ min} \mid P3)$	0,348	[0,331; 0,365]	4,9 %	35 % de P3 esperan >30 min
ρ	0,789	[0,784; 0,794]	0,3 %	Utilización 78,9 %

10.5. Análisis de resultados

- Los pacientes P2 (moderados) esperan en promedio ∼29 minutos, lo que puede exceder estándares de atención hospitalaria.
- Más de un tercio (35 %) de los pacientes P3 esperan más de 30 minutos.
- La utilización del 79 % indica un sistema cercano a la saturación. Pequeños incrementos en la demanda producen aumentos desproporcionados en las esperas (no-linealidad característica de colas, vista en el análisis de sensibilidad del Tema 3.2).
- Todas las métricas cumplen el criterio de precisión relativa $r \leq 5\,\%$.

Conclusiones del estudio terminal

En el turno de mañana, aproximadamente 1 de cada 3 pacientes de nivel P3 espera más de 30 minutos. Este resultado provee la base para evaluar la contratación de un cuarto médico (comparación de alternativas, Tema 3.4).
El procedimiento secuencial determinó que 59 réplicas son necesarias para alcanzar la precisión deseada en todas las métricas simultáneamente, y los resultados finales cumplen los criterios de calidad estadística.

No-Markovianidad y necesidad de simulación

El sistema de urgencias modela servicios con distribuciones Erlang-3 y Log-normal, ambas no exponenciales. No existe solución analítica exacta para la distribución del tiempo de espera ni para $P(W_q > 30 \text{ min})$ bajo prioridades no expulsivas con múltiples servidores y distribuciones mixtas. La simulación, combinada con el método de réplicas independientes, es la única herramienta que permite estimar estas métricas con intervalos de confianza rigurosos.

Referencias

[1] Law, A. M. (2015). *Simulation Modeling and Analysis*, 5th ed. McGraw-Hill. Cap. 7 y 9.

[2] Banks, J., Carson, J. S., Nelson, B. L. & Nicol, D. M. (2014). *Discrete-Event System Simulation*, 5th ed. Pearson. Cap. 11.

[3] Alexopoulos, C. (2006). Statistical analysis of simulation output. En *Handbook of Industrial Engineering*, 3rd ed. Wiley.

[4] Nelson, B. L. (2013). *Foundations and Methods of Stochastic Simulation*. Springer. Cap. 8.

[5] Kelton, W. D. (2006). Statistical issues in simulation. *Proceedings of the Winter Simulation Conference*.

[6] Goldsman, D. & Nelson, B. L. (1998). Comparing systems via simulation. En *Handbook of Simulation*. Wiley.